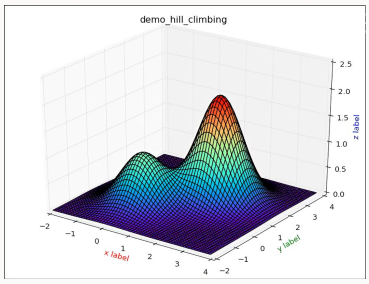
最优化理论与方法

Lin Wenjie

Nanjing Normal University

版本：1.0

更新：2025 年 10 月 24 日



目录

1 前言 **7**

1.1 数学优化的研究范式与学习方法 7

I 最优化理论基础 **9**

2 收敛性 **10**

3 光滑优化的最优性条件 **11**

4 一般的最优性条件 **14**

4.1 凸优化的最优性条件 14

4.2 非凸优化的最优性条件 15

4.3 KKT 条件 16

5 一般 NLP 中的 KKT 条件、锥与约束资格条件 **20**

5.1 问题形式与基本目标 20

5.2 切锥、线性化锥与极锥 20

5.3 Fréchet 正则法锥、Mordukhovich 法锥与 Clarke 法锥 21

5.4 局部极小点的最原始一阶必要条件 23

5.5 线性化锥极锥的显式表达 . . . 23
5.6 KKT 条件的由来 . . . 25
5.7 各类约束资格条件（CQ） . . . 26
5.8 CQ 之间的常见关系 . . . 27
5.9 KKT 定理 . . . 27
5.10 KKT 条件的几何意义与作用 . . . 28
5.11 总结 . . . 28

6 最优化问题的对偶 30
6.1 线性规划问题的对偶 . . . 30
6.2 一般优化问题的对偶 . . . 30
6.3 对偶问题的意义 . . . 31
6.4 影子价格 . . . 32

7 最优化基本算法框架 33
7.1 线搜索的搜索方向 . . . 34
7.1.1 下降方向 . . . 34
7.1.2 牛顿方向 . . . 34
7.1.3 拟牛顿方向 . . . 35
7.1.4 共轭梯度方向 . . . 35
7.2 信赖域子问题的近似模型 . . . 36

II 基础算法 37

8 线搜索方法：Line Search Methods 38
8.1 步长的选择 . . . 38
8.1.1 Wolfe Conditions . . . 38
8.1.2 Goldstein 条件 . . . 40
8.2 线搜索方法的收敛性 . . . 41
8.3 线搜索方法的收敛率 . . . 42
8.3.1 最速下降法的收敛率 . . . 42
8.3.2 梯度法在凸函数上的收敛性 . . . 43
8.3.3 牛顿法的收敛率 . . . 44
8.3.4 拟牛顿法的收敛率 . . . 45
8.4 调整海瑟矩阵的牛顿法 . . . 45

9 次梯度法 47
9.1 带 Polyak 步长的投影次梯度法 . . . 47

9.1.1 无约束优化的次梯度法 . . . 47
9.1.2 带约束优化的次梯度法 . . . 47
9.2 用投影梯度法求解凸可行性问题 . . . 52
9.2.1 贪婪投影算法 . . . 53
9.2.2 交替投影法 . . . 54
9.2.3 线性可行性问题的求解 . . . 54

10 交替方向乘子法 (Alternating Direction Method of Multipliers / ADMM) 56
10.1 增广拉格朗日法（The Augmented Lagrangian Method / ALM） . . . 56
10.2 交替方向乘子法（Alternating Direction Method of Multipliers / ADMM） . 57
10.3 ADMM 的收敛性 . . . 59
10.4 一个特殊格式的问题 . . . 63

11 信赖域方法 64
11.1 映射 H_k 的选择 . . . 66
11.2 子问题求解要求 . . . 66
11.3 正则化条件 . . . 67
11.4 信赖域算法的迭代复杂度 . . . 68
11.5 信赖域算法的收敛性 . . . 72
11.6 截断共轭梯度法 . . . 74

12 共轭梯度法 74
12.1 共轭方向法：共轭梯度法的原型 . . . 74
12.2 共轭梯度法的标准算法 . . . 76
12.3 经典误差估计 . . . 77

III 人工智能中的优化方法 79

13 课程第一讲：梯度法与随机优化 80
13.1 Lecture 1：梯度下降与反向传播 . . . 80
13.2 Lecture 2：SGD、动量与自适应方法 . . . 81

14 课程第二讲：语言模型与 Transformer 83
14.1 Lecture 3：词表示、语言模型、RNN 与 Seq2Seq . . . 83
14.2 Lecture 4：Attention 与 Transformer . . . 84

15 课程第三讲：预训练成本与混合精度 86
15.1 Lecture 5：参数量、计算量与训练显存 . . . 86
15.2 Lecture 6：混合精度训练 . . . 87

16 课程第四讲：分块、逐层与子空间训练 **88**
16.1 Lecture 7：块坐标与逐层训练 88
16.2 Lecture 8：子空间与低秩梯度投影 89

17 课程第五讲：零阶与分布式优化 **91**
17.1 Lecture 9：零阶优化、MeZO 与 LoZO 91
17.2 Lecture 10：并行、去中心化、局部更新与压缩 91

18 深度学习训练问题的优化建模 **94**
18.1 多分类问题 94
18.2 从线性模型到深度神经网络 95
18.3 深度学习优化的主要困难 96

19 前向传播、反向传播与矩阵求导 **97**
19.1 导数记号与常用矩阵求导公式 97
19.2 三层神经网络的前向传播 99
19.2.1 关于最后一层参数的梯度 100
19.2.2 关于第二层参数的梯度 100
19.2.3 关于第一层参数的梯度 101
19.3 反向传播的本质 101

20 随机梯度下降方法 (SGD) **102**
20.1 随机梯度下降方法 (SGD) 102
20.2 SGD with mini-batch 105
20.3 带动量的随机梯度下降（Momentum SGD） 106
20.4 自适应 SGD 107

21 大语言模型基础 **108**
21.1 词表示与统计语言模型 109
21.2 神经语言模型 (RNN) 110
21.3 序列到序列模型与注意力机制 112

IV 双层优化 **120**

22 双层优化的理论、算法与应用 **121**
22.1 基本模型：约束中嵌套一个优化问题 121
22.2 下层解多值时的决策语义 121
22.3 下层解映射的稳定性 122
22.4 三类基本的单层化方法 122

22.4.1 KKT/MPEC reformulation . . . 123
22.4.2 Value-function reformulation . . . 123
22.4.3 Generalized equation 与 variational inequality . . . 124
22.5 算法谱系与复杂性 . . . 124

23 第 14 章：Pessimistic bilevel optimization 126
23.1 模型与 Stackelberg 解 . . . 126
23.2 为什么精确解可能不存在 . . . 126
23.3 epsilon-近似反应与稳定化 . . . 127
23.4 单层化与 reduction 思想 . . . 128
23.5 算法与复杂度边界 . . . 128

24 第 12 章：双层问题的 MPEC 方法 131
24.1 从双层问题到 MPEC . . . 131
24.2 Complementarity set 的分支几何 . . . 132
24.3 从 B-stationarity 到 multiplier stationarity . . . 132
24.4 适用于 MPEC 的 constraint qualifications . . . 133
24.5 二阶条件 . . . 133
24.6 算法：平滑近似还是直接处理分支 . . . 134

25 第 7 章：Variational analysis 与 value-function 方法 136
25.1 Normal cone：非光滑集合的法向量 . . . 136
25.2 Coderivative 与 Aubin property . . . 137
25.3 函数的 limiting 与 singular subdifferential . . . 137
25.4 Marginal function 的次微分估计 . . . 138
25.5 Lipschitz program 的 multiplier rule . . . 138
25.6 Value-function reformulation 与内在退化 . . . 139
25.7 Partial calmness 与 exact penalty . . . 139
25.8 双层问题的 necessary optimality condition . . . 140
25.9 四章的统一逻辑 . . . 141

26 可高效计算的双层优化近似驻点 143
26.1 双层优化的模型与核心问题 . . . 143
26.2 下层解唯一：hypergradient . . . 143
26.3 下层解多值：Lipschitz hyperobjective . . . 144
26.4 Clarke、NAS 与 GAS . . . 146
26.5 Set smoothness：使 Clarke 驻点可计算的结构 . . . 147
26.6 结论与研究方向 . . . 148

27 双层优化与纳什均衡 **149**
27.1 双层优化简介 149
27.2 标准的乐观双层优化与均衡问题 151

28 双层优化中的约束品性与最优性条件 **153**
28.1 一些基本概念 153

V 其他 **156**

29 小记 **157**
29.1 一种证明迭代点列线性收敛的框架 157

1 前言

数学优化研究的是：在一组限制条件下，如何选择最好的方案。数学优化的核心问题通常有三类：

- 理论问题：什么是最优解？什么时候存在？如何刻画？
- 算法问题：如何高效找到解？
- 应用问题：如何把实际问题建模成优化问题？

1.1 数学优化的研究范式与学习方法

数学优化研究可以概括为一个相互关联的框架：

$$\text{问题类} - -\text{结构与假设} - -\text{信息模型} - -\text{算法} - -\text{评价指标} - -\text{理论界}.$$

其中，问题类说明研究对象（如光滑、非光滑、凸、非凸或约束问题）；结构与假设描述函数及可行域的性质；信息模型说明算法可以获得梯度、近端映射等何种信息；评价指标可以是目标函数差、梯度范数、对偶间隙或最优性残差；理论界则刻画算法达到给定精度所需的计算量。

连续优化中常见的研究范式包括：

- **算法设计与收敛分析**：构造迭代方法，寻找下降量或势函数，证明收敛性及收敛速度；
- **假设与结论的边界研究**：削弱光滑性、凸性等假设，或构造反例说明结论成立的必要条件；
- **复杂度与下界研究**：分析达到精度 ε 所需的迭代或信息调用次数，并判断该结果是否最优；
- **问题结构的利用**：利用可分、复合、稀疏、随机或原始–对偶结构，设计计算成本更低的专用算法；
- **统一框架与局部几何**：用势函数、单调算子、变分分析等语言统一解释算法，研究解附近的稳定性和快速收敛性质；
- **建模、理论与数值实验**：从实际问题提取数学结构，并通过理论分析和计算实验共同检验算法。

学习时不宜只记忆孤立的算法和定理。阅读每篇论文时，应依次回答：研究什么问题、使用哪些假设、算法可获得什么信息、每步如何计算、用什么指标衡量误差、得到什么复杂度，以及证明中最关键的不等式是什么。理解一个结果的标准，是能够解释算法为何有效、每个假设在哪里使用，以及删去假设后结论为何可能失效。

较高效的学习路径是：先选定一个较小方向，独立重证若干基础定理；再用上述框架比较一组代表性论文；随后复现一个核心证明和数值实验；最后通过削弱假设、改变信息模型或评价指标、改进复杂度以及构造反例来形成研究问题。研究能力并非在知识全部学完后才出现，而是在反复进行“例子–猜想–证明–失败–修正”的过程中逐步形成。

Part I

最优化理论基础

2 收敛性

定义 2.1 (收敛性) 若由某算法生成的序列 x_k 在有限次迭代内达到问题的最优解 x^*，或者 x_k 存在一个聚点且该聚点为最优解 x^*，则称该算法是收敛的。

- 特别地，若仅当初始点 x_0 充分接近 x^* 时，x_k 才收敛到最优解 x^*，则称该算法为局部收敛的。
- 若对任意可行初始点 x_0，x_k 都能收敛到最优解 x^*，则称该算法为全局收敛的。

另一种评估算法性能的方式是收敛速度，其定义如下。

定义 2.2 (收敛速度) 设序列 x_k 收敛到 x^*，且

$$\lim_{k\to\infty}\frac{\|x_{k+1}-x^*\|}{\|x_k-x^*\|}=\beta$$

- 若 $0<\beta<1$，则称 x_k 是线性收敛的。
- 若 $\beta=0$，则称 x_k 是超线性收敛的。
- 若 $\beta=1$，则称 x_k 是次线性收敛的。

上述定义给出了不同的收敛速度，其中超线性收敛表示序列 x_k 以最快的方式收敛到 x^*。下面我们进一步刻画超线性收敛。

定义 2.3 (p 阶收敛) 设序列 x_k 收敛到 x^*，若存在 $p\geq 1$，使得

$$\lim_{k\to\infty}\frac{\|x_{k+1}-x^*\|}{\|x_k-x^*\|^p}=\beta,\quad 0<\beta<\infty$$

则称 x_k 是 p 阶收敛的。特别地，当 $p=2$ 时，称 x_k 是二次收敛的。

3 光滑优化的最优性条件

无约束最优化问题考虑下面这样的问题形式：

$$\min_x f(x),$$

其中 $x \in \mathbb{R}^n$，$f : \mathbb{R}^n \to \mathbb{R}$ 是一个光滑函数。这个问题的解是什么呢？一般来说，最优化问题需要求解如下的三种极小点。

定义 3.1 (极小点)

- 全局极小点: 若对所有的 x，都有 $f(x^*) \leq f(x)$，则点 x^* 是全局极小点。
- 局部极小点: 若存在 x^* 的一个邻域 $\mathcal{N}$，使得对所有的 $x \in \mathcal{N}$，都有 $f(x^*) \leq f(x)$，则点 x^* 是局部极小点。
- 严格局部极小点: 若存在 x^* 的一个邻域 $\mathcal{N}$，使得对所有的 $x \in \mathcal{N}$ 且 $x \neq x^*$，都有 $f(x^*) < f(x)$，则点 x^* 是严格局部极小点（也称为强局部极小点）。

注 3.1 对于一个优化问题，最好当然可以找到全局极小点，实在不行也可以退而求其次找到局部极小点或严格局部极小点。

如何判断这个点是极小点呢？如果完全根据定义，那就需要比较其附近的所有点，对于数值计算来说不现实。不过对于一个光滑函数我们有更高效的方法验证某个点是否是极小点，主要用到的工具是光滑函数的泰勒展开。

定理 3.1 (泰勒定理) 设 $f : \mathbb{R}^n \to \mathbb{R}$ 是连续可微的，且 $p \in \mathbb{R}^n$。则存在 $t \in (0, 1)$，使得

$$f(x + p) = f(x) + \nabla f(x + tp)^T p.$$

此外，若 f 是二次连续可微的，则存在 $t \in (0, 1)$，使得

$$\nabla f(x + p) = \nabla f(x) + \int_0^1 \nabla^2 f(x + tp)p \, dt,$$

且

$$f(x + p) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T \nabla^2 f(x + tp)p.$$

定理 3.2 (一阶必要条件) 若 x^* 是局部极小点，且 f 在 x^* 的一个开邻域内连续可微，则 $\nabla f(x^*) = 0$。

证明. 假设 $\nabla f(x^*) \neq 0$。令 $p = -\nabla f(x^*)$，注意到 $p^T \nabla f(x^*) = -\|\nabla f(x^*)\|^2 < 0$。由于 ∇f 在 x^* 附近连续，存在 $T > 0$，使得对所有 $t \in [0, T]$，有

$$p^T \nabla f(x^* + tp) < 0.$$

对任意 $\bar{t} \in (0, T]$，由泰勒定理可知，存在 $t \in (0, \bar{t})$，使得

$$f(x^* + \bar{t}p) = f(x^*) + \bar{t}p^T \nabla f(x^* + tp).$$

因此，对所有 $\bar{t} \in (0, T]$，有 $f(x^* + \bar{t}p) < f(x^*)$。故 x^* 不是局部极小点，矛盾。

注 3.2

- 若 $\nabla f(x^*) = 0$，则称 x^* 为稳定点。根据定理 3.2，任何局部极小点都为稳定点。
- 我个人更习惯通过极限的保号性得到该结论：

  证明. 如果 $\nabla f(x^*) \neq 0$, 令 $g(t) = f(x^* - t\nabla f(x^*))$, 则 $g'(0) = -\|\nabla f(x^*)\|^2 < 0$，即

  $$\lim_{t \to 0^+} \frac{g(t) - g(0)}{t} = g'(0) < 0$$

  根据保号性，存在 $\delta > 0$, 使得 $\forall t \in (0, \delta)$, 有

  $$\frac{g(t) - g(0)}{t} < 0$$

  于是 $g(t) < g(0)$, 即 $f(x^* - t\nabla f(x^*)) < f(x^*), \forall t \in (0, \delta)$, 这与局部极小点的定义矛盾

定理 3.3 (二阶必要条件) *若 x^* 是 f 的局部极小点，且 $\nabla^2 f$ 在 x^* 的一个开邻域内存在且连续，则 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*)$ 是半正定的。*

证明. 由定理 3.2 知 $\nabla f(x^*) = 0$。假设 $\nabla^2 f(x^*)$ 不是半正定的。此时可选取向量 p 使得 $p^T \nabla^2 f(x^*) p < 0$，又因 $\nabla^2 f$ 在 x^* 附近连续，故存在 $T > 0$，使得对所有 $t \in [0, T]$，有 $p^T \nabla^2 f(x^* + tp) p < 0$。

对 x^* 做泰勒展开，对所有 $\bar{t} \in (0, T]$ 及某个 $t \in (0, \bar{t})$，有

$$f(x^* + \bar{t}p) = f(x^*) + \bar{t}p^T \nabla f(x^*) + \frac{1}{2}\bar{t}^2 p^T \nabla^2 f(x^* + tp) p < f(x^*).$$

故 x^* 不是局部极小点，矛盾。

定理 3.4 (二阶充分条件) *假设 $\nabla^2 f$ 在 x^* 的一个开邻域内连续，且 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*)$ 是正定的。则 x^* 是 f 的严格局部极小点。*

证明. 由于 Hessian 矩阵在 x^* 处连续且正定，存在 $r > 0$，使得对于开球 $\mathcal{D} = \{z \mid \|z - x^*\| < r\}$ 内的所有 x，$\nabla^2 f(x)$ 保持正定。取任意非零向量 p 满足 $\|p\| < r$，则 $x^* + p \in \mathcal{D}$，于是

$$\begin{aligned} f(x^* + p) &= f(x^*) + p^T \nabla f(x^*) + \frac{1}{2} p^T \nabla^2 f(z) p \\ &= f(x^*) + \frac{1}{2} p^T \nabla^2 f(z) p, \end{aligned}$$

其中 $z = x^* + tp$ 对某个 $t \in (0, 1)$ 成立。由于 $z \in \mathcal{D}$，故 $p^T \nabla^2 f(z) p > 0$，因此 $f(x^* + p) > f(x^*)$，得证。

注 3.3 注意, 二阶充分条件不是必要的：点 x^* 可能是严格局部极小点，但却不满足充分条件。一个简单的例子是函数 $f(x) = x^4$，其点 $x^* = 0$ 是严格局部极小点，但在该点处 Hessian 矩阵为零（因此不是正定的）。

定理 3.5 当 f 是凸函数时，任何局部极小点 x^* 都是 f 的全局极小点。又若 f 可微，则任何稳定点 x^* 都是 f 的全局极小点。

证明. 假设 x^* 是局部极小点但不是全局极小点，则存在点 $z \in \mathbb{R}^n$ 使得 $f(z) < f(x^*)$。考虑连接 x^* 和 z 的线段，即

$$x = \lambda z + (1-\lambda)x^*, \quad \text{对某个 } \lambda \in (0, 1].$$

由 f 的凸性，有

$$f(x) \le \lambda f(z) + (1-\lambda) f(x^*) < f(x^*).$$

x^* 的任意邻域 $\mathcal{N}$ 都包含线段的一部分，因此总存在 $x \in \mathcal{N}$ 满足上式，故 x^* 不是局部极小点，矛盾。

又若 f 可微，假设 x^* 不是全局极小点，点 $z \in \mathbb{R}^n$ 使得 $f(z) < f(x^*)$。由凸性，有

$$\begin{aligned}
\nabla f(x^*)^T (z - x^*) &= \frac{d}{d\lambda} f(x^* + \lambda(z - x^*))\Big|_{\lambda=0} \\
&= \lim_{\lambda \downarrow 0} \frac{f(x^* + \lambda(z - x^*)) - f(x^*)}{\lambda} \\
&\le \lim_{\lambda \downarrow 0} \frac{\lambda f(z) + (1-\lambda) f(x^*) - f(x^*)}{\lambda} \\
&= f(z) - f(x^*) < 0.
\end{aligned}$$

因此，$\nabla f(x^*) \neq 0$，故 x^* 不是稳定点，矛盾。

注 3.4 本节的讨论概括起来就是：

- 对于一个一般的无约束最优化问题，一个最好的情况是可以得到全局极小点；
- 如果无法全局极小点，可以退而求其次去得到局部极小点或严格局部极小点；
- 对于一个光滑函数，可以用局部极小点的一阶和二阶必要条件以及严格局部极小点的充分条件来判断极小点；
- 对于一个凸函数，局部极小点与全局极小点是等价的；
- 对于一个光滑凸函数，只要求得稳定点就可以得到全局极小点。

注 3.5 上述的讨论一般都基于其目标函数可微的情况，对于非光滑的目标函数，通常用次梯度（梯度的推广）来判断极小点，这里暂不做讨论。

4 一般的最优性条件

上一节考虑了可微背景下的最优性条件，本节考虑不可微的最优性条件，设 $\mathbb{E}$ 是一个赋范空间。

4.1 凸优化的最优性条件

定理 4.1 (Fermat 最优性条件) 设 $f:\mathbb{E}\to(-\infty,\infty]$ 是适当凸函数，则

$$x^*\in\operatorname{argmin}\{f(x):x\in\mathbb{E}\}$$

当且仅当 $0\in\partial f(x^*)$。

证明.

$$\begin{aligned}
&x^*\in\operatorname{argmin}\{f(x):x\in\mathbb{E}\}\\
\iff& f(x)\geqslant f(x^*),\quad \forall x\in\operatorname{dom}(f),\\
\iff& f(x)\geqslant f(x^*)+\langle 0,x-x^*\rangle,\quad \forall x\in\operatorname{dom}(f),\\
\iff& 0\in\partial f(x^*)
\end{aligned}$$

考虑约束优化问题

$$\min\{f(x):x\in C\},$$

其中 f 是广义实值凸函数，且 $C\subseteq\mathbb{E}$ 是凸集。

定理 4.2 (凸约束优化的充要最优性条件) 设 $f:\mathbb{E}\to(-\infty,\infty]$ 是适当凸函数，$C\subseteq\mathbb{E}$ 是凸集且满足 $\operatorname{ri}(\operatorname{dom}(f))\cap\operatorname{ri}(C)\neq\varnothing$。则 $x^*\in C$ 是上述问题的最优解当且仅当

$$\text{存在 } g\in\partial f(x^*) \text{ 使得 } -g\in N_C(x^*).$$

证明.

$$\min\{f(x):x\in C\},$$

可改写为

$$\min_{x\in\mathbb{E}} f(x)+\delta_C(x).$$

由于 $\operatorname{ri}(\operatorname{dom}(f))\cap\operatorname{ri}(C)\neq\varnothing$，根据次微分的和法则，对任意 $x\in C$，有

$$\partial(f+\delta_C)(x)=\partial f(x)+\partial\delta_C(x)=\partial f(x)+N_C(x).$$

于是，利用定理 4.1, $x^* \in C$ 是最优解当且仅当 $0 \in \partial f(x^*) + N_C(x^*)$，即当且仅当

$$\text{存在 } g \in \partial f(x^*) \text{ 使得 } -g \in N_C(x^*).$$

注 4.1 进一步由法锥的定义得到:$x^* \in C$ 是最优解当且仅当

$$\text{存在 } g \in \partial f(x^*) \text{ 使得对任意 } x \in C,\ \langle g, x - x^* \rangle \geq 0.$$

这就是变分不等式。

4.2 非凸优化的最优性条件

定理 4.3 (复合问题的最优性条件) 设 $f : \mathbb{E} \to (-\infty, \infty]$ 是适当函数，$g : \mathbb{E} \to (-\infty, \infty]$ 是适当凸函数，且满足 $\mathrm{dom}(g) \subseteq \mathrm{int}(\mathrm{dom}(f))$。考虑问题

$$\min_{x \in \mathbb{E}} f(x) + g(x).$$

(a)（必要条件）若 $x^* \in \mathrm{dom}(g)$ 是问题 (P) 的局部最优解，且 f 在 x^* 处可微，则

$$-\nabla f(x^*) \in \partial g(x^*).$$

(b)（凸问题的充要条件）假设 f 是凸函数。若 f 在 $x^* \in \mathrm{dom}(g)$ 处可微，则 x^* 是问题 (P) 的全局最优解当且仅当上述条件成立。

证明.

(a) 设 $y \in \mathrm{dom}(g)$。由 $\mathrm{dom}(g)$ 的凸性，对任意 $\lambda \in (0, 1)$，点 $x_\lambda = (1-\lambda)x^* + \lambda y$ 属于 $\mathrm{dom}(g)$；再由 x^* 的局部最优性，当 λ 足够小时，有

$$f(x_\lambda) + g(x_\lambda) \geq f(x^*) + g(x^*).$$

即

$$f((1-\lambda)x^* + \lambda y) + g((1-\lambda)x^* + \lambda y) \geq f(x^*) + g(x^*).$$

利用 g 的凸性，可得

$$f((1-\lambda)x^* + \lambda y) + (1-\lambda)g(x^*) + \lambda g(y) \geq f(x^*) + g(x^*),$$

整理得

$$\frac{f((1-\lambda)x^* + \lambda y) - f(x^*)}{\lambda} \geq g(x^*) - g(y).$$

令 $\lambda \to 0^+$，由 f 在 x^* 处可微, 于是 $f'(x^*; y - x^*) = \langle \nabla f(x^*), y - x^* \rangle$，因此对任意 $y \in \mathrm{dom}(g)$，有

$$g(y) \geq g(x^*) + \langle -\nabla f(x^*), y - x^* \rangle,$$

于是 $-\nabla f(x^*) \in \partial g(x^*)$。

(b) 额外假设 f 是凸函数。若 x^* 是问题 (P) 的最优解，由 (a) 已证条件成立。反之，若条件成立，则对任意 $y \in \mathrm{dom}(g)$，有

$$g(y) \geq g(x^*) + \langle -\nabla f(x^*), y - x^* \rangle.$$

由 f 的凸性，对任意 $y \in \mathrm{dom}(g)$，有

$$f(y) \geq f(x^*) + \langle \nabla f(x^*), y - x^* \rangle.$$

将两式相加，得对任意 $y \in \mathrm{dom}(g)$，有

$$f(y) + g(y) \geq f(x^*) + g(x^*),$$

即 x^* 是问题 (P) 的最优解。

注 4.2

- 当 f 可微，g 适当凸，我们称满足下面关系的 x^* 为稳定点：

$$-\nabla f(x^*) \in \partial g(x^*).$$

- 当 $g = \delta_C$（其中 $C \subseteq \mathbb{E}$ 是非空凸集）时，问题 (P) 变为

$$\min\{f(x) : x \in C\}.$$

若 f 在 $x^* \in C$ 处可微，则 x^* 是问题 (P) 的平稳点当且仅当

$$-\nabla f(x^*) \in \partial \delta_C(x^*) = N_C(x^*),$$

根据法锥的定义，条件可改写为

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0 \quad \forall x \in C.$$

也就是说，求这个问题的稳定点相当于求解一个变分不等式问题。

4.3 KKT 条件

引理 4.4 考虑如下约束的优化问题

$$\begin{aligned} &\min\ f(x) \\ &\text{s.t. } g_i(x) \leq 0,\ i = 1, 2, \ldots, m, \end{aligned}$$

其中 $f, g_1, g_2, \ldots, g_m : \mathbb{E} \to \mathbb{R}$ 是实值函数。假设问题的最小值有限且等于 $\bar{f}$。定义函数

$$F(x) \equiv \max\{f(x) - \bar{f}, g_1(x), g_2(x), \ldots, g_m(x)\}.$$

则原问题的最优解集与 F 的极小值点集相同。

证明. 设 X^* 是问题的最优解集。F 满足以下两个性质：

(i) 对任意 $x \notin X^*$，有 $F(x) > 0$；

设 $x \notin X^*$，分两种情况：

- 若 x 不可行，即存在 i 使得 $g_i(x) > 0$，由 F 的定义知 $F(x) > 0$；
- 若 x 可行但非最优，则对所有 i 有 $g_i(x) \le 0$ 且 $f(x) > \bar{f}$，因此 $F(x) > 0$。

(ii) 对任意 $x \in X^*$，有 $F(x) = 0$。

设 $x \in X^*$，则对所有 i 有 $g_i(x) \le 0$ 且 $f(x) = \bar{f}$，故 $F(x) = 0$。

上面分析可以看出, F 的极小值点集就是 $\{x : F(x) = 0\} = X^*$, 即原问题的最优解集与 F 的极小值点集相同。

定理 4.5 (Fritz-John 必要最优性条件) 考虑如下约束的优化问题

$$\begin{aligned} &\min\ f(x) \\ &\text{s.t. } g_i(x) \le 0,\ i = 1, 2, \dots, m, \end{aligned}$$

其中 $f, g_1, g_2, \dots, g_m : \mathbb{E} \to \mathbb{R}$ 是实值凸函数。设 x^* 是问题的最优解，则存在不全为零的 $\lambda_0, \lambda_1, \dots, \lambda_m \ge 0$，使得

$$\begin{aligned} &0 \in \lambda_0 \partial f(x^*) + \sum_{i=1}^{m} \lambda_i \partial g_i(x^*) \\ &\lambda_i g_i(x^*) = 0,\ i = 1, 2, \dots, m. \end{aligned}$$

证明. 设 x^* 是问题的最优解，记问题的最优值为 $\bar{f} = f(x^*)$。由定理 4.4，x^* 是问题

$$\min_{x \in \mathbb{E}} \{F(x) \equiv \max\{g_0(x), g_1(x), \dots, g_m(x)\}\}$$

(其中 $g_0(x) = f(x) - \bar{f}$) 的最优解，显然 $F(x^*) = 0$。由于 F 是凸函数的最大值，故 F 是凸函数。利用定理 4.1，有

$$0 \in \partial F(x^*) = \operatorname{conv}\left(\bigcup_{i \in I(x^*)} \partial g_i(x^*) \right),$$

其中 $I(x^*) = \{i \in \{0, 1, \dots, m\} : g_i(x^*) = 0\}$。结合上式可知，存在 $\lambda_i \ge 0$ $(i \in I(x^*))$ 且 $\sum_{i \in I(x^*)} \lambda_i = 1$，使得

$$0 \in \sum_{i \in I(x^*)} \lambda_i \partial g_i(x^*).$$

由于 $g_0(x^*) = f(x^*) - \bar{f} = 0$，故 $0 \in I(x^*)$，因此上式可改写为

$$0 \in \lambda_0 \partial f(x^*) + \sum_{i \in I(x^*) \setminus \{0\}} \lambda_i \partial g_i(x^*).$$

对任意 $i \in \{1, 2, \dots, m\} \setminus I(x^*)$, 令 $\lambda_i = 0$, 则两个条件都成立。最后, 由于 $\sum_{i \in I(x^*)} \lambda_i = 1$, 故 λ_i 不全为零。

如果要求 $\lambda_0 = 1$，则需要满足以下附加条件（称为 Slater 条件）：

$$\text{存在 } \overline{x} \in \mathbb{E} \text{ 使得 } g_i(\overline{x}) < 0,\ i = 1, 2, \ldots, m.$$

KKT 条件的充分性不需要额外假设（除凸性外），且无需借助弗里茨-约翰条件的结论即可轻松推导。

定理 4.6 (KKT 条件) 考虑如下的优化问题

$$\min\ f(x)$$

$$\text{s.t. } g_i(x) \leq 0,\ i = 1, 2, \ldots, m,$$

其中 $f, g_1, g_2, \ldots, g_m : \mathbb{E} \to \mathbb{R}$ 是实值凸函数。

(a) 设 x^* 是问题的最优解，且 Slater 条件成立，则存在 $\lambda_1, \ldots, \lambda_m \geq 0$，使得

$$0 \in \partial f(x*) + \sum_{i=1}^{m} \lambda_i \partial g_i(x^*)$$

$$\lambda_i g_i(x^*) = 0,\ i = 1, 2, \ldots, m.$$

(b) 若可行点 $x^* \in \mathbb{E}$ 对某组 $\lambda_1, \lambda_2, \ldots, \lambda_m \geq 0$ 满足上述两个条件，则 x^* 是问题的最优解。

证明.

(a) 由定理 4.5，存在不全为零的 $\tilde{\lambda}_0, \tilde{\lambda}_1, \ldots, \tilde{\lambda}_m \geq 0$，使得

$$0 \in \tilde{\lambda}_0 \partial f(x^*) + \sum_{i=1}^{m} \tilde{\lambda}_i \partial g_i(x^*)$$

且

$$\tilde{\lambda}_i g_i(x^*) = 0,\ i = 1, 2, \ldots, m.$$

只要证明 $\tilde{\lambda}_0 \neq 0$ 即可。假设 $\tilde{\lambda}_0 = 0$，则由上式得

$$0 \in \sum_{i=1}^{m} \tilde{\lambda}_i \partial g_i(x^*),$$

即存在 $\xi_i \in \partial g_i(x^*)$ $(i = 1, 2, \ldots, m)$，使得

$$\sum_{i=1}^{m} \tilde{\lambda}_i \xi_i = 0.$$

设 $\overline{x}$ 是满足 Slater 条件的点，对函数 g_i $(i = 1, 2, \ldots, m)$，由次梯度定义有

$$g_i(x^*) + \langle \xi_i, \overline{x} - x^* \rangle \leq g_i(\overline{x}),\ i = 1, 2, \ldots, m.$$

将第 i 个不等式乘以 $\tilde{\lambda}_i \geq 0$ 并对 $i = 1, 2, \ldots, m$ 求和，得

$$\sum_{i=1}^{m} \tilde{\lambda}_i g_i(x^*) + \left\langle \sum_{i=1}^{m} \tilde{\lambda}_i \xi_i, \overline{x} - x^* \right\rangle \leq \sum_{i=1}^{m} \tilde{\lambda}_i g_i(\overline{x}).$$

但是左边两项都为 0，故 $\sum_{i=1}^{m} \tilde{\lambda}_i g_i(\overline{x}) \geq 0$。但 Slater 条件中 $g_i(\overline{x}) < 0$ 且 $\tilde{\lambda}_i \geq 0$（不全为零），于是矛盾。因此 $\tilde{\lambda}_0 > 0$。

令 $\lambda_i = \frac{\tilde{\lambda}_i}{\tilde{\lambda}_0}$ $(i = 1, 2, \ldots, m)$，则

$$0 \in \partial f(x*) + \sum_{i=1}^{m} \lambda_i \partial g_i(x^*)$$

$$\lambda_i g_i(x^*) = 0,\ i = 1, 2, \ldots, m.$$

(b) 假设可行点 x^* 对某组 $\lambda_1, \lambda_2, \ldots, \lambda_m \geq 0$ 满足两个条件。设 $\overline{x}$ 是可行点，即 $g_i(\overline{x}) \leq 0$ $(i = 1, 2, \ldots, m)$，我们证明 $f(\overline{x}) \geq f(x^*)$。

定义函数

$$h(x) = f(x) + \sum_{i=1}^{m} \lambda_i g_i(x),$$

则 h 是凸函数。于是 KKT 条件告诉我们

$$0 \in \partial h(x^*),$$

结合定理 4.1，x^* 是 h 在 $\mathbb{E}$ 上的极小值点。

于是

$$f(x^*) = f(x^*) + \sum_{i=1}^{m} \lambda_i g_i(x^*) = h(x^*) \leq h(\overline{x}) = f(\overline{x}) + \sum_{i=1}^{m} \lambda_i g_i(\overline{x}).$$

由于 $\lambda_i \geq 0$ 且 $g_i(\overline{x}) \leq 0$，故 $\sum_{i=1}^{m} \lambda_i g_i(\overline{x}) \leq 0$，因此

$$f(x^*) \leq f(\overline{x}) + \sum_{i=1}^{m} \lambda_i g_i(\overline{x}) \leq f(\overline{x}),$$

即 x^* 是最优解。

注 4.3 我们将满足以下条件的 x^* 称为 KKT 点：

$$0 \in \partial f(x*) + \sum_{i=1}^{m} \lambda_i \partial g_i(x^*)$$

$$\lambda_i g_i(x^*) = 0,\ i = 1, 2, \ldots, m,$$

$$g_i(x^*) \leq 0,\ i = 1, 2, \ldots, m.$$

5 一般 NLP 中的 KKT 条件、锥与约束资格条件

5.1 问题形式与基本目标

考虑一般非线性规划问题

$$\begin{aligned} \min_{x\in\mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & g_i(x)\le 0, \quad i=1,\dots,m, \\ & h_j(x)=0, \quad j=1,\dots,p, \end{aligned} \tag{1}$$

其中 f, g_i, h_j 在所讨论点附近可微。记可行集为

$$\Omega := \{x\in\mathbb{R}^n :\ g_i(x)\le 0,\ i=1,\dots,m,\ h_j(x)=0,\ j=1,\dots,p\}. \tag{2}$$

对于给定可行点 $x^*\in\Omega$，记活动不等式指标集为

$$I(x^*) := \{i\in\{1,\dots,m\} : g_i(x^*)=0\}. \tag{3}$$

本文的目标是解释：

1. 局部极小点为什么应当满足 KKT 条件；
2. KKT 条件中的乘子从何而来；
3. 切锥、线性化锥、极锥与法锥在这一理论中扮演什么角色；
4. 为什么需要各种约束资格条件（constraint qualifications, CQ）。

5.2 切锥、线性化锥与极锥

定义 5.1 (Bouligand 切锥) 设 $\Omega\subset\mathbb{R}^n$，$x\in\Omega$。定义 Ω 在 x 处的 Bouligand（或 contingent）切锥为

$$T_\Omega(x) := \left\{ d\in\mathbb{R}^n : \exists\, x^k\in\Omega,\ x^k\to x,\ \exists\, t_k\downarrow 0,\ \frac{x^k-x}{t_k}\to d \right\}. \tag{4}$$

定义 5.1 中的切锥描述的是可行集在点 x 处的真实一阶可行方向。

定义 5.2 (线性化锥) 对问题 (1)，其在可行点 x^* 处的线性化锥定义为

$$L_\Omega(x^*) := \left\{ d\in\mathbb{R}^n : \nabla g_i(x^*)^\top d\le 0,\ i\in I(x^*),\ \nabla h_j(x^*)^\top d=0,\ j=1,\dots,p \right\}. \tag{5}$$

定义 5.2 中的线性化锥表示把约束在 x^* 处作一阶线性化后得到的“近似可行方向锥”。

命题 5.1 对任意可行点 $x^* \in \Omega$，都有

$$T_\Omega(x^*) \subseteq L_\Omega(x^*). \tag{6}$$

证明. 任取 $d \in T_\Omega(x^*)$。由定义 5.1，存在 $x^k \in \Omega$ 与 $t_k \downarrow 0$ 使

$$\frac{x^k - x^*}{t_k} \to d.$$

由于 x^k 可行，对任意 $i \in I(x^*)$，

$$g_i(x^k) \le 0, \qquad g_i(x^*) = 0.$$

由 g_i 的可微性，

$$g_i(x^k) = g_i(x^*) + \nabla g_i(x^*)^\top (x^k - x^*) + o(\|x^k - x^*\|).$$

除以 $t_k > 0$ 并令 $k \to \infty$，得到

$$\nabla g_i(x^*)^\top d \le 0.$$

同理，由 $h_j(x^k) = h_j(x^*) = 0$ 及 h_j 的可微性可得

$$\nabla h_j(x^*)^\top d = 0.$$

因此 $d \in L_\Omega(x^*)$，即 (6) 成立。

定义 5.3 (极锥) 对任意锥 $K \subseteq \mathbb{R}^n$，其极锥定义为

$$K^\circ := \{v \in \mathbb{R}^n : \langle v, d\rangle \le 0,\ \forall d \in K\}. \tag{7}$$

定义 5.3 表明：锥 K 描述“可以走的方向”，而其极锥 K° 描述“阻止这些方向的法向”。

5.3 Fréchet 正则法锥、Mordukhovich 法锥与 Clarke 法锥

定义 5.4 (Fréchet 正则法锥) 设 $\Omega \subseteq \mathbb{R}^n$，$x \in \Omega$。定义 Fréchet（regular）法锥为

$$\widehat{N}_\Omega(x) := \left\{ v \in \mathbb{R}^n : \limsup_{\substack{y \to x \\ y \in \Omega,\ y \neq x}} \frac{\langle v,\ y - x\rangle}{\|y - x\|} \le 0 \right\}. \tag{8}$$

命题 5.2 对任意集合 $\Omega \subseteq \mathbb{R}^n$ 及任意 $x \in \Omega$，有

$$\widehat{N}_\Omega(x) = T_\Omega(x)^\circ. \tag{9}$$

证明. 先证 “$\subseteq$”。任取 $v \in \widehat{N}_\Omega(x)$ 与 $d \in T_\Omega(x)$。由定义 5.1，存在 $y^k \in \Omega$ 与 $t_k \downarrow 0$ 使

$$\frac{y^k - x}{t_k} \to d.$$

若 $d \neq 0$，则

$$\left\langle v, \frac{y^k - x}{t_k} \right\rangle = \frac{\langle v, y^k - x\rangle}{\|y^k - x\|} \cdot \frac{\|y^k - x\|}{t_k}.$$

由 (8)，第一因子的上极限不超过 0；第二因子收敛到 $\|d\|$。因此

$$\langle v, d\rangle \leq 0.$$

若 $d = 0$，则结论显然成立。故 $v \in T_\Omega(x)^\circ$。

再证 “$\supseteq$”。设 $v \in T_\Omega(x)^\circ$，若 $v \notin \widehat{N}_\Omega(x)$，则由 (8) 的否定形式，存在 $\varepsilon > 0$ 与 $y^k \in \Omega,\ y^k \to x$ 使

$$\frac{\langle v, y^k - x\rangle}{\|y^k - x\|} \geq \varepsilon.$$

令

$$t_k := \|y^k - x\|, \qquad d^k := \frac{y^k - x}{t_k}.$$

则 $\|d^k\| = 1$。取子列仍记为 d^k，使 $d^k \to d$。由定义 5.1，有 $d \in T_\Omega(x)$。于是

$$\langle v, d\rangle = \lim_{k\to\infty} \left\langle v, \frac{y^k - x}{t_k} \right\rangle \geq \varepsilon > 0,$$

这与 $v \in T_\Omega(x)^\circ$ 矛盾。故 $v \in \widehat{N}_\Omega(x)$。

定义 5.5 (Mordukhovich 法锥) 定义 Mordukhovich（limiting/basic）法锥为

$$N_\Omega^M(x) := \left\{ v \in \mathbb{R}^n : \exists\, x^k \in \Omega,\ x^k \to x,\ \exists\, v^k \to v,\ v^k \in \widehat{N}_\Omega(x^k) \right\}. \tag{10}$$

定义 5.6 (Clarke 法锥) 定义 Clarke 法锥为

$$N_\Omega^C(x) := \overline{\mathrm{co}}\, N_\Omega^M(x). \tag{11}$$

命题 5.3 总有

$$\widehat{N}_\Omega(x) \subseteq N_\Omega^M(x) \subseteq N_\Omega^C(x). \tag{12}$$

证明. 由定义 (10)，取常值序列 $x^k \equiv x$ 与 $v^k \equiv v$，可得

$$\widehat{N}_\Omega(x) \subseteq N_\Omega^M(x).$$

再由定义 (11)，$N_\Omega^C(x)$ 是 $N_\Omega^M(x)$ 的闭凸包，故

$$N_\Omega^M(x) \subseteq N_\Omega^C(x).$$

5.4 局部极小点的最原始一阶必要条件

命题 5.4 若 x^* 是问题 (1) 的局部极小点，则

$$-\nabla f(x^*) \in T_\Omega(x^*)^\circ = \widehat{N}_\Omega(x^*). \tag{13}$$

证明. 任取 $d \in T_\Omega(x^*)$。由定义 5.1，存在 $x^k \in \Omega$ 与 $t_k \downarrow 0$ 使

$$\frac{x^k - x^*}{t_k} \to d.$$

由于 x^* 是局部极小点，对充分大的 k 有

$$f(x^k) \geq f(x^*).$$

由 f 的可微性，

$$f(x^k) = f(x^*) + \nabla f(x^*)^\top (x^k - x^*) + o(\|x^k - x^*\|).$$

移项并除以 t_k，令 $k \to \infty$，得

$$\nabla f(x^*)^\top d \geq 0.$$

这等价于

$$-\nabla f(x^*)^\top d \leq 0, \qquad \forall d \in T_\Omega(x^*),$$

即

$$-\nabla f(x^*) \in T_\Omega(x^*)^\circ.$$

再由命题 5.2，得到 (13)。

命题 5.4 表明：局部极小点处，目标函数不能沿任何真实切方向下降，因此其负梯度必须属于可行集的法锥。

5.5 线性化锥极锥的显式表达

令

$$K := \{d : \ \nabla g_i(x^*)^\top d \leq 0,\ i \in I(x^*)\}, \tag{14}$$

$$S := \{d : \ \nabla h_j(x^*)^\top d = 0,\ j = 1, \ldots, p\}. \tag{15}$$

则由定义 5.2，

$$L_\Omega(x^*) = K \cap S. \tag{16}$$

命题 5.5 对任意闭凸锥 $C_1, C_2 \subseteq \mathbb{R}^n$，有

$$(C_1 \cap C_2)^\circ = \overline{C_1^\circ + C_2^\circ}. \tag{17}$$

证明. 先证

$$\overline{C_1^\circ + C_2^\circ} \subseteq (C_1 \cap C_2)^\circ.$$

任取 $u = u_1 + u_2$，其中 $u_1 \in C_1^\circ,\ u_2 \in C_2^\circ$。对任意 $x \in C_1 \cap C_2$，有

$$\langle u_1, x\rangle \le 0, \qquad \langle u_2, x\rangle \le 0,$$

故

$$\langle u, x\rangle = \langle u_1, x\rangle + \langle u_2, x\rangle \le 0.$$

所以 $u \in (C_1 \cap C_2)^\circ$，进而其闭包也包含于 $(C_1 \cap C_2)^\circ$。

再证反向包含。设

$$M := \overline{C_1^\circ + C_2^\circ}.$$

由上一步，$M \subseteq (C_1 \cap C_2)^\circ$。对两边取极锥，包含关系反向，得

$$((C_1 \cap C_2)^\circ)^\circ \subseteq M^\circ.$$

由双极定理（闭凸锥满足 $K = (K^\circ)^\circ$），可得

$$C_1 \cap C_2 \subseteq M^\circ.$$

另一方面，因为闭包不影响极锥，所以

$$M^\circ = (C_1^\circ + C_2^\circ)^\circ.$$

若 $x \in (C_1^\circ + C_2^\circ)^\circ$，则对任意 $u_1 \in C_1^\circ,\ u_2 \in C_2^\circ$，

$$\langle x, u_1 + u_2\rangle \le 0.$$

令 $u_2 = 0$，得 $\langle x, u_1\rangle \le 0$ 对任意 $u_1 \in C_1^\circ$ 成立，因此

$$x \in (C_1^\circ)^\circ = C_1.$$

同理可得 $x \in C_2$。故

$$(C_1^\circ + C_2^\circ)^\circ \subseteq C_1 \cap C_2.$$

于是

$$M^\circ \subseteq C_1 \cap C_2.$$

结合前面的包含关系，得到 $M^\circ = C_1 \cap C_2$。再取极锥并用双极定理，即得

$$(C_1 \cap C_2)^\circ = M = \overline{C_1^\circ + C_2^\circ}.$$

命题 5.6 线性化锥 $L_\Omega(x^*)$ 的极锥可显式写成

$$L_\Omega(x^*)^\circ = \left\{ \sum_{i\in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^{p} \mu_j \nabla h_j(x^*) :\ \lambda_i \geq 0,\ \mu_j \in \mathbb{R} \right\}. \tag{18}$$

证明. 由 (16) 与命题 5.5，

$$L_\Omega(x^*)^\circ = (K \cap S)^\circ = \overline{K^\circ + S^\circ}.$$

先计算 K°。由 (14)，

$$K = \bigcap_{i\in I(x^*)} \{d :\ \nabla g_i(x^*)^\top d \leq 0\}.$$

每个半空间锥的极锥为

$$\{d :\ \nabla g_i(x^*)^\top d \leq 0\}^\circ = \{\lambda_i \nabla g_i(x^*) :\ \lambda_i \geq 0\}.$$

因此

$$K^\circ = \operatorname{cone}\{\nabla g_i(x^*) : i \in I(x^*)\} = \left\{ \sum_{i\in I(x^*)} \lambda_i \nabla g_i(x^*) :\ \lambda_i \geq 0 \right\}. \tag{19}$$

再计算 S°。由 (15)，S 是线性子空间，因此

$$S^\circ = S^\perp = \operatorname{span}\{\nabla h_j(x^*) : j = 1, \ldots, p\} = \left\{ \sum_{j=1}^{p} \mu_j \nabla h_j(x^*) :\ \mu_j \in \mathbb{R} \right\}. \tag{20}$$

将 (19) 与 (20) 代入，并注意此时和为闭集，故闭包可省，即得 (18)。

命题 5.6 正是 KKT 乘子式出现的根源：活动不等式梯度生成非负锥，等式梯度生成线性空间，两者相加便是线性化锥的极锥。

5.6 KKT 条件的由来

KKT 条件的证明结构可概括为：

$$\text{局部极小} \Longrightarrow -\nabla f(x^*) \in T_\Omega(x^*)^\circ \Longrightarrow -\nabla f(x^*) \in L_\Omega(x^*)^\circ \Longrightarrow \text{存在乘子，满足 KKT.}$$

因此真正的关键，是找到足够的条件保证

$$T_\Omega(x^*)^\circ = L_\Omega(x^*)^\circ.$$

这正是各类约束资格条件的作用。

5.7 各类约束资格条件（CQ）

定义 5.7 (LICQ) 称问题 (1) 在可行点 x^* 处满足 LICQ（linear independence constraint qualification），如果向量组

$$\{\nabla g_i(x^*) : i \in I(x^*)\} \cup \{\nabla h_j(x^*) : j = 1, \dots, p\} \tag{21}$$

线性无关。

定义 5.8 (MFCQ) 称问题 (1) 在可行点 x^* 处满足 MFCQ（Mangasarian–Fromovitz constraint qualification），如果

1. $\nabla h_j(x^*)$（$j = 1, \dots, p$）线性无关；
2. 存在某个方向 $d \in \mathbb{R}^n$ 使

$$\nabla h_j(x^*)^\top d = 0, \qquad j = 1, \dots, p, \tag{22}$$

且

$$\nabla g_i(x^*)^\top d < 0, \qquad i \in I(x^*). \tag{23}$$

定义 5.9 (CRCQ) 称问题 (1) 在可行点 x^* 处满足 CRCQ（constant rank constraint qualification），如果存在 x^* 的一个邻域 $N(x^*)$，使得对任意

$$I_1 \subseteq I(x^*), \qquad I_2 \subseteq \{1, \dots, p\},$$

向量组

$$\{\nabla g_i(x) : i \in I_1\} \cup \{\nabla h_j(x) : j \in I_2\}$$

在整个邻域 $N(x^*)$ 内都保持相同秩。

定义 5.10 (CPLD) 称问题 (1) 在可行点 x^* 处满足 CPLD（constant positive linear dependence），如果对任意

$$I_1 \subseteq I(x^*), \qquad I_2 \subseteq \{1, \dots, p\},$$

一旦向量组

$$\{\nabla g_i(x^*) : i \in I_1\} \cup \{\nabla h_j(x^*) : j \in I_2\}$$

在点 x^* 处正线性相关，则它们在某个邻域内保持线性相关。

定义 5.11 (ACQ) 称问题 (1) 在可行点 x^* 处满足 ACQ（Abadie constraint qualification），如果

$$T_\Omega(x^*) = L_\Omega(x^*). \tag{24}$$

定义 5.12 (GCQ) 称问题 (1) 在可行点 x^* 处满足 GCQ（Guignard constraint qualification），如果

$$T_\Omega(x^*)^\circ = L_\Omega(x^*)^\circ. \tag{25}$$

评论 5.1 各类 CQ 的本质作用都是保证：线性化信息足够忠实地反映可行集的局部几何。其中 ACQ 要求锥本身相等，GCQ 只要求极锥相等；对推出 KKT 而言，GCQ 已经足够。

5.8 CQ 之间的常见关系

在标准可微 NLP 框架下，常见的蕴含关系可写成

$$\text{LICQ} \Longrightarrow \text{MFCQ}, \qquad \text{LICQ} \Longrightarrow \text{CRCQ}, \tag{26}$$

$$\text{MFCQ} \Longrightarrow \text{CPLD}, \qquad \text{CRCQ} \Longrightarrow \text{CPLD}, \tag{27}$$

$$\text{CPLD} \Longrightarrow \text{ACQ} \Longrightarrow \text{GCQ}. \tag{28}$$

需要注意的是，MFCQ 与 CRCQ 一般互不包含。

5.9 KKT 定理

定理 5.7 (KKT 必要条件) 设 x^* 是问题 (1) 的局部极小点。若在 x^* 处满足 GCQ（见定义 5.12），则存在乘子

$$\lambda \in \mathbb{R}^m, \qquad \mu \in \mathbb{R}^p$$

使得

$$\nabla f(x^*) + \sum_{i=1}^{m} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^{p} \mu_j \nabla h_j(x^*) = 0, \tag{29}$$

$$g_i(x^*) \le 0, \qquad h_j(x^*) = 0, \tag{30}$$

$$\lambda_i \ge 0, \tag{31}$$

$$\lambda_i g_i(x^*) = 0, \qquad i = 1, \dots, m. \tag{32}$$

特别地，若在 x^* 处满足 ACQ、CPLD、MFCQ 或 LICQ，则上述 KKT 条件同样成立。

证明. 由命题 5.4，

$$-\nabla f(x^*) \in T_\Omega(x^*)^\circ.$$

由 GCQ 的定义 5.12，

$$T_\Omega(x^*)^\circ = L_\Omega(x^*)^\circ.$$

因此

$$-\nabla f(x^*) \in L_\Omega(x^*)^\circ.$$

再由命题 5.6，存在 $\lambda_i \geq 0$（$i \in I(x^*)$）与 $\mu_j \in \mathbb{R}$，使

$$-\nabla f(x^*) = \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^{p} \mu_j \nabla h_j(x^*).$$

对 $i \notin I(x^*)$ 定义 $\lambda_i := 0$，即可得到 (29)。由构造，$\lambda_i \geq 0$，且当 $i \notin I(x^*)$ 时 $g_i(x^*) < 0$ 且 $\lambda_i = 0$；当 $i \in I(x^*)$ 时 $g_i(x^*) = 0$。故

$$\lambda_i g_i(x^*) = 0, \qquad i = 1, \ldots, m.$$

结合原始可行性 (30)，定理得证。

最后，由 (28) 以及 (26)–(27) 可知，ACQ、CPLD、MFCQ、LICQ 都蕴含 GCQ，因此结论同样成立。

5.10 KKT 条件的几何意义与作用

评论 5.2 (几何意义) 由定理 5.7 可见，KKT 条件本质上是

$$-\nabla f(x^*) \in N_\Omega(x^*),$$

也就是：在局部极小点处，目标函数的下降趋势已经被活动约束的法向完全抵消。

评论 5.3 (理论作用) KKT 条件是一阶必要条件；在此基础上，可以进一步讨论二阶必要条件与二阶充分条件。

评论 5.4 (算法作用) SQP、内点法、增广拉格朗日法等经典 NLP 算法，本质上都在求解或逼近 KKT 系统 (29)–(32)。

评论 5.5 (灵敏度与对偶解释) KKT 乘子还具有对偶变量与边际价值的解释：某个活动约束的乘子越大，通常表明该约束对最优值的影响越显著。

5.11 总结

综上，一般 NLP 中 KKT 条件的由来可以概括为

$$\text{局部极小} \Longrightarrow -\nabla f(x^*) \in T_\Omega(x^*)^\circ \Longrightarrow -\nabla f(x^*) \in L_\Omega(x^*)^\circ \Longrightarrow \text{存在乘子，满足 KKT.} \tag{33}$$

其中：

- 切锥 $T_\Omega(x^*)$ 描述真实可行方向（定义 5.1）；
- 线性化锥 $L_\Omega(x^*)$ 描述一阶近似可行方向（定义 5.2）；
- Fréchet 正则法锥满足 $\widehat{N}_\Omega(x^*) = T_\Omega(x^*)^\circ$（命题 5.2）；

- 线性化锥的极锥具有显式梯度生成形式（命题 5.6）；
- 各类 CQ 的作用，是保证从真实几何到线性化几何的过渡合法（见定义 5.7–5.12 及定理 5.7）。

因此，KKT 条件并不是凭空写出的代数方程，而是局部最优性的几何性质、锥的对偶结构以及约束资格条件共同作用的结果。

6 最优化问题的对偶

6.1 线性规划问题的对偶

考虑标准形式的线性规划问题

$$\min_x \ c^\top x, \qquad \text{s.t.} \quad Ax = b, \quad x \geq 0.$$

其对偶问题为

$$\max_y \ b^\top y, \qquad \text{s.t.} \quad A^\top y \leq c,$$

其中对偶变量 y 为自由变量。

定义 Lagrange 函数

$$L(x, y) = c^\top x + y^\top (b - Ax) = b^\top y + (c - A^\top y)^\top x.$$

固定 y，定义对偶函数

$$q(y) := \inf_{x \geq 0} L(x, y).$$

为了使 $q(y) > -\infty$，必须有 $c - A^\top y \geq 0$，即 $A^\top y \leq c$。此时 $q(y) = b^\top y$，从而得到上述对偶问题。

若 x 和 y 分别为原问题和对偶问题的可行点，则

$$b^\top y = y^\top Ax = x^\top A^\top y \leq c^\top x.$$

因此，对偶目标值总是原问题目标值的下界，这称为**弱对偶性（weak duality）**。

在线性规划满足适当的可行性和有界性条件时，有

$$\min\{c^\top x : Ax = b, \ x \geq 0\} = \max\{b^\top y : A^\top y \leq c\},$$

称为**强对偶性（strong duality）**。

6.2 一般优化问题的对偶

考虑一般约束优化问题

$$\min_x \ f(x), \qquad \text{s.t.} \quad g_i(x) \leq 0, \ i = 1, \ldots, m, \quad h_j(x) = 0, \ j = 1, \ldots, p, \quad x \in X.$$

对不等式约束引入乘子 $\lambda_i \geq 0$，对等式约束引入自由乘子 $\nu_j \in \mathbb{R}$，定义 Lagrange 函数

$$L(x, \lambda, \nu) = f(x) + \sum_{i=1}^{m} \lambda_i g_i(x) + \sum_{j=1}^{p} \nu_j h_j(x).$$

定义**对偶函数（dual function）**

$$q(\lambda,\nu) := \inf_{x\in X} L(x,\lambda,\nu),$$

相应的 Lagrange 对偶问题为

$$\max_{\lambda,\nu}\ q(\lambda,\nu), \qquad \text{s.t.} \quad \lambda \geq 0.$$

若 x 为原问题可行点，则

$$q(\lambda,\nu) \leq L(x,\lambda,\nu) = f(x) + \sum_{i=1}^{m} \lambda_i g_i(x) \leq f(x).$$

若原问题和对偶问题的最优值分别为 p^* 和 d^*，则总有

$$d^* \leq p^*.$$

对于一般非凸问题，可能存在**对偶间隙（duality gap）**；对于凸优化问题，在 Slater 条件等适当约束规范条件下，通常有

$$d^* = p^*.$$

6.3 对偶问题的意义

对偶问题最基本的意义是寻找原问题最优值的最好 Lagrange 下界。由于

$$q(\lambda,\nu) \leq p^*$$

对所有对偶可行点都成立，因此求解

$$\sup_{\lambda\geq 0,\nu}\ q(\lambda,\nu)$$

就是在所有由 Lagrange 函数产生的下界中寻找最大的一个。

另一方面，对偶变量参与原问题的一阶最优性条件。在适当正则性条件下，最优解 (x^*,λ^*,ν^*) 满足 KKT 条件，其中驻点条件为

$$0 \in \partial_x L(x^*,\lambda^*,\nu^*) + N_X(x^*).$$

在光滑情形下，

$$\nabla f(x^*) + \sum_{i=1}^{m} \lambda_i^* \nabla g_i(x^*) + \sum_{j=1}^{p} \nu_j^* \nabla h_j(x^*) \in -N_X(x^*).$$

因此，对偶变量描述了各约束在最优点处如何参与一阶平衡。

此外，对偶变量还与**灵敏度分析（sensitivity analysis）**密切相关，即刻画约束发生微小扰动时最优目标值的一阶变化。

6.4 影子价格

考虑参数化线性规划

$$v(b) = \min_x \{c^\top x : Ax = b,\ x \geq 0\}.$$

由强对偶性，

$$v(b) = \max_y \{b^\top y : A^\top y \leq c\}.$$

设 y^* 是参数 b 处的最优对偶解。对扰动 $b + \Delta b$，由于 y^* 仍然对偶可行，

$$v(b + \Delta b) \geq (b + \Delta b)^\top y^* = v(b) + (y^*)^\top \Delta b.$$

因此

$$y^* \in \partial v(b).$$

若 v 在 b 处可微，则

$$\nabla v(b) = y^*, \qquad \frac{\partial v(b)}{\partial b_i} = y_i^*.$$

因此 y_i^* 表示约束右端参数 b_i 发生微小变化时，最优值的一阶变化率，这就是对偶变量的**影子价格（shadow price）**或边际价值含义。

需要注意，影子价格的符号依赖于约束的参数化方式。例如

$$v(u) = \min_x \{f(x) : g(x) \leq u\},$$

其 Lagrange 函数为

$$L(x, \lambda; u) = f(x) + \lambda^\top (g(x) - u), \qquad \lambda \geq 0.$$

因此在适当正则条件和可微性条件下，

$$\nabla v(u) = -\lambda^*.$$

所以严格地说，最优对偶变量刻画的是**约束扰动对最优值的一阶敏感度**；具体是 λ^* 还是 $-\lambda^*$，取决于约束中参数的符号约定。

7 最优化基本算法框架

最优化算法是一种数值算法，从初始点 x_0 开始，按一定的规则 (算法) 得到点列 $\{x^k\}$，从而得到解点 x^* 的近似点。

最优化算法根据 x^k 处 (甚至 $x^0, x^1, \ldots, x^{k-1}$ 处) 的信息 (如函数值、导数信息等) 得到下一个迭代点 x^{k+1}. 一般来说有两种类型的策略：**线搜索 (Line Search) 与信赖域 (Trust Region)**.

- **线搜索**:
  在线搜索策略中，算法选择一个方向 p_k，并从当前迭代点 x_k 沿该方向搜索，以找到函数值更小的新迭代点。沿 p_k 移动的距离 (步长 α_k) 可通过近似求解以下问题来确定：
  $$\alpha_k = \text{argmin}_{\alpha>0} f(x_k + \alpha p_k).$$
  然后令 $x_{k+1} = x^k + \alpha_k p_k$. 若精确求解 α_k 固然很好，但精确极小化可能成本高昂且通常得不偿失。

- **信赖域**:
  在信赖域策略中，每一次迭代需要构造一个模型函数 m_k，该函数是在当前点 x_k 附近对目标函数 f 的相似。由于当 x 远离 x_k 时，模型 m_k 可能无法很好地近似 f，因此我们将对 m_k 极小点的搜索限制在 x_k 周围的某个区域 (即信赖域) 内。信赖域策略通过近似求解以下子问题来找到候选步长 p_k：
  $$p_k = \text{argmin}_p m_k(x_k + p), \quad \text{其中 } x_k + p \text{ 位于信赖域内.}$$
  若 p_k 未使 f 产生足够的下降，则判定信赖域过大，会缩小并重新求解该子问题。通常，信赖域是一个由 $\|p\| \leq \Delta$ 定义的球，其中 $\Delta > 0$ 称为信赖域半径。

  f 的近似模型 m_k 通常定义为如下形式的二次函数：
  $$m_k(x_k + p) = f_k + p^T \nabla f_k + \frac{1}{2} p^T B_k p,$$
  其中 f_k 和 ∇f_k 选取为在点 x_k 处的函数值和梯度值，使得 m_k 和 f 在当前迭代点 x_k 处一阶一致, 矩阵 B_k 是 $\nabla^2 f_k$ 或其近似矩阵。

- **区别**：
  线搜索和信赖域方法的区别在于**选择移动到下一个迭代点的方向和距离的顺序**。线搜索先固定方向 p_k，然后确定合适的距离，即步长 α_k。在信赖域中，首先选择最大距离——信赖域半径 Δ_k，然后在该距离约束下寻找能实现最佳改进的方向和步长, 若该效果不理想，我们就减小距离度量 Δ_k 并再次尝试。

对此有两个主要问题：线搜索方法中搜索方向 p_k 的选择，以及信赖域方法中 B_k 的选择。

7.1 线搜索的搜索方向

7.1.1 下降方向

最速下降方向为 $-\nabla f_k$，它是线搜索方法中搜索方向的直观选择，是从 x_k 出发使 f 下降最快的方向。事实上，令 $h(\alpha) = f(x_k + \alpha p)$, 为了让其在 x_k 处有最快的下降方向，则需要 $\frac{d}{d\alpha}h(0) = \nabla f_k^\top p$ 最小，即

$$\min_p \nabla f_k^\top p, \quad \text{s.t. } \|p\| = 1.$$

由于 $\nabla f_k^\top p = \|p\|\|\nabla f_k\| \cos\theta = \|\nabla f_k\| \cos\theta$（其中 θ 是 p 与 ∇f_k 的夹角），易知当 $\cos\theta = -1$ 时取得极小值，此时

$$p = -\nabla f_k / \|\nabla f_k\|.$$

除此之外，**任何下降方向**——与 $-\nabla f_k$ 的夹角严格小于 $\pi/2$ 的方向，也可以作为线搜索方向。这是因为只要步长足够小，都能保证使 f 减小。事实上，此时 $\frac{d}{d\alpha}h(0) = \nabla f_k^\top p < 0$，则根据可微函数的性质对足够小的 $\epsilon > 0$，有 $f(x_k + \epsilon p_k) < f(x_k)$。

7.1.2 牛顿方向

另一种线搜索方向是**牛顿方向**。该方向由 $f(x_k + p)$ 的二阶泰勒级数近似推导而来，即

$$f(x_k + p) \approx f_k + p^T \nabla f_k + \frac{1}{2} p^T \nabla^2 f_k p \stackrel{\text{def}}{=} m_k(p).$$

假设 $\nabla^2 f_k$ 是正定的，通过寻找使 $m_k(p)$ 极小的向量 p 可得到牛顿方向，即：

$$p_k^{\text{N}} = -(\nabla^2 f_k)^{-1} \nabla f_k.$$

注 7.1 牛顿方向实际上是利用对目标函数的二阶近似得到的搜索方向，而下降方向是通过对目标函数的一阶近似得到的。从这个角度上来看，如果忽略求使用牛顿方向涉及到的矩阵运算带来的计算成本，牛顿方向比下降方向更有优势。

当 $\nabla^2 f_k$ 正定时，有

$$\nabla f_k^T p_k^{\text{N}} = -p_k^{\text{N}T} \nabla^2 f_k p_k^{\text{N}} \leq -\sigma_k \|p_k^{\text{N}}\|^2$$

其中 $\sigma_k > 0$ 为 $\nabla^2 f_k$ 的最小特征值, 故牛顿方向也是下降方向。但是与一般的下降方向不同的是，选取牛顿方向是步长一般可以直接取 1, 不必再进行线搜索 (这是因为求解牛顿方向时已经蕴含了对步长的求解)。

7.1.3 拟牛顿方向

如果 $\nabla^2 f_k$ 或者 $\nabla^2 f_k^{-1}$ 不易求解怎么办？通常可以使用 $\nabla^2 f_k$ 的近似矩阵 B_k 代替 $\nabla^2 f_k$，且在每一步后更新 B_k。更新利用了如下近似：

$$\nabla^2 f_k(x_{k+1} - x_k) \approx \nabla f_{k+1} - \nabla f_k,$$

即选择的 Hessian 近似 B_{k+1}，要求它满足以下割线方程：

$$B_{k+1} s_k = y_k,$$

其中

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f_{k+1} - \nabla f_k.$$

另外通常会对 B_{k+1} 施加额外条件，例如：

- 对称性（由精确 Hessian 的对称性启发）；
- 要求连续近似 B_k 和 B_{k+1} 之间的差具有低秩。

以下是两种更新公式：

- 秩一公式: $B_{k+1} = B_k + \frac{(y_k - B_k s_k)(y_k - B_k s_k)^T}{(y_k - B_k s_k)^T s_k}$
- BFGS 公式: $B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k}$

注 7.2 注意，秩一公式中矩阵 B_k 和 B_{k+1} 之间的差是秩一矩阵, BFGS 公式中是秩二矩阵。这两种更新都满足割线方程，且都保持对称性。可以证明，当初始近似 B_0 正定且 $s_k^T y_k > 0$ 时，BFGS 更新会生成正定近似。

由于搜索方向定义为 $p_k = -B_k^{-1} \nabla f_k$，于是更节约的办法是直接对 $H_K = B_k^{-1}$ 进行更新：

$$H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T, \quad \rho_k = \frac{1}{y_k^T s_k}.$$

此时，搜索方向可通过 $p_k = -H_k \nabla f_k$ 计算。

7.1.4 共轭梯度方向

非线性共轭梯度方向形式为

$$p_k = -\nabla f(x_k) + \beta_k p_{k-1},$$

其中 $\beta_k \in \mathbb{R}^n$ 使得 p_k 和 p_{k-1} 是共轭的。

注 7.3 共轭梯度方法最初用于求解线性方程组 $Ax = b$（其中系数矩阵 A 对称正定）。求解该线性系统的问题等价于极小化凸二次函数

$$\min_x \phi(x) = \frac{1}{2} x^T A x - b^T x,$$

如果将其推广到扩展到更一般的无约束极小化问题就是非线性共轭梯度法。一般来说，非线性共轭梯度方向比最速下降方向有效得多，且计算几乎同样简单。这些方法虽未达到牛顿或拟牛顿方法的快速收敛速度，但优势在于避免存储矩阵。

7.2 信赖域子问题的近似模型

信赖域子问题一般取：

$$\min_p m_k(x_k+p) = f_k + p^T\nabla f_k + \frac{1}{2}p^T B_k p, \quad \text{s.t.}\|p\| \le \Delta_k.$$

若令 $B_k = 0$，并使用欧几里得范数，则信赖域子问题变为

$$\min_p f_k + p^T\nabla f_k \quad \text{s.t. } \|p\|_2 \le \Delta_k,$$

上述问题的解可写成：

$$p_k = -\frac{\Delta_k \nabla f_k}{\|\nabla f_k\|}.$$

注 7.4 这是一个简单的最速下降步，步长由信赖域半径确定；此时信赖域和线搜索方法本质上是相同的。

如果选择 B_k 为精确 Hessian $\nabla^2 f_k$。由于信赖域限制 $\|p\|_2 \le \Delta_k$，即使 $\nabla^2 f_k$ 不正定，子问题也保证有解。

若二次模型函数 m_k 中的矩阵 B_k 由拟牛顿近似定义，则得到信赖域拟牛顿法。

Part II

基础算法

8 线搜索方法：Line Search Methods

线搜索方法的每次迭代都会计算一个搜索方向 p_k，然后决定沿该方向移动多远 (即步长 α_k)。迭代公式为

$$x_{k+1} = x_k + \alpha_k p_k$$

其中 α_k 称为步长。p_k 和 α_k 的有效选择是线搜索方法的关键。

8.1 步长的选择

在选择步长时, 当然希望 α_k 可以显著降低 f 的值，但是同时又不能花费过多时间。比如可以选择 $\phi(\cdot)$ 的全局极小点：

$$\phi(\alpha) = f(x_k + \alpha p_k), \quad \alpha > 0$$

但一般来说，确定这个值的计算成本很高。更实用的策略是执行**非精确线搜索准则**，以较小的成本获得使 f 足够降低的步长。

8.1.1 Wolfe Conditions

一个显然的目的是选择 α_k 使得 f 有充分的减少：

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f_k^T p_k,$$

其中 $c_1 \in (0, 1)$。这个不等式就是**充分下降条件**，有时被称为 Armijo 条件。不等式右侧是一个线性函数，可记为 $l(\alpha)$，斜率为 $c_1 \nabla f_k^T p_k$ 为负。Wolfe Conditions 表明，只有当 $\phi(\alpha) \leq l(\alpha)$ 时，α 才被接受。在实际应用中，c_1 通常选得很小，例如 $c_1 = 10^{-4}$。

通常充分下降条件本身不一定确保算法取得合理进展，因为对于所有足够小的 α，该条件都能满足。为了排除过小的步长，通常会要求步长 α_k 满足**曲率条件**：

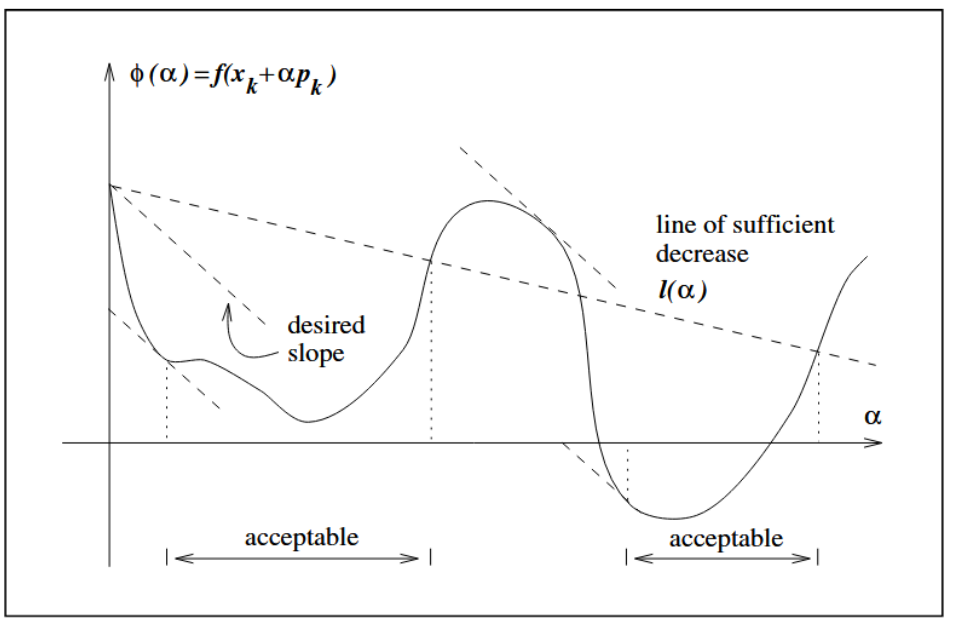
$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f_k^T p_k,$$

其中 $c_2 \in (c_1, 1)$。注意，左侧就是导数 $\phi'(\alpha_k)$，这个条件确保了 ϕ 在 α_k 处的斜率大于初始斜率 $\phi'(0)$ 的 c_2 倍。当搜索方向 p_k 由牛顿法或拟牛顿法选取时，c_2 一般为 0.9；当 p_k 由非线性共轭梯度法得到时，c_2 一般为 0.1。

充分下降条件和曲率条件都被统称为 Wolfe 条件:

$$\begin{aligned} f(x_k + \alpha p_k) &\leq f(x_k) + c_1 \alpha \nabla f_k^T p_k, \\ \nabla f(x_k + \alpha_k p_k)^T p_k &\geq c_2 \nabla f_k^T p_k, \end{aligned}$$

其中，$0 < c_1 < c_2 < 1$.



如果按照 Wolfe 条件，步长可能较大，从而远离附近的局部极小点，如上图。可以修改曲率条件，迫使 α_k 至少位于 ϕ 的局部极小值点或驻点的一个邻域内, 则得到强 Wolfe 条件:

$$f(x_k + \alpha_k p_k) \leq f(x_k) + c_1 \alpha_k \nabla f_k^T p_k,$$
$$|\nabla f(x_k + \alpha_k p_k)^T p_k| \leq c_2 |\nabla f_k^T p_k|,$$

其中 $0 < c_1 < c_2 < 1$。区别在于强 Wolfe 条件不允许 $\phi'(\alpha_k)$ 超过 0 太多。

下面一个定理说明了对于一个连续可微函数一定存在步长区间满足 Wolfe 条件。

定理 8.1 *假设 $f : \mathbb{R}^n \to \mathbb{R}$ 是连续可微的。设 p_k 是在 x_k 处的下降方向，且假设 $f(x_k+\alpha p_k)$ 在 $\alpha > 0$ 时下方有界。那么若 $0 < c_1 < c_2 < 1$，存在满足 Wolfe 条件和强 Wolfe 条件的步长区间。*

证明. 注意到 $\phi(\alpha) = f(x_k + \alpha p_k)$ 对所有 $\alpha > 0$ 下方有界。由于 $c_1 \nabla f_k^T p_k < 0$，则直线 $l(\alpha) = f(x_k) + \alpha c_1 \nabla f_k^T p_k$ 下方无界，因此至少与 ϕ 的图像相交一次。设 $\alpha' > 0$ 是 α 的最小相交值，即

$$f(x_k + \alpha' p_k) = f(x_k) + \alpha' c_1 \nabla f_k^T p_k$$

考虑函数 $g(\alpha) = f(x_k + \alpha p_k) - f(x_k) - \alpha c_1 \nabla f_k^T p_k$, 因为 $g(0) = g(\alpha') = 0$ 且 $g'(0) = (1 - c_1)\nabla f_k^T p_k < 0$, 则根据连续可微函数的性质，充分下降条件对所有小于 α' 的步长成立。

由中值定理，存在 $\alpha'' \in (0, \alpha')$ 使得

$$f(x_k + \alpha' p_k) - f(x_k) = \alpha' \nabla f(x_k + \alpha'' p_k)^T p_k$$

结合上述两式，可得

$$\nabla f(x_k + \alpha'' p_k)^T p_k = c_1 \nabla f_k^T p_k > c_2 \nabla f_k^T p_k$$

因为 $c_1 < c_2$ 且 $\nabla f_k^T p_k < 0$。因此，α'' 满足 Wolfe 条件，。又由 f 的连续可微，存在以 α'' 的领域，在该领域内 Wolfe 条件成立。

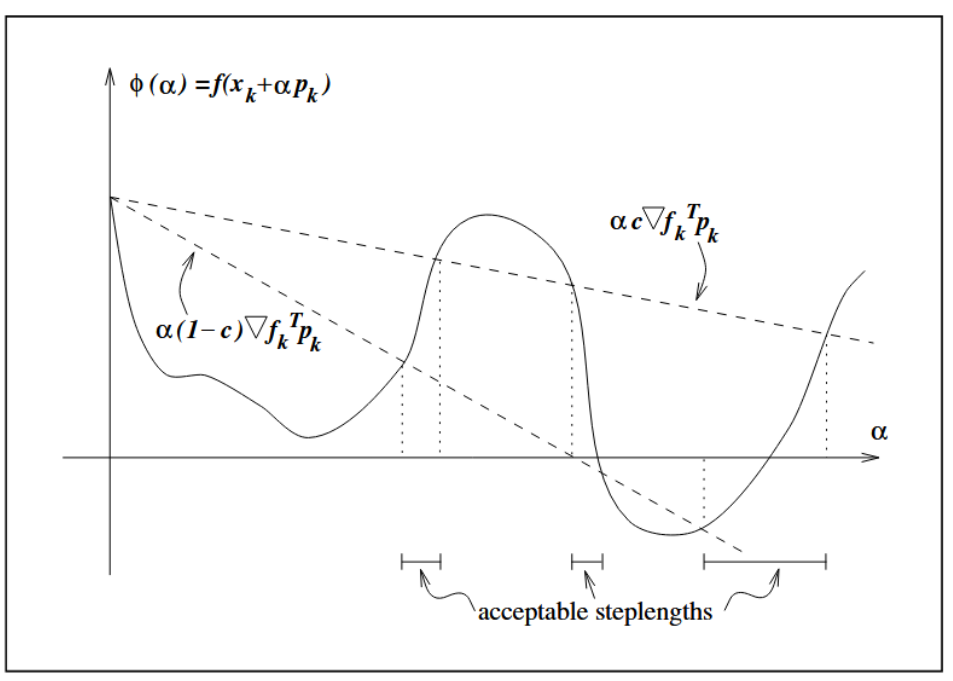
此外，由于 $\nabla f(x_k + \alpha'' p_k)^T p_k = c_1 \nabla f_k^T p_k$ 为负，显然强 Wolfe 条件在同一领域内也成立。

8.1.2 Goldstein 条件

另一种 Goldstein 条件也可以确保步长 α 实现充分下降且不会过短。Goldstein 条件为：

$$f(x_k) + (1-c)\alpha_k \nabla f_k^T p_k \leq f(x_k + \alpha_k p_k) \leq f(x_k) + c\alpha_k \nabla f_k^T p_k$$

其中 $0 < c < 1/2$。其中第二个不等式是充分下降条件，而第一个不等式用于从下方控制步。



注 8.1 Goldstein 条件相较于 Wolfe 条件有一个缺点是，其第一个不等式可能会排除 ϕ 的所有极小值点。不过，Goldstein 条件和 Wolfe 条件的收敛理论十分相似。Goldstein 条件常用于牛顿型方法，但不太适用于保持正定 Hessian 近似的拟牛顿方法。

8.2 线搜索方法的收敛性

假设 p_k 为下降方向，即 $\nabla f_k^\top p_k < 0$, 因此 p_k 和最速下降方向 $-f_k$ 的夹角的余弦值为

$$\cos\theta_k = \frac{-\nabla f_k^\top p_k}{\|\nabla f_k\|\|p_k\|}.$$

定理 8.2 考虑迭代 $x_{k+1} = x_k + \alpha_k p_k$，其中 p_k 是下降方向且 α_k 满足 Wolfe 条件。假设 f 在 $\mathbb{R}^n$ 上下有界，且 f 在包含水平集 $\mathcal{L} \triangleq \{x : f(x) \le f(x_0)\}$ 的开集 $\mathcal{N}$ 上连续可微，其中 x_0 是迭代的起始点, 假设梯度 ∇f 在 $\mathcal{N}$ 上是 Lipschitz 连续的，即存在常数 $L > 0$，使得

$$\|\nabla f(x) - \nabla f(\tilde{x})\| \le L\|x - \tilde{x}\|, \quad \forall\, x, \tilde{x} \in \mathcal{N}.$$

则

$$\sum_{k\ge 0} \cos^2\theta_k \|\nabla f_k\|^2 < \infty.$$

证明. 由 Wolfe 条件第二个不等式与 Lipschitz 条件可得

$$\begin{aligned}(\nabla f_{k+1} - \nabla f_k)^T p_k &\ge (c_2 - 1)\nabla f_k^T p_k,\\ (\nabla f_{k+1} - \nabla f_k)^T p_k &\le \alpha_k L\|p_k\|^2.\end{aligned}$$

于是可得

$$\alpha_k \ge \frac{c_2 - 1}{L}\frac{\nabla f_k^T p_k}{\|p_k\|^2}.$$

将此不等式代入 Wolfe 条件第二个不等式可得

$$f_{k+1} \le f_k - c_1\frac{1 - c_2}{L}\frac{(\nabla f_k^T p_k)^2}{\|p_k\|^2}.$$

即

$$c\cos^2\theta_k\|\nabla f_k\|^2 \le f_k - f_{k+1},$$

其中 $c = c_1(1 - c_2)/L$。求和可得 $\forall N \in \mathbb{N}^+$

$$\sum_{k=0}^{N} \cos^2\theta_j\|\nabla f_j\|^2 \le \frac{1}{c}(f_0 - f_{k+1}).$$

由于 f 下有界，所以有 $f_0 - f_{k+1}$ 小于某个正常数。取极限可得

$$\sum_{k=0}^{\infty} \cos^2\theta_k\|\nabla f_k\|^2 < \infty.$$

注 8.2

- 我们称 $\sum_{k=0}^{\infty}\cos^2\theta_k\|\nabla f_k\|^2<\infty$ 为 Zoutendijk 条件.
- 由 Zoutendijk 条件可以得到：$\cos^2\theta_k\|\nabla f_k\|^2\to 0$. 因此如果 $\exists\,\delta>0,\ \forall\,k,\ \cos\theta_k\geq\delta>0$, 则 $\|\nabla f_k\|\to 0$. 也就是说，只要让搜索方向与负梯度的方向夹角始终小于 $\pi/2$, 就可以得到迭代点梯度的收敛性.
- 对于牛顿法或者拟牛顿法，$p_k=-B_k^{-1}f_k$，其中 B_k 为对称正定矩阵，则

$$\cos\theta_k=\frac{\nabla f_k^{\top}B_k\nabla f_k}{\|\nabla f_k\|\|B_k^{-1}f_k\|}\geq\frac{\|B_k\|^{-1}\|\nabla f_k\|^2}{\|B_k^{-1}\|\|\nabla f_k\|^2}=\frac{\|B_k\|^{-1}}{\|B_k^{-1}\|},$$

  因此只要 $\|B_k\|\|B_k^{-1}\|\leq\delta^{-1}$ 即可.

8.3 线搜索方法的收敛率

8.3.1 最速下降法的收敛率

我们先考虑最基础的算法最速下降法的收敛率，先考虑最简单问题

$$f(x)=\frac{1}{2}x^TQx-b^Tx,$$

其中 Q 是对称正定矩阵。梯度为 $\nabla f(x)=Qx-b$，问题的全局极小点 x^* 就是线性方程组 $Qx=b$ 的唯一解。通过对 $f(x_k-\alpha\nabla f_k)$ 求极小可得最速下降法的步长为:

$$\alpha_k=\frac{\nabla f_k^T\nabla f_k}{\nabla f_k^TQ\nabla f_k},$$

于是最速下降迭代式为

$$x_{k+1}=x_k-\left(\frac{\nabla f_k^T\nabla f_k}{\nabla f_k^TQ\nabla f_k}\right)\nabla f_k,$$

其中 $\nabla f_k=Qx_k-b$.

设 $||x||_Q^2=x^TQx$。利用关系 $Qx^*=b$，可以得到

$$\begin{aligned}\frac{1}{2}||x-x^*||_Q^2&=\frac{1}{2}x^{\top}Qx-x^{*\top}Qx+\frac{1}{2}x^{*\top}Qx^*\\&=\frac{1}{2}x^{\top}Qx-b^{\top}x-\frac{1}{2}x^{*\top}Qx^*+x^{*\top}Qx^*\\&=\frac{1}{2}x^{\top}Qx-b^{\top}x-\left(\frac{1}{2}x^{*\top}Qx^*-b^{\top}x^*\right)\\&=f(x)-f(x^*),\end{aligned}$$

因此该范数衡量了当前目标函数值与最优值之间的距离。由于 $\nabla f_k=Q(x_k-x^*)$，可推

导出等式

$$\begin{aligned}\frac{1}{2}\|x_{k+1}-x^*\|_Q^2 &= f(x^{k+1})-f(x^*)\\ &= \frac{1}{2}\left(x^k-\alpha_k\nabla f(x^k)\right)^\top Q\left(x^k-\alpha_k\nabla f(x^k)\right)-b^\top(x^k-\alpha_k\nabla f(x^k))-f(x^*)\\ &= \frac{1}{2}{x^k}^\top Qx^k-b^\top x^k-f(x^*)+\frac{\alpha_k^2}{2}\nabla f(x^k)^\top Q\nabla f(x^k)-\alpha_k\nabla f(x^k)^\top(Qx^k-b)\\ &= \frac{1}{2}\|x_k-x^*\|_Q^2+\frac{\alpha_k^2}{2}\nabla f(x^k)^\top Q\nabla f(x^k)-\alpha_k\nabla f(x^k)^\top\nabla f(x^k)\end{aligned}$$

其中由于

$$\begin{aligned}&\alpha_k^2\nabla f(x^k)^\top Q\nabla f(x^k)-2\alpha_k\nabla f(x^k)^\top\nabla f(x^k)\\ =&\frac{(\nabla f_k^T\nabla f_k)^2}{(\nabla f_k^TQ\nabla f_k)^2}\nabla {f_k}^\top Q\nabla f_k-2\frac{(\nabla f_k^T\nabla f_k)^2}{\nabla f_k^TQ\nabla f_k}\\ =&-\frac{(\nabla f_k^T\nabla f_k)^2}{\nabla f_k^TQ\nabla f_k}\\ =&-\frac{(\nabla f_k^T\nabla f_k)^2}{(\nabla f_k^TQ\nabla f_k)(\nabla f_k^TQ^{-1}\nabla f_k)}\nabla f_k^TQ^{-1}\nabla f_k\\ =&-\frac{(\nabla f_k^T\nabla f_k)^2}{(\nabla f_k^TQ\nabla f_k)(\nabla f_k^TQ^{-1}\nabla f_k)}(x_k-x^*)^\top Q^\top Q^{-1}Q(x_k-x^*)\\ =&-\frac{(\nabla f_k^T\nabla f_k)^2}{(\nabla f_k^TQ\nabla f_k)(\nabla f_k^TQ^{-1}\nabla f_k)}\|x_k-x^*\|_Q^2\end{aligned}$$

于是：

$$||x_{k+1}-x^*||_Q^2=\left\{1-\frac{(\nabla f_k^T\nabla f_k)^2}{(\nabla f_k^TQ\nabla f_k)(\nabla f_k^TQ^{-1}\nabla f_k)}\right\}||x_k-x^*||_Q^2$$

这个表达式描述了每次迭代中 f 的精确下降量，上述讨论可以进一步得到下面这个定理：

定理 8.3

$$\|x_{k+1}-x^*\|_Q^2\le\left(\frac{\lambda_n-\lambda_1}{\lambda_n+\lambda_1}\right)^2\|x_k-x^*\|_Q^2$$

其中 $0<\lambda_1\le\lambda_2\le\cdots\le\lambda_n$ 是 Q 的特征值。

8.3.2 梯度法在凸函数上的收敛性

定理 8.4 (梯度法在凸函数上的收敛性) 设函数 $f(x)$ 为凸的梯度 L-利普希茨连续函数，$f^*=f(x^*)=\inf\limits_x f(x)$ 存在且可达。如果步长 α_k 取为常数 α 且满足 $0<\alpha<\frac{1}{L}$，那么由迭代得到的点列 $\{x^k\}$ 的函数值收敛到最优值，且在函数值的意义下收敛速度为 $O\left(\frac{1}{k}\right)$。

证明. 因为函数 f 是利普希茨可微函数，对任意的 x 有

$$f(x-\alpha\nabla f(x)) \le f(x) - \alpha\left(1-\frac{L\alpha}{2}\right)\|\nabla f(x)\|^2$$

现在记 $\tilde{x} = x - \alpha\nabla f(x)$ 并限制 $0 < \alpha < \frac{1}{L}$ 有

$$\begin{aligned} f(\tilde{x}) &\le f(x) - \frac{\alpha}{2}\|\nabla f(x)\|^2 \\ &\le f^* + \nabla f(x)^{\mathrm{T}}(x-x^*) - \frac{\alpha}{2}\|\nabla f(x)\|^2 \\ &= f^* + \frac{1}{2\alpha}\left(\|x-x^*\|^2 - \|x-x^*-\alpha\nabla f(x)\|^2\right) \\ &= f^* + \frac{1}{2\alpha}\left(\|x-x^*\|^2 - \|\tilde{x}-x^*\|^2\right), \end{aligned}$$

其中第一个不等式是由于前述式子，第二个不等式为 f 的凸性。在上式中取 $x = x^{i-1}$，$\tilde{x} = x^i$ 并将不等式对 $i = 1, 2, \cdots, k$ 求和得到

$$\begin{aligned} \sum_{i=1}^{k}(f(x^i) - f^*) &\le \frac{1}{2\alpha}\sum_{i=1}^{k}\left(\|x^{i-1}-x^*\|^2 - \|x^i-x^*\|^2\right) \\ &= \frac{1}{2\alpha}\left(\|x^0-x^*\|^2 - \|x^k-x^*\|^2\right) \\ &\le \frac{1}{2\alpha}\|x^0-x^*\|^2. \end{aligned}$$

根据前述式子得知 $f(x^i)$ 是非增的，所以

$$f(x^k) - f^* \le \frac{1}{k}\sum_{i=1}^{k}(f(x^i) - f^*) \le \frac{1}{2k\alpha}\|x^0-x^*\|^2.$$

注 8.3 如果只要求 $0 < \alpha < \frac{2}{L}$, 则只能得到迭代点收敛到稳定点，而得不到收敛率

8.3.3 牛顿法的收敛率

考虑步长为 1 的牛顿法 $x_{k+1} = x_k + p_k^N = x_k - \nabla^2 f_k^{-1}\nabla f_k$

定理 8.5 假设 f 二阶可微，且 Hessian 矩阵 $\nabla^2 f(x)$ 在解 x^* 的邻域内 Lipschitz 连续，其中 x^* 满足 $\nabla f(x^*) = 0$, $\nabla^2 f(x^*)$ 正定。考虑迭代 $x_{k+1} = x_k + p_k^N = x_k - \nabla^2 f_k^{-1}\nabla f_k$。则

(i) 若初始点 x_0 足够接近 x^*，则迭代序列收敛到 x^*;
(ii) $\{x_k\}$ 的收敛速度是二次的;
(iii) 梯度范数序列 $\{\|\nabla f_k\|\}$ 二次收敛到零。

证明. 由 $\nabla f_* = 0$

$$x_k + p_k^{\mathrm{N}} - x^* = x_k - x^* - \nabla^2 f_k^{-1}\nabla f_k = \nabla^2 f_k^{-1}\left[\nabla^2 f_k(x_k - x^*) - (\nabla f_k - \nabla f_*)\right]$$

由于

$$\nabla f_k - \nabla f_* = \int_0^1 \nabla^2 f(x_k + t(x^* - x_k))(x_k - x^*)dt$$

我们有

$$\begin{aligned}\|\nabla^2 f(x_k)(x_k - x^*) - (\nabla f_k - \nabla f(x^*))\| &= \left\|\int_0^1 [\nabla^2 f(x_k) - \nabla^2 f(x_k + t(x^* - x_k))](x_k - x^*)dt\right\| \\ &\le \int_0^1 \|\nabla^2 f(x_k) - \nabla^2 f(x_k + t(x^* - x_k))\|\|x_k - x^*\|dt \\ &\le \|x_k - x^*\|^2 \int_0^1 Ltdt = \frac{1}{2}L\|x_k - x^*\|^2,\end{aligned}$$

其中 L 是 $\nabla^2 f(x)$ 在 x 接近 x^* 时的 Lipschitz 常数（**上面这个不等式很像 L-smooth 里面的下降引理，证明都差不多**）。

由于 $\nabla^2 f(x^*)$ 非奇异，存在半径 $r > 0$，使得对所有满足 $\|x_k - x^*\| \le r$ 的 x_k，有 $\|\nabla^2 f_k^{-1}\| \le 2\|\nabla^2 f(x^*)^{-1}\|$。将其代入上面的式子，我们得到

$$\|x_k + p_k^{\mathrm{N}} - x^*\| \le L\|\nabla^2 f(x^*)^{-1}\|\|x_k - x^*\|^2 = \tilde{L}\|x_k - x^*\|^2,$$

其中 $\tilde{L} = L\|\nabla^2 f(x^*)^{-1}\|$。选择 x_0 使得 $\|x_0 - x^*\| \le \min(r, 1/(2\tilde{L}))$，我们可以用数学归纳法推出该序列收敛到 x^*，且收敛速度是二次的。

通过利用关系 $x_{k+1} - x_k = p_k^{\mathrm{N}}$ 和 $\nabla f_k + \nabla^2 f_k p_k^{\mathrm{N}} = 0$，我们得到

$$\begin{aligned}\|\nabla f(x_{k+1})\| &= \|\nabla f(x_{k+1}) - \nabla f_k - \nabla^2 f(x_k)p_k^{\mathrm{N}}\| \\ &= \left\|\int_0^1 \nabla^2 f(x_k + tp_k^{\mathrm{N}})(x_{k+1} - x_k)dt - \nabla^2 f(x_k)p_k^{\mathrm{N}}\right\| \\ &\le \int_0^1 \|\nabla^2 f(x_k + tp_k^{\mathrm{N}}) - \nabla^2 f(x_k)\|\|p_k^{\mathrm{N}}\|dt \\ &\le \frac{1}{2}L\|p_k^{\mathrm{N}}\|^2 \\ &\le \frac{1}{2}L\|\nabla^2 f(x_k)^{-1}\|^2\|\nabla f_k\|^2 \\ &\le 2L\|\nabla^2 f(x^*)^{-1}\|^2\|\nabla f_k\|^2,\end{aligned}$$

这证明了梯度范数二次收敛到零。

注 8.4 上述定理的条件其实是比较强的

8.3.4 拟牛顿法的收敛率

8.4 调整海瑟矩阵的牛顿法

牛顿法的迭代方向由以下方程聚决定：

$$\nabla^2 f(x_k)p_k^{\mathrm{N}} = -\nabla f(x_k)$$

但是这带来几个问题

- Hessian 矩阵 $\nabla^2 f(x)$ 可能不是正定的, 因此牛顿方向 p_k^{N} 可能不是下降方向
- 求解上述方程有时不是一件容易的事情

为了克服上述困难，考虑修改 Hessian 矩阵，修改后的 Hessian 矩阵是通过将正定对角矩阵或满矩阵添加到真实的 Hessian 矩阵 $\nabla^2 f(x_k)$ 中得到的：

Algorithm 1 带修正的线搜索牛顿法

Require: 初始点 x_0

1: **while** $k = 0, 1, 2, \ldots$ **do**

2: 对矩阵 $B_k = \nabla^2 f(x_k) + E_k$ 进行分解，其中若 $\nabla^2 f(x_k)$ 是充分正定的，则 $E_k = 0$；否则，选择 E_k 以确保 B_k 是充分正定的；

3: 求解 $B_k p_k = -\nabla f(x_k)$；

4: 令 $x_{k+1} \leftarrow x_k + \alpha_k p_k$，其中 α_k 满足 Wolfe、Goldstein 或 Armijo 回溯条件；

5: **end while**

注 8.5 通常不需要得到显示的 E_k，而是动态的修改。为了得到全局收敛结果，需要选择 E_k 使得 B_k 满足有界修改分解性质, 即 $\{\nabla^2 f(x_k)\}$ 有界时

$$\kappa(B_k) = \|B_k\|\|B_k^{-1}\| \leq C, \quad \text{对某个 } C > 0 \text{ 和所有 } k = 0, 1, 2, \ldots,$$

它确保了修正后的矩阵 B_k 不会过于“病态”

定理 8.6 设 f 在开集 D 上二阶连续可微，假设算法 1的起始点 x_0 满足水平集 $\mathcal{L} = \{x \in D : f(x) \leq f(x_0)\}$ 是紧集。且有界修改分解性质成立，则有

$$\lim_{k \to \infty} \nabla f(x_k) = 0.$$

9 次梯度法

9.1 带 Polyak 步长的投影次梯度法

9.1.1 无约束优化的次梯度法

考虑无约束优化问题

$$\min_{x\in\mathbb{E}} f(x)$$

其中 f 是适当闭凸函数。

- 如果 f 可微：我们知道 $-\nabla f(x^k)$ 是 f 在 x^k 处的下降方向，则可以考虑最速下降法:

$$x^{k+1} = x^k - t_k \nabla f(x^k)$$
$$t_k \in \operatorname{argmin}_{t\geq 0} f(x^k - t\nabla f(x^k)).$$

- 如果 f 不可微，则对非光滑情形的一个自然推广是用次梯度代替梯度 (假设次梯度存在), 即次梯度法：

$$x^{k+1} = x^k - t_k g^k, \quad g^k \in \partial f(x^k),$$

其中从 $\partial f(x^k)$ 中选取的次梯度是任意的。

注 9.1 梯度法与次梯度法的一个关键区别在于：负次梯度方向不一定是下降方向。次梯度法的步长 t_k 无法被选成保证函数值下降的形式。

注 9.2 Wolfe 给出过一个经典反例：将梯度法应用于非光滑凸函数，且步长由精确线搜索选取。该迭代方法生成的每一个迭代点处，函数都是可微的.(算法每一步选取的搜索方向均为下降方向，且函数值序列严格单调递减) 然而，尽管表面上算法似乎“避开”了函数的非光滑区域，但事实并非如此。梯度法生成的迭代序列最终会收敛到一个非最优点。

9.1.2 带约束优化的次梯度法

如果考虑带约束的优化问题

$$\min_{x\in\mathbb{E}} f(x)$$
$$\text{s.t.} x \in C$$

假设 9.1

- $f : \mathbb{E} \to (-\infty, \infty]$ 是适当闭凸函数

- $C \subseteq \mathrm{int}(\mathrm{dom}(f))$ 是非空闭凸集
- 上述问题的最优解集非空，记为 X^*，问题的最优值记为 f_{opt}

- 由于 f 是凸函数且 $C \subseteq \mathrm{int}(\mathrm{dom}(f))$，则 f 在 C 上是次可微的。
- 此外，由于 f 是闭函数，集合 $X^* = C \cap \mathrm{Lev}(f, f_{\mathrm{opt}})$ 是闭的。
- 以下我们使用 $f'(x)$ 表示 f 在 x 处的某个次梯度，即 $\partial f(x)$ 中的一个元素

Algorithm 2 投影此梯度法 (Projected Subgradient Method)

Require: 初始点 $x^0 \in C$

1: **while** $k = 0, 1, 2, \ldots$ **do**
2: 选择步长 $t_k > 0$ 和次梯度 $f'(x^k) \in \partial f(x^k)$;
3: 令 $x^{k+1} = P_C(x^k - t_k f'(x^k))$.
4: **end while**

注 9.3 对于可微情形的投影梯度法，本节的结论也全部成立

设投影次梯度法生成的序列为 $\{x^k\}_{k\geq 0}$，方法生成的函数值序列为 $\{f(x^k)\}_{k\geq 0}$。此时的函数值序列不一定是单调的，因此我们关注已达最优函数值序列，即

$$f_{\mathrm{best}}^k \equiv \min_{n=0,1,\ldots,k} f(x^n).$$

显然，序列 $\{f_{\mathrm{best}}^k\}_{k\geq 0}$ 是非增的。

投影次梯度法的分析依赖以下简单的技术性引理。

引理 9.1 (投影次梯度法的基本不等式) 在本节的假设下。令 $\{x^k\}_{k\geq 0}$ 为投影次梯度法生成的序列，则对任意 $x^* \in X^*$ 及 $k \geq 0$，有

$$\|x^{k+1} - x^*\|^2 \leq \|x^k - x^*\|^2 - 2t_k(f(x^k) - f_{\mathrm{opt}}) + t_k^2 \|f'(x^k)\|^2.$$

证明.

$$\begin{aligned}
\|x^{k+1} - x^*\|^2 &= \|P_C(x^k - t_k f'(x^k)) - P_C(x^*)\|^2 \\
&\overset{(*)}{\leq} \|x^k - t_k f'(x^k) - x^*\|^2 \\
&= \|x^k - x^*\|^2 - 2t_k \langle f'(x^k), x^k - x^* \rangle + t_k^2 \|f'(x^k)\|^2 \\
&\overset{(**)}{\leq} \|x^k - x^*\|^2 - 2t_k(f(x^k) - f_{\mathrm{opt}}) + t_k^2 \|f'(x^k)\|^2,
\end{aligned}$$

其中不等式 (*) 由正交投影算子的非扩张性得到，(**) 由次梯度不等式得到。

注 9.4 为了使得上式的右端充分小，步长 t_k 的一种选择方式是：

$$t_k = \frac{f(x^k) - f_{\mathrm{opt}}}{\|f'(x^k)\|^2}.$$

当 $f'(x^k)=0$ 时，上述公式无定义，而此时 x^k 是问题的最优解，这时我们人为定义 $t_k=1$。因此完整的公式为：

$$t_k=\begin{cases}\dfrac{f(x^k)-f_{\text{opt}}}{\|f'(x^k)\|^2}, & f'(x^k)\neq 0,\\ 1, & f'(x^k)=0.\end{cases}$$

该步长称为 Polyak 步长。

假设 9.2 存在常数 $L_f>0$，使得对所有 $g\in\partial f(x)$ 及 $x\in C$，均有 $\|g\|\leq L_f$.

注 9.5 上述假设意味着 f 在 C 上是 Lipschitz 连续的，Lipschitz 常数为 L_f，即

$$|f(x)-f(y)|\leq L_f\|x-y\| \quad \text{对所有} x,y\in C.$$

定理 9.2 (采用 Polyak 步长的投影次梯度法的性质) 假设 9.1和假设 9.2成立。令 $\{x^k\}_{k\geq 0}$ 为采用 Polyak 步长的投影次梯度法生成的序列，则

(a) $\forall k\geq 0$ 和 $x^*\in X^*$, $\|x^{k+1}-x^*\|^2\leq\|x^k-x^*\|^2$;
(b) $\lim_{k\to\infty} f(x^k)=f_{\text{opt}}$;
(c) $\forall k\geq 0$, $f_{\text{best}}^k-f_{\text{opt}}\leq\dfrac{L_f d_{X^*}(x^0)}{\sqrt{k+1}}$.

证明.

(a) 设 n 为非负整数，$x^*\in X^*$。由定理 9.1，有

$$\|x^{n+1}-x^*\|^2\leq\|x^n-x^*\|^2-2t_n(f(x^n)-f_{\text{opt}})+t_n^2\|f'(x^n)\|^2.$$

若 $f'(x^n)\neq 0$，将 $t_n=\dfrac{f(x^n)-f_{\text{opt}}}{\|f'(x^n)\|^2}$ 代入上式，可得

$$\|x^{n+1}-x^*\|^2\leq\|x^n-x^*\|^2-\frac{(f(x^n)-f_{\text{opt}})^2}{\|f'(x^n)\|^2}.$$

利用界 $\|f'(x^n)\|\leq L_f$，得到

$$\|x^{n+1}-x^*\|^2\leq\|x^n-x^*\|^2-\frac{(f(x^n)-f_{\text{opt}})^2}{L_f^2}.$$

当 $f'(x^n)=0$ 时，上述不等式同样成立 (因为此时 $f(x^n)=f_{\text{opt}}$ 且 $x^{n+1}=x^n$)。由上式可直接得到

$$\|x^{n+1}-x^*\|^2\leq\|x^n-x^*\|^2,$$

将 $n=k$ 代入即证明了 (a)。

(b) 对 $n=0,1,\ldots,k$ 求和，得

$$\frac{1}{L_f^2}\sum_{n=0}^{k}(f(x^n)-f_{\text{opt}})^2 \le \|x^0-x^*\|^2-\|x^{k+1}-x^*\|^2,$$

因此

$$\sum_{n=0}^{k}(f(x^n)-f_{\text{opt}})^2 \le L_f^2\|x^0-x^*\|^2.$$

由于上述不等式对任意 $x^*\in X^*$ 成立，故有

$$\sum_{n=0}^{k}(f(x^n)-f_{\text{opt}})^2 \le L_f^2 d_{X^*}^2(x^0),$$

这意味着 $\lim_{k\to\infty} f(x^k)=f_{\text{opt}}$。

(c) 对任意 $n=0,1,\ldots,k$，均有 $f(x^n)\ge f_{\text{best}}^k$，因此

$$\sum_{n=0}^{k}(f(x^n)-f_{\text{opt}})^2 \ge (k+1)(f_{\text{best}}^k-f_{\text{opt}})^2,$$

结合之前的结论，可得

$$(k+1)(f_{\text{best}}^k-f_{\text{opt}})^2 \le L_f^2 d_{X^*}^2(x^0),$$

因此

$$f_{\text{best}}^k-f_{\text{opt}} \le \frac{L_f d_{X^*}(x^0)}{\sqrt{k+1}}.$$

注 9.6 在上面的证明中，常数 L_f 可以替换为 $\max_{n=0,1,\ldots,k}\|f'(x^n)\|$，可以进一步的压缩右端项

注 9.7 在复杂度分析中，我们关注的问题是：要获得一个 ε-最优解，需要多少次迭代？即需要多少次迭代才能满足

$$f_{\text{best}}^k-f_{\text{opt}} \le \varepsilon.$$

由定理 9.2(c)，满足上式的一个充分条件是

$$\frac{L_f d_{X^*}(x^0)}{\sqrt{k+1}} \le \varepsilon,$$

即

$$k \ge \frac{L_f^2 d_{X^*}^2(x^0)}{\varepsilon^2}-1.$$

因此，要获得一个 ε-最优解，需要的迭代次数为 $O(1/\varepsilon^2)$ 阶. 于是有下面的定理

定理 9.3 (采用 Polyak 步长的投影次梯度法的复杂度) 假设 9.1和假设 9.2成立。设 $\{x^k\}_{k\geq 0}$ 为采用 Polyak 步长的投影次梯度法生成的序列。则对任意满足

$$k \geq \frac{L_f^2 d_{X^*}^2(x^0)}{\varepsilon^2} - 1$$

的非负整数 k，有

$$f_{\text{best}}^k - f_{\text{opt}} \leq \varepsilon.$$

定义 9.1 (Fejér 单调性) 若序列 $\{x^k\}_{k\geq 0} \subseteq \mathbb{E}$ 对集合 $S \subseteq \mathbb{E}$ 满足：

$$\|x^{k+1} - y\| \leq \|x^k - y\| \quad \text{对所有} k \geq 0 \text{和} y \in S,$$

则称该序列关于集合 S 是 Fejér 单调的。

注 9.8 由于关于集合 S 的 Fejér 单调性意味着对所有 $k \geq 0$ 和任意 $y \in S$，均有 $\|x^k - y\| \leq \|x^0 - y\|$，因此 Fejér 单调序列总是有界的。现在我们证明：若一个序列关于包含其所有极限点的集合是 Fejér 单调的，则该序列收敛。

定理 9.4 (Fejér 单调性下的收敛性) 设 $\{x^k\}_{k\geq 0} \subseteq \mathbb{E}$ 为一序列，S 为满足 $D \subseteq S$ 的集合，其中 D 是 $\{x^k\}_{k\geq 0}$ 的所有极限点构成的集合。若 $\{x^k\}_{k\geq 0}$ 关于 S 是 Fejér 单调的，则该序列收敛于 D 中的某一点。

证明. 由于 $\{x^k\}_{k\geq 0}$ 是 Fejér 单调的，因此它是有界的，从而存在极限点。设 $\tilde{x}$ 为序列 $\{x^k\}_{k\geq 0}$ 的一个极限点，即存在子序列 $\{x^{k_j}\}_{j\geq 0}$ 使得 $x^{k_j} \to \tilde{x}$。由于 $\tilde{x} \in D \subseteq S$，由关于 S 的 Fejér 单调性可知，对任意 $k \geq 0$，有

$$\|x^{k+1} - \tilde{x}\| \leq \|x^k - \tilde{x}\|.$$

因此，$\{\|x^k - \tilde{x}\|\}_{k\geq 0}$ 是一个非增且有下界 (下界为 0) 的序列，从而收敛。由于当 $j \to \infty$ 时 $\|x^{k_j} - \tilde{x}\| \to 0$，故整个序列 $\{\|x^k - \tilde{x}\|\}_{k\geq 0}$ 收敛于 0，因此当 $k \to \infty$ 时 $x^k \to \tilde{x}$。

定理 9.5 (采用 Polyak 步长的投影次梯度法生成序列的收敛性) 假设 9.1和假设 9.2成立。设 $\{x^k\}_{k\geq 0}$ 为采用 Polyak 步长的投影次梯度法生成的序列，则 $\{x^k\}_{k\geq 0}$ 收敛于 X^* 中的某一点。

证明. 由定理 9.2(a)，该序列关于 X^* 是 Fejér 单调的。因此，根据定理 9.4，要证明序列收敛于 X^* 中的某一点，只需证明序列的任何极限点必然属于 X^*(即问题的最优解)。设 $\tilde{x}$ 为序列的一个极限点，则存在子序列 $\{x^{k_j}\}_{j\geq 0}$ 收敛于 $\tilde{x}$。由 C 的闭性可知 $\tilde{x} \in C$。由定理 9.2(b)，有

$$f(x^{k_j}) \to f_{\text{opt}}, \quad j \to \infty.$$

由于 $\tilde{x} \in C \subseteq \text{int}(\text{dom}(f))$，由 f 的闭性，结合上式可得 $f(\tilde{x}) = f_{\text{opt}}$，即 $\tilde{x} \in X^*$。

9.2 用投影梯度法求解凸可行性问题

设 $S_1, S_2, \ldots, S_m \subseteq \mathbb{E}$ 为非空闭凸集，且 $S \equiv \bigcap_{i=1}^m S_i \neq \emptyset$.

凸可行性问题就是寻找交集 $\bigcap_{i=1}^m S_i$ 中一点 x 。该问题可以转化为如下优化问题：

$$\min_x \left\{ f(x) \equiv \max_{i=1,2,\ldots,m} d_{S_i}(x) \right\}.$$

注 9.9 由于交集非空，因此最优值 $f_{\text{opt}} = 0$，最优解集为 S。此外，函数 f 是 Lipschitz 连续的，Lipschitz 常数为 1。

证明. 设 $i \in \{1, 2, \ldots, m\}$，对任意 $x, y \in \mathbb{E}$，有

$$\begin{aligned} d_{S_i}(x) &= \|x - P_{S_i}(x)\| \\ &\leq \|x - P_{S_i}(y)\| \quad (\text{由} d_{S_i}(x) = \arg\min_{v \in S_i} \|x - v\|) \\ &\leq \|x - y\| + \|y - P_{S_i}(y)\| \quad (\text{三角不等式}) \\ &= \|x - y\| + d_{S_i}(y). \end{aligned}$$

因此

$$d_{S_i}(x) - d_{S_i}(y) \leq \|x - y\|.$$

交换 x 和 y 的角色，可得

$$d_{S_i}(y) - d_{S_i}(x) \leq \|x - y\|,$$

综上得到

$$|d_{S_i}(x) - d_{S_i}(y)| \leq \|x - y\|.$$

对任意 $x, y \in \mathbb{E}$，有

$$|f(x) - f(y)| = \left| \max_{i=1,2,\ldots,m} d_{S_i}(x) - \max_{i=1,2,\ldots,m} d_{S_i}(y) \right| = \left| \|v_x\|_\infty - \|v_y\|_\infty \right|,$$

其中 $v_x = (d_{S_i}(x))_{i=1}^m \in \mathbb{R}^m$，$v_y = (d_{S_i}(y))_{i=1}^m \in \mathbb{R}^m$。利用范数的三角不等式得

$$\begin{aligned} |f(x) - f(y)| &\leq \left| \|v_x\|_\infty - \|v_y\|_\infty \right| \\ &\leq \|v_x - v_y\|_\infty \\ &= \max_{i=1,2,\ldots,m} |d_{S_i}(x) - d_{S_i}(y)| \\ &\leq \|x - y\|. \end{aligned}$$

9.2.1 贪婪投影算法

我们将 Polyak 步长规则下的投影次梯度法求解凸可行性问题

- 第 k 次迭代的次梯度可通过以下步骤计算：
  (i) 计算 $i_k \in \operatorname{argmax}_{i=1,2,\dots,m} d_{S_i}(\mathbf{x}^k)$；
  (ii) 任取 $\mathbf{g}^k \in \partial d_{S_{i_k}}(\mathbf{x}^k)$。
- 次梯度可以选择为 $\mathbf{g}^k = \frac{\mathbf{x}^k - P_{S_{i_k}}(\mathbf{x}^k)}{d_{S_{i_k}}(\mathbf{x}^k)}$
- 此时更新步骤为 (利用 $f_{\text{opt}} = 0$ 和 $\|\mathbf{g}^k\| = 1$)

$$\begin{aligned}\mathbf{x}^{k+1} &= \mathbf{x}^k - \frac{d_{S_{i_k}}(\mathbf{x}^k) - f_{\text{opt}}}{\|\mathbf{g}^k\|^2} \cdot \frac{\mathbf{x}^k - P_{S_{i_k}}(\mathbf{x}^k)}{d_{S_{i_k}}(\mathbf{x}^k)} \\ &= \mathbf{x}^k - d_{S_{i_k}}(\mathbf{x}^k) \frac{\mathbf{x}^k - P_{S_{i_k}}(\mathbf{x}^k)}{d_{S_{i_k}}(\mathbf{x}^k)} \\ &= P_{S_{i_k}}(\mathbf{x}^k),\end{aligned}$$

上述算法称为贪婪投影算法，它在每次迭代中将当前迭代点 $\mathbf{x}^k$ 投影到 $S_1, S_2, \dots, S_m$ 中距离最远的集合上。算法总结如下：

Algorithm 3 贪婪投影算法 (Greedy Projection Algorithm)

Require: m 个非空闭凸集 $S_1, S_2, \dots, S_m$, 初始点 $x^0 \in C$

1: **while** $k = 0, 1, 2, \dots$ **do**

2:

$$\mathbf{x}^{k+1} = P_{S_{i_k}}(\mathbf{x}^k),$$

其中 $i_k \in \operatorname{argmax}_{i=1,2,\dots,m} d_{S_i}(\mathbf{x}^k)$。

3: **end while**

我们可以调用定理 9.2和定理 9.5，得到该算法的收敛性结果。

定理 9.6 (贪婪投影算法的收敛性) 设 $S_1, S_2, \dots, S_m \subseteq \mathbb{E}$ 为闭凸集，满足 $S \equiv \bigcap_{i=1}^m S_i \neq \emptyset$。令 $\{\mathbf{x}^k\}_{k\geq 0}$ 为贪婪投影算法生成的序列。

(a) 对任意 $k \geq 0$，有

$$\min_{n=0,1,\dots,k} \left\{ \max_{i=1,2,\dots,m} d(\mathbf{x}^n, S_i) \right\} \leq \frac{d_S(\mathbf{x}^0)}{\sqrt{k+1}}.$$

(b) 存在 $\mathbf{x}^* \in S$，使得 $\lim_{k\to+\infty} \mathbf{x}^k = \mathbf{x}^*$.

证明. 定义 $f(\mathbf{x}) \equiv \max_{i=1,2,\dots,m} d(\mathbf{x}, S_i)$，并取 $C = \mathbb{E}$。此时问题 $\min\{f(\mathbf{x}) : \mathbf{x} \in C\}$ 的最优解集为 $X^* = S$。

此时假设 9.1(f 是真、闭且凸的，$C = \mathbb{E}$ 显然是非空闭凸集，且包含在 $\text{int}(\text{dom}(f)) = \mathbb{E}$ 中；$X^* = S$ 非空) 和假设 9.2(取 $L_f = 1$) 满足, 因此，由于贪婪投影算法等价于采用 Polyak 步长规则的投影次梯度法，由定理 9.2和定理 9.5可得结论。

9.2.2 交替投影法

当 $m = 2$ 时，该算法退化为交替投影法，描述如下：

Algorithm 4 交替投影法 (Alternating Projection Method)

Require: 两个非空闭凸集 S_1, S_2, 初始点 $x^0 \in C$

1: **while** $k = 0, 1, 2, \ldots$ **do**

2:

$$\mathbf{x}^{k+1} = P_{S_2}(P_{S_1}(\mathbf{x}^k)).$$

。

3: **end while**

如果 $S_1 \cap S_2 \neq \emptyset$，由定理 9.6，交替投影法生成的序列收敛于 $S_1 \cap S_2$ 中的一点。

推论 9.7 (交替投影法的收敛性) *设 S_1, S_2 为闭凸集，满足 $S \equiv S_1 \cap S_2 \neq \emptyset$。令 $\{\mathbf{x}^k\}_{k\geq 0}$ 为以 $\mathbf{x}^0 \in S_2$ 为初始点的交替投影法生成的序列，则*

(a) *对任意 $k \geq 0$，*

$$\min_{n=0,1,\ldots,k} d(\mathbf{x}^n, S_1) \leq \frac{d_S(\mathbf{x}^0)}{\sqrt{k+1}};$$

(b) *存在 $\mathbf{x}^* \in S$，使得 $\lim_{k\to+\infty} \mathbf{x}^k = \mathbf{x}^*$。*

9.2.3 线性可行性问题的求解

例 9.1 (线性可行性问题的求解) *考虑如下线性等式与不等式系统：*

$$\mathbf{Ax} = \mathbf{b},\ \mathbf{x} \geq 0,$$

其中 $\mathbf{A} \in \mathbb{R}^{m\times n}$ 为满行秩矩阵，$\mathbf{b} \in \mathbb{R}^m$。这是线性规划问题可行集的标准形式之一。求解该问题的一种方法是使用交替投影法。定义

$$S_1 = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{Ax} = \mathbf{b}\}, \quad S_2 = \mathbb{R}^n_+.$$

S_1 和 S_2 上的投影有如下的解析表达式：

$$P_{S_1}(\mathbf{x}) = \mathbf{x} - \mathbf{A}^T(\mathbf{AA}^T)^{-1}(\mathbf{Ax} - \mathbf{b}), \quad P_{S_2}(\mathbf{x}) = [\mathbf{x}]_+.$$

求解上述问题的交替投影法形式如下：

Algorithm 5 求解线性可行性问题的交替投影法

- **初始化：**任选 $\mathbf{x}^0 \in \mathbb{R}^n_+$。
- **迭代步骤**（$k \geq 0$）：

$$\mathbf{x}^{k+1} = \left[\mathbf{x}^k - \mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^{-1}(\mathbf{A}\mathbf{x}^k - \mathbf{b})\right]_+.$$

注 9.10 上述方案的迭代步骤需要计算 $(\mathbf{A}\mathbf{A}^T)^{-1}(\mathbf{A}\mathbf{x}^k - \mathbf{b})$，这涉及矩阵 $\mathbf{A}\mathbf{A}^T$ 的计算以及线性系统 $(\mathbf{A}\mathbf{A}^T)\mathbf{z} = \mathbf{A}\mathbf{x}^k - \mathbf{b}$ 的求解。当这些计算成本过高，此时可以采用另一种投影算法，避免求解线性系统：

记 $\mathbf{A}$ 的第 i 行为 $\mathbf{a}_i^T$，并定义

$$T_i = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{a}_i^T\mathbf{x} = b_i\},\ i = 1, 2, \ldots, m, \quad T_{m+1} = \mathbb{R}^n_+,$$

则求解上述问题等价于寻找交集 $\bigcap_{i=1}^{m+1} T_i$ 中的一点。因为

$$P_{T_i}(\mathbf{x}) = \mathbf{x} - \frac{\mathbf{a}_i^T\mathbf{x} - b_i}{\|\mathbf{a}_i\|_2^2}\mathbf{a}_i,\ i = 1, 2, \ldots, m.$$

所以

$$d_{T_i}(\mathbf{x}) = \|\mathbf{x} - P_{T_i}(\mathbf{x})\| = \frac{|\mathbf{a}_i^T\mathbf{x} - b_i|}{\|\mathbf{a}_i\|_2}.$$

我们现在可以调用贪婪投影法，其形式如下：

Algorithm 6 求解线性可行性问题的贪婪投影法

- **初始化：**任选 $\mathbf{x}^0 \in \mathbb{E}$。
- **迭代步骤**（$k = 0, 1, \ldots$）：
  1. 计算 $i_k \in \operatorname{argmax}_{i=1,2,\ldots,m} \frac{|\mathbf{a}_i^T\mathbf{x}^k - b_i|}{\|\mathbf{a}_i\|_2}$。
  2. 若 $\frac{|\mathbf{a}_{i_k}^T\mathbf{x}^k - b_{i_k}|}{\|\mathbf{a}_{i_k}\|_2} > \|\mathbf{x}^k - [\mathbf{x}^k]_+\|_2$，则

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \frac{\mathbf{a}_{i_k}^T\mathbf{x}^k - b_{i_k}}{\|\mathbf{a}_{i_k}\|_2^2}\mathbf{a}_{i_k};$$

否则，

$$\mathbf{x}^{k+1} = [\mathbf{x}^k]_+.$$

此时贪婪投影法比交替投影法计算上更简单。

10 交替方向乘子法 (Alternating Direction Method of Multipliers / ADMM)

10.1 增广拉格朗日法（The Augmented Lagrangian Method / ALM）

考虑问题

$$H_{\text{opt}} = \min\{H(x,z) \equiv h_1(x) + h_2(z) : Ax + Bz = c\}, \tag{34}$$

其中 $A \in \mathbb{R}^{m\times n}$，$B \in \mathbb{R}^{m\times p}$，$c \in \mathbb{R}^m$。设 h_1 和 h_2 是适当闭凸函数。构造拉格朗日函数：

$$L(x,z;y) = h_1(x) + h_2(z) + \langle y, Ax + Bz - c\rangle.$$

因此对偶目标函数为

$$\begin{aligned} q(y) &= \min_{x\in\mathbb{R}^n, z\in\mathbb{R}^p} \{h_1(x) + h_2(z) + \langle y, Ax + Bz - c\rangle\} \\ &= -h_1^*(-A^Ty) - h_2^*(-B^Ty) - \langle c, y\rangle, \end{aligned}$$

对应的对偶问题为

$$q_{\text{opt}} = \max_{y\in\mathbb{R}^m} \left\{-h_1^*(-A^Ty) - h_2^*(-B^Ty) - \langle c, y\rangle\right\}, \tag{35}$$

或等价的极小化形式

$$\min_{y\in\mathbb{R}^m} \left\{h_1^*(-A^Ty) + h_2^*(-B^Ty) + \langle c, y\rangle\right\}.$$

将邻近点方法应用于上述对偶问题，其更新步骤为（$\rho > 0$ 为给定常数）

$$y^{k+1} = \arg\min_{y\in\mathbb{R}^m} \left\{h_1^*(-A^Ty) + h_2^*(-B^Ty) + \langle c, y\rangle + \frac{1}{2\rho}\|y - y^k\|^2\right\}.$$

由最优性条件可知，上述成立当且仅当

$$0 \in -A\partial h_1^*(-A^Ty^{k+1}) - B\partial h_2^*(-B^Ty^{k+1}) + c + \frac{1}{\rho}(y^{k+1} - y^k).$$

利用共轭次梯度定理，可知 y^{k+1} 满足上式当且仅当

$$y^{k+1} = y^k + \rho(Ax^{k+1} + Bz^{k+1} - c),$$

其中 x^{k+1} 和 z^{k+1} 满足

$$x^{k+1} \in \arg\min_{x\in\mathbb{R}^n} \left\{\langle A^Ty^{k+1}, x\rangle + h_1(x)\right\},$$

$$z^{k+1} \in \arg\min_{z\in\mathbb{R}^p} \left\{ \langle B^T y^{k+1}, z\rangle + h_2(z) \right\}.$$

将 y^{k+1} 的更新式代入上述条件，可得 y^{k+1} 满足原条件当且仅当

$$y^{k+1} = y^k + \rho(Ax^{k+1} + Bz^{k+1} - c),$$

$$x^{k+1} \in \arg\min_{x\in\mathbb{R}^n} \left\{ \langle A^T(y^k + \rho(Ax^{k+1} + Bz^{k+1} - c)), x\rangle + h_1(x) \right\},$$

$$z^{k+1} \in \arg\min_{z\in\mathbb{R}^p} \left\{ \langle B^T(y^k + \rho(Ax^{k+1} + Bz^{k+1} - c)), z\rangle + h_2(z) \right\}.$$

利用 h_1 和 h_2 的适当凸性，结合最优性条件，上述条件等价于

$$y^{k+1} = y^k + \rho(Ax^{k+1} + Bz^{k+1} - c),$$

$$0 \in A^T(y^k + \rho(Ax^{k+1} + Bz^{k+1} - c)) + \partial h_1(x^{k+1}),$$

$$0 \in B^T(y^k + \rho(Ax^{k+1} + Bz^{k+1} - c)) + \partial h_2(z^{k+1}).$$

上述两条件成立当且仅当 (x^{k+1}, z^{k+1}) 是函数

$$\tilde{H}(x,z) \equiv h_1(x) + h_2(z) + \frac{\rho}{2}\left\| Ax + Bz - c + \frac{1}{\rho}y^k \right\|^2$$

的极小点，即全局极小点。因此，我们给出了对偶邻近点方法的原始形式，即增广拉格朗日方法。**上述论证说明，对对偶问题做邻近方法得到了增广拉格朗日方法。**

Algorithm 7 增广拉格朗日方法（ALM）

- **初始化：**任选 $y^0 \in \mathbb{R}^m$，$\rho > 0$。
- **迭代步骤**（$k = 0, 1, \ldots$）：
  1. 计算

$$(x^{k+1}, z^{k+1}) = \arg\min_{x,z} \left\{ h_1(x) + h_2(z) + \frac{\rho}{2}\left\| Ax + Bz - c + \frac{1}{\rho}y^k \right\|^2 \right\}.$$

  2. 更新对偶变量

$$y^{k+1} = y^k + \rho\left(Ax^{k+1} + Bz^{k+1} - c\right).$$

10.2 交替方向乘子法（Alternating Direction Method of Multipliers / ADMM）

增广拉格朗日方法通常不是一种可直接实现的方法，因为子问题的求解难度与原问题相当，主要的困难在于变量 x 和 z 之间的耦合项，形式为 $\rho(x^T A^T Bz)$。交替方向乘子法（ADMM）为解决这一问题，先对 x 极小化目标函数，再对 z 极小化。

Algorithm 8 交替方向乘子法（ADMM）

- **初始化：** $x^0 \in \mathbb{R}^n$, $z^0 \in \mathbb{R}^p$, $y^0 \in \mathbb{R}^m$, $\rho > 0$.
- **迭代步骤**（$k = 0, 1, \ldots$）：
  1. 对 x 进行更新：

$$x^{k+1} \in \arg\min_x \left\{ h_1(x) + \frac{\rho}{2} \left\| Ax + Bz^k - c + \frac{1}{\rho} y^k \right\|^2 \right\};$$

  2. 对 z 进行更新：

$$z^{k+1} \in \arg\min_z \left\{ h_2(z) + \frac{\rho}{2} \left\| Ax^{k+1} + Bz - c + \frac{1}{\rho} y^k \right\|^2 \right\};$$

  3. 更新对偶变量：

$$y^{k+1} = y^k + \rho \left(Ax^{k+1} + Bz^{k+1} - c \right).$$

接下来我们分析一种比 ADMM 更一般的方法，在该方法中，我们在前两个步骤的目标函数中加入邻近项。假设给定两个半正定矩阵 $G \in \mathbb{S}_+^n, Q \in \mathbb{S}_+^p$，并定义 $\|x\|_G^2 = x^T G x$, $\|x\|_Q^2 = x^T Q x$。

Algorithm 9 带邻近项的交替方向乘子法（AD-PMM）

- **初始化：** $x^0 \in \mathbb{R}^n$, $z^0 \in \mathbb{R}^p$, $y^0 \in \mathbb{R}^m$, $\rho > 0$.
- **迭代步骤**（$k = 0, 1, \ldots$）：
  1. 对 x 进行更新：

$$x^{k+1} \in \arg\min_{x \in \mathbb{R}^n} \left\{ h_1(x) + \frac{\rho}{2} \left\| Ax + Bz^k - c + \frac{1}{\rho} y^k \right\|^2 + \frac{1}{2} \|x - x^k\|_G^2 \right\};$$

  2. 对 z 进行更新：

$$z^{k+1} \in \arg\min_{z \in \mathbb{R}^p} \left\{ h_2(z) + \frac{\rho}{2} \left\| Ax^{k+1} + Bz - c + \frac{1}{\rho} y^k \right\|^2 + \frac{1}{2} \|z - z^k\|_Q^2 \right\};$$

  3. 更新对偶变量：

$$y^{k+1} = y^k + \rho \left(Ax^{k+1} + Bz^{k+1} - c \right).$$

引入 AD-PMM 的一个重要动机是，通过选择合适的 G 和 Q，可以极大简化 ADMM 步骤中的极小化问题。选择 $G = \alpha I - \rho A^T A$（其中 $\alpha \geq \rho \lambda_{\max}(A^T A)$），$Q = \beta I - \rho B^T B$

（其中 $\beta \geq \rho\lambda_{\max}(B^TB)$），此时 $G, Q \in \mathbb{S}_+^n$，x 步需要极小化的函数可简化为：

$$\begin{aligned}
&h_1(x) + \frac{\rho}{2}\left\|Ax + Bz^k - c + \frac{1}{\rho}y^k\right\|^2 + \frac{1}{2}\|x - x^k\|_G^2 \\
=&h_1(x) + \frac{\rho}{2}\left\|A(x - x^k) + Ax^k + Bz^k - c + \frac{1}{\rho}y^k\right\|^2 + \frac{1}{2}\|x - x^k\|_G^2 \\
=&h_1(x) + \frac{\rho}{2}\left\|A(x - x^k)\right\|^2 + \left\langle \rho Ax, Ax^k + Bz^k - c + \frac{1}{\rho}y^k \right\rangle \\
&+ \frac{\alpha}{2}\|x - x^k\|^2 - \frac{\rho}{2}\left\|A(x - x^k)\right\|^2 + \text{常数} \\
=&h_1(x) + \rho\left\langle Ax, Ax^k + Bz^k - c + \frac{1}{\rho}y^k \right\rangle + \frac{\alpha}{2}\|x - x^k\|^2 + \text{常数}.
\end{aligned}$$

因此，AD-PMM 的步骤 1 等价于：

$$x^{k+1} = \arg\min_{x\in\mathbb{R}^n}\left\{h_1(x) + \rho\left\langle Ax, Ax^k + Bz^k - c + \frac{1}{\rho}y^k \right\rangle + \frac{\alpha}{2}\|x - x^k\|^2\right\}.$$

同理，步骤 2 等价于：

$$z^{k+1} = \arg\min_{z\in\mathbb{R}^p}\left\{h_2(z) + \rho\left\langle Bz, Ax^{k+1} + Bz^k - c + \frac{1}{\rho}y^k \right\rangle + \frac{\beta}{2}\|z - z^k\|^2\right\}.$$

上述更新公式中的目标函数，是通过对 ADMM 步骤 1 和 2 中的二次项进行线性化，并添加邻近项得到的，因此该方法被称为交替方向线性化邻近乘子法（AD-LPMM）。我们也可以用邻近算子来表示这些更新公式

Algorithm 10 交替方向线性化邻近乘子法（AD-LPMM）

- **初始化：** $x^0 \in \mathbb{R}^n, z^0 \in \mathbb{R}^p, y^0 \in \mathbb{R}^m, \rho > 0, \alpha \geq \rho\lambda_{\max}(A^TA), \beta \geq \rho\lambda_{\max}(B^TB)$.
- **迭代步骤**（$k = 0, 1, \ldots$）：
  1. 对 x 进行更新：

$$x^{k+1} = \text{prox}_{\frac{1}{\alpha}h_1}\left[x^k - \frac{\rho}{\alpha}A^T\left(Ax^k + Bz^k - c + \frac{1}{\rho}y^k\right)\right];$$

  2. 对 z 进行更新：

$$z^{k+1} = \text{prox}_{\frac{1}{\beta}h_2}\left[z^k - \frac{\rho}{\beta}B^T\left(Ax^{k+1} + Bz^k - c + \frac{1}{\rho}y^k\right)\right];$$

  3. 更新对偶变量：

$$y^{k+1} = y^k + \rho\left(Ax^{k+1} + Bz^{k+1} - c\right).$$

10.3 ADMM 的收敛性

在本节对 AD-PMM 方法进行收敛速率分析。注意，ADMM 和 AD-LPMM 都是 AD-PMM 的特例。

假设 10.1

- (A) $h_1 : \mathbb{R}^n \to (-\infty, \infty]$ 和 $h_2 : \mathbb{R}^p \to (-\infty, \infty]$ 是适当闭凸函数。
- (B) $A \in \mathbb{R}^{m\times n}$, $B \in \mathbb{R}^{m\times p}$, $c \in \mathbb{R}^m$, $\rho > 0$。
- (C) $G \in \mathbb{S}^n_+$, $Q \in \mathbb{S}^p_+$。
- (D) 对任意 $a \in \mathbb{R}^n, b \in \mathbb{R}^p$，问题

$$\min_{x\in\mathbb{R}^n} \left\{ h_1(x) + \frac{\rho}{2}\|Ax\|^2 + \frac{1}{2}\|x\|_G^2 + \langle a, x\rangle \right\}$$

与

$$\min_{z\in\mathbb{R}^p} \left\{ h_2(z) + \frac{\rho}{2}\|Bz\|^2 + \frac{1}{2}\|z\|_Q^2 + \langle b, z\rangle \right\}$$

的最优解集非空。

- (E) 存在 $\hat{x} \in \mathrm{ri}(\mathrm{dom}(h_1))$ 和 $\hat{z} \in \mathrm{ri}(\mathrm{dom}(h_2))$，使得 $A\hat{x} + B\hat{z} = c$。
- (F) 问题(34)的最优解集非空，记为 X^*，对应的最优值为 H_{opt}。

定理 10.1 上述假设成立时，令 H_{opt} 和 q_{opt} 分别为原始问题(34)和对偶问题(35)的最优值，则 $H_{\text{opt}} = q_{\text{opt}}$，且对偶问题(35)存在最优解。

定理 10.2 (AD-PMM 的 $O(1/k)$ 收敛速率) 上述假设成立时，设 $\{x^k, z^k\}_{k\geq 0}$ 为 AD-PMM 求解问题(34)生成的序列，(x^*, z^*) 为问题(34)的最优解，y^* 为对偶问题(35)的最优解。设 $\gamma > 0$ 为任意满足 $\gamma \geq 2\|y^*\|$ 的常数，则对所有 $n \geq 0$，有

$$H(x^{(n)}, z^{(n)}) - H_{\text{opt}} \leq \frac{\|x^* - x^0\|_G^2 + \|z^* - z^0\|_C^2 + \frac{1}{\rho}(\gamma + \|y^0\|)^2}{2(n+1)},$$

$$\|Ax^{(n)} + Bz^{(n)} - c\| \leq \frac{\|x^* - x^0\|_G^2 + \|z^* - z^0\|_C^2 + \frac{1}{\rho}(\gamma + \|y^0\|)^2}{\gamma(n+1)},$$

其中 $C = \rho B^T B + Q$，且

$$x^{(n)} = \frac{1}{n+1}\sum_{k=0}^{n} x^{k+1}, \quad z^{(n)} = \frac{1}{n+1}\sum_{k=0}^{n} z^{k+1}.$$

证明.

- 由费马最优性条件及 AD-PMM 的更新步骤，可得 x^{k+1} 和 z^{k+1} 满足

$$-\rho A^T\left(Ax^{k+1} + Bz^k - c + \frac{1}{\rho}y^k\right) - G(x^{k+1} - x^k) \in \partial h_1(x^{k+1}),$$

$$-\rho B^T\left(Ax^{k+1} + Bz^k - c + \frac{1}{\rho}y^k\right) - Q(z^{k+1} - z^k) \in \partial h_2(z^{k+1}).$$

我们使用如下记号：

$$\tilde{x}^k = x^{k+1}, \quad \tilde{z}^k = z^{k+1}, \quad \tilde{y}^k = y^k + \rho(Ax^{k+1} + Bz^k - c).$$

利用上述两式、次梯度不等式及上述记号，对任意 $x \in \mathrm{dom}(h_1)$ 和 $z \in \mathrm{dom}(h_2)$，有

$$h_1(x) - h_1(\tilde{x}^k) + \left\langle \rho A^T \left(A\tilde{x}^k + Bz^k - c + \frac{1}{\rho} y^k \right) + G(\tilde{x}^k - x^k), x - \tilde{x}^k \right\rangle \geq 0,$$

$$h_2(z) - h_2(\tilde{z}^k) + \left\langle \rho B^T \left(Ax^k + B\tilde{z}^k - c + \frac{1}{\rho} y^k \right) + Q(\tilde{z}^k - z^k), z - \tilde{z}^k \right\rangle \geq 0.$$

利用 $\tilde{y}^k$ 的定义，上述两个不等式可改写为

$$h_1(x) - h_1(\tilde{x}^k) + \left\langle A^T \tilde{y}^k + G(\tilde{x}^k - x^k), x - \tilde{x}^k \right\rangle \geq 0,$$

$$h_2(z) - h_2(\tilde{z}^k) + \left\langle B^T \tilde{y}^k + (\rho B^T B + Q)(\tilde{z}^k - z^k), z - \tilde{z}^k \right\rangle \geq 0.$$

将上述两个不等式相加，并利用恒等式

$$y^{k+1} - y^k = \rho(A\tilde{x}^k + B\tilde{z}^k - c),$$

可得对任意 $x \in \mathrm{dom}(h_1)$, $z \in \mathrm{dom}(h_2)$ 和 $y \in \mathbb{R}^m$，有

$$H(x,z) - H(\tilde{x}^k, \tilde{z}^k) + \left\langle \begin{pmatrix} x - \tilde{x}^k \\ z - \tilde{z}^k \\ y - \tilde{y}^k \end{pmatrix}, \begin{pmatrix} A^T \tilde{y}^k \\ B^T \tilde{y}^k \\ -A\tilde{x}^k - B\tilde{z}^k + c \end{pmatrix} - \begin{pmatrix} G(x^k - \tilde{x}^k) \\ C(z^k - \tilde{z}^k) \\ \frac{1}{\rho}(y^k - y^{k+1}) \end{pmatrix} \right\rangle \geq 0,$$

其中 $C = \rho B^T B + Q$。

- 我们将使用对任意半正定矩阵 P 成立的恒等式：

$$(a-b)^T P(c-d) = \frac{1}{2}\left(\|a-d\|_P^2 - \|a-c\|_P^2 + \|b-c\|_P^2 - \|b-d\|_P^2 \right).$$

利用上述恒等式，可得

$$(x-\tilde{x}^k)^T G(x^k - \tilde{x}^k) = \frac{1}{2}\left(\|x-\tilde{x}^k\|_G^2 - \|x-x^k\|_G^2 + \|\tilde{x}^k - x^k\|_G^2 \right) \geq \frac{1}{2}\|x-\tilde{x}^k\|_G^2 - \frac{1}{2}\|x-x^k\|_G^2,$$

以及

$$(z-\tilde{z}^k)^T C(z^k - \tilde{z}^k) = \frac{1}{2}\|z-\tilde{z}^k\|_C^2 - \frac{1}{2}\|z-z^k\|_C^2 + \frac{1}{2}\|z^k - \tilde{z}^k\|_C^2,$$

还有

$$\begin{aligned} 2(y-\tilde{y}^k)^T(y^k - y^{k+1}) &= \|y-y^{k+1}\|^2 - \|y-y^k\|^2 + \|\tilde{y}^k - y^k\|^2 - \|\tilde{y}^k - y^{k+1}\|^2 \\ &= \|y-y^{k+1}\|^2 - \|y-y^k\|^2 + \rho^2\|A\tilde{x}^k + Bz^k - c\|^2 - \rho^2\|B(z^k - \tilde{z}^k)\|^2. \end{aligned}$$

因此

$$\frac{1}{\rho}(y-\tilde{y}^k)^T(y^k - y^{k+1}) \geq \frac{1}{2\rho}\left(\|y-y^{k+1}\|^2 - \|y-y^k\|^2 \right) - \frac{\rho}{2}\|B(z^k - \tilde{z}^k)\|^2.$$

记

$$H = \begin{pmatrix} G & 0 & 0 \\ 0 & C & 0 \\ 0 & 0 & \frac{1}{\rho} I \end{pmatrix},$$

以及

$$w = \begin{pmatrix} x \\ z \\ y \end{pmatrix}, \quad w^k = \begin{pmatrix} x^k \\ z^k \\ y^k \end{pmatrix}, \quad \tilde{w}^k = \begin{pmatrix} \tilde{x}^k \\ \tilde{z}^k \\ \tilde{y}^k \end{pmatrix},$$

结合上述不等式可得

$$\left\langle \begin{pmatrix} x - \tilde{x}^k \\ z - \tilde{z}^k \\ y - \tilde{y}^k \end{pmatrix}, \begin{pmatrix} G(x^k - \tilde{x}^k) \\ C(z^k - \tilde{z}^k) \\ \frac{1}{\rho}(y^k - y^{k+1}) \end{pmatrix} \right\rangle \geq \frac{1}{2}\|w - w^{k+1}\|_H^2 - \frac{1}{2}\|w - w^k\|_H^2.$$

- 将上述不等式与之前的不等式结合，对任意 $x \in \mathrm{dom}(h_1)$, $z \in \mathrm{dom}(h_2)$ 和 $y \in \mathbb{R}^m$，有

$$H(x,z) - H(\tilde{x}^k, \tilde{z}^k) + \langle w - \tilde{w}^k, F\tilde{w}^k + \tilde{c} \rangle \geq \frac{1}{2}\|w - w^{k+1}\|_H^2 - \frac{1}{2}\|w - w^k\|_H^2,$$

其中

$$F = \begin{pmatrix} 0 & 0 & A^T \\ 0 & 0 & B^T \\ -A & -B & 0 \end{pmatrix}, \quad \tilde{c} = \begin{pmatrix} 0 \\ 0 \\ c \end{pmatrix}.$$

注意到

$$\langle w - \tilde{w}^k, F\tilde{w}^k + \tilde{c} \rangle = \langle w - \tilde{w}^k, Fw + \tilde{c} \rangle,$$

因此上式可改写为

$$H(x,z) - H(\tilde{x}^k, \tilde{z}^k) + \langle w - \tilde{w}^k, Fw + \tilde{c} \rangle \geq \frac{1}{2}\|w - w^{k+1}\|_H^2 - \frac{1}{2}\|w - w^k\|_H^2.$$

对 $k = 0, 1, \ldots, n$ 求和，可得

$$(n+1)H(x,z) - \sum_{k=0}^{n} H(\tilde{x}^k, \tilde{z}^k) + \left\langle (n+1)w - \sum_{k=0}^{n} \tilde{w}^k, Fw + \tilde{c} \right\rangle \geq -\frac{1}{2}\|w - w^0\|_H^2.$$

定义

$$w^{(n)} = \frac{1}{n+1}\sum_{k=0}^{n} \tilde{w}^k, \quad x^{(n)} = \frac{1}{n+1}\sum_{k=0}^{n} x^{k+1}, \quad z^{(n)} = \frac{1}{n+1}\sum_{k=0}^{n} z^{k+1},$$

利用 H 的凸性，可得

$$H(x,z) - H(x^{(n)}, z^{(n)}) + \langle w - w^{(n)}, Fw + \tilde{c} \rangle + \frac{1}{2(n+1)}\|w - w^0\|_H^2 \geq 0.$$

对任意 $x \in \mathrm{dom}(h_1)$ 和 $z \in \mathrm{dom}(h_2)$，上式可改写为

$$H(x^{(n)}, z^{(n)}) - H(x, z) + \langle w^{(n)} - w, Fw^{(n)} + \tilde{c} \rangle \leq \frac{1}{2(n+1)} \|w - w^0\|_H^2.$$

设 (x^*, z^*) 为问题(34)的最优解，则 $H(x^*, z^*) = H_{\text{opt}}$ 且 $Ax^* + Bz^* = c$。将 $x = x^*$，$z = z^*$ 代入上式，整理可得

$$H(x^{(n)}, z^{(n)}) - H_{\text{opt}} + \langle y, Ax^{(n)} + Bz^{(n)} - c \rangle \leq \frac{\|x^* - x^0\|_G^2 + \|z^* - z^0\|_C^2 + \frac{1}{\rho}\|y - y^0\|^2}{2(n+1)}.$$

由于上式对任意 $y \in \mathbb{R}^m$ 成立，两边在 $y \in B[0, \gamma]$ 上取最大值，可得

$$H(x^{(n)}, z^{(n)}) - H_{\text{opt}} + \gamma \|Ax^{(n)} + Bz^{(n)} - c\| \leq \frac{\|x^* - x^0\|_G^2 + \|z^* - z^0\|_C^2 + \frac{1}{\rho}(\gamma + \|y^0\|)^2}{2(n+1)}.$$

结合强对偶性，定理得证。

10.4 一个特殊格式的问题

11 信赖域方法

信赖域方法其基本思想与牛顿法一致：在点 x 附近，我们用二次模型来逼近函数 f：

$$f(x+s) \approx m_x(s) = f(x) + \langle \nabla f(x), s \rangle + \frac{1}{2}\langle H_x(s), s \rangle.$$

这里，H_x 可以是任意自伴线性映射，通常选择 H_x 为 f 的 Hessian。在迭代点 x_k 处，定义

$$m_k(s) = f(x_k) + \langle \nabla f(x_k), s \rangle + \frac{1}{2}\langle H_k(s), s \rangle$$

其中 H_k 是一个自伴线性映射，考虑信赖域子问题：

$$\min_s m_k(s) \quad \text{s.t.} \quad \|s\| \leq \Delta_k,$$

其中 Δ_k 是第 k 次迭代的信赖域半径。如果 s_k 是信赖法子问题的解，则下一步迭代点为 $x_k^+ = x_k + s_k$。

Algorithm 11 信赖域方法 (TR)

参数: 最大信赖域半径 $\bar{\Delta} > 0$，接受阈值 $\rho' \in (0, 1/4)$

输入: 初始点 x_0，初始半径 $\Delta_0 \in (0, \bar{\Delta}]$

初始化: $k = 0$

for $k = 0, 1, 2, \ldots$

- 选取映射 H_k，构造二次模型

$$m_k(s) = f(x_k) + \langle \nabla f(x_k), s \rangle + \frac{1}{2}\langle H_k(s), s \rangle$$

- 近似求解信赖域子问题，得到试探步 s_k

$$\min_s m_k(s) \quad \text{s.t.} \quad \|s\| \le \Delta_k,$$

- 计算试探迭代点 $x_k^+ = x_k + s_k$
- 计算实际下降与模型下降的比值

$$\rho_k = \frac{f(x_k) - f(x_k^+)}{m_k(0) - m_k(s_k)}$$

- 更新迭代点

$$x_{k+1} = \begin{cases} x_k^+ & \rho_k > \rho' (\textbf{成功步}) \\ x_k & \rho_k \le \rho' (\textbf{失败步}) \end{cases}$$

- 更新信赖域半径

$$\Delta_{k+1} = \begin{cases} \frac{1}{4}\Delta_k & \rho_k < \frac{1}{4} \\ \min(2\Delta_k, \bar{\Delta}) & \rho_k > \frac{3}{4} \text{ 且} \|s_k\| = \Delta_k \\ \Delta_k & \text{其他} \end{cases}$$

注 11.1

- 更现实的目标是找到 x_k，满足

$$\|\nabla f(x)\| \le \varepsilon_g \quad \text{且} \quad \nabla^2 f(x) \succeq -\varepsilon_H I (\lambda_{min}(\nabla^2 f(x)) > \varepsilon_H) \tag{36}$$

- 如果只关心一阶最优性条件，ε_H 也可以取为无穷大 (也就是说忽略第二个条件)。
- 本章的主要目标之一是证明：在合适的假设条件下，无论算法如何初始化，算法都能在有限次迭代内找到满足上述条件的点。
- 需要先考虑的问题是
  - 如何选取映射 H_k
  - 信赖域子问题如何求解以及求解精度
  - f 的正则性条件

11.1 映射 H_k 的选择

模型 m_{x_k} 由映射 H_k 决定。映射越简单，信赖域子问题就越容易求解。选择 H_k 时，我们需要在模型精度、计算效率和实现便利性之间取得平衡。

考虑到我们的目标是 $\|\nabla f(x)\| \le \varepsilon_g,\ \nabla^2 f(x) \succeq -\varepsilon_H I,$，我们引入以下要求：

- 当迭代点的梯度较大时，条件会非常宽松。本质上，这类迭代的核心目标是降低梯度范数，仅用一阶精度的模型即可实现:

  假设 11.1 (条件 A1) 对所有满足 $\|\nabla f(x_k)\| > \varepsilon_g$ 的迭代 k，我们要求：

  1. H_k 是线性的，即
  $$\forall s, \alpha \ge 0, \quad H_k(\alpha s) = \alpha H_k(s);$$
  2. H_k 是一致有界的，即存在与 k 无关的常数 $c_0 \ge 0$，使得
  $$\forall s, \quad |\langle s, H_k(s)\rangle| \le c_0 \|s\|^2.$$

  注 11.2

  - 一个选择是 $H_k = L \cdot \mathrm{Id}$（其中 $L > 0$）。这种形式简单、计算成本低，且信赖域子问题有闭式解。但该模型完全不包含二阶信息，可能会减慢收敛速度。
  - 也可以通过有限差分近似 Hessian 来构造径向线性的 H_k
  - 也可以直接使用 f 的 Hessian 作为 H_k。

- 当迭代点的梯度较小，且我们希望近似满足二阶必要最优性条件（即 $\varepsilon_H < \infty$）时，模型需要至少具有近似二阶精度。

  假设 11.2 (A2) 对所有满足 $\|\nabla f(x_k)\| \le \varepsilon_g$ 的迭代 k，我们要求

  1. H_k 是线性自伴映射。
  2. 存在与 k 无关的常数 $c_1 \ge 0$，使得
  $$\|\nabla^2 f(x_k) - H_k\| \le \frac{c_1 \Delta_k}{3},$$
  其中 $\|\cdot\|$ 表示自伴映射的算子范数，即其特征值的最大绝对值。

  注 11.3

  - 下文的收敛结果保证，H_k 最终几乎是半正定的。这一结论只有在 H_k 与 $\nabla^2 f(x_k)$ 的算子范数距离足够小时才有意义。
  - 当 $H_k = \nabla^2 (f \circ R_{x_k})(0) = \nabla^2 f(x_k)$. 此时 A2 成立，且常数 $c_1 = 0$。

11.2 子问题求解要求

近似求解信赖域子问题是每次迭代中最关键的一步。这里先给出子问题求解的最低要求。

- 针对一阶条件：

  假设 11.3 (A3) 存在常数 $c_2 > 0$，使得对所有满足 $\|\nabla f(x_k)\| > \varepsilon_g$ 的迭代 k，步长 s_k 满足

  $$m_k(0) - m_k(s_k) \geq c_2 \min\left(\Delta_k, \frac{\|\nabla f(x_k)\|}{c_0}\right) \|\nabla f(x_k)\|,$$

  其中 c_0 是 A1 中的常数。

  A3 可以通过以下方式得到

  引理 11.1 设 $g_k = \nabla f(x_k)$。柯西点是切向量 $s_k^C = -t\nabla f(x_k)$（$t \geq 0$），且在约束 $\|s_k^C\| \leq \Delta_k$ 下使 $m_k(s_k^C)$ 最小。在 A1 下，最优的 t 可显式地表达为：

  $$t = \begin{cases} \min\left(\frac{\|g_k\|^2}{\langle g_k, H_k(g_k)\rangle_{x_k}}, \frac{\Delta_k}{\|g_k\|}\right) & \text{若} \langle, H_k(g_k)\rangle_{x_k} > 0, \\ [6pt]\frac{\Delta_k}{\|g_k\|} & \text{其他.} \end{cases}$$

  此外，取 $s_k = s_k^C$ 时，则 A3 成立，且 $c_2 = \frac{1}{2}$。

- 当梯度较小且 $\varepsilon_H < \infty$ 时，需要关注二阶最优性条件:

  假设 11.4 (A4) 存在常数 $c_3 > 0$，使得对所有满足 $\|\nabla f(x_k)\| \leq \varepsilon_g$ 且 $\lambda_{\min}(H_k) < -\varepsilon_H$ 的迭代 k，步长 s_k 满足

  $$m_k(0) - m_k(s_k) \geq c_3 \Delta_k^2 \varepsilon_H.$$

  (注意: 由 A2，H_k 的特征值均为实数)

  A4 可以通过以下方式得到

  引理 11.2 在 A2 下，若 $\lambda_{\min}(H_k) < -\varepsilon_H$，则存在切向量 $u \in T_{x_k}\mathcal{M}$，满足

  $$\|u\| = 1, \quad \langle \nabla f(x_k), u\rangle \leq 0, \quad \langle u, H_k(u)\rangle < -\varepsilon_H.$$

  在 RTR 中取 $s_k = \Delta_k u$（称为特征步）时，A 6.4 成立，且 $c_3 = \frac{1}{2}$。

推论 11.3 若每次迭代中 H_k 都是线性自伴映射，则在每次迭代中取 s_k 为信赖域子问题的全局极小值点，可同时满足 A3 和 A4，且 $c_2 = c_3 = \frac{1}{2}$。类似地，若 s_k 能达到最优模型下降的至少 $\alpha \in (0, 1)$ 倍，则条件成立，且 $c_2 = c_3 = \frac{\alpha}{2}$。

11.3 正则化条件

假设 11.5 (A5) 存在常数 $f_{\text{low}} \in \mathbb{R}$，使得对 $\forall k \in \mathbb{N}^+$，均有 $f(x_k) \geq f_{\text{low}}$。

此外，我们仍需要拉回函数在给定缩回 R 下满足一阶 Lipschitz 型条件。集合 S_g 的定义稍后给出。

假设 11.6 (A6) 给定集集 S_g，存在常数 $L_g > 0$，使得对所有 $(x, s) \in S_g$，有

$$f(x+s) \le f(x) + \langle \nabla f(x), s \rangle + \frac{L_g}{2}\|s\|^2.$$

除上述条件外，我们还引入二阶 Lipschitz 型条件。若 $\nabla^2 f$ 以常数 L_H Lipschitz 连续，则该条件成立。

假设 11.7 (A7) 给定集合 S_H，存在常数 $L_H > 0$，使得对所有 $(x, s) \in S_H$，有

$$f(x+s) \le f(x) + \langle \nabla f(x), s \rangle + \frac{1}{2}\langle s, \nabla^2 f(x)[s] \rangle + \frac{L_H}{6}\|s\|^3.$$

注 11.4 注意，由于 $\bar{\Delta}$ 是算法中考虑的最大信赖域半径，因此 S_g 和 S_H 无需包含范数大于 $\bar{\Delta}$ 的切向量。这对处理非全局定义或性质不佳的缩回尤为有用。

11.4 信赖域算法的迭代复杂度

定理 11.4 (信赖域算法的迭代复杂度) 设 $S = \{(x_0, s_0), (x_1, s_1), \dots\}$ 为信赖域算法在假设 11.1, 假设 11.1, 假设 11.2, 假设 11.3, 假设 11.4, 假设 11.5下生成的迭代点与迭代方向。进一步假设在集合

$$S_g = \{(x_k, s_k) \in S : \|\nabla f(x_k)\| > \varepsilon_g\},$$

$$S_H = \{(x_k, s_k) \in S : \|\nabla f(x_k)\| \le \varepsilon_g \text{ 且} \lambda_{\min}(H_k) < -\varepsilon_H\}$$

上，假设 11.6, 假设 11.6以常数 L_g 和 L_H 成立。定义

$$\lambda_g = \frac{1}{4}\min\left(\frac{1}{c_0}, \frac{c_2}{L_g + c_0}\right), \quad \lambda_H = \frac{3}{4}\frac{c_3}{L_H + c_1}.$$

我们分两种情况讨论 (取决于是否以二阶最优性条件为目标)：

1. 若 $\varepsilon_g \le \frac{\Delta_0}{\lambda_g}$ 且 $\varepsilon_H = \infty$，则存在迭代次数 t，使得 $\|\nabla f(x_t)\| \le \varepsilon_g$，且

$$t \le \frac{3}{2}\frac{f(x_0) - f_{\text{low}}}{\rho' c_2 \lambda_g}\frac{1}{\varepsilon_g^2} + \frac{1}{2}\log_2\left(\frac{\Delta_0}{\lambda_g \varepsilon_g}\right) = O\left(\frac{1}{\varepsilon_g^2}\right).$$

（此情形下，假设 A6.2、A6.4 和 A6.7 无关。）

2. 若 $\varepsilon_g \le \frac{\Delta_0}{\lambda_g}$、$\varepsilon_g \le \frac{c_2}{c_3}\frac{\lambda_H}{\lambda_g^2}$ 且 $\varepsilon_H < \frac{c_2}{c_3}\frac{1}{\lambda_g}$，则存在 $t' \ge t$，使得 $\|\nabla f(x_{t'})\| \le \varepsilon_g$ 且 $\lambda_{\min}(H_{t'}) \ge -\varepsilon_H$，且

$$t' \le \frac{3}{2}\frac{f(x_0) - f_{\text{low}}}{\rho' c_3 \lambda^2}\frac{1}{\varepsilon^2 \varepsilon_H} + \frac{1}{2}\log_2\left(\frac{\Delta_0}{\lambda\varepsilon}\right) = O\left(\frac{1}{\varepsilon^2 \varepsilon_H}\right),$$

其中 $(\lambda, \varepsilon) = (\lambda_g, \varepsilon_g)$ 当 $\lambda_g \varepsilon_g \le \lambda_H \varepsilon_H$，否则 $(\lambda, \varepsilon) = (\lambda_H, \varepsilon_H)$。

由于算法是下降方法，故 $f(x_{t'}) \le f(x_t) \le f(x_0)$。

为证明上述定理，我们通过三个引理逐步推导。第一个引理给出信赖域半径的下界。

引理 11.5 (信赖域半径的下界) *在定理 11.4的假设下，设 $x_0, \dots, x_n$ 为信赖域算法生成的迭代序列。若所有迭代均不满足终止条件，则对 $k = 0, \dots, n$，有*

$$\Delta_k \geq \min(\Delta_0, \lambda_g \varepsilon_g, \lambda_H \varepsilon_H).$$

证明. 由 ρ_k 的定义，结合 $m_k(0) = f(x_k)$，有

$$1 - \rho_k = 1 - \frac{f(x_k) - f(x_k + s_k)}{m_k(0) - m_k(s_k)} = \frac{f(x_k + s_k) - m_k(s_k)}{m_k(0) - m_k(s_k)}.$$

- **如果** $\|\nabla f(x_k)\| > \varepsilon_g$：
  - 由假设 11.1和假设 11.6，有：

$$\begin{aligned} f(x_k + s_k) - m_k(s_k) &= f(x_k + s_k) - f(x_k) - \langle \nabla f(x_k), s_k \rangle - \frac{1}{2}\langle H_k(s_k), s_k \rangle \\ &\leq \frac{L_g + c_0}{2} \|s_k\|^2. \end{aligned}$$

  - 由假设 11.3，有：

$$m_k(0) - m_k(s_k) \geq c_2 \min\left(\Delta_k, \frac{\varepsilon_g}{c_0}\right) \varepsilon_g.$$

  - 结合 $\|s_k\|_{x_k} \leq \Delta_k$，可得

$$1 - \rho_k \leq \frac{1}{2} \frac{L_g + c_0}{c_2 \varepsilon_g} \frac{\Delta_k^2}{\min\left(\Delta_k, \frac{\varepsilon_g}{c_0}\right)}.$$

  - 若 $\Delta_k \leq \frac{\varepsilon_g}{c_0}$，则上式中的最后一项为 Δ_k。若进一步有 $\Delta_k \leq \frac{c_2 \varepsilon_g}{L_g + c_0}$，则 $1 - \rho_k \leq \frac{1}{2}$。结合 λ_g 的定义，可得：若 $\Delta_k \leq 4\lambda_g \varepsilon_g$，则 $\rho_k \geq \frac{1}{2}$，且算法的更新规则得到 $\Delta_{k+1} \geq \Delta_k$。
- **如果** $\|\nabla f(x_k)\| \leq \varepsilon_g$ **且** $\lambda_{\min}(H_k) < -\varepsilon_H$
  - 由假设 11.2和假设 11.7及 $\|s_k\|_{x_k} \leq \Delta_k$，分子：

$$\begin{aligned} &f(x_k + s_k) - m_k(s_k) \\ &= f(x_k + s_k) - f(x_k) - \langle \nabla f(x_k), s_k \rangle_{x_k} - \frac{1}{2}\langle \mathrm{Hess}(f \circ R_{x_k}(0))[s_k], s_k \rangle_{x_k} \\ &\quad + \frac{1}{2}\langle (\mathrm{Hess}(f \circ R_{x_k}(0)) - H_k)[s_k], s_k \rangle_{x_k} \\ &\leq \frac{L_H + c_1}{6} \Delta_k^3, \end{aligned}$$

  - 由假设 11.4，有：

$$m_k(0) - m_k(s_k) \geq c_3 \Delta_k^2 \varepsilon_H.$$

- 综合可得：

$$1-\rho_k \le \frac{L_H + c_1}{6c_3\varepsilon_H}\Delta_k.$$

  - 结合 λ_H 的定义，若 $\Delta_k \le 4\lambda_H\varepsilon_H$，则 $\rho_k \ge \frac{1}{2}$，因此 $\Delta_{k+1} \ge \Delta_k$。
- 综上，若 $\Delta_k \le 4\min(\lambda_g\varepsilon_g, \lambda_H\varepsilon_H)$，则 $\Delta_{k+1} \ge \Delta_k$。
- 根据上述性质，由数学归纳法可以得到引理结论。

第二个引理给出终止前成功迭代次数的上界。

引理 11.6 (终止前成功迭代次数的上界) 在定理 11.4的假设下，设 $x_0, \dots, x_n$ 为信赖域生成的迭代序列。若所有迭代均不满足终止条件，定义其中成功迭代步的集合为

$$S_n = \{k \in \{0, \dots, n\} : \rho_k > \rho'\},$$

并令 U_n 表示失败迭代的集. 合 (S_n 和 U_n 构成 $\{0, \dots, n\}$ 的一个划分。在定理 11.4的第一种情形下，成功迭代次数满足

$$|S_n| \le \frac{f(x_0) - f_{\text{low}}}{\rho' c_2}\frac{1}{\lambda_g\varepsilon_g^2}.$$

同理，在第二种情形下，有

$$|S_n| \le \frac{f(x_0) - f_{\text{low}}}{\rho' c_3}\frac{1}{\min(\lambda_g\varepsilon_g, \lambda_H\varepsilon_H)^2\varepsilon_H}.$$

证明.

- 若 $k \in U_n$，则 $f(x_k) = f(x_{k+1})$。
- 若 $k \in S_n$，则由 ρ_k 的定义结合假设 11.3和假设 11.4可得：

$$\begin{aligned} f(x_k) - f(x_{k+1}) &= \rho_k(m_k(0) - m_k(s_k)) \\ &\ge \rho' \min\left(c_2 \min\left(\Delta_k, \frac{\varepsilon_g}{c_0}\right)\varepsilon_g,\ c_3\Delta_k^2\varepsilon_H\right). \end{aligned}$$

  由定理 11.5及 $\lambda_g\varepsilon_g \le \Delta_0$(定理 11.4的条件)，可知 $\Delta_k \ge \min(\lambda_g\varepsilon_g, \lambda_H\varepsilon_H)$。此外，利用 $\lambda_g \le 1/c_0$ 可得

$$\min\left(\Delta_k, \frac{\varepsilon_g}{c_0}\right) \ge \min(\Delta_k, \lambda_g\varepsilon_g) \ge \min(\lambda_g\varepsilon_g, \lambda_H\varepsilon_H).$$

  因此，

$$f(x_k) - f(x_{k+1}) \ge \rho' \min(c_2\lambda_g\varepsilon_g^2,\ c_2\lambda_H\varepsilon_g\varepsilon_H,\ c_3\lambda_g^2\varepsilon_g^2\varepsilon_H,\ c_3\lambda_H^2\varepsilon_H^3).$$

- 在第一种情形下，$\varepsilon_H = \infty$，上式简化为：

$$f(x_k) - f(x_{k+1}) \geq \rho' c_2 \lambda_g \varepsilon_g^2.$$

对迭代求和并结合假设 11.5(f 有下界)，得：

$$\begin{aligned} f(x_0) - f_{\text{low}} \geq & f(x_0) - f(x_{n+1}) \\ = & \sum_{k \in S_n} f(x_k) - f(x_{k+1}) + \sum_{k \in U_n} f(x_k) - f(x_{k+1}) \\ = & \sum_{k \in S_n} f(x_k) - f(x_{k+1}) \geq |S_n| \rho' c_2 \lambda_g \varepsilon_g^2. \end{aligned}$$

整理即得 $|S_n|$ 的上界。

- 同理，在第二种情形下，由上述不等式出发，结合条件可得

$$f(x_0) - f_{\text{low}} \geq |S_n| \rho' c_3 \min(\lambda_g \varepsilon_g, \lambda_H \varepsilon_H)^2 \varepsilon_H.$$

整理即得 $|S_n|$ 的上界。

第三个引理给出了终止前成功迭代次数的下界，它与终止前总迭代次数成一定比例。这反映了一个事实：我们不可能出现任意长的连续失败迭代序列。

引理 11.7 (终止前成功迭代次数的下界) 在定理 11.4的假设下，设 $x_0, \ldots, x_n$ 为信赖域算法生成的迭代序列。若所有迭代均不满足终止条件，则采用定理 11.6中的记号 S_n 和 U_n，有

$$|S_n| \geq \frac{2}{3}(n+1) - \frac{1}{3} \max\left(0, \log_2\left(\frac{\Delta_0}{\lambda_g \varepsilon_g}\right), \log_2\left(\frac{\Delta_0}{\lambda_H \varepsilon_H}\right)\right).$$

证明.

- 对所有 $k \in S_n$，有 $\Delta_{k+1} \leq 2\Delta_k$；对所有 $k \in U_n$，有 $\Delta_{k+1} \leq 2^{-2}\Delta_k$。因此，

$$\Delta_n = \Delta_0 \prod_{k=1}^{n} \Delta_k / \Delta_{k-1} \leq 2^{|S_n| - 2|U_n|} \Delta_0.$$

- 另一方面，由定理 11.5，有

$$\Delta_n \geq \min(\Delta_0, \lambda_g \varepsilon_g, \lambda_H \varepsilon_H).$$

- 结合两式，除以 Δ_0 并取以 2 为底的对数，可得：

$$|S_n| - 2|U_n| \geq \min\left(0, \log_2\left(\frac{\lambda_g \varepsilon_g}{\Delta_0}\right), \log_2\left(\frac{\lambda_H \varepsilon_H}{\Delta_0}\right)\right).$$

利用 $|S_n| + |U_n| = n + 1$ 即可得出结论。

有了这些引理，主定理的证明就很容易了。

定理 11.4的证明. 对每种情形，定理 11.7和定理 11.6分别给出了 $|S_n|$ 的上界和下界，结合两者即可得到 n 的上界。例如，在第一种情形下，若 n 使得所有迭代 $x_0, \dots, x_n$ 的梯度均不小于 ε_g，则

$$n \le \frac{3}{2}\frac{f(x_0) - f_{\text{low}}}{\rho' c_2}\frac{1}{\lambda_g \varepsilon_g^2} + \frac{1}{2}\log_2\left(\frac{\Delta_0}{\lambda_g \varepsilon_g}\right) - 1.$$

因此，由逆否命题可知，当迭代次数超过上式右侧的值后，必然会找到一个梯度足够小的迭代点。同理，第二种情形的论证过程类似。

11.5 信赖域算法的收敛性

基于定理 11.4，还可以证明算法的所有聚点都是临界点。

推论 11.8 设 $S = \{(x_0, s_0), (x_1, s_1), \dots\}$ 为信赖域算法在假设 11.1假设 11.3假设 11.5且取 $\varepsilon_g = 0$ 时生成的迭代与迭代方向。进一步假设 11.6在 S 上成立。则

$$\liminf_{k\to\infty} \|\nabla f(x_k)\| = 0,$$

即对任意 $\varepsilon > 0$ 和 K，存在 $k \ge K$ 使得 $\|\nabla f(x_k)\| \le \varepsilon$。

证明. 任取 $\varepsilon > 0$ 和 $K \in \{0, 1, 2, \dots\}$。由假设可知，$S_K = \{(x_K, s_K), (x_{K+1}, s_{K+1}), \dots\}$ 是信赖域算法在假设 11.1假设 11.3假设 11.5且取 $\varepsilon_g = 0$,$\varepsilon_H = \infty$ 且假设 11.6在 S_K 上成立时生成的序列。因此，定理 11.4保证存在 $k \ge K$ 使得 $\|\nabla f(x_k)\| \le \varepsilon$。

假设 11.8 (A8) 给定子集 S，存在常数 $L_{gn} > 0$，使得对所有 $(x, s) \in S$，有

$$|\|\nabla f(x+s)\| - \|\nabla f(x)\|| \le L_{gn}\|s\|.$$

注 11.5 上述假设比一般的

$$\|\nabla f(x+s) - \nabla f(x)\| \le L_{gn}\|s\|$$

更弱，但是依然可以证明相应结论。

命题 11.9 设 $S = \{(x_0, s_0), (x_1, s_1), \dots\}$ 为信赖域算法在假设 11.1假设 11.3假设 11.5且取 $\varepsilon_g = 0$ 时生成的迭代与迭代方向。进一步假设 11.6和假设 11.8在 S 上成立。则

$$\lim_{k\to\infty} \|\nabla f(x_k)\| = 0.$$

特别地，$x_0, x_1, \dots$ 的所有聚点 (若存在) 都是临界点。

证明.

- 若迭代 k 是失败的（$\rho_k \le \rho'$），则 $x_{k+1} = x_k$。
- 若迭代 k 是成功的，则由假设 11.8可得

$$\|\nabla f(x_{k+1})\| \ge \|\nabla f(x_k)\| - L_{gn}\|s_k\|.$$

- 固定任意满足 $\nabla f(x_m) \ne 0$ 的索引 m。对所有 $\ell \ge m$，有

$$\|\nabla f(x_{\ell+1})\| \ge \|\nabla f(x_m)\| - L_{gn} \sum_{\substack{m \le k \le \ell \\ \rho_k > \rho'}} \|s_k\|.$$

- 选取满足 $\|\nabla f(x_{\ell+1})\| \le \frac{1}{2}\|\nabla f(x_m)\|$ 的最小 $\ell \ge m$，由定理 11.8可知这样的 ℓ 存在。于是

$$\|\nabla f(x_m)\| \le 2L_{gn} \sum_{\substack{m \le k \le \ell \\ \rho_k > \rho'}} \|s_k\| \le 2L_{gn} \sum_{\substack{m \le k \le \ell \\ \rho_k > \rho'}} \Delta_k.$$

- 根据 ℓ 的选取，对 $k = m, \dots, \ell$，有 $\|\nabla f(x_k)\| > \frac{1}{2}\|\nabla f(x_m)\|$。又对所有满足 $\rho_k > \rho'$ 的 k，有 $x_{k+1} = x_k + s_k$。因此，由假设 11.3和 ρ_k 的定义可得

$$\begin{aligned} f(x_m) - f(x_{\ell+1}) &= \sum_{\substack{m \le k \le \ell \\ \rho_k > \rho'}} f(x_k) - f(x_{k+1}) \\ &\ge \sum_{\substack{m \le k \le \ell \\ \rho_k > \rho'}} \frac{\rho' c_2}{2} \min\left(\Delta_k, \frac{\|\nabla f(x_m)\|}{2c_0}\right) \|\nabla f(x_m)\|. \end{aligned}$$

- 考虑两种情形：
  - 若求和范围内存在某个 k 使得 $\frac{\|\nabla f(x_m)\|_{x_m}}{2c_0} \le \Delta_k$，则用对应项给出下界：

$$f(x_m) - f(x_{\ell+1}) \ge \frac{\rho' c_2}{4c_0}\|\nabla f(x_m)\|^2.$$

  - 若对求和范围内所有 k 都有 $\frac{\|\nabla f(x_m)\|_{x_m}}{2c_0} > \Delta_k$，则结合上式可得：

$$\begin{aligned} f(x_m) - f(x_{\ell+1}) &\ge \frac{\rho' c_2}{2}\|\nabla f(x_m)\| \sum_{\substack{m \le k \le \ell \\ \rho_k > \rho'}} \Delta_k \\ &\ge \frac{\rho' c_2}{4L_{gn}}\|\nabla f(x_m)\|^2. \end{aligned}$$

- 序列 $\{f(x_k)\}$ 由假设 11.5知有下界且单调不增，故收敛于某个 f_∞。结合上述结果与 $f(x_m) - f_\infty \ge f(x_m) - f(x_{\ell+1})$，对所有 m 可得

$$f(x_m) - f_\infty \ge \frac{\rho' c_2}{4\max(L_{gn}, c_0)}\|\nabla f(x_m)\|^2.$$

令 $m \to \infty$，利用 $f(x_m) - f_\infty \to 0$ 即可证得结论。

11.6 截断共轭梯度法

12 共轭梯度法

12.1 共轭方向法：共轭梯度法的原型

定义 12.1 (H-共轭) 设 $p_i, p_j \in \mathbb{R}^n$. 若

$$p_i^\top H p_j = 0 \qquad (i \neq j),$$

则称 p_i 与 p_j 关于 H 共轭, 或称它们是 H-正交的.

在介绍共轭梯度法之前, 先考虑一个更一般的框架, 即共轭方向法.

设 $p_0, \dots, p_{n-1}$ 是 $\mathbb{R}^n$ 中一组非零向量, 并且它们两两关于 H 共轭, 即

$$p_i^\top H p_j = 0 \qquad (i \neq j),$$

给定初始点 x_0, 定义迭代

$$x_{k+1} = x_k + \alpha_k p_k,$$

其中步长 α_k 通过一维精确搜索确定：

$$\alpha_k = \arg\min_{\alpha \in \mathbb{R}} \phi(x_k + \alpha p_k).$$

这便称为**共轭方向法**.

命题 12.1 (步长公式) 对任意非零方向 p_k, 若 H 对称正定, 则精确搜索步长 α_k 满足

$$\alpha_k = \frac{p_k^\top (b - H x_k)}{p_k^\top H p_k}.$$

证明. 定义一元函数

$$\psi(\alpha) := \phi(x_k + \alpha p_k).$$

将 ϕ 展开可得

$$\psi(\alpha) = \frac{1}{2}(x_k + \alpha p_k)^\top H (x_k + \alpha p_k) - b^\top (x_k + \alpha p_k).$$

由于 H 对称,

$$\psi'(\alpha) = p_k^\top (H x_k - b) + \alpha\, p_k^\top H p_k.$$

令导数为零, 得到

$$p_k^\top (H x_k - b) + \alpha_k\, p_k^\top H p_k = 0,$$

故

$$\alpha_k = \frac{p_k^\top (b - Hx_k)}{p_k^\top H p_k}.$$

又因为 H 正定且 $p_k \neq 0$, 故

$$p_k^\top H p_k > 0,$$

因此该极小点唯一.

下面给出共轭方向法最核心的结论.

定理 12.2 (共轭方向法的有限步终止性) 设 $H \in \mathbb{R}^{n\times n}$ 对称正定, 且 $p_0, \ldots, p_{n-1}$ 两两关于 H 共轭, 并张成 $\mathbb{R}^n$. 从任意初始点 x_0 出发, 按

$$x_{k+1} = x_k + \alpha_k p_k$$

迭代, 其中 α_k 为沿方向 p_k 的精确搜索步长, 则经过至多 n 步可得到最优解 x^*.

证明. 记最优解为 x^*, 并令误差向量 $e_k := x^* - x_k$. 由于 x^* 是问题

$$\min_x \left(\frac{1}{2} x^\top H x - b^\top x\right)$$

的唯一最优解, 故满足 $Hx^* = b$.

我们可以归纳证明

$$p_i^\top H e_{k+1} = 0, \qquad i = 0, 1, \ldots, k, \qquad \forall k$$

- 先证 $p_k^\top H e_{k+1} = 0, \forall k$
  由于 $b - Hx_k = H(x^* - x_k) = He_k$. 由上面的步长公式可知

  $$\alpha_k = \frac{p_k^\top H e_k}{p_k^\top H p_k}.$$

  又因为 $e_{k+1} = x^* - x_{k+1} = e_k - \alpha_k p_k$. 则

  $$p_k^\top H e_{k+1} = p_k^\top H(e_k - \alpha_k p_k) = p_k^\top H e_k - \alpha_k p_k^\top H p_k.$$

  代入 α_k 的表达式, 得到

  $$p_k^\top H e_{k+1} = 0.$$

- 对于 $p_i^\top H e_{k+1}, \qquad i = 0, 1, \ldots, k-1$, 有

  $$\begin{aligned} p_{k-1}^\top H e_{k+1} &= p_{k-1}^\top H(e_k - \alpha_k p_k) \\ &= p_{k-1}^\top H e_k - \alpha_k p_{k-1}^\top H p_k \\ &= 0 \end{aligned}$$

  于是同理可得: $p_i^\top H e_{k+1} = 0, \qquad i = 0, 1, \ldots, k-1$

于是

$$p_i^\top H e_n = 0, \qquad i = 0, 1, \ldots, n-1.$$

又因为 $\{p_0, \ldots, p_{n-1}\}$ 张成整个 $\mathbb{R}^n$, 故 e_n 与 $\mathbb{R}^n$ 中任意向量都在 H-内积下正交. 特别地, 取该向量为 e_n 自身, 便有 $e_n^\top H e_n = 0$. 而 H 正定, 故

$$e_n^\top H e_n = 0 \quad \Longrightarrow \quad e_n = 0.$$

即 $x_n = x^*$. 因此, 共轭方向法在至多 n 步内到达最优解.

注 12.1 上述定理说明：若能找到一组两两 H-共轭的搜索方向, 并沿这些方向依次做精确搜索, 那么对于对称正定二次问题, 就可以在有限步内精确到达最优解.

不过, 共轭方向法本身仍留下一个关键问题：如何在计算中高效地构造这样一组两两 H-共轭的方向？共轭梯度法正是对这一问题的一个巧妙回答. 它并不预先给出全部共轭方向, 而是在迭代过程中利用当前残差与上一方向递推生成新的搜索方向, 从而得到一种既具有有限步性质、又适合大规模稀疏问题的高效算法.

12.2 共轭梯度法的标准算法

共轭梯度法 (Conjugate Gradient Method, CG) 的初始化为

$$x_0 \text{ 给定}, \qquad r_0 = b - H x_0, \qquad p_0 = r_0.$$

随后对 $k = 0, 1, 2, \ldots$ 进行迭代：

$$\begin{aligned}
\alpha_k &= \frac{r_k^\top r_k}{p_k^\top H p_k}, \\
x_{k+1} &= x_k + \alpha_k p_k, \\
r_{k+1} &= r_k - \alpha_k H p_k, \\
\beta_{k+1} &= \frac{r_{k+1}^\top r_{k+1}}{r_k^\top r_k}, \\
p_{k+1} &= r_{k+1} + \beta_{k+1} p_k.
\end{aligned}$$

当 $r_k = 0$ 时停止, 此时 $x_k = x^*$.

从形式上看, CG 与最速下降法非常接近, 但它并不是简单地令每一步方向都等于当前残差 r_k, 而是通过递推

$$p_{k+1} = r_{k+1} + \beta_{k+1} p_k$$

构造出一列新的搜索方向, 使得这些方向彼此关于 H 共轭, 从而避免最速下降法中的重复修正现象.

可以证明：

定理 12.3 (CG 的核心结论)

- $\alpha_k = \frac{r_k^\top r_k}{p_k^\top H p_k}$ 恰好是沿方向 p_k 对函数 ϕ 做精确一维搜索得到的最优步长.
- $r_i^\top r_j = 0, \qquad i \neq j.$
- $p_i^\top H p_j = 0, \qquad i \neq j.$

上述三个结论说明：CG 中的步长不是任意选取的, 而是精确搜索步长；残差序列具有正交性；搜索方向序列具有关于 H 的共轭性. 这三个性质共同构成了 CG 方法高效性的理论基础.

定义与初始残差 r_0 相关的 Krylov 子空间

$$\mathcal{K}_k(H, r_0) := \mathrm{span}\{r_0, Hr_0, \ldots, H^{k-1}r_0\}.$$

定理 12.4 (Krylov 子空间最优性) 在第 k 步, CG 迭代点 x_k 满足

$$x_k \in x_0 + \mathcal{K}_k(H, r_0),$$

并且

$$x_k = \arg \min_{x \in x_0 + \mathcal{K}_k(H, r_0)} \phi(x).$$

这一结论表明：CG 的第 k 步并不是随意得到的近似点, 而是在不断扩大的 Krylov 子空间上实现了当前最优.

定理 12.5 (CG 在精确算术下至多 n 步终止) 设 $H \in \mathbb{R}^{n\times n}$ 对称正定, 则共轭梯度法在精确算术下至多经过 n 步可得到精确解 x^*.

这一结论说明：对于对称正定二次问题, CG 不是仅仅“渐近收敛”, 而是在精确算术下具有有限步到达最优解的强性质.

12.3 经典误差估计

在实际浮点计算中, 由于舍入误差的影响, CG 一般不会严格在 n 步内终止, 因此还需要讨论其收敛速度.

记误差向量

$$e_k := x^* - x_k,$$

并定义由 H 诱导的范数

$$\|v\|_H := \sqrt{v^\top H v}.$$

设 H 的条件数为

$$\kappa(H) := \frac{\lambda_{\max}(H)}{\lambda_{\min}(H)}.$$

定理 12.6 (经典 CG 收敛估计) 对任意 $k \geq 0$, 有

$$\|e_k\|_H \leq 2\left(\frac{\sqrt{\kappa(H)}-1}{\sqrt{\kappa(H)}+1}\right)^k \|e_0\|_H.$$

该估计说明：CG 的收敛速度与矩阵 H 的条件数密切相关, 条件数越小, 收敛越快. 这也是预条件共轭梯度法存在的根本原因.

Part III

人工智能中的优化方法

本部分内容来自中国运筹学会“道·立”课程品牌工程——人工智能中的优化方法专题培训会，由北京大学袁坤教授主讲。

13 课程第一讲：梯度法与随机优化

13.1 Lecture 1：梯度下降与反向传播

从分类到随机优化模型 设类别数为 C，线性分类器对特征 $h \in \mathbb{R}^d$ 给出得分 $s = Xh$，经 softmax 得到

$$p_j = \frac{\exp(s_j)}{\sum_{\ell=1}^{C} \exp(s_\ell)}, \qquad j = 1, \dots, C.$$

若真实类别为 y，交叉熵为 $H(q,p) = -\log p_y$。推广到参数为 x 的深度网络 $h(x;a)$，经验风险与总体风险分别写为

$$\min_x \frac{1}{N} \sum_{i=1}^{N} L(h(x;a_i), b_i), \qquad \min_x f(x) := \mathbb{E}_{\xi \sim \mathcal{D}}[F(x;\xi)].$$

深度学习优化的主要困难是目标高度非凸、参数维度极高且数据量巨大，因此算法必须兼顾单步计算、显存和可扩展性。

反向传播就是链式法则的高效复用 采用列梯度时，若 $y = g(x)$ 且 $f = f(y)$，则

$$\nabla_x f = \left(\frac{\partial y}{\partial x}\right)^{\top} \nabla_y f.$$

线性层 $y = Wx$ 与逐坐标激活 $z = \phi(h)$ 分别满足

$$\nabla_W f = (\nabla_y f) x^{\top}, \qquad \nabla_h f = \phi'(h) \odot \nabla_z f.$$

以三层网络

$$h_1 = W_1 x, \quad z_1 = \phi(h_1), \quad h_2 = W_2 z_1, \quad z_2 = \phi(h_2), \quad \widehat{y} = W_3 z_2$$

为例，令 $\delta_3 = \nabla_{\widehat{y}} L$，反向递推为

$$\nabla_{W_3} L = \delta_3 z_2^{\top}, \quad \delta_2 = \phi'(h_2) \odot (W_3^{\top} \delta_3), \quad \nabla_{W_2} L = \delta_2 z_1^{\top},$$

$$\delta_1 = \phi'(h_1) \odot (W_2^{\top} \delta_2), \qquad \nabla_{W_1} L = \delta_1 x^{\top}.$$

每层参数梯度均为“该层反向误差信号”与“该层输入”的外积。前向传播保存的中间激活正是反向传播计算这些梯度所需的信息，这一事实也解释了后续各种省显存方法为何关注激活值。

梯度下降的下降性质 若 f 为 L-光滑函数，即

$$\|\nabla f(x)-\nabla f(y)\|\le L\|x-y\|,$$

则下降引理给出

$$f(y)\le f(x)+\langle\nabla f(x),y-x\rangle+\frac{L}{2}\|y-x\|^2.$$

对梯度下降 $x_{k+1}=x_k-\gamma\nabla f(x_k)$，有

$$f(x_{k+1})\le f(x_k)-\gamma\left(1-\frac{L\gamma}{2}\right)\|\nabla f(x_k)\|^2.$$

因此 $0<\gamma\le 1/L$ 时函数值保证下降；学习率过大则可能振荡或发散。

三类典型收敛结论

- 非凸且 L-光滑时，若 $\gamma\le 1/L$，则

  $$\frac{1}{K+1}\sum_{k=0}^{K}\|\nabla f(x_k)\|^2\le\frac{2(f(x_0)-f^\star)}{\gamma(K+1)}.$$

  该结果保证逼近一阶驻点，而不保证一般非凸问题的全局最优。
- 凸且 L-光滑时，适当常步长给出 $f(x_K)-f^\star=O(L/K)$。
- 若 f 还是 μ-强凸函数，条件数记为 $\kappa=L/\mu$。取 $\gamma=2/(L+\mu)$ 时，

  $$\|x_K-x^\star\|\le\left(\frac{L-\mu}{L+\mu}\right)^{K+1}\|x_0-x^\star\|,$$

  故迭代复杂度为 $O(\kappa\log(1/\varepsilon))$。条件数越大，梯度法沿狭长等高线产生的“之字形”越明显。

13.2 Lecture 2：SGD、动量与自适应方法

随机梯度的基本假设 对 $f(x)=\mathbb{E}_\xi[F(x;\xi)]$，SGD 每轮采样 ξ_k 并更新

$$g_k=\nabla F(x_k;\xi_k),\qquad x_{k+1}=x_k-\gamma g_k.$$

令 $\mathcal{F}_k$ 表示采样前的历史，标准分析假设

$$\mathbb{E}[g_k\mid\mathcal{F}_k]=\nabla f(x_k),\qquad\mathbb{E}[\|g_k-\nabla f(x_k)\|^2\mid\mathcal{F}_k]\le\sigma^2.$$

在非凸光滑情形，若 $\gamma\le 1/L$，则

$$\frac{1}{K+1}\sum_{k=0}^{K}\mathbb{E}\|\nabla f(x_k)\|^2\le\frac{2\Delta_0}{\gamma(K+1)}+\gamma L\sigma^2,\qquad\Delta_0=f(x_0)-f^\star.$$

第一项是有限迭代造成的优化误差，偏好较大步长；第二项是随机噪声造成的误差平台，偏好较小步长。平衡两项后主导收敛率为 $O(\sigma/\sqrt{K})$。严格地说，上式直接控制遍历平均，或等价地控制均匀随机输出迭代点的期望梯度平方。

Mini-batch 的作用 用 B 个条件独立样本平均，

$$g_k = \frac{1}{B}\sum_{b=1}^{B} \nabla F(x_k;\xi_k^{(b)}),$$

其条件方差降为至多 σ^2/B。大批量能减少梯度噪声并提高硬件并行度，但若按处理样本总数计费，总计算量并不必然按 B 倍下降。

动量：在一致方向加速，在振荡方向抵消 重球动量可写为

$$m_k = \beta m_{k-1} + g_k, \qquad x_{k+1} = x_k - \gamma m_k, \qquad 0 \le \beta < 1.$$

展开 $m_k = \sum_{t=0}^{k} \beta^{k-t} g_t$ 可见，它是历史梯度的指数加权和。Nesterov 动量先前瞻再计算梯度：

$$y_k = x_k + \beta(x_k - x_{k-1}), \qquad x_{k+1} = y_k - \gamma \nabla f(y_k).$$

二者的关键区别是梯度在当前点还是前瞻点计算。

自适应方法是对角预条件 一般预条件更新为 $x_{k+1} = x_k - \gamma P_k g_k$。AdaGrad、RMSProp 和 Adam 以梯度历史构造廉价的对角 P_k：

$$\text{AdaGrad:}\quad s_k = s_{k-1} + g_k \odot g_k, \qquad x_{k+1} = x_k - \gamma \frac{g_k}{\sqrt{s_k} + \varepsilon};$$

$$\text{RMSProp:}\quad s_k = \beta s_{k-1} + (1-\beta) g_k \odot g_k, \qquad x_{k+1} = x_k - \gamma \frac{g_k}{\sqrt{s_k} + \varepsilon}.$$

AdaGrad 的累计量只增不减，适合稀疏梯度，但有效学习率可能过早衰减；RMSProp 只强调近期平方梯度。

Adam 同时维护一阶与二阶矩：

$$m_k = \beta_1 m_{k-1} + (1-\beta_1) g_k, \qquad v_k = \beta_2 v_{k-1} + (1-\beta_2) g_k \odot g_k,$$

$$\widehat{m}_k = \frac{m_k}{1-\beta_1^{k+1}}, \qquad \widehat{v}_k = \frac{v_k}{1-\beta_2^{k+1}}, \qquad x_{k+1} = x_k - \gamma \frac{\widehat{m}_k}{\sqrt{\widehat{v}_k} + \varepsilon}.$$

一阶矩平滑方向，二阶矩逐坐标调节尺度。代价是 Adam 需为每个参数额外保存两份优化器状态，这在大模型中成为主要显存来源之一。

14 课程第二讲：语言模型与 Transformer

14.1 Lecture 3：词表示、语言模型、RNN 与 Seq2Seq

从 one-hot 到词嵌入 设词表大小为 V，第 i 个词的 one-hot 向量为 $o_i \in \mathbb{R}^V$。可训练嵌入矩阵

$$E \in \mathbb{R}^{d_e \times V}, \qquad e_i = E o_i \in \mathbb{R}^{d_e}, \qquad d_e \ll V$$

把离散词映射到低维连续空间，使语义相近的词可以共享统计规律。

语言模型 概率链式法则给出

$$P(w_{1:T}) = \prod_{t=1}^{T} P(w_t \mid w_{<t}).$$

n-gram 用最近 $n-1$ 个词近似全部历史：

$$P(w_t \mid w_{<t}) \approx P(w_t \mid w_{t-n+1:t-1}).$$

它简单直观，但随 n 增大出现数据稀疏、存储爆炸和上下文仍有限的问题。固定窗口神经语言模型用词嵌入和神经网络缓解稀疏性，却仍受固定窗口限制。

RNN：用隐藏状态压缩历史 基本 RNN 递推为

$$h_t = \phi(W_h h_{t-1} + W_x e_t + b_h), \qquad \widehat{y}_t = \mathrm{softmax}(U h_t + b_y).$$

参数在所有时间步共享，故参数量不随序列长度增长。训练时最小化 token 级负对数似然

$$\mathcal{L}(\theta) = -\sum_{t=1}^{T-1} \log P_\theta(w_{t+1} \mid w_{\le t}).$$

推理时上一步生成词会作为下一步输入，因此需区分训练阶段使用真实历史的 teacher forcing 与生成阶段使用模型自身输出。

时间反向传播包含长 Jacobian 乘积

$$\frac{\partial h_t}{\partial h_k} = \prod_{j=k+1}^{t} \mathrm{Diag}(\phi'(a_j)) W_h.$$

其范数指数衰减或增长分别造成梯度消失或爆炸。这说明 RNN 虽能形式上接收任意长历史，却未必能学到长距离依赖。

Seq2Seq 是条件语言模型 编码器将源序列 $x_{1:N}$ 压缩为表示，解码器自回归地产生目标序列：

$$P(y_{1:M} \mid x_{1:N}) = \prod_{t=1}^{M} P(y_t \mid y_{<t}, x_{1:N}), \qquad \mathcal{L} = -\sum_{t=1}^{M} \log P(y_t \mid y_{<t}, x_{1:N}).$$

若只用编码器最终状态作为固定长度语义向量，长源序列会产生明显的信息瓶颈；同时 RNN 的时间递归难以并行。

14.2 Lecture 4：Attention 与 Transformer

Attention：按当前需求动态检索 令编码器状态为 $h_1, \dots, h_N$，解码器第 t 步状态为 s_t。点积注意力为

$$e_{ti} = s_t^\top h_i, \qquad \alpha_{ti} = \frac{\exp(e_{ti})}{\sum_{j=1}^{N} \exp(e_{tj})}, \qquad a_t = \sum_{i=1}^{N} \alpha_{ti} h_i.$$

它不再强迫一个固定向量保存全部源序列，而是在每个解码步用 query 对全部编码状态动态加权。

缩放点积 Self-Attention 令输入 $X \in \mathbb{R}^{n \times d}$，

$$Q = XW_Q \in \mathbb{R}^{n \times d_k}, \quad K = XW_K \in \mathbb{R}^{n \times d_k}, \quad V = XW_V \in \mathbb{R}^{n \times d_v}.$$

则

$$\mathrm{Attn}(Q, K, V) = \mathrm{softmax}_{\mathrm{row}}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V.$$

$1/\sqrt{d_k}$ 防止维数增大时点积方差过大、softmax 过早饱和。任意两个位置可在一层内直接交互，但注意力矩阵为 $n \times n$，注意力部分的时间与显存分别约为 $O(n^2 d)$ 与 $O(n^2)$；线性投影另需 $O(nd^2)$ 计算。

从 Self-Attention 到 Transformer

- **位置表示：** self-attention 本身不感知次序，故输入写为 $x_i = e_i + p_i$。
- **多头注意力：**

$$\mathrm{head}_r = \mathrm{Attn}(XW_Q^{(r)}, XW_K^{(r)}, XW_V^{(r)}),$$

$$\mathrm{MHA}(X) = \mathrm{Concat}(\mathrm{head}_1, \dots, \mathrm{head}_H) W_O.$$

  不同头在不同投影子空间中捕捉不同关系。
- **逐位置前馈网络：**

$$\mathrm{FFN}(x) = W_2 \phi(W_1 x + b_1) + b_2,$$

  它在注意力的信息混合之后提供非线性特征变换。

- **残差与归一化**：课程采用经典 post-norm 表述

$$\mathrm{LayerNorm}(x + \mathrm{Sublayer}(x)).$$

  残差提供信息与梯度短路径，LayerNorm 稳定层间数值尺度。
- **因果掩码**：自回归模型取

$$M_{ij} = \begin{cases} 0, & j \le i, \\ -\infty, & j > i, \end{cases}$$

  并在 softmax 前将 M 加到注意力得分上，从而严格屏蔽未来 token。

编码器使用双向 self-attention；经典解码器依次使用 masked self-attention、以解码器表示为 Q 且以编码器输出为 K, V 的 cross-attention，以及 FFN。Transformer 消除了时间递归，显著改善并行性和长距离交互路径，但长序列上的二次注意力开销成为新瓶颈。

15 课程第三讲：预训练成本与混合精度

15.1 Lecture 5：参数量、计算量与训练显存

统一记号 考虑 decoder-only Transformer：层数为 l，序列长度为 s，隐藏维数为 h，注意力头数为 a，词表大小为 v，batch size 为 b。以下估算忽略 bias、LayerNorm 参数等低阶项，并取 FFN 中间维数为 $4h$。

参数量 每层注意力的 Q, K, V, O 投影共约 $4h^2$ 个参数，FFN 的两层矩阵共约 $8h^2$ 个参数，因此每个 Transformer block 约有 $12h^2$ 个参数。若输入 embedding 与输出预测矩阵不共享权重，

$$P \approx 12lh^2 + 2vh.$$

若二者权重绑定，则末项约为 vh。当 $12lh^2$ 主导时，常用近似为 $P \approx 12lh^2$。

一次前向与一次训练步的 FLOPs 一次 $m \times n$ 与 $n \times p$ 的矩阵乘法约需 $2mnp$ FLOPs。单层注意力的线性投影约为 $8sh^2$，注意力得分及其与 V 的乘积约为 $4s^2h$，FFN 约为 $16sh^2$。故 batch size 为 1 时，一次前向传播约为

$$C_{\text{fwd}} \approx 24lsh^2 + 4ls^2h + 4svh.$$

乘以 batch size b 即得一个 batch 的前向计算。反向传播的计算量通常约为前向的两倍，因此前向加反向约为 $3C_{\text{fwd}}$。当 block 参数与 h^2 项主导，且总训练 token 数为 T 时，可得到课程强调的数量级关系

$$C_{\text{train}} \approx 6TP.$$

该式是主导项估算，不包含数据处理、通信、重计算及稀疏结构等额外成本。

训练显存分解 训练显存不是只有模型参数，而是

$$M_{\text{train}} = M_{\text{model}} + M_{\text{grad}} + M_{\text{opt}} + M_{\text{act}}.$$

对 P 个参数，梯度约需 P 个同精度元素，Adam 的一阶、二阶矩再需 $2P$ 个状态。若四部分都按 FP32 保存，仅模型、梯度和优化器状态就约为

$$4P \times 4 \text{ Bytes} = 16P \text{ Bytes}.$$

激活值依赖 batch size 和序列长度。按课程中的标准实现估算，忽略 embedding 与输出层的低阶激活后，每层每个样本约需

$$2s^2a + 14sh$$

个激活元素，故

$$M_{\text{act}} \approx b\,l(2s^2a + 14sh) \times q \text{ Bytes},$$

其中 q 是每个激活元素的字节数。隐藏维数很大时参数相关状态占主导；batch size 或序列长度很大时，激活显存可能反而占主导。因此评估能否训练某个模型时，不能只用“参数量 × 每参数字节数”。

15.2 Lecture 6：混合精度训练

数值格式的核心权衡 FP16 由 1 位符号、5 位指数和 10 位尾数组成，最大有限值为 65504，最小正次正规数约为 2^{-24}。FP32 具有更大的指数范围和更高尾数精度，但显存与带宽成本约为 FP16 的两倍。低精度训练的风险是上溢、下溢和小更新被舍入掉。

混合精度的三项关键技术

1. **FP32 主权重**。前向与反向可使用 FP16 权重副本，但更新累积在 FP32 主权重上。若权重与更新量之比过大，FP16 中可能出现

   $$w + \Delta w = w,$$

   即更新因尾数精度不足而完全消失；FP32 主副本保留这些小更新。
2. **Loss scaling**。激活梯度可能小于 FP16 可表示范围。先将损失乘以 $c > 1$，反向传播后再除以 c：

   $$g = \frac{\partial L}{\partial x} = \frac{1}{c}\frac{\partial (cL)}{\partial x}.$$

   这样可把梯度临时移入可表示区间。实际系统常动态调整 c：出现 inf/NaN 时降低，否则逐步提高。
3. **算术精度选择**。矩阵乘法输入可用低精度以提高吞吐，但点积累加与归约通常用 FP32 累积；逐元素运算可更多使用低精度。关键不是所有运算统一降精度，而是对误差敏感的累积保留高精度。

混合精度以少量高精度主状态换取大部分低精度计算和存储，目标是在不明显损害优化稳定性的前提下降低显存、提高吞吐。它不会自动消除激活、梯度或 Adam 状态，只是改变这些量的表示精度；具体显存还取决于实现保留了哪些高精度副本。

16 课程第四讲：分块、逐层与子空间训练

16.1 Lecture 7：块坐标与逐层训练

块坐标更新 将 $x \in \mathbb{R}^d$ 分成 m 个块 $x = (x_1, \dots, x_m)$。第 k 轮只更新块 i_k。精确块最小化为

$$x_{i_k}^{k+1} \in \arg\min_u f(x_1^k, \dots, u, \dots, x_m^k),$$

更常用的块梯度更新为

$$x_{i_k}^{k+1} = x_{i_k}^k - \alpha_{i_k} \nabla_{i_k} f(x^k), \qquad x_j^{k+1} = x_j^k \quad (j \neq i_k).$$

随机问题中把块梯度换为 $\nabla_{i_k} F(x^k; \xi_k)$ 即得 block SGD。

块选择可采用循环、随机打乱、均匀采样、按块 Lipschitz 常数的重要性采样，或 Gauss–Southwell 贪心规则

$$i_k \in \arg\max_i \|\nabla_i f(x^k)\|.$$

贪心选择常能减少迭代数，但需要检查更多块，选择本身可能很贵。

均匀随机块梯度的基本界 若第 i 块梯度关于该块是 L_i-Lipschitz 的，记 $L_{\max} = \max_i L_i$。取 $\alpha = 1/L_{\max}$ 并均匀采样块，则光滑下降式给出

$$\frac{1}{K+1} \sum_{k=0}^{K} \mathbb{E}\|\nabla f(x^k)\|^2 \leq \frac{2mL_{\max}(f(x^0) - f^\star)}{K+1}.$$

只有当计算单个块更新的代价约为全更新的 $1/m$ 时，块方法才具有真正的“坐标友好”计算结构。神经网络反向传播通常仍需完整前向，并需把误差信号传播到目标层，因此逐层训练未必按块数成比例节省 FLOPs。

Layer-wise training 的显存逻辑 把 Transformer 层视为参数块，每次只解冻一层或少数层，其余层冻结，并在选中块上执行若干步 Adam。LISA 使用随机层选择，BAdam 使用块式 Adam；相关延伸 MISA 则进一步按模块重要性采样。共同点是只为活动块保存梯度和 Adam 状态。若各层参数近似均分，活动 r 层、总层数 l，则梯度和优化器状态可由全量的 $P + 2P$ 降至约

$$\frac{r}{l}P + 2\frac{r}{l}P.$$

冻结某些权重后，相应权重梯度所需的部分激活也可不保存，但从输入到活动层的前向计算仍然存在，反向误差信号也必须传播到活动层。因此这类方法的主要收益是显存，而非按 l/r 成比例减少计算。

逐层方法允许在有限显存设备上进行全参数式更新，尤其适合微调；代价是块间耦合被延迟处理、收敛通常慢于同时更新全部参数，而且层选择与每块内循环步数会影响最终效果。

16.2 Lecture 8：子空间与低秩梯度投影

子空间优化统一形式 对矩阵参数 $X \in \mathbb{R}^{m\times n}$，选择低维基 $P_k \in \mathbb{R}^{m\times r}$，$r \ll m$，在子空间中更新：

$$G_k = \nabla_X F(X_k;\xi_k), \qquad \widetilde{G}_k = P_k^\top G_k \in \mathbb{R}^{r\times n}.$$

在低维梯度上应用算子 ρ（如 momentum 或 Adam），再映回原空间：

$$U_k = \rho(\widetilde{G}_k), \qquad X_{k+1} = X_k - \eta P_k U_k.$$

块坐标法是 P_k 取坐标基的特例；一般子空间可为随机子空间或由梯度结构自适应得到的子空间。

GaLore：用低秩状态节省 Adam 显存 GaLore（Gradient Low-Rank Projection）观察到部分层的梯度矩阵具有显著低秩结构，周期性对 G_k 做 SVD，取主导左奇异子空间 P_k，只在

$$\widetilde{G}_k = P_k^\top G_k \in \mathbb{R}^{r\times n}$$

上维护 Adam 的一阶、二阶矩。原参数仍为 $m\times n$，但优化器状态由 $O(mn)$ 降为 $O(rn)$；投影矩阵仅需 $O(mr)$。为降低 SVD 成本，实际常隔若干步才更新一次 P_k（lazy SVD）。

GaLore 与 LoRA 不同：LoRA 把可训练参数限制为低秩适配器；GaLore 仍更新原始全参数，只把梯度和优化器状态投影到低秩子空间。

SVD 子空间的噪声问题与 GoLore 随机梯度可分解为真实梯度加噪声。训练后期真实梯度变小，若噪声主导，则 SVD 可能捕捉噪声的主方向，丢失真正下降信息；因此固定 batch 的随机 GaLore 在一般条件下未必收敛到目标驻点。无噪声或 batch size 随迭代增大时可恢复相应保证，但这对大模型并不总是实际。

GoLore 用从 Stiefel 流形均匀采样的随机正交投影替代 SVD 投影。若 $P_k^\top P_k = I_r$，则

$$\mathbb{E}[P_k P_k^\top] = \frac{r}{m} I_m, \qquad \mathbb{E}\|P_k P_k^\top G - G\|_F^2 = \left(1-\frac{r}{m}\right)\|G\|_F^2.$$

随机投影不追逐某一次噪声的主方向，因而在固定小 batch 的随机情形下仍可得到 $O(K^{-1/2})$ 型驻点收敛率。课程给出的实用折中是：训练早期梯度信号强时用 SVD 捕捉结构，后期噪声占优时切换到随机投影。标准 GaLore/GoLore 若先形成完整梯度再压

缩，主要节省优化器状态，完整梯度及其所需激活仍可能存在；只有计算图原生形成压缩梯度时，才可能进一步节省这些部分。

17 课程第五讲：零阶与分布式优化

17.1 Lecture 9：零阶优化、MeZO 与 LoZO

只用函数值估计梯度 当梯度不可得，或反向传播的激活显存不可承受时，可取 $z \sim \mathcal{N}(0, I_d)$ 并使用双边估计

$$\widehat{\nabla} f(\theta; z) = \frac{f(\theta + \mu z) - f(\theta - \mu z)}{2\mu} z.$$

它只需两次前向计算；期望对应高斯平滑目标的梯度，而非有限 μ 下原目标梯度的严格无偏估计。扰动尺度 μ 太大产生平滑偏差，太小则差分易受浮点误差和随机噪声影响。坐标差分约需 $2d$ 次函数计算；随机方向把单步函数查询降至两次，但方差通常随维数增长。若损失还含 mini-batch 随机性，正负扰动应使用同一批数据以抵消样本噪声。

MeZO：用随机种子复现方向 MeZO 保存随机种子而不保存完整扰动 z。令

$$\widehat{g} = \frac{\ell(\theta + \mu z; \mathcal{B}) - \ell(\theta - \mu z; \mathcal{B})}{2\mu}, \qquad \theta^+ = \theta - \eta \widehat{g} z.$$

实现时用同一种子依次完成正扰动、负扰动、参数复原和更新。由于全过程只有前向计算，不保存反向图、参数梯度和中间激活，核心的 MeZO-SGD 可把训练显存降至接近推理显存。代价是每步至少两次前向、估计方差高且超参数更敏感；若使用动量或 Adam 型零阶变体，仍会产生相应优化器状态。

LoZO：低秩随机方向 对矩阵参数 $W \in \mathbb{R}^{m \times n}$，取

$$Z = UV^\top, \qquad U \in \mathbb{R}^{m \times r}, \quad V \in \mathbb{R}^{n \times r}, \quad r \ll \min\{m, n\},$$

并更新

$$\widehat{g}_W = \frac{\ell(W + \mu Z) - \ell(W - \mu Z)}{2\mu}, \qquad W^+ = W - \eta \widehat{g}_W Z.$$

低秩扰动减少方向的生成与存储成本，并利用矩阵参数的结构；秩 r 控制搜索表达能力与效率的折中。LoZO 是用低秩随机方向估计并更新目标参数，不能与显式训练低秩适配器的 LoRA 混同。

17.2 Lecture 10：并行、去中心化、局部更新与压缩

三类基本并行

- **数据并行**：各设备保存完整模型，处理不同 mini-batch，再用 All-Reduce 聚合梯度。吞吐高、实现直接，但单卡仍需容纳完整模型状态，每步通信量与参数量同阶。

- **张量并行**：把同一层的矩阵运算沿行或列切分到多卡，降低单卡参数和计算负担，但层内通信频繁，依赖高速互连。
- **流水线并行**：把连续层分配给不同设备，以微批量填充流水线；可容纳更深模型，但存在流水线气泡、阶段负载不均和调度复杂度。

实际大模型常组合三种并行。方案选择应同时比较单卡显存、计算负载、通信频率、互连带宽和端到端吞吐。

中心化与去中心化 SGD 设 n 个节点的局部目标为 f_i，全局问题为

$$\min_x f(x), \qquad f(x) = \frac{1}{n}\sum_{i=1}^{n} f_i(x).$$

中心化数据并行在共同模型上聚合局部梯度：

$$x^{k+1} = x^k - \eta_k \frac{1}{n}\sum_{i=1}^{n} g_i^k.$$

去中心化方法只与图上的邻居通信。令 $W = [w_{ij}]$ 为与通信图匹配的混合矩阵，D-PSGD 为

$$x_i^{k+1} = \sum_{j=1}^{n} w_{ij} x_j^k - \eta_k g_i^k.$$

当 W 双随机时，网络平均近似遵循全局 SGD，但各节点在不同 x_i^k 处计算梯度，需额外控制一致性误差。收敛受通信图谱间隙和数据异质性影响。

梯度跟踪增加辅助变量：

$$x_i^{k+1} = \sum_j w_{ij} x_j^k - \eta y_i^k, \qquad y_i^{k+1} = \sum_j w_{ij} y_j^k + g_i^{k+1} - g_i^k.$$

y_i^k 跟踪网络平均梯度，可减轻异质数据造成的偏差，但每轮需同时通信模型和跟踪变量。

Local SGD：以本地计算换通信 每轮通信之间，各节点连续做 H 次本地更新：

$$x_{i,t+1}^r = x_{i,t}^r - \eta g_i(x_{i,t}^r; \xi_{i,t}^r), \quad t = 0, \dots, H-1,$$

$$x^{r+1} = \sum_{i=1}^{n} p_i x_{i,H}^r.$$

增大 H 可减少通信轮数，却会放大本地模型漂移；数据越非独立同分布，漂移通常越严重。因此本地步数、学习率和通信频率必须联合选择。

通信压缩与误差反馈 量化、随机稀疏化、Top-k 和符号压缩能减少传输字节。常见无偏压缩假设为

$$\mathbb{E}[Q(v)] = v, \qquad \mathbb{E}\|Q(v) - v\|^2 \le \omega\|v\|^2.$$

Top-k 等有偏压缩器可能长期丢失小坐标，误差反馈将未发送部分留到下一轮：

$$u_i^k = g_i^k + e_i^k, \qquad q_i^k = Q(u_i^k), \qquad e_i^{k+1} = u_i^k - q_i^k.$$

压缩越强，通信越少，但压缩误差及编码开销通常越大。评价方法时应比较实际字节数与端到端时间，而不只比较发送元素个数。

课程主线 后五讲的共同问题是如何在大模型训练中重新分配资源：

- 混合精度以数值稳定性设计换取更低字节数与更高吞吐；
- 逐层和低秩方法主要减少梯度及优化器状态，但可能增加迭代或投影成本；
- 零阶方法以更多前向查询和更高方差换取不做反向传播；
- 并行、局部更新和压缩分别以同步、模型漂移或压缩误差换取容量与通信效率。

因此不存在脱离硬件、数据异质性和目标精度的“绝对最优”方法；应明确瓶颈究竟是计算、显存还是通信，再选择相应优化策略。

18 深度学习训练问题的优化建模

本节从多分类问题出发，介绍深度学习训练问题如何被表述为一个优化问题。我们首先讨论线性多分类模型，然后引入 softmax 函数与交叉熵损失，最后将其推广到深度神经网络模型，并说明深度学习优化问题的主要困难。

18.1 多分类问题

在许多机器学习任务中，输入样本需要被划分到若干个类别之一。例如，在图像分类中，一张图片可能属于 “cat”、“dog” 或 “ship” 等类别；在人脸识别中，输入图像需要被识别为某一个具体的人。这类问题通常称为多分类问题。

设训练数据集为

$$\{(h_i, y_i)\}_{i=1}^{N},$$

其中 $h_i \in \mathbb{R}^d$ 表示第 i 个样本的特征向量，$y_i \in \{1, \dots, C\}$ 表示对应的类别标签，C 为类别总数。多分类问题的目标是学习一个模型，使其能够根据输入特征 h 判断其所属类别。

线性分类器与类别得分 为了说明基本思想，先考虑一个线性多分类模型。设模型参数为

$$X \in \mathbb{R}^{C\times d}.$$

对于输入特征 $h \in \mathbb{R}^d$，模型输出一个类别得分向量

$$s = Xh \in \mathbb{R}^C.$$

其中 s_j 表示样本 h 属于第 j 类的得分。一般来说，得分越大，模型越倾向于认为该样本属于对应类别。

但是，得分本身并不是概率。为了得到各个类别的预测概率，需要进一步对得分向量进行归一化。

Softmax 函数 给定得分向量 $s = (s_1, \dots, s_C) \in \mathbb{R}^C$，softmax 函数定义为

$$p_j = \frac{\exp(s_j)}{\sum_{k=1}^{C} \exp(s_k)}, \quad j = 1, \dots, C.$$

由定义可知，$p_j \in (0, 1)$，并且

$$\sum_{j=1}^{C} p_j = 1.$$

因此，$p=(p_1,\dots,p_C)$ 可以看作模型对各类别的预测概率分布。

在得到预测概率后，模型通常将输入样本判定为概率最大的类别，即

$$j^*=\arg\max_{1\le j\le C} p_j.$$

交叉熵损失 为了训练模型，需要衡量模型预测概率与真实标签之间的差异。设真实标签采用 one-hot 编码表示，即 $q\in\mathbb{R}^C$，其中真实类别对应的分量为 1，其余分量为 0。若模型预测概率为 $p\in\mathbb{R}^C$，则交叉熵损失定义为

$$H(q,p)=-\sum_{j=1}^{C} q_j\log p_j.$$

由于 q 是 one-hot 向量，若真实类别为 y，则上式可化为

$$H(q,p)=-\log p_y.$$

因此，交叉熵损失越小，说明模型赋予真实类别的概率越大；交叉熵损失越大，则说明模型预测与真实标签之间的差异越大。

线性多分类模型的训练问题 对于训练集 $\{(h_i,y_i)\}_{i=1}^N$，记第 i 个样本的真实标签 one-hot 向量为 q_i，模型预测概率为

$$p_i=\mathrm{softmax}(Xh_i).$$

于是，线性多分类模型的训练可以写成如下优化问题：

$$X^*\in\arg\min_X \frac{1}{N}\sum_{i=1}^{N} H(q_i,p_i),\quad p_i=\mathrm{softmax}(Xh_i).$$

该问题的含义是：在所有可能的模型参数 X 中，寻找一个参数 X^*，使得模型在训练数据上的平均预测误差最小。

当得到训练好的参数 X^* 后，对于新的输入特征 h，模型先计算

$$p=\mathrm{softmax}(X^*h),$$

然后预测其类别为

$$j^*=\arg\max_{1\le j\le C} p_j.$$

18.2 从线性模型到深度神经网络

线性分类器的表达能力有限。为了处理图像、语音、文本等复杂数据，深度学习通常使用深度神经网络。一个典型的深度神经网络可以分为两个部分：

- 特征提取器：用于从原始输入中提取有效特征；
- 分类器：根据提取出的特征输出类别概率。

例如，在卷积神经网络中，卷积层和池化层通常承担特征提取的作用，而全连接层和 softmax 层则用于完成多分类预测。

设深度神经网络模型为

$$h(x;\xi) : \mathbb{R}^d \to \mathbb{R}^C,$$

其中 $x \in \mathbb{R}^d$ 表示需要训练的模型参数，ξ 表示随机输入样本，C 表示类别数。模型输出

$$\hat{y} = h(x;\xi),$$

其中 $\hat{y}$ 表示对输入样本 ξ 的预测概率分布。

深度神经网络训练的优化形式 设真实标签为 $y \in \mathbb{R}^C$，预测结果为 $\hat{y} = h(x;\xi)$。采用交叉熵作为损失函数：

$$L(\hat{y}, y) = -\sum_{j=1}^{C} y_j \log(\hat{y}_j).$$

于是，深度神经网络的训练目标可以写成

$$x^* \in \arg\min_{x\in\mathbb{R}^d} \mathbb{E}_{(\xi,y)\sim\mathcal{D}} \left[L(h(x;\xi), y)\right],$$

其中 $\mathcal{D}$ 表示数据分布。

为了简化记号，令

$$\zeta = (\xi, y), \quad F(x;\zeta) = L(h(x;\xi), y).$$

则上述问题可以简写为

$$x^* \in \arg\min_{x\in\mathbb{R}^d} \mathbb{E}_{\zeta\sim\mathcal{D}} \left[F(x;\zeta)\right].$$

这就是深度学习训练问题在优化理论中的基本形式。大多数深度学习优化算法，例如随机梯度下降、动量法、自适应梯度方法等，都是围绕这一优化模型展开的。

18.3 深度学习优化的主要困难

虽然深度神经网络训练可以形式化为一个优化问题，但该问题通常非常困难，主要原因有以下三点。

- **高度非凸性**
  深度神经网络通常由多层非线性映射复合而成，其损失函数一般是高度非凸的。因此，训练目标通常不是凸优化问题。非凸性带来的困难包括：

- 难以保证找到全局最优解；
- 可能存在大量鞍点和局部极小点；
- 损失景观复杂，算法行为难以完全刻画。

- **参数维度极高**

  现代深度神经网络，尤其是大语言模型，通常包含海量参数。此时优化变量

  $$x \in \mathbb{R}^d$$

  的维度 d 可能非常大。高维参数使得存储、计算和通信成本显著增加，也使传统的二阶优化方法难以直接应用。

- **数据规模巨大**

  深度学习模型往往需要在大规模数据集上训练。特别是在大语言模型预训练中，数据可能来自网页、书籍、代码库和百科等多种来源，规模可达数百 GB 甚至 TB 级别。由于完整计算期望风险或全梯度的代价极高，实际训练通常依赖随机近似方法。

19 前向传播、反向传播与矩阵求导

深度学习模型的训练本质上是一个大规模优化问题。为了利用梯度下降及其变体更新模型参数，需要计算损失函数关于各层参数的梯度。神经网络通常由多层复合函数构成，因此其梯度计算依赖链式法则。反向传播算法正是链式法则在神经网络结构上的系统化实现。

本节首先回顾多元函数的梯度与雅各比矩阵，然后讨论机器学习中常用的列梯度记号，最后通过一个三层神经网络模型说明反向传播的基本推导过程。

19.1 导数记号与常用矩阵求导公式

本节固定若干导数记号，并列出后续推导反向传播时需要用到的基本结论。设 $f : \mathbb{R}^d \to \mathbb{R}$。在数学分析中，常将梯度写成行向量：

$$\frac{\partial f}{\partial x} = \left(\frac{\partial f}{\partial x_1}, \cdots, \frac{\partial f}{\partial x_d} \right) \in \mathbb{R}^{1 \times d}.$$

这种写法的优点是链式法则可以直接写成矩阵乘法。若 $y = g(x) : \mathbb{R}^d \to \mathbb{R}^p$，$f = f(y) : \mathbb{R}^p \to \mathbb{R}$，则

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial y} \frac{\partial y}{\partial x}.$$

其中 $\frac{\partial y}{\partial x} \in \mathbb{R}^{p\times d}$ 是雅各比矩阵：

$$\frac{\partial y}{\partial x} = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_1}{\partial x_d} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_p}{\partial x_1} & \cdots & \frac{\partial y_p}{\partial x_d} \end{pmatrix}.$$

在机器学习和优化中，为了使梯度与变量具有相同形状，通常把梯度写成列向量：

$$\nabla f(x) = \left(\frac{\partial f}{\partial x_1}, \ldots, \frac{\partial f}{\partial x_d}\right)^\top \in \mathbb{R}^d.$$

此时微分写为

$$df = dx^\top \nabla f(x).$$

对应地，若 $y = g(x)$，$f = f(y)$，则链式法则变为

$$\nabla_x f = \left(\frac{\partial y}{\partial x}\right)^\top \nabla_y f.$$

后续反向传播中，我们主要采用列梯度记号。

对于矩阵变量 $X = (x_{ij}) \in \mathbb{R}^{m\times n}$，若 $f : \mathbb{R}^{m\times n} \to \mathbb{R}$，则矩阵梯度定义为

$$\nabla f(X) = \begin{pmatrix} \frac{\partial f}{\partial x_{11}} & \cdots & \frac{\partial f}{\partial x_{1n}} \\ \vdots & \ddots & \vdots \\ \frac{\partial f}{\partial x_{m1}} & \cdots & \frac{\partial f}{\partial x_{mn}} \end{pmatrix} \in \mathbb{R}^{m\times n}.$$

即矩阵梯度与矩阵变量具有相同形状。矩阵微分常用 Frobenius 内积表示：

$$\langle A, B\rangle_F = \operatorname{tr}(A^\top B), \quad df = \langle \nabla f(X), dX\rangle_F.$$

后续最常用的是线性层的矩阵求导公式。设

$$y = Wx, \quad x \in \mathbb{R}^d, \quad W \in \mathbb{R}^{p\times d}, \quad y \in \mathbb{R}^p,$$

且 $f = f(y)$。若采用列梯度记号，则

$$\frac{\partial f}{\partial W} = \frac{\partial f}{\partial y} x^\top.$$

也就是说，线性层权重矩阵的梯度等于“输出端反向传播回来的梯度”与“输入向量转置”的乘积。

若 $z = \phi(h)$，其中 ϕ 是逐分量作用的激活函数，即

$$z_i = \phi(h_i), \quad i = 1, \ldots, m,$$

则其雅各比矩阵为对角矩阵

$$\frac{\partial z}{\partial h} = \mathrm{Diag}(\phi'(h)).$$

因此，对任意向量 $v \in \mathbb{R}^m$，有

$$\left(\frac{\partial z}{\partial h}\right)^{\top} v = \phi'(h) \odot v.$$

这里 $\odot$ 表示 Hadamard 乘积。该公式说明，在反向传播中，经过激活函数层时，只需将反向传播向量与 $\phi'(h)$ 做逐分量乘积即可。

综上，后续推导主要使用三条规则：

- 若 $y = g(x)$，则列梯度满足 $\nabla_x f = \left(\frac{\partial y}{\partial x}\right)^{\top} \nabla_y f$；
- 若 $y = Wx$，则 $\frac{\partial f}{\partial W} = \frac{\partial f}{\partial y} x^{\top}$；
- 若 $z = \phi(h)$，则 $\frac{\partial f}{\partial h} = \phi'(h) \odot \frac{\partial f}{\partial z}$。

19.2 三层神经网络的前向传播

考虑如下三层神经网络：

$$h_1 = W_1 x, \quad z_1 = \phi(h_1),$$

$$h_2 = W_2 z_1, \quad z_2 = \phi(h_2),$$

$$\hat{y} = W_3 z_2, \quad f = L(y, \hat{y}).$$

其中

$$x \in \mathbb{R}^d, \quad W_1 \in \mathbb{R}^{p \times d}, \quad h_1, z_1 \in \mathbb{R}^p,$$

$$W_2 \in \mathbb{R}^{q \times p}, \quad h_2, z_2 \in \mathbb{R}^q,$$

$$W_3 \in \mathbb{R}^{s \times q}, \quad \hat{y} \in \mathbb{R}^s.$$

这里 x 是输入，y 是真实标签，$\hat{y}$ 是模型输出，f 是损失函数。函数 ϕ 是逐分量作用的激活函数，即

$$\phi(h) = (\phi(h_1), \ldots, \phi(h_m))^{\top}.$$

前向传播的作用是：在给定参数 W_1, W_2, W_3 和输入 x 后，依次计算

$$h_1, z_1, h_2, z_2, \hat{y}, f.$$

反向传播的作用是：在前向传播结果的基础上，计算

$$\frac{\partial f}{\partial W_3}, \quad \frac{\partial f}{\partial W_2}, \quad \frac{\partial f}{\partial W_1}.$$

19.2.1 关于最后一层参数的梯度

首先考虑 W_3。因为

$$\hat{y} = W_3 z_2,$$

由线性层矩阵求导公式可得

$$\frac{\partial f}{\partial W_3} = \frac{\partial f}{\partial \hat{y}} z_2^\top.$$

其中 $\frac{\partial f}{\partial \hat{y}}$ 可以由损失函数 $L(y, \hat{y})$ 直接计算得到，z_2 已经在前向传播中得到。

19.2.2 关于第二层参数的梯度

接下来计算 W_2。由于

$$h_2 = W_2 z_1,$$

由线性层矩阵求导公式得到

$$\frac{\partial f}{\partial W_2} = \frac{\partial f}{\partial h_2} z_1^\top.$$

因此关键是计算 $\frac{\partial f}{\partial h_2}$。

根据链式法则，

$$\frac{\partial f}{\partial h_2} = \left(\frac{\partial z_2}{\partial h_2}\right)^\top \left(\frac{\partial \hat{y}}{\partial z_2}\right)^\top \frac{\partial f}{\partial \hat{y}}.$$

由于 $\hat{y} = W_3 z_2$，所以

$$\frac{\partial \hat{y}}{\partial z_2} = W_3.$$

又因为 $z_2 = \phi(h_2)$ 是逐分量激活函数，所以它的雅各比矩阵是对角矩阵：

$$\frac{\partial z_2}{\partial h_2} = \mathrm{Diag}(\phi'(h_2)).$$

因此

$$\frac{\partial f}{\partial h_2} = \mathrm{Diag}(\phi'(h_2)) W_3^\top \frac{\partial f}{\partial \hat{y}}.$$

在计算实现中，通常不用显式构造对角矩阵，而是写成 Hadamard 乘积形式：

$$\frac{\partial f}{\partial h_2} = \phi'(h_2) \odot \left(W_3^\top \frac{\partial f}{\partial \hat{y}}\right).$$

于是

$$\frac{\partial f}{\partial W_2} = \left[\phi'(h_2) \odot \left(W_3^\top \frac{\partial f}{\partial \hat{y}}\right)\right] z_1^\top.$$

19.2.3 关于第一层参数的梯度

最后计算 W_1。由于

$$h_1 = W_1 x,$$

由线性层矩阵求导公式得到

$$\frac{\partial f}{\partial W_1} = \frac{\partial f}{\partial h_1} x^\top.$$

因此需要继续计算 $\frac{\partial f}{\partial h_1}$。

根据链式法则，

$$\frac{\partial f}{\partial h_1} = \left(\frac{\partial z_1}{\partial h_1}\right)^\top \left(\frac{\partial h_2}{\partial z_1}\right)^\top \frac{\partial f}{\partial h_2}.$$

由于 $h_2 = W_2 z_1$，所以

$$\frac{\partial h_2}{\partial z_1} = W_2.$$

又因为 $z_1 = \phi(h_1)$，所以

$$\frac{\partial z_1}{\partial h_1} = \mathrm{Diag}(\phi'(h_1)).$$

因此

$$\frac{\partial f}{\partial h_1} = \mathrm{Diag}(\phi'(h_1)) W_2^\top \frac{\partial f}{\partial h_2}.$$

用 Hadamard 乘积表示为

$$\frac{\partial f}{\partial h_1} = \phi'(h_1) \odot \left(W_2^\top \frac{\partial f}{\partial h_2}\right).$$

于是

$$\frac{\partial f}{\partial W_1} = \left[\phi'(h_1) \odot \left(W_2^\top \frac{\partial f}{\partial h_2}\right)\right] x^\top.$$

19.3 反向传播的本质

反向传播并不是一种新的求导规则，而是链式法则在复合函数结构上的高效实现。对于多层神经网络，前向传播负责计算每一层的中间变量，反向传播则利用这些中间变量，从输出层开始逐层计算梯度。

越靠近输出层的参数，其梯度依赖的信息越少；越靠近输入层的参数，其梯度需要经过更多层的链式传递。因此，梯度计算自然呈现出从后向前的传播过程。

从优化角度看，反向传播的作用是为梯度下降类方法提供梯度信息。若学习率为 $\alpha > 0$，则参数更新可以写为

$$W_\ell^{k+1} = W_\ell^k - \alpha \frac{\partial f}{\partial W_\ell}, \quad \ell = 1, 2, 3.$$

对于更深的神经网络，反向传播公式具有完全类似的递推结构，只是层数更多、参数规模更大。

20 随机梯度下降方法 (SGD)

深度神经网络训练通常可以写成一个随机优化问题。与传统确定性优化不同，随机优化中的目标函数往往是某个样本损失关于数据分布的期望，而数据分布通常未知。因此，算法无法直接使用完整目标函数或完整梯度，只能通过随机采样构造梯度估计。随机梯度下降方法正是处理这类问题的基本算法。

随机优化模型 考虑如下随机优化问题：

$$\min_{x\in\mathbb{R}^d} f(x) = \mathbb{E}_{\xi\sim\mathcal{D}}[F(x;\xi)],$$

其中 ξ 表示随机样本，$\mathcal{D}$ 表示数据分布，$F(x;\xi)$ 表示参数 x 在样本 ξ 上的损失函数。这里假设 $F(x;\xi)$ 关于 x 可微。

在深度学习中，若训练数据来自分布 $\mathcal{D}$，每个样本记为 (a,b)，其中 a 是输入数据，b 是真实标签。设神经网络模型为 $h(x;a)$，损失函数为 $L(h(x;a),b)$，则训练问题可以写成

$$\min_{x\in\mathbb{R}^d} \mathbb{E}_{(a,b)\sim\mathcal{D}}[L(h(x;a),b)].$$

令 $\xi=(a,b)$，并记

$$F(x;\xi) = L(h(x;a),b),$$

则上式就是一般随机优化问题

$$\min_{x\in\mathbb{R}^d} \mathbb{E}_{\xi\sim\mathcal{D}}[F(x;\xi)].$$

如果训练集是有限样本集 $\{(a_i,b_i)\}_{i=1}^m$，则对应的经验风险最小化问题为

$$\min_{x\in\mathbb{R}^d} \frac{1}{m}\sum_{i=1}^m L(h(x;a_i),b_i).$$

它可以看作随机优化问题在有限样本分布上的特殊情形。

20.1 随机梯度下降方法 (SGD)

对于随机优化问题

$$\min_{x\in\mathbb{R}^d} f(x) = \mathbb{E}_{\xi\sim\mathcal{D}}[F(x;\xi)],$$

由于数据分布 $\mathcal{D}$ 通常未知，目标函数 $f(x)$ 的闭式表达一般无法得到，因此标准梯度下降法

$$x^{k+1} = x^k - \gamma\nabla f(x^k)$$

通常不可直接使用。

随机梯度下降方法的基本思想是：在第 k 次迭代中随机抽取一个样本 ξ_k，用样本梯度 $\nabla F(x^k;\xi_k)$ 代替真实梯度 $\nabla f(x^k)$，并进行如下更新：

$$x^{k+1} = x^k - \gamma \nabla F(x^k;\xi_k), \quad k = 0, 1, \ldots.$$

其中 $\gamma > 0$ 是学习率。

设 $\mathcal{F}_k = \{x_k, \xi_{k-1}, x_{k-1}, \ldots, \xi_0\}$ 为包含迭代次数 k 及之前所有历史变量（不含 ξ_k）的迭代集合。

假设 20.1 给定迭代集合 $\mathcal{F}_k$，假设

$$\mathbb{E}\left[\nabla F(x_k;\xi_k) \mid \mathcal{F}_k\right] = \nabla f(x_k)$$

$$\mathbb{E}\left[\|\nabla F(x_k;\xi_k) - \nabla f(x_k)\|^2 \mid \mathcal{F}_k\right] \le \sigma^2$$

这意味着随机梯度是无偏的，且方差有界。

非凸光滑情形下的收敛性

定理 20.1 设 $f(x)$ 为 L-光滑函数，且假设 20.1成立。若学习率 $\gamma \le 1/L$，则 SGD 的收敛率满足

$$\frac{1}{K+1}\sum_{k=0}^{K}\mathbb{E}\left[\|\nabla f(x_k)\|^2\right] \le \frac{2\Delta_0}{\gamma(K+1)} + \gamma L\sigma^2,$$

其中 $\Delta_0 = f(x_0) - f^*$。

- 固定学习率下，SGD 无法收敛到稳定点
- 较小的学习率 γ 或方差 σ^2 会带来更小的收敛误差

推论 20.2 设 $f(x)$ 为 L-光滑函数，且假设 20.1成立。若选择学习率

$$\gamma = \left[\left(\frac{2\Delta_0}{(K+1)L\sigma^2}\right)^{-1/2} + L\right]^{-1},$$

则 SGD 的收敛率满足

$$\frac{1}{K+1}\sum_{k=0}^{K}\mathbb{E}\left[\|\nabla f(x_k)\|^2\right] \le \sqrt{\frac{8L\Delta_0\sigma^2}{K+1}} + \frac{2L\Delta_0}{K+1},$$

其中 $\Delta_0 = f(x_0) - f^*$。

$$\frac{1}{K+1}\sum_{k=0}^{K}\mathbb{E}\,\|\nabla f(x_k)\|^2 = O\left(\sqrt{\frac{L\sigma^2}{K+1}} + \frac{L}{K+1}\right)$$

- 当迭代次数 $K \to \infty$ 时，有 $\mathbb{E}\left\|\nabla f(x_K)\right\|^2 \to 0$
- $\mathbb{E}\left\|\nabla f(x_K)\right\|^2 \to 0$ 意味着 SGD 收敛到一个稳定解
- 稳定解可以是局部极小、局部极大或鞍点
- 一般来说，收敛到稳定点是 SGD 能达到的最好结果，无法保证收敛到全局极小
- 经验上，SGD 在训练深度神经网络时表现极佳
- 近期研究表明，SGD 可以逃离局部极大、鞍点，甚至“尖锐”的局部极小
- 在某些条件下（如 PL 条件），SGD 甚至可以找到全局极小

凸光滑情形下的收敛性

定理 20.3 设 $f(x)$ 为凸且 L-光滑函数。在假设 20.1下，若学习率 $\gamma \leq 1/(2L)$，则 SGD 的收敛率满足

$$\frac{1}{K+1}\sum_{k=0}^{K}\mathbb{E}[f(x_k)-f(x^*)] \leq \frac{\Delta_0}{\gamma(K+1)}+\gamma\sigma^2$$

其中 $\Delta_0 = \|x_0 - x^*\|^2$。若进一步选择学习率

$$\gamma = \left[\left(\frac{\Delta_0}{(K+1)\sigma^2}\right)^{-1/2} + 2L\right]^{-1},$$

则 SGD 的收敛率为

$$\frac{1}{K+1}\sum_{k=0}^{K}\mathbb{E}[f(x_k)-f(x^*)] \leq 2\sqrt{\frac{\sigma^2\Delta_0}{K+1}}+\frac{2L\Delta_0}{K+1}.$$

该收敛率是紧的，当 $\sigma^2 = 0$ 时退化为梯度下降（GD）的收敛率。

强凸光滑情形下的收敛性

定理 20.4 设 $f(x)$ 为 μ-强凸且 L-光滑函数。在假设 20.1下，若学习率 $\gamma \leq 1/L$，则 SGD 的收敛率满足

$$\mathbb{E}[f(x_k)] - f^* \leq (1-\gamma\mu)^k\Delta_0 + \frac{\gamma L\sigma^2}{\mu}.$$

其中 $\Delta_0 = f(x_0) - f^*$。若进一步选择学习率

$$\gamma = \min\left\{\frac{1}{L}, \frac{1}{\mu K}\ln\left(\frac{\mu^2\Delta_0 K}{L\sigma^2}\right)\right\},$$

则 SGD 的收敛率为

$$\mathbb{E}[f(x_K)] - f^* = \tilde{O}\left(\frac{L\sigma^2}{\mu^2 K} + \Delta_0\exp\left(-\frac{\mu}{L}K\right)\right),$$

其中 $\tilde{O}(\cdot)$ 记号省略了所有对数项。该收敛率是紧的，当 $\sigma^2 = 0$ 时退化为梯度下降（GD）的收敛率。

- 当 $\sigma^2 = 0$ 时，SGD 退化为 GD
- σ^2 的存在会显著降低收敛速度

算法	场景	收敛率	复杂度
SGD	非凸	$\frac{\sigma}{\sqrt{K}}+\frac{1}{K}$	$\frac{\sigma^2}{\epsilon^2}+\frac{1}{\epsilon}$
	一般凸	$\frac{\sigma}{\sqrt{K}}+\frac{1}{K}$	$\frac{\sigma^2}{\epsilon^2}+\frac{1}{\epsilon}$
	强凸	$\frac{\sigma^2}{K}+\exp(-K)$	$\frac{\sigma^2}{\epsilon}+\ln\left(\frac{1}{\epsilon}\right)$
GD	非凸	$\frac{1}{K}$	$\frac{1}{\epsilon}$
	一般凸	$\frac{1}{K}$	$\frac{1}{\epsilon}$
	强凸	$\exp(-K)$	$\ln\left(\frac{1}{\epsilon}\right)$

20.2 SGD with mini-batch

在深度神经网络（DNN）中，通常会采样一批数据来估计梯度。小批量 SGD 的迭代方式如下：

$$g_k=\frac{1}{B}\sum_{b=1}^{B}\nabla F(x_k;\xi_k^{(b)}),$$
$$x_{k+1}=x_k-\gamma g_k,$$

其中 B 为批量大小。B 个样本一起可以提供对 $\nabla f(x)$ 更好的估计

我们首先引入滤波

$$\mathcal{F}_k^B=\left\{x_k,\{\xi_{k-1}^{(b)}\}_{b=1}^B,x_{k-1},\{\xi_{k-2}^{(b)}\}_{b=1}^B,\dots,x_0\right\}.$$

假设 20.2 给定滤波 $\mathcal{F}_k^B$，我们假设

$$\mathbb{E}\left[\nabla F(x_k;\xi_k^{(b)})\mid\mathcal{F}_k^B\right]=\nabla f(x_k),$$
$$\mathbb{E}\left[\left\|\nabla F(x_k;\xi_k^{(b)})-\nabla f(x_k)\right\|^2\mid\mathcal{F}_k^B\right]\le\sigma^2.$$

此外，假设对任意 k，$\{\xi_k^{(b)}\}_{b=1}^B$ 相互独立。

这意味着小批量可以提供对 $\nabla f(x)$ 更好的估计：

$$\mathbb{E}\left[\|g_k-\nabla f(x_k)\|^2\mid\mathcal{F}_k^B\right]=\frac{1}{B^2}\sum_{b=1}^{B}\mathbb{E}\left[\left\|\nabla F(x_k;\xi_k^{(b)})-\nabla f(x_k)\right\|^2\mid\mathcal{F}_k^B\right]\le\frac{\sigma^2}{B}.$$

定理 20.5 设 $f(x)$ 为 L-光滑函数，且假设 20.2成立。小批量 SGD 的收敛率为

$$\frac{1}{K+1}\sum_{k=0}^{K}\mathbb{E}\left[\|\nabla f(x_k)\|^2\right]=O\left(\sqrt{\frac{L\Delta_0\sigma^2}{B(K+1)}}+\frac{L\Delta_0}{K+1}\right),$$

其中 $\Delta_0=f(x_0)-f^*$。

- 较大的批量大小可以加速收敛；当 $B=1$ 时退化为 SGD
- 类似的结果在凸和强凸场景中同样成立

凸性	SGD	小批量 SGD
非凸	$\frac{L}{\epsilon^2}$	$\frac{L}{B\epsilon^2}$
凸	$\frac{L}{\epsilon^2}$	$\frac{L}{B\epsilon^2}$
强凸	$\frac{L}{\mu\epsilon}$	$\frac{L}{\mu B\epsilon}$

20.3 带动量的随机梯度下降（Momentum SGD）

带 Polyak 动量的梯度下降 为了加速算法，我们需要缓解梯度下降过程中的“之字形”振荡问题。Polyak 动量法，又称重球梯度法，其迭代公式为：

$$x_k = x_{k-1} - \gamma \nabla f(x_{k-1}) + \beta(x_{k-1} - x_{k-2})$$

其中 $\beta \in (0, 1)$ 为动量参数。

带 Nesterov 动量的梯度下降 带 Nesterov 动量的梯度下降，又称 Nesterov 加速梯度法（NAG），其迭代公式为：

$$y_{k-1} = x_{k-1} + \beta(x_{k-1} - x_{k-2})$$

$$x_k = y_{k-1} - \gamma \nabla f(y_{k-1})$$

其中 $\beta \in (0, 1)$ 为动量参数。

带动量的随机梯度下降（Momentum SGD） 回顾随机优化问题：

$$\min_{x \in \mathbb{R}^d} \mathbb{E}_{\xi \in \mathcal{D}}[F(x; \xi)]$$

标准 SGD 算法的迭代公式为：

$$x_{k+1} = x_k - \gamma \nabla F(x_k; \xi_k)$$

带动量的 SGD 迭代公式为：

$$x_{k+1} = x_k - \gamma \nabla F(x_k; \xi_k) + \beta(x_k - x_{k-1})$$

其中 $\beta \in [0, 1)$ 为动量系数。

动量 SGD 的等价形式

- 动量 SGD 可以重写为以下形式（这也是程序中的实现方式）：

$$m_k = \beta m_{k-1} + \nabla F(x_k; \xi_k)$$

$$x_{k+1} = x_k - \gamma m_k$$

其中 $m_0 = 0$。

- 推导过程：从第二式出发，我们有

$$\beta x_k = \beta x_{k-1} - \gamma\beta m_{k-1}.$$

将其从原式中减去，可得：

$$\begin{aligned} x_{k+1} - \beta x_k &= x_k - \beta x_{k-1} - \gamma(m_k - \beta m_{k-1}) \\ &= x_k - \beta x_{k-1} - \gamma\nabla F(x_k;\xi_k). \end{aligned}$$

整理后，即可得到原始的动量 SGD 迭代公式。

20.4 自适应 SGD

预处理梯度下降（Preconditioned GD） 预处理梯度下降算法的迭代公式为：

$$x_{k+1} = x_k - \gamma P_k \nabla f(x_k)$$

其中 P_k 随迭代次数 k 变化。

预处理矩阵 P_k 的选择至关重要。若取 $P_k = [\nabla^2 f(x_k)]^{-1}$，则预处理梯度下降退化为牛顿法。构造高效且有效的 P 矩阵是预处理方法的核心。

预处理随机梯度下降（Preconditioned SGD） 与预处理梯度下降类似，预处理随机梯度下降的迭代公式为：

$$x_{k+1} = x_k - \gamma P_k \nabla F(x_k;\xi_k)$$

不过问题是这些高阶算法在大模型时代并不适用，因为数据量实在是太大了。

自适应梯度法（AdaGrad） 自适应梯度方法的迭代过程如下：

$$\begin{aligned} g_k &= \nabla F(x_k;\xi_k) \\ s_k &= s_{k-1} + g_k \odot g_k \\ x_{k+1} &= x_k - \frac{\gamma}{\sqrt{s_k} + \epsilon} \odot g_k \end{aligned}$$

其中 $1/\sqrt{s_k} = \mathrm{col}\{1/\sqrt{s_{k,1}}, \ldots, 1/\sqrt{s_{k,d}}\} \in \mathbb{R}^d$ 为逐元素操作；s_0 初始化为 0；ϵ 是为了数值稳定性而添加的一个小常数。

- 这个方法对每个梯度分量都有个学习率
- AdaGrad 属于预处理随机梯度下降（preconditioned SGD）方法。

- 若定义预处理矩阵

$$P_k = \operatorname{diag}\left\{\frac{1}{\sqrt{s_{k,1}}+\epsilon}, \ldots, \frac{1}{\sqrt{s_{k,d}}+\epsilon}\right\} \in \mathbb{R}^{d\times d},$$

  则 AdaGrad 的迭代公式可写为：

$$x_{k+1} = x_k - \gamma P_k g_k$$

  其中 P_k 是随时间变化的预处理矩阵。
- AdaGrad 对梯度较大的方向施加较小的学习率。
- AdaGrad 对梯度较小的方向施加较大的学习率。

RMSProp 由于 s_k 会不断累积增大，AdaGrad 中的有效学习率 γ_k 会持续下降。这可能导致 AdaGrad 收敛速度变慢。RMSProp 提出了一种不同的方式来构造 s_k, 其更新过程如下：

$$\begin{aligned} g_k &= \nabla F(x_k;\xi_k) \\ s_k &= \beta s_{k-1} + (1-\beta) g_k \odot g_k \\ x_{k+1} &= x_k - \frac{\gamma}{\sqrt{s_k}+\epsilon} \odot g_k \end{aligned}$$

其中 s_0 初始化为 0，ϵ 是为了数值稳定性而添加的一个小常数。$\beta \in (0,1)$，典型取值为 0.9。在 RMSProp 中，只有最近的梯度 g_k 会显著影响收敛速度。

Adam Adam 同时使用动量和自适应学习率来缓解优化过程中的“之字形”振荡问题。其迭代过程如下：

$$\begin{aligned} g_k &= \nabla F(x_k;\xi_k) \\ m_k &= \beta_1 m_{k-1} + (1-\beta_1) g_k \\ s_k &= \beta_2 s_{k-1} + (1-\beta_2) g_k \odot g_k \\ x_{k+1} &= x_k - \frac{\gamma}{\sqrt{s_k}+\epsilon} \odot m_k \end{aligned}$$

其中 m_0 和 s_0 初始化为 0；ϵ 是为了数值稳定性而添加的一个小常数。推荐设置为 $\beta_1 = 0.9$，$\beta_2 = 0.999$。

后续的大模型训练方法基本都是基于 Adam 方法求解的。

21 大语言模型基础

神经网络 神经元 = 仿射映射 + 非线性激活函数。在实际应用中，会使用多种不同的激活函数。

神经元的数学模型为：

$$y = f\left(\sum_i w_i x_i + b\right)$$

其中：x_i 为输入信号；w_i 为连接权重；b 为偏置项；$f(\cdot)$ 为非线性激活函数。

常见的激活函数包括：

- **Sigmoid**：$f(x) = \dfrac{1}{1+e^{-x}}$
- **Tanh**：$f(x) = \dfrac{e^{x}-e^{-x}}{e^{x}+e^{-x}}$
- **ReLU**：$f(x) = \max(0, x)$

全连接神经网络可以逼近任意连续函数。对于任意连续函数 $f(x)$ 和任意 $\epsilon > 0$，存在一个仅含单隐藏层（并采用合理的非线性激活函数，例如 sigmoid）的神经网络 $g(x)$，使得：

$$\|f(x) - g(x)\| \leq \epsilon$$

21.1 词表示与统计语言模型

词表示

- 给定词表 $\mathcal{V} = \{w_1, \ldots, w_{|\mathcal{V}|}\}$，one-hot 表示用 $e_i \in \mathbb{R}^{|\mathcal{V}|}$ 表示第 i 个词，其中仅第 i 个分量为 1。
- one-hot 表示无法刻画语义相似性，因为任意两个不同词的 one-hot 向量都是正交的。
- 词嵌入将词映射为低维稠密向量 $v_i \in \mathbb{R}^d$，其中 $d \ll |\mathcal{V}|$，使语义相近的词在向量空间中更接近。
- 设嵌入矩阵 $E \in \mathbb{R}^{d\times|\mathcal{V}|}$，则 $v_i = Ee_i$，即词向量 v_i 是 E 的第 i 列。
- 嵌入矩阵 E 需要训练得到，很大大公司已经训练出来了。

语言模型

语言模型的任务是根据已有上下文预测下一个词。设当前词序列为

$$x^{(1)}, x^{(2)}, \ldots, x^{(t)},$$

其中 $x^{(i)} \in \mathcal{V}$，则语言模型需要估计条件概率

$$P(x^{(t+1)} \mid x^{(t)}, x^{(t-1)}, \ldots, x^{(1)}).$$

也就是说，语言模型输出的是下一个词在整个词表上的概率分布。该模型可用于输入法联想、搜索补全、文本补全和文本生成等任务。

n-gram 语言模型

n-gram 语言模型是一种经典的统计语言模型。其基本思想是用最近的 $n-1$ 个词近似全部历史信息，即

$$P(x^{(t+1)} \mid x^{(t)}, \dots, x^{(1)}) \approx P(x^{(t+1)} \mid x^{(t)}, x^{(t-1)}, \dots, x^{(t-n+2)}).$$

在实际中，该条件概率通常由语料中的频数估计：

$$P(x^{(t+1)} \mid x^{(t)}, \dots, x^{(t-n+2)}) \approx \frac{\text{count}(x^{(t+1)}, x^{(t)}, \dots, x^{(t-n+2)})}{\text{count}(x^{(t)}, \dots, x^{(t-n+2)})}.$$

例如，在一个 4-gram 模型中，下一个词只依赖于前面三个词。若上下文为 “students opened their”，则对候选词 w，有

$$P(w \mid \text{students opened their}) \approx \frac{\text{count}(\text{students opened their } w)}{\text{count}(\text{students opened their})}.$$

如果 “students opened their books” 在语料中出现较多，则模型会给 “books” 较高的概率。

n-gram 模型也可以用于文本生成：给定初始上下文，模型根据最近的 $n-1$ 个词预测下一个词，然后将生成的新词加入上下文，继续预测后续词语。其主要局限是：

- **上下文有限**：模型只利用最近的 $n-1$ 个词，难以刻画长距离依赖，因此生成文本可能局部通顺但整体连贯性不足；
- **数据稀疏**：随着 n 增大，可能的 n-gram 数量迅速增加，许多合理词组在语料中可能从未出现；
- **存储成本高**：n-gram 模型需要保存大量词组及其频数，词表和语料规模越大，存储压力越明显。

21.2 神经语言模型 (RNN)

n-gram 语言模型通过统计词组频数估计下一个词的概率，但容易受到数据稀疏和存储成本的限制。神经语言模型的基本思想是：先将词表示为低维词向量，再用神经网络学习 “上下文 $\rightarrow$ 下一个词概率分布” 的映射。

固定窗口神经语言模型

固定窗口神经语言模型只利用最近 m 个词预测下一个词。给定上下文窗口

$$x^{(1)}, x^{(2)}, \dots, x^{(m)},$$

先通过嵌入矩阵得到词向量并将其拼接为

$$e = [e^{(1)}; e^{(2)}; \cdots; e^{(m)}].$$

然后通过神经网络计算隐藏表示和预测概率：

$$h = \phi(We + b_1), \quad \hat{y} = \mathrm{softmax}(Uh + b_2) \in \mathbb{R}^{|\mathcal{V}|}.$$

其中 $\hat{y}_j$ 表示下一个词为词表中第 j 个词的概率。

与 n-gram 模型相比，固定窗口神经语言模型不再直接存储词组频数，而是通过参数学习上下文与下一个词之间的关系，并利用词嵌入缓解数据稀疏问题。但它仍然只能利用固定长度上下文：**窗口太短难以捕捉长程依赖，窗口太长又会增加输入维度和模型参数量。**

循环神经网络语言模型

循环神经网络（RNN）通过隐藏状态递推处理变长序列。给定词序列

$$x^{(1)}, x^{(2)}, \ldots, x^{(T)},$$

将每个词映射为词向量 $e^{(t)}$，并递推计算隐藏状态 **(注意 $h^{(t)}$ 相当于在保留历史信息)**：

$$h^{(t)} = \phi(W_h h^{(t-1)} + W_e e^{(t)} + b_1).$$

随后根据隐藏状态预测下一个词：

$$\hat{y}^{(t)} = \mathrm{softmax}(Uh^{(t)} + b_2).$$

其中 $h^{(0)}$ 通常取为零向量或可学习参数，模型参数 (需要训练) 为

$$\theta = \{W_h, W_e, U, b_1, b_2\}.$$

RNN 的关键特点是参数共享：同一组参数在所有时间步重复使用，因此模型可以处理不同长度的序列，且参数量不随序列长度线性增长。隐藏状态 $h^{(t)}$ 可看作对历史信息 $x^{(1)}, \ldots, x^{(t)}$ 的压缩表示，用于预测后续词语。

RNN 语言模型的训练与生成

- **训练目标：**给定序列 $x^{(1)}, \ldots, x^{(T)}$，RNN 在第 t 步根据历史信息预测下一个词 $x^{(t+1)}$，输出概率分布 $\hat{y}^{(t)}$。
- **损失函数：**若真实下一个词的 one-hot 向量为 $y^{(t+1)}$，则

$$J^{(t)}(\theta) = -\sum_{j=1}^{|\mathcal{V}|} y_j^{(t+1)} \log \hat{y}_j^{(t)} = -\log \hat{y}_{x^{(t+1)}}^{(t)}.$$

整段序列的平均损失为

$$J(\theta) = \frac{1}{T} \sum_{t=1}^{T} J^{(t)}(\theta).$$

- **文本生成**：RNN 与 n-gram 模型类似，都是逐词生成；但 RNN 依赖隐藏状态保存历史信息，而不是固定长度窗口，因此更适合处理变长序列。
- **训练困难**：RNN 的隐藏状态沿时间递推，长序列反向传播时容易出现梯度消失或梯度爆炸，导致长距离依赖难以学习、训练不稳定。

RNN 的变种

- 双向 RNN (Bidirectional RNN): 从前往后 + 从后往前，适合完形填空、词义理解
- 多层次 RNN (Muti-layer RNNs)

21.3 序列到序列模型与注意力机制

Seq2Seq 模型

序列到序列 (Seq2Seq) 模型是一类编码器-解码器结构，用于将输入序列映射为输出序列。设输入序列为 $x = (x_1, x_2, \ldots, x_T)$, 输出序列为 $y = (y_1, y_2, \ldots, y_{T'})$. 编码器将输入序列映射为一组隐藏状态

$$h^{(t)} = \text{EncoderRNN}(x_t, h^{(t-1)}), \quad t = 1, \ldots, T,$$

最终编码状态 $h^{(T)}$ 被作为解码器初始状态，解码器递推生成输出：

$$\hat{y}_{t'} = \text{DecoderRNN}(h_{t'-1}, \hat{y}_{t'-1}), \quad t' = 1, \ldots, T'.$$

训练目标为最小化序列预测交叉熵：

$$\mathcal{L} = -\sum_{t'=1}^{T'} \log P(y_{t'} \mid y_1, \ldots, y_{t'-1}, x).$$

Seq2Seq 模型可用于机器翻译、文本摘要、对话生成、语法解析和代码生成等任务。Seq2Seq 本质上是一个条件语言模型。

Seq2Seq+RNN 的历史信息瓶颈

RNN 假设隐藏状态 $h^{(t)}$ 包含了序列 $x_1, \ldots, x_t$ 的全部信息：

$$h^{(t)} = f(h^{(t-1)}, x_t).$$

但在实际情况中，当序列较长时，早期输入的信息可能在梯度传播过程中丢失，导致长距离依赖难以学习。这说明 RNN 的单一隐藏状态无法完全保留历史上下文。

注意力机制 (Attention)

传统 Seq2Seq 模型通常用 Encoder 的最后一个隐藏状态概括整个输入序列，这容易造成信息瓶颈：当源句较长时，前面词语的信息可能在递归传递中逐渐丢失。注意力机制的思想是：Decoder 在生成每个词时，不只依赖当前隐藏状态，还直接访问 Encoder 的所有隐藏状态，并按相关性加权平均。**通过加权平均保留过去若干步编码器隐藏状态的信息**

- 设 Encoder 得到的隐藏状态为 $h_1, h_2, \ldots, h_N \in \mathbb{R}^h$, 其中 h_i 表示源句第 i 个位置的信息。设 Decoder 在第 t 步的隐藏状态为 $s_t \in \mathbb{R}^h$.
- 首先计算 Decoder 当前状态与各个 Encoder 状态的匹配分数：

$$e^t = [s_t^\top h_1, \ldots, s_t^\top h_N] \in \mathbb{R}^N.$$

- 然后通过 softmax 得到注意力权重：$\alpha^t = \mathrm{softmax}(e^t), \quad \sum_{i=1}^N \alpha_i^t = 1, \quad \alpha_i^t \geq 0$. 再对 Encoder 隐藏状态加权平均，得到上下文向量：

$$a_t = \sum_{i=1}^N \alpha_i^t h_i \in \mathbb{R}^h.$$

- 最后，将上下文向量与 Decoder 当前隐藏状态拼接，用于预测当前输出词：

$$\hat{y}_t = \mathrm{softmax}(W[a_t; s_t] + b).$$

但是这里面还需要 RNN 来训练，但是 Transformer 不需要 RNN，可以完全依赖于 Attention

不仅需要字面表征也需要文本表征（自己本身的信息以及周边的信息）

key value query

顺序表征

加入非线性

多层

多头的机制

文本 + 文字信息

Self-Attention

传统 RNN 通过递归结构处理序列，因此存在难以并行和长距离信息传递困难的问题。Self-attention 的思想是：对于序列中的每一个位置，直接与序列中所有位置建立联系，从而得到当前位置的新表示。

- 设输入序列的词向量表示为 $X = [x_1; x_2; \cdots; x_n] \in \mathbb{R}^{n\times d}$.
- **生成 Query、Key 和 Value：**

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V.$$

  其中 W_Q, W_K, W_V 是可训练参数矩阵，Q, K, V 分别表示查询、匹配键和值。对第 i 个词而言，q_i 表示“当前词想找什么信息”；对第 j 个词而言，k_j 表示“第 j 个词可供匹配的标签”，v_j 表示“第 j 个词真正提供的信息”。
- **计算相关性分数：**通过 Query 与 Key 的内积计算词与词之间的相关性：

$$QK^\top \in \mathbb{R}^{n\times n}.$$

  其中第 (i, j) 个元素表示第 i 个词对第 j 个词的关注程度。
- **归一化注意力权重：**为了避免内积值过大，通常除以 $\sqrt{d_k}$，再使用 softmax 得到注意力权重：

$$A = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right).$$

- **加权平均 Value：**最后用注意力权重对 Value 做加权平均，得到新的序列表示：

$$\mathrm{Attention}(Q, K, V) = AV = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V.$$

Self-Attention 的局限与位置编码

Self-attention 本身不包含序列顺序信息。也就是说，如果只看注意力公式，模型无法区分词语的先后位置。为了解决这一问题，需要在输入词向量中加入位置编码。若 e_i 是第 i 个词的词向量，p_i 是其位置编码，则 Transformer 的输入通常写为

$$x_i = e_i + p_i.$$

其中 p_i 可以是固定的正弦位置编码，也可以是可学习的位置向量。位置编码的作用是让模型在计算注意力时能够感知词语的相对或绝对位置。

非线性变换与前馈网络

单纯的 self-attention 本质上是对 Value 的加权平均，表达能力仍然有限。因此，Transformer 在注意力层之后通常加入逐位置前馈神经网络：

$$\mathrm{FFN}(x) = W_2\phi(W_1x + b_1) + b_2.$$

该网络对序列中每个位置分别作用，参数在不同位置之间共享。它的作用是为模型引入非线性变换，提高单层表示能力。

Multi-Head Attention

单头注意力只能在一个表示子空间中计算相关性。多头注意力将输入投影到多个子空间，在每个子空间中分别计算注意力，再将结果拼接起来：

$$\text{head}_r = \text{Attention}(XW_Q^{(r)}, XW_K^{(r)}, XW_V^{(r)}), \quad r = 1, \ldots, H.$$

最终输出为

$$\text{MultiHead}(X) = \text{Concat}(\text{head}_1, \ldots, \text{head}_H)W_O.$$

多头注意力的作用是让模型从多个角度捕捉词语之间的关系。例如，不同的 head 可以分别关注语法关系、指代关系、局部搭配或长距离依赖。

残差连接与层归一化

Transformer block 中通常使用残差连接和层归一化来稳定训练。对于某个子层 $\text{Sublayer}(\cdot)$，其基本形式可以写为

$$\text{LayerNorm}(x + \text{Sublayer}(x)).$$

残差连接使信息和梯度可以更直接地传播，缓解深层网络训练困难；层归一化用于稳定各层输出的尺度。

因此，一个典型 Transformer encoder block 可以概括为

$$X' = \text{LayerNorm}(X + \text{MultiHead}(X)),$$

$$Y = \text{LayerNorm}(X' + \text{FFN}(X')).$$

Transformer Encoder

Transformer Encoder 由若干个 encoder block 堆叠而成。每个 block 主要包含：

- multi-head self-attention，用于建模输入序列内部各位置之间的关系；
- feed-forward network，用于逐位置非线性变换；
- residual connection 和 layer normalization，用于稳定训练。

Encoder 的输出是一组上下文相关的表示：

$$H = \text{Encoder}(X).$$

其中每个位置的表示不仅包含该词本身的信息，也融合了整个输入序列中其他位置的信息。

Transformer Decoder

Transformer Decoder 用于自回归生成目标序列。它与 Encoder 类似，但多了两个关键结构：

- masked self-attention：保证第 t 个位置只能看到 $1, \ldots, t$ 的历史信息，不能看到未来词；
- cross-attention：让 Decoder 在生成目标词时访问 Encoder 的输出表示。

Masked self-attention 可理解为在注意力矩阵中屏蔽未来位置：

$$\alpha_{ij} = 0, \quad j > i.$$

这保证了生成过程满足自回归结构：

$$P(y \mid x) = \prod_{t=1}^{T} P(y_t \mid y_1, \ldots, y_{t-1}, x).$$

Cross-Attention

在 encoder-decoder Transformer 中，cross-attention 用于连接源序列和目标序列。它与 self-attention 的区别在于：Query 来自 Decoder，Key 和 Value 来自 Encoder。若 Decoder 当前表示为 S，Encoder 输出为 H，则

$$Q = SW_Q, \quad K = HW_K, \quad V = HW_V.$$

Cross-attention 的输出为

$$\mathrm{CrossAttn}(S, H) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V.$$

直观地说，Decoder 在生成每个目标词时，用自己的 Query 去匹配源句 Encoder 表示中的 Key，再从对应的 Value 中取回相关信息。这相当于 Seq2Seq attention 的矩阵化推广。

Transformer 的整体结构

Transformer 可以看作完全基于注意力机制的 encoder-decoder 模型。Encoder 负责将输入序列编码为上下文表示，Decoder 负责在 masked self-attention 和 cross-attention 的帮助下逐词生成输出。与 RNN 相比，Transformer 不依赖时间递归，因此可以并行处理整个序列，并且任意两个位置之间只需一层 attention 即可直接交互。

其核心优势包括：

- 并行性强：不需要按时间步递推；
- 长距离依赖建模能力强：任意两个位置可以直接建立联系；
- 表示能力强：multi-head attention 可以从多个子空间捕捉不同关系；
- 可堆叠性强：通过残差连接和层归一化可以训练较深模型。

计算复杂度

Self-attention 的主要计算来自注意力矩阵 $QK^\top$。若序列长度为 n，隐藏维度为 d，则注意力矩阵大小为 $n \times n$，因此计算复杂度约为

$$O(n^2 d).$$

这说明 Transformer 在序列长度较大时计算和显存开销会迅速增长。因此，虽然 Transformer 具有很强的并行性和建模能力，但标准 self-attention 对长序列的二次复杂度也是其主要瓶颈。

Transformer 的基本组成 Self-attention 可以作为 Transformer 的核心模块，但若直接使用，还存在一些问题。主要障碍及对应解决方法如下：

- **位置信息**：self-attention 本身不包含词语的先后顺序，因此模型无法仅凭注意力公式区分不同位置。在输入中加入位置表示，例如 $x_i = e_i + p_i$. 其中 e_i 是词向量，p_i 是位置编码。
- **非线性变换**：self-attention 本质上是对 Value 的加权平均，若只使用这一操作，模型表达能力有限。在 self-attention 后对每个位置加入相同的前馈神经网络：$\mathrm{FFN}(x) = W_2\phi(W_1 x + b_1) + b_2$.
- **序列生成时可能看到未来信息**：在机器翻译或语言建模中，预测第 t 个词时不能使用第 t 个词之后的信息。使用 masked self-attention，将未来位置的注意力权重置为 0：$\alpha_{ij} = 0, \quad j > i$.

在基本 self-attention 模块之外，Transformer 还引入了若干技巧来增强表示能力并稳定训练。

- **多头注意力（Multi-head attention）**：单个 attention 只能从一个角度建模词与词之间的关系。多头注意力将输入投影到多个子空间中，分别计算 attention，再将结果拼接：

  $$\mathrm{head}_r = \mathrm{Attention}(XW_Q^{(r)}, XW_K^{(r)}, XW_V^{(r)}), \quad r = 1, \ldots, H.$$

  $$\mathrm{MultiHead}(X) = \mathrm{Concat}(\mathrm{head}_1, \ldots, \mathrm{head}_H)W_O.$$

  不同的 head 可以关注不同类型的信息，例如局部搭配、语法关系、指代关系或长距离依赖。
- **残差连接（Residual connection）**：为了避免深层网络中信息和梯度传递困难，Transformer 在每个子层后加入残差连接，即将子层输入与子层输出相加：

  $$x + \mathrm{Sublayer}(x).$$

  这可以理解为：模型既保留原始输入信息，又加入当前子层学习到的新信息，从而缓解深层模型训练困难。

- **层归一化（Layer normalization）**：为了稳定每一层输出的尺度，Transformer 通常在残差连接后进行归一化：

$$\text{LayerNorm}(x + \text{Sublayer}(x)).$$

层归一化可以减少不同层之间数值分布的剧烈变化，使训练更加稳定。

Transformer 真正的架构

Transformer Decoder 的计算流程可以写成：

- 输入目标序列，得到词嵌入：

$$\text{Decoder Inputs} \longrightarrow \text{Embeddings}.$$

- 加入位置编码：

$$\text{Embeddings} \longrightarrow \text{Add Position Embeddings}.$$

- 进入若干个 Decoder block，每个 block 包含：
  - Masked Multi-Head Attention；
  - Add & Norm；
  - Feed-Forward；
  - Add & Norm。
- 经过若干层 Decoder block 后，接线性层和 Softmax：

$$\text{Output} \longrightarrow \text{Linear} \longrightarrow \text{Softmax}.$$

- 最终得到下一个词的概率分布：

$$\text{Softmax Output} = \text{Probabilities}.$$

其中，Masked Multi-Head Attention 用于屏蔽未来信息，使第 t 个位置只能看到当前位置及其之前的信息。

Transformer Encoder 的计算流程可以写成：

- 输入源序列，得到词嵌入：

$$\text{Encoder Inputs} \longrightarrow \text{Embeddings}.$$

- 加入位置编码：

$$\text{Embeddings} \longrightarrow \text{Add Position Embeddings}.$$

- 进入若干个 Encoder block，每个 block 包含：
  - Multi-Head Attention；

- Add & Norm；
- Feed-Forward；
- Add & Norm。

- 经过若干层 Encoder block 后，得到输入序列的上下文表示：

$$H = \mathrm{Encoder}(X).$$

与 Decoder 不同，Encoder 中的 Multi-Head Attention 不使用 mask，因此每个位置都可以看到整个输入序列的信息。

总结

Transformer 可以看作完全基于注意力机制的 encoder-decoder 模型。相比 RNN，它不依赖时间递归，因此可以并行处理序列；任意两个位置之间可以通过 attention 直接交互，因此更适合建模长距离依赖。其核心优点是并行性强、表示能力强、可堆叠性好；主要瓶颈是 self-attention 需要计算 $n \times n$ 的注意力矩阵。若序列长度为 n、隐藏维度为 d，则标准 self-attention 的复杂度约为

$$O(n^2 d).$$

因此，Transformer 在长序列任务中会面临较高的计算和显存开销。

Part IV

双层优化

22 双层优化的理论、算法与应用

双层优化研究具有先后次序的两个优化问题：leader 先作决策，follower 观察该决策后求解自己的优化问题，而 leader 必须预见这一最优响应。它既是 hierarchical decision 的数学模型，也是 mathematical programming、equilibrium theory 与 game theory 的交汇点。本章的任务是建立这一领域的整体框架；本节主要依据 Dempe 的领域综述整理，并参考经典专著中的统一表述 [1–3]。

22.1 基本模型：约束中嵌套一个优化问题

设 $x \in X \subseteq \mathbb{R}^m$ 为上层变量，$y \in Y \subseteq \mathbb{R}^n$ 为下层变量。给定 x 后，下层可行集、optimal value function 与 solution mapping 分别定义为

$$M(x) := \{y \in Y : g(x,y) \le 0\}, \qquad \vartheta(x) := \inf_{y \in M(x)} f(x,y), \qquad S(x) := \arg\min_{y \in M(x)} f(x,y).$$

定义 22.1 (双层可行点与诱导区域) 若 $x \in X$、$G(x,y) \le 0$ 且 $y \in S(x)$，则称 (x,y) 为一个双层可行点。所有双层可行点构成的集合

$$\mathcal{I} := \{(x,y) : x \in X,\ G(x,y) \le 0,\ y \in S(x)\}$$

称为 inducible region。标准 optimistic bilevel problem 写成

$$\min_{x,y}\ F(x,y) \qquad \text{s.t.} \qquad (x,y) \in \mathcal{I}.$$

这里的约束 $y \in S(x)$ 不是普通等式或不等式，而是要求 y 解出另一个参数化优化问题。即使所有原始函数均为 smooth convex functions，$\operatorname{gph} S$ 仍可能非凸、非连通，solution mapping 也可能在参数变化时跳跃。因此，双层问题的主要困难并不只来自原始函数，而来自“最优解作为参数的函数”这一隐含结构。

注 22.1 上下层目标不能简单地相加。加权和 $F + \rho f$ 表示两个目标由同一个决策者同时权衡；双层模型则要求 follower 在给定 x 后独立达到自己的最优值。二者的可行集不同，除非另有 exact penalty 定理，否则不能互相替代。

22.2 下层解多值时的决策语义

当 $S(x)$ 为 singleton 时，follower 的选择是唯一的。若 $S(x)$ 多值，则模型必须说明 follower 如何从多个最优解中选择。

定义 22.2 (Optimistic 与 pessimistic value) 假设 $S(x) \neq \varnothing$，定义

$$\Phi_o(x) := \inf_{y \in S(x)} F(x,y), \qquad \Phi_p(x) := \sup_{y \in S(x)} F(x,y).$$

Φ_o 假设 follower 在下层最优解中选择最有利于 leader 的点；Φ_p 则按其中最不利的点评价 x。相应上层问题分别为 $\min_{x \in X} \Phi_o(x)$ 与 $\min_{x \in X} \Phi_p(x)$。

二者不是同一问题的两种数值方法，而是两种不同的行为假设。只有当 $S(x)$ 单值，或 $F(x,\cdot)$ 在 $S(x)$ 上为常数时，才有 $\Phi_o(x) = \Phi_p(x)$。optimistic formulation 可直接保留变量 y 并在 $\operatorname{gph} S$ 上优化；pessimistic formulation 则含有“min–max over $\arg\min$”三重结构，解的存在性和计算均更困难。

除了这两个基本模型，综述还讨论了 semivectorial bilevel optimization、multi-follower model、stochastic bilevel optimization 以及 bilevel equilibrium problem。它们虽然形式不同，但核心对象仍是参数化 solution mapping：多目标下层需要先说明 efficient solution 的选择规则；多个 follower 需要说明它们之间是 cooperative、Nash 还是 Stackelberg 关系；随机模型还要区分随机性位于哪一层以及信息何时可见。

22.3 下层解映射的稳定性

solution mapping 的稳定性决定上层看到的是一个可控目标，还是一个会突然跳变的对象。常用的性质包括 upper/lower semicontinuity、Lipschitz-like property、single-valuedness 与 strong stability。它们分别控制解是否突然远离、附近解能否被跟踪，以及能否把 y 局部写成 $y(x)$。

一个容易忽略的现象是：向下层加入一条在当前最优解处 inactive 的约束，仍可能改变整个 $S(x)$，进而破坏原来的双层最优解。这与普通 nonlinear programming 中“inactive constraint 对局部一阶条件没有贡献”的直觉不同。双层模型关心的是一族下层问题，而不只是某个固定参数下的一次最优化。

注 22.2 研究双层问题时应先检查 $S(x)$ 是否非空、是否紧、是否单值以及如何随 x 变化。若这些问题尚未回答，就直接对 $F(x,y(x))$ 求导，往往已经暗中加入了不存在的唯一性与可微性假设。

22.4 三类基本的单层化方法

单层化的目的不是“消去”下层困难，而是把 follower optimality 转换为可分析的约束。不同变换保留的信息不同，因而适用条件也不同。

22.4.1 KKT/MPEC reformulation

假设对每个固定 x，$f(x,\cdot)$ 与各分量 $g_i(x,\cdot)$ 为 convex differentiable functions，并且下层满足适当 constraint qualification。定义 Lagrangian

$$\mathcal{L}(x,y,\lambda) := f(x,y) + \lambda^{\mathsf{T}} g(x,y).$$

定理 22.1 (Convex 下层的 KKT 等价刻画) *在上述假设下，$y \in S(x)$ 当且仅当存在 $\lambda \geq 0$，使得*

$$\nabla_y \mathcal{L}(x,y,\lambda) = 0, \qquad g(x,y) \leq 0, \qquad \lambda_i g_i(x,y) = 0, \quad i = 1,\dots,p.$$

因此 optimistic bilevel problem 可等价转化为带 complementarity constraints 的 MPEC。

证明. 必要性来自 convex programming 的 KKT theorem。反之，stationarity 与 convexity 给出

$$f(x,z) \geq f(x,y) + \langle \nabla_y f(x,y), z - y \rangle$$

对任意 $z \in M(x)$ 成立；结合 $\nabla_y f = -\nabla_y g^{\mathsf{T}} \lambda$、$g(z) \leq 0$ 与 complementary slackness，可得 $f(x,z) \geq f(x,y)$，故 $y \in S(x)$。

若下层非凸，KKT conditions 一般只刻画 stationary point，而非 global minimizer。此时 MPEC 的可行域可能严格大于 $\operatorname{gph} S$，求得的点甚至不是原双层问题的可行点 [2]。即使下层 convex，complementarity 也使普通 MFCQ 在 MPEC 可行点处失效；其 stationarity 与算法将在第 24 节系统讨论。

22.4.2 Value-function reformulation

由 optimal value 的定义，任意 $y \in M(x)$ 都满足 $f(x,y) \geq \vartheta(x)$。因此有以下无需 convexity 的精确等价关系。

命题 22.2 (Value-function 等价关系) *若下层最优值有限且能够达到，则*

$$y \in S(x) \quad \Longleftrightarrow \quad y \in M(x), \quad f(x,y) - \vartheta(x) \leq 0.$$

于是 optimistic bilevel problem 等价于

$$\min_{x,y} F(x,y) \quad \text{s.t.} \quad x \in X, G(x,y) \leq 0, g(x,y) \leq 0, f(x,y) - \vartheta(x) \leq 0.$$

该变换保留了下层 global optimality，因此比 KKT reformulation 更一般；代价是 ϑ 通常 nonsmooth，且约束 $f - \vartheta \leq 0$ 在可行点处必为等式，具有内在退化性。第 25 节中的 generalized differentiation 与 partial calmness 正是为处理这一困难而引入。

22.4.3 Generalized equation 与 variational inequality

当下层关于 y 为 convex 时，其最优性也可写成

$$0 \in \nabla_y f(x,y) + N_{M(x)}(y),$$

或等价地写成 variational inequality

$$y \in M(x), \qquad \langle \nabla_y f(x,y), z-y \rangle \geq 0, \quad \forall z \in M(x).$$

这种表示避免显式列出某一组 constraint multipliers，并将双层优化与 equilibrium theory、normal-cone calculus 及 set-valued analysis 联系起来。不过，对于非凸下层，上述一阶条件同样不能自动保证 global optimality。

22.5 算法谱系与复杂性

一般双层优化是 NP-hard 的；因此，不存在一种对所有结构都有效且具有 global guarantee 的算法。算法选择应由问题结构决定。linear bilevel problem 常利用 extreme-point 或 optimal-basis enumeration、KKT/MILP reformulation、branch-and-bound 及 cutting planes；quadratic 与 integer model 可结合 convex relaxation、global search 和分支技术；一般 nonlinear model 则常采用 penalty、trust-region、bundle、value-function approximation 或 smoothing。若下层解局部唯一且 strongly stable，还可利用 implicit function theorem 构造 reduced objective $x \mapsto F(x, y(x))$，这也是现代 hypergradient 方法的理论原型。

注 22.3 评价一个双层算法至少要问三件事：其 reformulation 是否与原问题等价；极限点满足何种 stationarity；结论是 local、global 还是 approximate。仅报告“收敛”并不充分，因为算法可能只是收敛到 KKT reformulation 的驻点，而该点未必对应 follower 的 global optimum。

综述列举的 transportation、energy market、security、principal–agent、engineering design 与 machine learning 应用具有共同结构：上层决策改变下层目标或可行域，下层最优响应又反过来决定上层的真实代价。由此可见，双层优化的主线不是机械地消去 y，而是在保持 follower optimality 的同时理解并控制 $S(x)$ 的非凸性、非光滑性与稳定性。

本章参考文献

[1] Jonathan F. Bard. *Practical Bilevel Optimization: Algorithms and Applications*. Dordrecht: Kluwer Academic Publishers, 1998.

[2] Stephan Dempe. “Bilevel Optimization: Theory, Algorithms, Applications and a Bibliography”. In: *Bilevel Optimization: Advances and Next Challenges*. Ed. by Stephan Dempe and Alain Zemkoho. Vol. 161. Springer Optimization and Its Applications. Cham: Springer International Publishing, 2020, pp. 581–665. DOI: 10.1007/978-3-030-52119-6_20.

[3] Stephan Dempe. *Foundations of Bilevel Programming*. Nonconvex Optimization and Its Applications. Dordrecht: Kluwer Academic Publishers, 2002.

23 第 14 章：Pessimistic bilevel optimization

optimistic model 假定 follower 会在多重最优解中帮助 leader；当双方利益冲突、follower 的 tie-breaking rule 未知，或 leader 希望作出保守决策时，这一假设并不合适。pessimistic bilevel optimization 改为按照最坏的 lower-level optimal response 评价上层决策。它与 robust optimization 的思想相近，但其“不确定集合”不是预先给定的集合，而是由另一个优化问题内生生成的 $S(x)$。本节依据该方向的专门综述整理 [2, 3]。

23.1 模型与 Stackelberg 解

考虑联合约束集

$$\Omega := \{(x,y) \in X \times Y : g(x,y) \le 0\}.$$

它在上层空间的投影为 $X_0 := \{x \in X : Y(x) \neq \varnothing\}$，其中

$$Y(x) := \{y \in Y : g(x,y) \le 0\}, \qquad \vartheta(x) := \inf_{y \in Y(x)} f(x,y).$$

定义 23.1 (Rational reaction set) 给定 $x \in X_0$，follower 的 rational reaction set 为

$$S(x) := \arg\min_{y \in Y(x)} f(x,y) = \{y \in Y(x) : f(x,y) = \vartheta(x)\}.$$

集合 $\operatorname{gph} S = \{(x,y) : x \in X_0,\ y \in S(x)\}$ 称为 inducible region。

定义 23.2 (Pessimistic Stackelberg solution) 定义 pessimistic value function

$$\Psi(x) := \sup_{y \in S(x)} F(x,y).$$

若 $\bar{x} \in X_0$ 满足 $\Psi(\bar{x}) = \inf_{x \in X_0} \Psi(x)$，则称 $\bar{x}$ 为 pessimistic Stackelberg solution。若上确界在 $\bar{y} \in S(\bar{x})$ 处达到，则称 $(\bar{x}, \bar{y})$ 为相应 equilibrium pair。

该模型含有三层运算：follower 先对 f 取最小，nature 或 adversarial tie-breaker 再在 $S(x)$ 上最大化 F，leader 最后选择 x 使最坏值最小。因此，不能把它简单理解为把 optimistic formulation 中的一个 $\min$ 改成 $\max$。

注 23.1 若 $S(x)$ 单值，则 optimistic 与 pessimistic models 完全相同。由此可见，pessimistic theory 的独特困难全部集中在下层解的多值性以及多值集合随参数的变化上。

23.2 为什么精确解可能不存在

即使 F, f, g 连续、上下层可行域有界，pessimistic problem 也可能没有最优解。原因是 x 轻微改变时，$S(x)$ 中可能突然出现一个对 leader 极为不利的最优解，使 Ψ 向上跳

跃；而最小化问题需要的恰是 lower semicontinuity。仅有 X_0 compact 与 $S(x)$ 非空，并不足以排除这种现象。

定理 23.1 (基于 Berge theorem 的存在性条件) 假设 X_0 非空且 compact，$S : X_0 \rightrightarrows Y$ nonempty compact-valued 且 continuous，并且 F continuous。则 Ψ 在 X_0 上连续，故 pessimistic problem 至少存在一个 global solution。

证明. 将 $\Psi(x) = \max_{y\in S(x)} F(x,y)$ 看作一个参数化 maximization problem。由 Berge maximum theorem，compact-valued continuity of S 与 continuity of F 推出 Ψ continuous。再由 Weierstrass theorem，连续函数在 compact set X_0 上达到最小值。

该定理的强点和弱点都很清楚：它把存在性归结为 reaction mapping 的连续性，但实际 bilevel model 中 S 往往恰好不连续。因此，章节引入 regularization、viscosity solution 与 approximate Stackelberg solution，目的不仅是方便数值计算，也是为了构造更稳定的解概念。

23.3 ε-近似反应与稳定化

定义 23.3 (ε-solution set) 给定 $\varepsilon > 0$，定义

$$S_\varepsilon(x) := \{y \in Y(x) : f(x,y) \le \vartheta(x) + \varepsilon\}, \qquad \Psi_\varepsilon(x) := \sup_{y\in S_\varepsilon(x)} F(x,y).$$

最小化 Ψ_ε 得到的解称为 perturbed pessimistic solution；若只要求上层目标与最优值相差不超过给定容差，则得到 ε-Stackelberg solution。

由于 $S(x) \subseteq S_\varepsilon(x)$，有 $\Psi_\varepsilon(x) \ge \Psi(x)$。换言之，leader 不仅防御精确最优响应，而且防御所有近似最优响应，因此 perturbed model 比原 pessimistic model 更保守。随着 $\varepsilon \downarrow 0$，这些较大的反应集合逐渐收缩。

定理 23.2 (近似最优解的极限) 设 X_0 compact，$\varepsilon_k \downarrow 0$，并且 $\Psi_{\varepsilon_k} \to \Psi$ 在 X_0 上 uniformly。若 $x_k \in \arg\min_{x\in X_0} \Psi_{\varepsilon_k}(x)$ 且 $x_{k_j} \to \bar{x}$，则 $\bar{x}$ 是原 pessimistic problem 的 global solution。

证明. 对任意 $x \in X_0$，由 x_k 的最优性有 $\Psi_{\varepsilon_k}(x_k) \le \Psi_{\varepsilon_k}(x)$。uniform convergence 允许两边同时令 $k_j \to \infty$，从而得到 $\Psi(\bar{x}) \le \Psi(x)$。

注 23.2 $S_\varepsilon(x) \downarrow S(x)$ 的逐点集合收敛并不自动推出 $\Psi_\varepsilon \to \Psi$ uniformly；还需要 compactness、连续性或更强的 variational convergence 条件。这正是近似理论中不能省略的技术环节。

23.4 单层化与 reduction 思想

pessimistic model 的直接困难是内层 maximization 的约束本身为 $y \in S(x)$。在线性或 convex 情形，可以借助 lower-level strong duality 或 KKT conditions，把 $y \in S(x)$ 写成 primal feasibility、dual feasibility 与 zero duality gap；随后再使用 penalty、complementarity reformulation 或 variational necessary conditions[1]。但这些变换仍需分别验证 global equivalence，尤其不能用非凸下层的 KKT points 代替 $S(x)$。

另一种重要思路是引入一个下层候选点 $\widetilde{y}$，并定义

$$\widehat{Y}(x,\widetilde{y}) := \{y \in Y(x) : f(x,y) \le f(x,\widetilde{y})\}.$$

若 $\widetilde{y} \in S(x)$，则 $\widehat{Y}(x,\widetilde{y}) = S(x)$；若 $\widetilde{y}$ 尚未最优，该集合则包含所有不比它差的下层点。这样可把“最坏的最优响应”拆成寻找 lower-level candidate 与在水平集上寻找 worst response 两个相互耦合的任务。

命题 23.3 (Reduction 的恢复性质) *对章节给出的 reduction model，若 $(x^*,\widetilde{y}^*,y^*)$ 是其 global solution，则存在 $\widehat{y} \in S(x^*)$，使 $(x^*,\widehat{y})$ 构成原 pessimistic problem 的一个 global solution pair。*

该命题的意义在于：reduction model 中出现的辅助点未必就是最终 follower response，但它确定的上层决策能够通过重新求解下层问题恢复原模型的解。因此，求解后必须执行 recovery step，不能直接把所有辅助变量解释为 Stackelberg equilibrium。

对 S_ε 的近似还可引入两个 followers：一个负责产生近似下层解，另一个在相应集合上最大化上层损失。二者形成 generalized Nash equilibrium problem；若各自子问题满足 convexity 与 constraint qualification，再可用 KKT conditions 得到 MPCC。该路线展示了 pessimistic bilevel、GNEP 与 MPEC 之间的联系，但每一步都附带新的正则性假设。

23.5 算法与复杂度边界

在线性情形，polyhedral geometry 提供了几类可计算方法。K-th best algorithm 利用最优解可在有限个 vertices 或 bases 中寻找，按上层评价依次检验候选点；duality-gap penalty method 用 strong duality 衡量下层最优性违反程度，在满足 exactness 条件时由足够大的 penalty parameter 恢复原解；mixed-integer model 还可采用 two-phase algorithm、value-function cuts 与 branch-and-bound。对于一般 nonlinear problem，则主要依靠 regularization、penalty、value-function approximation 及局部 MPEC 方法。

章节总结的复杂度结果说明：某些 independent pessimistic linear models 在附加结构下可 polynomial-time 求解；当下层变量维数固定时，也存在 polynomial-time algorithm；若下层维数属于输入的一部分，则相应问题一般 strongly NP-hard[4]。

注 23.3 (需补充信息) 本章的综述性正文没有完整列出上述第一个 polynomial-time 结论的全部技术假设。严格引用该结论时，应回查其所引原始论文，而不能只写成“independent linear model 总是 polynomial-time”。

本章最值得保留的观点是：pessimistic optimization 的难点是最坏反应映射的稳定性，而不是单独某个 max 运算。一个可信的计算结论必须同时说明 reaction set 如何近似、reformulation 是否精确、所得解是 exact 还是 ε-solution，以及是否具有 global guarantee。其与 optimistic model 的语义差别可回看第 22.2 节。

本章参考文献

[1] Stephan Dempe, Boris S. Mordukhovich, and Alain B. Zemkoho. “Necessary Optimality Conditions in Pessimistic Bilevel Programming”. In: *Optimization* 63.4 (2014), pp. 505–533.

[2] June Liu et al. “Methods for Pessimistic Bilevel Optimization”. In: *Bilevel Optimization: Advances and Next Challenges*. Ed. by Stephan Dempe and Alain Zemkoho. Vol. 161. Springer Optimization and Its Applications. Cham: Springer International Publishing, 2020, pp. 403–422. DOI: 10.1007/978-3-030-52119-6_14.

[3] June Liu et al. “Pessimistic Bilevel Optimization: A Survey”. In: *International Journal of Computational Intelligence Systems* 11.1 (2018), pp. 725–736.

[4] Wolfram Wiesemann et al. “Pessimistic Bi-Level Optimisation”. In: *SIAM Journal on Optimization* 23.1 (2013), pp. 353–380.

24 第 12 章：双层问题的 MPEC 方法

当下层是 smooth convex program 时，可以用 KKT conditions 精确表达 follower optimality，由此把 optimistic bilevel problem 转化为 Mathematical Program with Equilibrium Constraints (MPEC)。该变换把隐含的层级关系改写成显式约束，因而可以借用 nonlinear programming 的思想；但 complementarity set 是若干光滑分支的并，其交点具有内在退化性。MPEC theory 的核心任务正是重新定义适用于这种几何结构的一阶、二阶条件与算法。本节主要依据 Kim、Leyffer 与 Munson 的综述，并参考经典 MPEC 专著 [1, 2]。

24.1 从双层问题到 MPEC

考虑

$$\min_{x,y} F(x,y) \quad \text{s.t.} \quad C(x,y) \le 0, \qquad y \in \arg\min_{v}\{f(x,v) : g(x,v) \le 0\}.$$

假设所有函数 continuously differentiable；对每个相关的 x，下层可行集非空，$f(x,\cdot)$ 与 $g_i(x,\cdot)$ convex，并满足 Slater condition。令 λ 为下层约束的 multiplier，则 KKT theorem 给出等价的 MPEC

$$\begin{aligned} \min_{x,y,\lambda} \quad & F(x,y) \\ \text{s.t.} \quad & C(x,y) \le 0, \quad \nabla_y f(x,y) + \nabla_y g(x,y)^{\mathsf{T}}\lambda = 0, \\ & 0 \le \lambda \perp -g(x,y) \ge 0. \end{aligned}$$

符号 $0 \le a \perp b \ge 0$ 表示 $a \ge 0$、$b \ge 0$ 且 $a^{\mathsf{T}}b = 0$。

定理 24.1 (全局解的对应关系) *在上述 convexity 与 Slater assumptions 下，(x^*, y^*) 是原 optimistic bilevel problem 的 global solution，当且仅当存在一个下层 KKT multiplier λ^*，使 (x^*, y^*, λ^*) 是 MPEC 的 global solution。*

证明. Slater condition 保证下层 KKT conditions 对 global optimality 必要，convexity 保证其充分。因此 MPEC 在 (x,y) 空间上的投影恰为原问题的 inducible region；两个问题的目标同为 $F(x,y)$，故 global minimizers 对应。

local solution 的对应关系更细致。原问题的 local minimizer 可以在适当 multiplier 下提升为 MPEC local minimizer；但反向命题一般不成立，因为同一 (x,y) 可能对应多个 λ，而 MPEC 中的“局部”同时限制了 (x,y,λ)。若 multiplier 唯一，例如满足 MPEC-LICQ，投影后的局部对应关系才可恢复。

注 24.1 *若下层 nonconvex，KKT system 只说明 y 是一个 first-order stationary point，未必属于 global solution set $S(x)$。此时 KKT reformulation 通常只是 relaxation，而非原双层问题的等价形式。*

24.2 Complementarity set 的分支几何

以下考虑一般形式

$$\min_{z} \Phi(z) \quad \text{s.t.} \quad c(z) \le 0, \qquad 0 \le G(z) \perp H(z) \ge 0.$$

对一个 feasible point $\bar{z}$，定义指标集

$$I^{0+} := \{j : G_j(\bar{z}) = 0, H_j(\bar{z}) > 0\}, \qquad I^{+0} := \{j : G_j(\bar{z}) > 0, H_j(\bar{z}) = 0\},$$

$$I^{00} := \{j : G_j(\bar{z}) = H_j(\bar{z}) = 0\}.$$

I^{00} 称为 biactive set。对每个 $j \in I^{00}$，局部可行集由“$G_j = 0$”与“$H_j = 0$”两条分支组成；若 $|I^{00}| = q$，则至多有 2^q 个 associated NLPs。

定义 24.1 (Tightened 与 relaxed NLP) tightened NLP 在 I^{00} 上同时施加 $G_j = 0$、$H_j = 0$，从而固定所有 biactive constraints；relaxed NLP 只保留 $G_j \ge 0$、$H_j \ge 0$。每一种对 I^{00} 的划分则给出一个 associated NLP，即为每个 biactive index 选择一条活动分支。

把 complementarity 写成 $G \ge 0$、$H \ge 0$、$G^{\mathsf{T}}H \le 0$ 虽然形式上得到普通 NLP，但该 NLP 在每个 feasible point 都违反标准 MFCQ。直观上，乘积约束的一阶导数无法正确区分两条可行分支；因此，普通 NLP 的 KKT theorem 和 tangent linearization 不能原封不动地使用。

24.3 从 B-stationarity 到 multiplier stationarity

定义 24.2 (B-stationarity) 若 $\bar{z}$ feasible 且

$$\nabla\Phi(\bar{z})^{\mathsf{T}} d \ge 0, \qquad \forall d \in T_{\mathrm{MPEC}}(\bar{z}),$$

则称 $\bar{z}$ 为 Bouligand stationary，简称 B-stationary。若将真实 tangent cone 换成 MPEC linearized cone，则得到 algebraic B-stationarity。

B-stationarity 直接排除了所有一阶可行下降方向，是最接近经典一阶必要条件的概念。不过 tangent cone 是多个分支切锥的并，检查 B-stationarity 本身通常要解一个 Linear Program with Equilibrium Constraints (LPEC)。为便于分析和计算，引入 multiplier-based conditions。

采用 Lagrangian

$$L(z, \alpha, \beta, \gamma) := \Phi(z) + \alpha^{\mathsf{T}} c(z) - \beta^{\mathsf{T}} G(z) - \gamma^{\mathsf{T}} H(z).$$

在普通活动约束满足相应符号与 complementary slackness 的基础上，biactive multipliers (β_j, γ_j) 的限制区分出下列概念。

定义 24.3 (MPEC stationarity hierarchy) 设 $\nabla_z L(\bar{z},\alpha,\beta,\gamma)=0$。对每个 $j\in I^{00}$：不附加符号条件称为 W-stationarity；要求 $\beta_j\gamma_j\geq 0$ 称为 C-stationarity；要求 $\beta_j\gamma_j=0$ 或 $\beta_j>0,\gamma_j>0$ 称为 M-stationarity；要求 $\beta_j\geq 0,\gamma_j\geq 0$ 称为 S-stationarity。

S-stationarity 最强，它相当于一组 multipliers 同时支持所有相关分支；M-stationarity 表示至少有一个 associated NLP 满足适当的一阶条件；C-stationarity 更弱，仍可能允许某一分支上的下降方向。当 $I^{00}=\varnothing$ 时不存在分支交点，这些概念退化为通常的 KKT stationarity[3]。

定理 24.2 (Stationarity 之间的基本关系) S-stationarity 蕴含 B-stationarity。若 $\bar{z}$ 满足 MPEC-LICQ，则

$$\bar{z}\text{ 为 B-stationary}\quad\Longleftrightarrow\quad\bar{z}\text{ 为 S-stationary},$$

且相应 multipliers 唯一。

24.4 适用于 MPEC 的 constraint qualifications

MPEC-LICQ、MPEC-MFCQ 与 MPEC-CPLD 通过 tightened NLP 的活动梯度定义；MPEC-ACQ 与 MPEC-GCQ 则比较真实 tangent cone、linearized cone 及其 polar。常用蕴含链为

$$\text{MPEC-LICQ}\Longrightarrow\text{MPEC-MFCQ}\Longrightarrow\text{MPEC-CPLD}\Longrightarrow\text{MPEC-ACQ}\Longrightarrow\text{MPEC-GCQ}.$$

定理 24.3 (局部最优点的必要条件) 若 $\bar{z}$ 是 MPEC 的 local minimizer 且满足 MPEC-GCQ，则 $\bar{z}$ 至少是 M-stationary；若进一步满足 MPEC-LICQ，则 $\bar{z}$ 是 S-stationary，并具有唯一 multipliers。

这些专用 CQ 并不是让标准 MFCQ “重新成立”，而是利用分支结构建立正确的 tangent/normal calculus。条件越强，能推出的 multiplier stationarity 越强，但在应用中也越难验证。

24.5 二阶条件

设 $\bar{z}$ 为 S-stationary point，$\mathcal{C}_{\mathrm{MPEC}}(\bar{z})$ 为与一阶活动分支相容的 critical cone。典型 second-order sufficient condition 要求对所有非零 critical directions d，有

$$d^{\mathsf{T}}\nabla^2_{zz}L(\bar{z},\bar{\alpha},\bar{\beta},\bar{\gamma})d>0.$$

在相应 CQ 下，该正定性推出 $\bar{z}$ 是严格 local minimizer。由于 MPEC 可行集是多个 NLP 分支的并，二阶条件实质上必须覆盖所有可能的 active branches。章节中的强弱关系可概括为

$$\text{RNLP-SSOSC}\Longrightarrow\text{RNLP-SOSC}\Longrightarrow\text{MPEC-SOSC}.$$

24.6 算法：平滑近似还是直接处理分支

第一类是 NLP-based relaxation。对 $t > 0$，把 complementarity 放宽为

$$G_j(z) \geq 0, \qquad H_j(z) \geq 0, \qquad G_j(z)H_j(z) \leq t,$$

然后依次求解 $t_k \downarrow 0$ 的 smooth NLPs[4]。

类似地，penalty method 在目标中加入 $\rho G(z)^{\mathsf{T}} H(z)$，也可结合 elastic mode 或 augmented Lagrangian。这些方法可直接使用 SQP 与 interior-point solver，但一般极限点往往只能保证 C-或 M-stationarity；若希望得到更强结论，需要额外 CQ、参数更新规则或更精细的 relaxation。

第二类方法直接利用 disjunctive structure。branch-and-bound 对 complementarity 的两条分支进行枚举；active-set、pivoting、branch-and-cut 与 LPEC-based trust-region method 则在迭代中识别活动分支。SLPEC–EQP 先解 trust-region LPEC 以获得正确的一阶几何，再解 equality-constrained QP 取得快速局部步，因此能够以 B-stationarity 作为有意义的终止标准。

第三类是 implicit approach。若下层 KKT solution $(y(x), \lambda(x))$ 局部唯一且 strongly stable，可用 implicit function theorem 消去它们，得到 reduced problem。这与 hypergradient/implicit differentiation 本质相通，但唯一性或稳定性一旦失效，reduced derivative 也随之失去依据。global optimization 一般只在 LPEC/QPEC、affine complementarity、显式变量界或 mixed-integer representability 等特殊结构下可行。

注 24.2 建模软件能够生成 complementarity constraints，并不意味着 reformulation 已在数学上成立。使用 GAMS/EMP、Pyomo 或通用 MPEC solver 前，仍须独立检查 lower-level convexity、constraint qualification、local/global correspondence 与目标 stationarity 的含义。

因此，MPEC 方法包含三层逻辑：KKT reformulation 负责表达 follower optimality，MPEC stationarity 负责描述分支交点处的一阶与二阶几何，数值算法则负责在这种退化几何上计算具有明确保证的点。只掌握其中一层，都会对最终结论作出过强解释。其 KKT 等价性的基本版本可回看 定理 22.1。

本章参考文献

[1] Youngdae Kim, Sven Leyffer, and Todd Munson. “MPEC Methods for Bilevel Optimization Problems”. In: *Bilevel Optimization: Advances and Next Challenges*. Ed. by Stephan Dempe and Alain Zemkoho. Vol. 161. Springer Optimization and Its Applications. Cham: Springer International Publishing, 2020, pp. 335–360. DOI: 10.1007/978-3-030-52119-6_12.

[2] Zhi-Quan Luo, Jong-Shi Pang, and Daniel Ralph. *Mathematical Programs with Equilibrium Constraints*. Cambridge: Cambridge University Press, 1996.

[3] Holger Scheel and Stefan Scholtes. “Mathematical Programs with Complementarity Constraints: Stationarity, Optimality, and Sensitivity”. In: *Mathematics of Operations Research* 25.1 (2000), pp. 1–22.

[4] Stefan Scholtes. “Convergence Properties of a Regularization Scheme for Mathematical Programs with Complementarity Constraints”. In: *SIAM Journal on Optimization* 11.4 (2001), pp. 918–936.

25 第 7 章：Variational analysis 与 value-function 方法

双层问题即使由 smooth data 构成，也会因为 optimal value function 与 solution mapping 而呈现 nonsmoothness。classical gradient 不能描述解映射的多值分支，也不能处理 value function 的折点。Variational analysis 以 normal cone 为基础建立 coderivative 与 generalized subdifferential，从而在非凸、非光滑情形下研究参数稳定性并推导必要最优性条件。本节依据 Mordukhovich 的综述及其专著整理 [2, 3]。

25.1 Normal cone：非光滑集合的法向量

设 $\Omega \subseteq \mathbb{R}^n$，$\bar{z} \in \Omega$，且 Ω 在 $\bar{z}$ 附近 locally closed。

定义 25.1 (Regular normal cone) *Ω 在 $\bar{z}$ 处的 regular normal cone 定义为*

$$\widehat{N}_\Omega(\bar{z}) := \left\{ v : \limsup_{z \to \bar{z},\, z \in \Omega} \frac{\langle v, z - \bar{z} \rangle}{\|z - \bar{z}\|} \le 0 \right\}.$$

该定义表示：从 $\bar{z}$ 沿集合内任意微小位移，一阶上都不会与 v 形成正夹角。若 Ω 是 smooth manifold，它给出通常的法空间；若 Ω convex，则等于 convex analysis 中的 normal cone。

定义 25.2 (Limiting normal cone) *若存在 $z_k \xrightarrow{\Omega} \bar{z}$ 与 $v_k \to v$，使 $v_k \in \widehat{N}_\Omega(z_k)$，则称 v 为 limiting normal，并记*

$$N_\Omega(\bar{z}) := \operatorname*{Limsup}_{z \xrightarrow{\Omega} \bar{z}} \widehat{N}_\Omega(z).$$

$N_\Omega(\bar{z})$ 一般不凸，但它保留了邻近光滑分支的极限法向，因此比 convexified normal 更适合表达非凸集合的局部结构。regular normal 描述“当前点的一阶支撑”，limiting normal 则允许从附近点逼近，这一极限过程是 Mordukhovich calculus 的基础。

定理 25.1 (Extremal principle) *设 locally closed sets $\Omega_1, \dots, \Omega_s$ 在 $\bar{z} \in \cap_{i=1}^s \Omega_i$ 处构成一个 local extremal system。则存在不全为零的向量 $v_i \in N_{\Omega_i}(\bar{z})$，使*

$$v_1 + \cdots + v_s = 0.$$

所谓 local extremality，是指这些集合经任意小的平移后可在 $\bar{z}$ 的某邻域内彼此分离。定理将“集合不能同时向某方向移动”的几何事实转化为一组平衡的 normals。normal-cone intersection rule、subdifferential sum rule 与 nonsmooth multiplier rule 都可由此导出；相关体系可参见 [3, 4]。

注 25.1 *在 smooth optimization 中，约束梯度线性组合为零是 Lagrange multiplier condition；extremal principle 是它的集合值、非光滑版本。normal qualification 的作用，就是排除仅由约束集合自身产生的异常平衡。*

25.2 Coderivative 与 Aubin property

定义 25.3 (Coderivative) 对 set-valued mapping $\Gamma:\mathbb{R}^m \rightrightarrows \mathbb{R}^n$ 及 $(\bar{x},\bar{y})\in \operatorname{gph}\Gamma$，定义

$$D^*\Gamma(\bar{x},\bar{y})(v) := \{u : (u,-v)\in N_{\operatorname{gph}\Gamma}(\bar{x},\bar{y})\}.$$

若 Γ 是 continuously differentiable single-valued mapping，则

$$D^*\Gamma(\bar{x},\Gamma(\bar{x}))(v) = \{\nabla\Gamma(\bar{x})^{\mathsf{T}}v\}.$$

因此 coderivative 是 transposed Jacobian 的集合值推广：输入一个输出空间的 covector v，得到所有与之相容的输入空间 covectors。

定义 25.4 (Lipschitz-like/Aubin property) 若存在 $\kappa>0$ 及 $\bar{x},\bar{y}$ 的邻域 U,V，使

$$\Gamma(x_1)\cap V \subseteq \Gamma(x_2)+\kappa\|x_1-x_2\|\mathbb{B}, \qquad \forall x_1,x_2\in U,$$

则称 Γ 在 $(\bar{x},\bar{y})$ 处具有 Lipschitz-like property，也称 Aubin property。

定理 25.2 (Mordukhovich criterion) 若 $\operatorname{gph}\Gamma$ 在 $(\bar{x},\bar{y})$ 附近 locally closed，则

$$\Gamma \text{ 在}(\bar{x},\bar{y}) \text{ 处具有 Aubin property} \iff D^*\Gamma(\bar{x},\bar{y})(0)=\{0\}.$$

右端条件排除了“零输出变化对应非零输入法向”的竖直退化。它把一个难以直接验证的集合 Lipschitz 性质转化为 coderivative 的零核条件，是后续研究 lower-level solution mapping 稳定性的关键工具。

25.3 函数的 limiting 与 singular subdifferential

设 $h:\mathbb{R}^m\to\overline{\mathbb{R}}$ 在 $\bar{x}$ 处有限且 lower semicontinuous。

定义 25.5 (Generalized subdifferentials) limiting subdifferential 与 singular subdifferential 定义为

$$\partial h(\bar{x}) := \{v : (v,-1)\in N_{\operatorname{epi}h}(\bar{x},h(\bar{x}))\},$$
$$\partial^\infty h(\bar{x}) := \{v : (v,0)\in N_{\operatorname{epi}h}(\bar{x},h(\bar{x}))\}.$$

若 h differentiable，则 $\partial h(\bar{x})=\{\nabla h(\bar{x})\}$；若 h convex，则它退化为经典 convex subdifferential。$\partial^\infty h$ 不描述通常斜率，而描述 epigraph 的水平异常法向，因此用于判断函数是否具有局部 Lipschitz regularity。

定理 25.3 (Singular subdifferential criterion) 在标准 local closedness assumptions 下，

$$h \text{ 在}\bar{x} \text{ 附近 locally Lipschitz} \iff \partial^\infty h(\bar{x})=\{0\}.$$

limiting subdifferential 的优点是具有精细的 nonconvex calculus；代价是它一般不凸，并且 $\partial(-h)$ 不能简单写成 $-\partial h$。因此，涉及 value-function difference 的公式中常出现 convex hull 或专门的 difference rule。

25.4 Marginal function 的次微分估计

考虑参数化优化问题

$$\vartheta(x) := \inf_{y\in\Gamma(x)} \varphi(x,y), \qquad M(x) := \arg\min_{y\in\Gamma(x)} \varphi(x,y).$$

ϑ 又称 marginal function。即使 φ smooth，最优分支的切换仍可使 ϑ nondifferentiable；因此，不能只对某个任意选择的 $y(x)\in M(x)$ 套用 chain rule。

定义 25.6 (Inner semicontinuity) 若对任意 $x_k\to\bar{x}$，均可选取 $y_k\in M(x_k)$ 使 $y_k\to\bar{y}\in M(\bar{x})$，则称 M 在 $(\bar{x},\bar{y})$ 处 inner semicontinuous。该性质保证所关注的最优分支能够被邻近参数下的最优解跟踪。

定理 25.4 (Marginal function 的基本估计) 设 $\bar{y}\in M(\bar{x})$，M 在 $(\bar{x},\bar{y})$ 处 inner semicontinuous，φ 在 $(\bar{x},\bar{y})$ 附近 locally Lipschitz，且相关 graph locally closed。则

$$\partial\vartheta(\bar{x}) \subseteq \bigcup_{(u,v)\in\partial\varphi(\bar{x},\bar{y})} \left[u + D^*\Gamma(\bar{x},\bar{y})(v)\right],$$

并且

$$\partial^\infty\vartheta(\bar{x}) \subseteq D^*\Gamma(\bar{x},\bar{y})(0).$$

特别地，若 Γ 在 $(\bar{x},\bar{y})$ 处具有 Aubin property，则 ϑ 在 $\bar{x}$ 附近 locally Lipschitz。

第一式把 value function 的 generalized slope 分解为两部分：u 是目标 φ 对参数的直接变化，coderivative 项则反映可行映射 Γ 的移动。第二式先控制 singular part；结合 定理 25.2，便得到 ϑ 的 Lipschitz continuity。该类 two-level value-function sensitivity estimates 的系统推导可参见 [1]。

注 25.2 正确的分析顺序是：先研究 feasible/solution mapping 的 stability，再证明 value function 的 Lipschitz regularity，最后才推导 stationarity。若跳过前两步，公式中的 $\partial\vartheta$ 可能没有预期的良好性质。

25.5 Lipschitz program 的 multiplier rule

考虑

$$\min_z h_0(z) \quad \text{s.t.} \quad h_i(z)\le 0, \quad i=1,\dots,r,$$

其中所有 h_i locally Lipschitz。

定理 25.5 (Nonsmooth Fritz–John condition) 若 $\bar{z}$ 为 local minimizer，则存在不全为零的 $\lambda_i \geq 0$，满足

$$\lambda_i h_i(\bar{z}) = 0, \qquad 0 \in \sum_{i=0}^{r} \lambda_i \partial h_i(\bar{z}).$$

若 generalized MFCQ 排除了 $\lambda_0 = 0$ 的 abnormal multiplier，则可令 $\lambda_0 = 1$，得到 nonsmooth KKT condition。

该结果是后续双层最优性条件的直接工具：一旦通过 value-function reformulation 与 exact penalty 把问题化为单层 Lipschitz program，就可应用这一 multiplier rule。

25.6 Value-function reformulation 与内在退化

考虑 lower-level problem

$$\vartheta(x) := \inf_{y} \{\varphi(x,y) : f_i(x,y) \leq 0, i = 1, \ldots, p\},$$

以及 optimistic bilevel problem

$$\min_{x,y} \psi(x,y) \quad \text{s.t.} \quad g_j(x) \leq 0, \quad j = 1, \ldots, q, \qquad y \in S(x).$$

由 $y \in S(x)$ 的定义，得到 value-function reformulation

$$\min_{x,y} \psi(x,y) \quad \text{s.t.} \quad g_j(x) \leq 0, \quad f_i(x,y) \leq 0, \quad \varphi(x,y) - \vartheta(x) \leq 0.$$

该表示在 global level 上精确；要保持 local minimizer 的对应关系，还需要 S 在所研究解处 inner semicontinuous。更重要的是，任意 lower-level feasible point 均满足 $\varphi(x,y) - \vartheta(x) \geq 0$，所以最后一个不等式在双层可行点处必为等式，且不存在使其严格下降的普通可行方向。由此，标准 MFCQ 对 value-function constraint 内在地失效。

25.7 Partial calmness 与 exact penalty

定义 25.7 (Partial calmness) 设 $(\bar{x}, \bar{y})$ 为 bilevel local solution。将 value-function constraint 扰动为

$$\varphi(x,y) - \vartheta(x) \leq \nu.$$

若存在 $\kappa > 0$ 及 $(\bar{x}, \bar{y}, 0)$ 的邻域，使所有扰动可行点满足

$$\psi(x,y) - \psi(\bar{x}, \bar{y}) + \kappa|\nu| \geq 0,$$

则称该问题在 $(\bar{x}, \bar{y})$ 处 partially calm。

partial calmness 只惩罚最难处理的 value-function constraint，而保留其余上下层约束。它等价于一种局部 exact penalization。

命题 25.6 (Partial calmness 的 exact penalty 解释) 若问题在 $(\bar{x},\bar{y})$ 处以模 κ partially calm，则 $(\bar{x},\bar{y})$ 是下列问题的 local solution：

$$\min_{x,y}\ \psi(x,y)+\kappa\big(\varphi(x,y)-\vartheta(x)\big)\quad \text{s.t.}\quad g_j(x)\le 0,\quad f_i(x,y)\le 0.$$

证明. 对原约束可行点取 $\nu=\varphi(x,y)-\vartheta(x)\ge 0$，partial calmness inequality 立即给出 penalized objective 不小于其在 $(\bar{x},\bar{y})$ 处的值。

25.8 双层问题的 necessary optimality condition

下面给出本章的核心结论。它把 marginal-function estimate、partial calmness 与 nonsmooth multiplier rule 连接起来。

定理 25.7 (一阶必要条件) 设 $(\bar{x},\bar{y})$ 为 bilevel local solution，并且满足以下条件：

(i) ψ,φ,f_i,g_j 均 locally Lipschitz；
(ii) S 在 $(\bar{x},\bar{y})$ 处 inner semicontinuous，且上下层满足相应的 generalized regularity；
(iii) 问题以某个 $\kappa>0$ partially calm。

则存在 multipliers $\lambda_i,\mu_j,\nu_i\ge 0$，满足

$$\lambda_i f_i(\bar{x},\bar{y})=0,\qquad \mu_j g_j(\bar{x})=0,\qquad \nu_i f_i(\bar{x},\bar{y})=0,$$

以及某个 $u\in \operatorname{co}\partial\vartheta(\bar{x})$，使

$$(u,0)\in \operatorname{co}\partial\varphi(\bar{x},\bar{y})+\sum_{i=1}^{p}\nu_i\operatorname{co}\partial f_i(\bar{x},\bar{y}),$$

并且

$$(u,0)\in \partial\psi(\bar{x},\bar{y})+\kappa^{-1}\partial\varphi(\bar{x},\bar{y})+\sum_{i=1}^{p}\lambda_i\partial f_i(\bar{x},\bar{y})+\sum_{j=1}^{q}\mu_j\big(\partial g_j(\bar{x}),0\big).$$

第一组 inclusion 说明 u 不是任意的 value-function subgradient，而可由下层目标与活动约束的 generalized gradients 构造；第二组 inclusion 则是 penalized upper-level problem 的 stationarity condition。二者共享同一个 u，从而把上下层的一阶信息耦合起来。

注 25.3 公式中的 co 不是装饰。limiting subdifferential 一般不凸，且对函数取负不满足简单的正负对称；在处理 $-\vartheta$ 和 subdifferential sum 时会自然出现 convexification。章节进一步利用 subdifferential difference rule 给出另一类条件，以减少这种 convexification 带来的信息损失。

25.9 四章的统一逻辑

第 22 节给出双层优化的总体地图；第 23 节说明 multivalued response 在 worst-case 语义下如何影响存在性；第 24 节在 smooth convex lower-level assumptions 下用 KKT system 得到 MPEC；本节则直接研究 value function 与 solution mapping 的 nonsmooth geometry。MPEC 路线计算工具成熟，但依赖 KKT 等价性并需处理 complementarity degeneracy；variational/value-function 路线能够保留 global lower-level optimality，适用范围更广，但需要 inner semicontinuity、coderivative qualification 与 partial calmness。

因此，一条严谨的分析流程是：先确定 optimistic 或 pessimistic semantics；再研究 S 的非空性、紧性、单值性与 stability；随后依据 lower-level convexity 选择 KKT/MPEC 或 value-function reformulation；最后明确 constraint qualification、stationarity concept 以及 local/global guarantee。双层优化的核心始终是：在不丢失 follower global optimality 的前提下，处理参数化 solution mapping 所引入的非凸与非光滑结构。

本章参考文献

[1] Stephan Dempe, Boris S. Mordukhovich, and Alain B. Zemkoho. “Sensitivity Analysis for Two-Level Value Functions with Applications to Bilevel Programming”. In: *SIAM Journal on Optimization* 22.4 (2012), pp. 1309–1343.

[2] Boris S. Mordukhovich. “Bilevel Optimization and Variational Analysis”. In: *Bilevel Optimization: Advances and Next Challenges*. Ed. by Stephan Dempe and Alain Zemkoho. Vol. 161. Springer Optimization and Its Applications. Cham: Springer International Publishing, 2020, pp. 197–226. DOI: 10.1007/978-3-030-52119-6_7.

[3] Boris S. Mordukhovich. *Variational Analysis and Applications*. Cham: Springer, 2018.

[4] R. Tyrrell Rockafellar and Roger J.-B. Wets. *Variational Analysis*. Berlin: Springer, 1998.

26 可高效计算的双层优化近似驻点

本节根据苏文藻（Anthony Man-Cho So）在清华大学丘成桐数学科学中心的讲座 *On Efficiently Computable Approximate Stationarity Concepts in Bilevel Optimization* 整理，相关工作由 He Chen、Jiajin Li 与 Anthony Man-Cho So 合作完成。

26.1 双层优化的模型与核心问题

双层优化（Bilevel Optimization, BO）描述 leader 与 follower 的层级决策。leader 先选取上层变量 $x \in \mathbb{R}^m$，follower 再通过下层问题作出最优响应。设上层目标为 $F(x,y)$、下层目标为 $f(x,y)$，定义下层解映射

$$S(x) := \arg\min_{y\in\mathbb{R}^n} f(x,y).$$

当 $S(x)$ 含有多个解时，follower 对 leader 可以采取两种态度：

$$\varphi_o(x) := \min_{y\in S(x)} F(x,y), \qquad \varphi_p(x) := \max_{y\in S(x)} F(x,y).$$

相应地，optimistic BO 与 pessimistic BO 分别为

$$\min_{x\in\mathbb{R}^m} \varphi_o(x), \qquad \min_{x\in\mathbb{R}^m} \varphi_p(x).$$

optimistic 模型假设 follower 在下层最优解中选择最有利于 leader 的解；pessimistic 模型假设其选择最不利的解。后者还包含一般非凸–非凹 min–max 问题这一特例。典型应用包括 meta-learning、hyperparameter optimization 与 signal demodulation。

讲座围绕两个问题展开：

- 当下层解不唯一、hyperobjective 可能不可微时，应采用什么 stationarity concept？
- 能否用有限次计算找到近似驻点，并给出非渐近 complexity guarantee？

26.2 下层解唯一：hypergradient

若 $f(x,\cdot)$ 强凸且足够光滑，则 $S(x)=\{y^\star(x)\}$，双层问题化为光滑单层问题

$$\min_x \varphi(x), \qquad \varphi(x) := F\big(x, y^\star(x)\big).$$

由下层一阶条件 $\nabla_y f(x,y^\star(x))=0$ 及 implicit differentiation 可得 hypergradient

$$\nabla\varphi(x) = \nabla_x F(x,y^\star) - \nabla^2_{xy} f(x,y^\star)\big[\nabla^2_{yy} f(x,y^\star)\big]^{-1}\nabla_y F(x,y^\star).$$

因此自然的近似驻点条件为 $\|\nabla\varphi(x)\| \le \varepsilon$。这一情形已有 implicit gradient、fully first-order 等成熟方法；困难主要出现在 $S(x)$ 多值时。

26.3 下层解多值：Lipschitz hyperobjective

当 $S(x)$ 多值时，φ_o 与 φ_p 一般可以是非凸、不可微甚至不连续的，因此首先需要控制解集随参数 x 的变化。设 $\mathbb{B}$ 为单位闭球，若存在 $\kappa > 0$ 使得

$$S(x') \subseteq S(x) + \kappa\|x' - x\|\mathbb{B}, \qquad \forall x, x',$$

则称 S 为 κ-Lipschitz set-valued mapping；等价地，$d_H(S(x), S(x')) \le \kappa\|x - x'\|$，其中 d_H 为 Hausdorff distance。

记号说明

引用论文使用 f 表示 upper-level objective、g 表示 lower-level objective，而本讲座的主要记号是 F 表示上层目标、f 表示下层目标。因此，在讨论 optimistic value function 的 Lipschitz continuity 时，需要 Lipschitz 的目标是上层函数 F；下层函数 f 则通过

$$S(x) = \arg\min_y f(x, y)$$

决定集合值映射 S。

第一步：S 的正则性如何传递给 φ_o

假设每个 $S(x)$ 非空且紧，F 关于联合变量 (x, y) 为 M_F-Lipschitz，并且 S 为 κ-Lipschitz。任取

$$y_1 \in \arg\min_{y \in S(x_1)} F(x_1, y),$$

由 S 的 Lipschitz continuity，可在 $S(x_2)$ 中找到 $\widehat{y}_2$，使 $\|\widehat{y}_2 - y_1\| \le \kappa\|x_2 - x_1\|$。于是

$$\varphi_o(x_2) - \varphi_o(x_1) \le F(x_2, \widehat{y}_2) - F(x_1, y_1) \le M_F(1 + \kappa)\|x_2 - x_1\|.$$

交换 x_1, x_2 后得到

$$|\varphi_o(x_2) - \varphi_o(x_1)| \le M_F(1 + \kappa)\|x_2 - x_1\|.$$

因此，S 为 Lipschitz 会推出 optimistic value function φ_o 为 Lipschitz；对 φ_p 也有相同结论。

课件将这一关系概括为 “φ_o 为 Lipschitz 当且仅当 S 为 Lipschitz”。严格地说，反向结论要求：对任意 Lipschitz 上层目标 F，所诱导的 value function 都是 Lipschitz，并且其 Lipschitz 模可由 $\mathrm{Lip}(F)$ 一致控制。换言之，

$$S \text{ 为 Lipschitz} \quad \Longleftrightarrow \quad \{\varphi_{o,F} : F \text{ 为 Lipschitz}\} \text{ 具有一致的 Lipschitz 控制.}$$

对某个固定的 F，仅由 φ_o 为 Lipschitz 不能推出 S 为 Lipschitz；例如 $F \equiv 0$ 时 $\varphi_o \equiv 0$，无论 S 是否 Lipschitz。

第二步：何时 S 为 Lipschitz

讲座随后给出一组 sufficient conditions：

- 存在 $x_o^\star \in \mathbb{R}^m$ 使 $\varphi_o(x_o^\star) > -\infty$；
- F 为 M_F-Lipschitz，且 ∇F 为 L_F-Lipschitz；
- 下层函数 f 二次连续可微，∇f 与 $\nabla^2 f$ 均为 Lipschitz；
- 对每个 x，$S(x)$ 非空、闭且凸；
- 存在与 x 无关的 $\tau > 0$，使 uniform error bound 成立：

$$\operatorname{dist}(y, S(x)) \le \tau \|\nabla_y f(x, y)\|, \qquad \forall x, y.$$

其中，第一项排除 hyperobjective 取 $-\infty$ 的退化情形；F 的正则性用于将 S 的稳定性传给 hyperobjective，并用于后续算法分析。直接保证 S 为 Lipschitz 的关键是下层 smoothness、解集非空性与 uniform error bound。

具体地，任取 $y_1 \in S(x_1)$，无约束下层问题的一阶条件给出 $\nabla_y f(x_1, y_1) = 0$。若 $\nabla_y f$ 关于 x 为 L_f-Lipschitz，则在 (x_2, y_1) 处使用 error bound，有

$$\operatorname{dist}(y_1, S(x_2)) \le \tau \|\nabla_y f(x_2, y_1)\| = \tau \|\nabla_y f(x_2, y_1) - \nabla_y f(x_1, y_1)\| \le \tau L_f \|x_2 - x_1\|.$$

交换 x_1, x_2 并对解集中的点取上确界，便得到

$$d_H(S(x_1), S(x_2)) \le L_f \tau \|x_1 - x_2\|.$$

在标准 smoothness 条件下，该 error bound 与下层的 Polyak–Łojasiewicz (PL) 条件等价至常数，并允许 $S(x)$ 含有多个解。再结合 F 的 M_F-Lipschitz 性与 hyperobjective 的有限值性，两个 hyperobjective 的 Lipschitz 模均可取

$$M_\varphi = M_F(1 + L_f \tau).$$

两页课件的逻辑链

$$\text{EB} + \text{下层 smoothness} \Longrightarrow S \text{ Lipschitz} \Longrightarrow \varphi_o, \varphi_p \text{ Lipschitz},$$

$$\varphi_o, \varphi_p \text{ Lipschitz} \Longrightarrow \partial\varphi_o, \partial\varphi_p \text{ 有定义}.$$

第一张课件提出两个问题：“何时 S 为 Lipschitz？”以及“若 φ_o 可求值，能否计算 approximate Clarke stationary point？”第二张课件回答了第一个问题；第二个问题则留给后续内容。仅有 Lipschitz continuity 可以支持 GAS 的计算，但仍不足以保证更强的 NAS/Clarke stationarity 可高效计算，这正是后面引入 Set smoothness 的原因。

26.4 Clarke、NAS 与 GAS

Clarke stationarity

对局部 Lipschitz 函数 $h:\mathbb{R}^m\to\mathbb{R}$，Clarke subdifferential 定义为

$$\partial h(x):=\operatorname{conv}\{v:\exists\, x_k\to x,\ h\text{ 在}x_k\text{ 可微且}\nabla h(x_k)\to v\}.$$

若 h 光滑，则 $\partial h(x)=\{\nabla h(x)\}$；若 h 凸，则它与通常的 convex subdifferential 一致。因此

$$0\in\partial h(x)$$

是光滑一阶驻点条件在 nonsmooth 情形下的自然推广。应用于 φ_o 或 φ_p 时，称为 Clarke hyper-stationarity。

Near-approximate stationarity (NAS)

点 x 称为 h 的 (ε,δ)-NAS 点，若

$$\operatorname{dist}\left(0,\ \bigcup_{z\in\mathbb{B}(x,\delta)}\partial h(z)\right)\le\varepsilon.$$

其含义是：在 x 的 δ-邻域内，至少存在一点 z 满足 $\operatorname{dist}(0,\partial h(z))\le\varepsilon$。NAS 直接逼近 Clarke stationarity，但对一般 Lipschitz 函数，即使允许 randomized first-order oracle，也无法在有限次查询内保证找到非平凡的 NAS 点；因此 Lipschitz continuity 本身太弱。

Goldstein approximate stationarity (GAS)

Goldstein δ-subdifferential 在邻域内的 Clarke subdifferential 之外再取凸包：

$$\partial_\delta h(x):=\operatorname{conv}\left(\bigcup_{z\in\mathbb{B}(x,\delta)}\partial h(z)\right).$$

若 $\operatorname{dist}(0,\partial_\delta h(x))\le\varepsilon$，则称 x 为 (ε,δ)-GAS 点。两者的关系为

$$\text{NAS}\Longrightarrow\text{GAS},\qquad\text{GAS}\not\Longrightarrow\text{NAS}.$$

GAS 允许来自不同邻近点的 subgradient 相互抵消，因而更弱，但也更容易计算。只要能够近似求值 $\varphi_o(x)$ 且 S 为 Lipschitz，已有 randomized zeroth-order 方法可在 $\operatorname{poly}(m,\varepsilon^{-1},\delta^{-1})$ 次迭代内得到 GAS 点。问题在于如何在仍可计算的同时获得更强的 NAS/Clarke 保证。

26.5 Set smoothness：使 Clarke 驻点可计算的结构

定义

设 $T:\mathbb{R}^m \rightrightarrows \mathbb{R}^n$ 的定义域非空且凸。令 $x_\theta := \theta x_1 + (1-\theta)x_2$。若对任意 $x_1, x_2 \in \mathrm{dom}(T)$、$\theta \in [0,1]$ 及 $y_\theta \in T(x_\theta)$，都存在 $y_1 \in T(x_1)$ 与 $y_2 \in T(x_2)$ 使

$$\|\theta y_1 + (1-\theta)y_2 - y_\theta\| \le \frac{L}{2}\theta(1-\theta)\|x_1 - x_2\|^2, \qquad \|y_1 - y_2\|^2 \le L\|x_1 - x_2\|^2,$$

则称 T 是 L-set-smooth。

第一个条件表示端点像集中的适当元素经线性插值后，以二阶误差逼近中间像集中的元素；第二个条件要求这两个端点元素来自彼此一致的 branch，排除距离很远的“交叉配对”。因此 Set smoothness 不只是集合值映射的 Lipschitz continuity，还保留了类似光滑函数二阶余项的结构。

对 hyperobjective 的影响

回忆：若 $h(x) + \frac{\rho}{2}\|x\|^2$ 为凸函数，则称 h 为 ρ-weakly convex；若 $-h$ 为 ρ-weakly convex，则称 h 为 ρ-weakly concave。在前述 smoothness、闭凸性与 uniform error bound 条件下，下层解映射 S 不仅 Lipschitz，而且是 set-smooth。若 S 的 set-smoothness 模为 L_S，F 为 M_F-Lipschitz 且 L_F-smooth，则可取

$$\rho = M_F L_S + L_F(1 + L_S),$$

并有

$$\varphi_o \text{ 是}\rho\text{-weakly concave}, \qquad \varphi_p \text{ 是}\rho\text{-weakly convex}.$$

这就是关键的 hidden structure：Set smoothness 将下层解集的几何正则性传递给 hyperobjective，使一般 Lipschitz 函数中不可计算的 Clarke/NAS 保证在此结构下变得可计算。

Inexact zeroth-order method

hyperobjective 的 subgradient 通常无法直接获得，但其函数值可以通过近似求解内层问题得到。对单位球面上的随机方向 u 与 smoothing radius $r > 0$，可使用两点估计

$$\widetilde{G}(x) := \frac{m}{2r}\big(\widetilde{\varphi}(x + ru) - \widetilde{\varphi}(x - ru)\big)u, \qquad x^+ = x - \eta\widetilde{G}(x).$$

在 set-smooth solution mapping 及上述正则条件下，该 randomized zeroth-order scheme 对 optimistic 与 pessimistic BO 都能给出 approximate Clarke hyper-stationarity 的非渐近复杂度保证；这严格强于仅保证 GAS。

26.6 结论与研究方向

- 下层解唯一时，hyperobjective 光滑，可通过 implicit differentiation 计算 hypergradient。
- 下层解多值时，hyperobjective 通常 nonsmooth；Lipschitz solution mapping 足以支持 GAS，却不足以保证 NAS 可计算。
- Set smoothness 揭示了 optimistic hyperobjective 的 weak concavity 与 pessimistic hyperobjective 的 weak convexity，从而“解锁”approximate Clarke hyper-stationarity。
- 后续方向包括 lower-level constrained setting，以及设计具有 complexity guarantee 且数值上更高效的方法。

主要参考

H. Chen, J. Li, A. M.-C. So, *Set Smoothness Unlocks Clarke Hyper-stationarity in Bilevel Optimization*, NeurIPS 2025 (Spotlight).

27 双层优化与纳什均衡

本文通过 $Lampariello, L., Sagratella, S., Shikhman, V., Stein, O.(2020). Interactions Between Bil$ $Dempe, S., Zemkoho, A.(eds) Bilevel Optimization. Springer Optimization and Its Applications, vol 161.$ $//doi.org/10.1007/978-3-030-52119-6_1$ 整理

本章对双层规划与广义纳什均衡问题（GNEP）之间的相互作用进行简洁、高层次的分析。

27.1 双层优化简介

双层问题具有涉及上层和下层两个决策层级。在下一层中，所谓的跟随者问题为：在可行集 Y 上最小化目标函数 f（该函数以变量 x 为参数）：

$$\begin{aligned} \min_{v} \quad & f(x,v) \\ \text{s.t.} \quad & v \in Y \end{aligned} \tag{37}$$

为便于表述，我们首先考虑下层问题的可行集不依赖于 x 的情况。假设问题(37)对每个 $x \in X$ 均有解，定义下层最优值函数

$$\varphi(x) \triangleq \min_{v}\{f(x,v) \mid v \in Y\},$$

并令 $S(x)$ 为下层最优解的集合。

此外，记 ε 为问题(37)最优值的一个正的误差，则对任意 x，跟随者的 ε-最优解集合为

$$\{y \in Y \mid f(x,y) \le \varphi(x) + \varepsilon\},$$

该集合一般不是单点集。因此：

- 若在跟随者问题的解中，仅选择那些对主导者目标函数 F 最有利的解，则在上层可得到原始乐观型双层问题：

$$\begin{aligned} \min_{x} \quad & \min_{y} \{F(x,y) \mid y \in Y,\ f(x,y) \le \varphi(x) + \varepsilon\} \\ \text{s.t.} \quad & x \in X. \end{aligned} \tag{38}$$

- 如果考虑了“较不乐观”的方法，则在上层可得到原始悲观观型双层问题：

$$\begin{aligned} \min_{x} \quad & \max_{y} \{F(x,y) \mid y \in Y,\ f(x,y) \le \varphi(x) + \varepsilon\} \\ \text{s.t.} \quad & x \in X. \end{aligned} \tag{39}$$

注 27.1 *在函数 f 和 F 连续、集合 X 和 Y 紧且非空、跟随者问题(37)为凸的标准假设下，问题 (1.1.2) 和 (1.1.3) 是可解的。*

引入

$$\psi_\varepsilon^o(x) \triangleq \min_y\{F(x,y) \mid y \in Y,\ f(x,y) \le \varphi(x)+\varepsilon\}$$

和

$$\psi_\varepsilon^p(x) \triangleq \max_y\{F(x,y) \mid y \in Y,\ f(x,y) \le \varphi(x)+\varepsilon\}$$

分别作为主导者的乐观型和悲观型最优值函数。

注 27.2 在实际应用中，要求得到精确最优解通常过于严苛，跟随者往往可以接受一个近似最优解。因此，按照文献 [M.B. Lignola, J. Morgan, Stability of regularized bilevel programming problems. J. Optim. Theory Appl. 93(3), 575-596 (1997)] 和 [D.A. Molodtsov, V.V., Fedorov, Approximation of two-person games with information exchange. USSR Comput. Math. Math. Phys. 13(6), 123-142 (1973)] 的方式，同时为便于讨论，我们直接考虑近似问题(38)和(39)，而非它们的精确版本（在近似版本中取 $\varepsilon = 0$ 得到）。

一个很自然的问题是：当 ε 趋于零时会发生什么。针对乐观型问题，下面的命题揭示了当 ε 趋于零时最优解的变化情况。

命题 27.1 令 $\varepsilon \searrow 0$，且 x^ε 为原始悲观型问题(38)对应的最优解序列，则序列 $\{x^\varepsilon\}$ 的任意聚点 x^0 均能取到 $\varepsilon = 0$ 时(38)的下确界，即

$$\operatorname{cl}\psi_0^p(x^0) = \lim_{x\to x^0}\inf_{x\in X}\psi_0^p(x) = \inf_{x\in X}\psi_0^p(x),$$

其中 $\operatorname{cl}\psi_0^p$ 表示 ψ_0^p 在 X 上的闭包。

为设计实用求解方法，可将(38)和(39)目标函数中的难点转移到约束条件中，得到所谓的标准乐观型和悲观型双层问题。具体而言，标准乐观型问题为：

$$\begin{aligned} \min_{x,y}\quad & F(x,y) \\ \text{s.t.}\quad & x \in X,\ y \in Y \\ & f(x,y) \le \varphi(x)+\varepsilon, \end{aligned} \tag{40}$$

其中原则上应包含的约束 $F(x,y) \le \psi_\varepsilon^o(x)$ 因冗余而被省略。标准悲观型问题为：

$$\begin{aligned} \min_{x,y}\quad & F(x,y) \\ \text{s.t.}\quad & x \in X,\ y \in Y \\ & f(x,y) \le \varphi(x)+\varepsilon \\ & F(x,y) \ge \psi_\varepsilon^p(x). \end{aligned} \tag{41}$$

但是，(40)和(41)的局部最优解可能并不对应(38)和(39)的局部最优解；但另一方面，全局最优解之间存在完全对应关系（更详细的讨论参见文献 [3, 11]）。

从现在起，我们假设：F 和 f 连续可微；对任意 x，f 关于 y 为凸函数；X 和 Y 为非空紧凸集。

27.2 标准的乐观双层优化与均衡问题

我们注意到，问题(40)难以直接处理，因为值函数约束中的 φ 是隐式定义的；因此有两种不同的方法对值函数约束进行合适的重构：这两种方法得到两个不同的广义纳什均衡问题（GNEP）模型，它们与标准乐观型双层问题(40)密切相关，且不含任何隐式定义的函数。GNEP 与双层问题一样具有参数化特性，但不同的是，GNEP 中所有参与者都在同一层级上行动。特别地，我们称 GNEP 的一个可行解为均衡点。

第一个 GNEP 模型如下：

$$\begin{aligned} \min_{x,y} \quad & F(x,y) \\ \text{s.t.} \quad & x \in X,\ y \in Y \\ & f(x,y) \le f(x,v) + \varepsilon \end{aligned} \qquad \begin{aligned} \min_{v} \quad & f(x,v) \\ \text{s.t.} \quad & v \in Y. \end{aligned} \tag{42}$$

第二个 GNEP 模型如下：

$$\begin{aligned} \min_{x,y} \quad & F(x,y) \\ \text{s.t.} \quad & x \in X,\ y \in Y \\ & f(x,y) \le f(u,v) + \nabla_1 f(u,v)^T (x-u) + \varepsilon \end{aligned} \qquad \begin{aligned} \min_{u,v} \quad & f(x,v) \\ \text{s.t.} \quad & v \in Y \\ & u = x. \end{aligned} \tag{43}$$

定理 27.2 *若 (x^*, y^*, v^*) 是 GNEP(42)的一个均衡点，则 (x^*, y^*) 是标准乐观型双层问题(40)的全局最优解。*

命题 27.3 *若 f 为凸函数，则值函数 φ 为凸函数且连续可微。此外，对任意 x，集合 $\{\nabla_1 f(x,v) \mid v \in S(x)\}$ 为单点集，且对任意 $v \in S(x)$，有 $\nabla\varphi(x) = \nabla_1 f(x,v)$。*

根据上述命题，若 (x,y) 是(40)的可行解，我们称 (x,y) 为(40)的平稳点，当存在标量 λ 使得：

$$\begin{aligned} & 0 \in \nabla_1 F(x,y) + \lambda \nabla_1 f(x,y) - \lambda \nabla\varphi(x) + N_X(x) \\ & 0 \in \nabla_2 F(x,y) + \lambda \nabla_2 f(x,y) + N_Y(y) \\ & \lambda \in N_{\mathbb{R}_-}(f(x,y) - \varphi(x) - \varepsilon). \end{aligned}$$

命题 27.4 *标准乐观型双层问题(40)满足 Mangasarian-Fromovitz 约束规格（MFCQ）。*

证明. 为证明该结论，只需注意：要使值函数约束的乘子为正，必须满足 $f(x,y) - \varphi(x) - \varepsilon = 0$，即 $f(x,y) = \varphi(x) + \varepsilon > \varphi(x)$。而由下层问题的凸性可知，给定 x 时 y 并非下层问题的解。因此，在任意可行点处，该乘子必为零，故 MFCQ 自然成立。

命题 27.5 *若 F 和 f 均为凸函数，则(43)为凸博弈，其均衡解集非空；且 Mangasarian-Fromovitz 约束规格（MFCQ）成立。*

下述定理表明，(40)的平稳点与(43)的均衡点之间存在一一对应关系

定理 27.6 设 F 和 f 均为凸函数，则以下结论成立：

(i) GNEP(43)的任意均衡点 (x^*, y^*, u^*, v^*)，均满足 (x^*, y^*) 是标准乐观型双层问题(40)的平稳点；

(ii) 标准乐观型双层问题(40)的任意平稳点 (x^*, y^*)，对任意 $v^* \in S(x^*)$，均满足 (x^*, y^*, x^*, v^*) 是 GNEP(43)的均衡点。

28 双层优化中的约束品性与最优性条件

本文研究如下双层规划问题：

$$\begin{aligned}(\text{BP})\quad &\min F(x,y)\\ &\text{s.t. } y\in S(x),\ G(x,y)\le 0,\ H(x,y)=0,\end{aligned}$$

其中

- $S(x)$ 表示下层规划问题
$$(\mathrm{P}_x)\quad \min_{y\in\Gamma(x)} f(x,y),$$
的解集。
- $\Gamma(x):=\{y\in\mathbb{R}^m : g(x,y)\le 0,\ h(x,y)=0\}$ 为下层问题的可行域
- - $F:\mathbb{R}^n\times\mathbb{R}^m\to\mathbb{R}$, $G:\mathbb{R}^n\times\mathbb{R}^m\to\mathbb{R}^p$, $H:\mathbb{R}^n\times\mathbb{R}^m\to\mathbb{R}^q$
  - $f:\mathbb{R}^n\times\mathbb{R}^m\to\mathbb{R}$, $g:\mathbb{R}^n\times\mathbb{R}^m\to\mathbb{R}^r$, $h:\mathbb{R}^n\times\mathbb{R}^m\to\mathbb{R}^s$
- 始终假设对所有 x，均有 $S(x)\neq\emptyset$

研究双层优化最优性条件的经典方法是：用下层问题的 KKT 条件替换原问题，并同时对原变量与乘子进行优化，得到的问题被称为互补约束数学规划或均衡约束数学规划。但是使用一阶方法存在两个问题：

- 由于 KKT 条件仅为最优性的充分条件而非必要条件，该方法仅当下层问题为凸优化时适用。
- 即使下层问题为凸优化，当存在多个乘子时，若考虑局部最优性，转化后的问题也未必与原双层问题等价。

本文将提出解决策略，包括值函数方法、组合方法与广义方程方法。

28.1 一些基本概念

定义 28.1 (余导数 (Coderivatives)) 设集值映射 $\Phi:\mathbb{R}^d\rightrightarrows\mathbb{R}^s$，且 $(\bar{x},\bar{y})\in\operatorname{gph}\Phi$。

- Φ 在 $(\bar{x},\bar{y})$ 处的 Fréchet 余导数是集值映射 $\widehat{D}^*\Phi(\bar{x},\bar{y}):\mathbb{R}^s\rightrightarrows\mathbb{R}^d$，定义为：
$$\widehat{D}^*\Phi(\bar{x},\bar{y})(w):=\left\{\xi\in\mathbb{R}^d \mid (\xi,-w)\in\widehat{N}_{\operatorname{gph}\Phi}(\bar{x},\bar{y})\right\}.$$
- Φ 在 $(\bar{x},\bar{y})$ 处的极限（Mordukhovich）余导数是集值映射 $D^*\Phi(\bar{x},\bar{y}):\mathbb{R}^s\rightrightarrows\mathbb{R}^d$，定义为：
$$D^*\Phi(\bar{x},\bar{y})(w):=\left\{\xi\in\mathbb{R}^d \mid (\xi,-w)\in N_{\operatorname{gph}\Phi}(\bar{x},\bar{y})\right\}.$$

接下来，我们回顾集值映射的一些稳定性概念: 我们现在回顾集值映射的一些稳定性概念。

定义 28.2 （Aubin [2]）设 $\Sigma:\mathbb{R}^n \rightrightarrows \mathbb{R}^d$ 为集值映射，且 $(\bar{\alpha},\bar{x}) \in \operatorname{gph}\Sigma$。若存在 $\bar{\alpha}$ 的邻域 V、$\bar{x}$ 的邻域 U 以及常数 $\kappa \geq 0$，使得：

$$\Sigma(\alpha) \cap U \subseteq \Sigma(\alpha') + \kappa \left\|\alpha' - \alpha\right\| B, \quad \forall \alpha', \alpha \in V,$$

则称 Σ 在 $(\bar{\alpha},\bar{x})$ 处伪 Lipschitz 连续。

定义 28.3 （Robinson [25]）设 $\Sigma:\mathbb{R}^n \rightrightarrows \mathbb{R}^d$ 为集值映射，且 $\bar{\alpha} \in \mathbb{R}^n$。若存在 $\bar{\alpha}$ 的邻域 V 以及常数 $\kappa \geq 0$，使得：

$$\Sigma(\alpha) \subseteq \Sigma(\bar{\alpha}) + \kappa \left\|\alpha - \bar{\alpha}\right\| B, \quad \forall \alpha \in V,$$

则称 Σ 在 $\bar{\alpha}$ 处上 Lipschitz 连续。

定义 28.4 （Ye 和 Ye [35]）设 $\Sigma:\mathbb{R}^n \rightrightarrows \mathbb{R}^d$ 为集值映射，且 $(\bar{\alpha},\bar{x}) \in \operatorname{gph}\Sigma$。若存在 $\bar{\alpha}$ 的邻域 V、$\bar{x}$ 的邻域 U 以及常数 $\kappa \geq 0$，使得：

$$\Sigma(\alpha) \cap U \subseteq \Sigma(\bar{\alpha}) + \kappa \left\|\alpha - \bar{\alpha}\right\| B, \quad \forall \alpha \in V,$$

则称 Σ 在 $(\bar{\alpha},\bar{x})$ 处 Calm（或伪上 Lipschitz 连续）。

许多优化问题可以写成如下形式：

$$\begin{aligned} \min_{x} \quad & f(x) \\ \text{s.t.} \quad & 0 \in \Phi(x), \end{aligned} \tag{44}$$

其中 $f:\mathbb{R}^d \to \mathbb{R}$ 在感兴趣的点附近 Lipschitz 连续，且 $\Phi:\mathbb{R}^d \rightrightarrows \mathbb{R}^n$ 是具有闭图像的集值映射。设 $\bar{x}$ 为上述优化问题的可行解。我们称在 $\bar{x}$ 处满足 Mordukhovich（M-）平稳性条件，若存在 η 使得：

$$0 \in \partial f(\bar{x}) + D^*\Phi(\bar{x},0)(\eta). \tag{45}$$

我们现在讨论保证局部最优解 $\bar{x}$ 满足 M-平稳性条件的约束规格。为此，我们考虑扰动可行解映射：

$$\Sigma(\alpha) := \Phi^{-1}(\alpha) = \left\{x \in \mathbb{R}^d \mid \alpha \in \Phi(x)\right\}. \tag{46}$$

集值映射 $\Sigma(\cdot)$ 在 $(0,\bar{x}) \in \operatorname{gph}\Sigma$ 处的 Calm，等价于其逆映射 $\Sigma^{-1}(x) = \Phi(x)$ 在 $(\bar{x},0)$ 处的度量次正则性。这为下面定义的术语提供了依据。

定义 28.5 设 $0 \in \Phi(\bar{x})$。我们称在 $\bar{x}$ 处满足度量次正则约束规格（MSCQ），若由(46)定义的扰动可行解映射 $\Sigma(\cdot)$ 在 $(0,\bar{x})$ 处是 Calm 的。

定理 28.1 （Ye 和 Ye [35, 定理 3.1]）设 $\bar{x}$ 为问题 (8.2.1) 的局部最优解。若在 $\bar{x}$ 处满足 MSCQ，则在 $\bar{x}$ 处满足 M-平稳性条件(45)。

注 28.1 当 $\Phi(x) := (h(x), g(x) + \mathbb{R}^r_+)$，其中 $g : \mathbb{R}^n \to \mathbb{R}^r$、$h : \mathbb{R}^n \to \mathbb{R}^s$ 均为光滑函数时，问题(44)即为带等式和不等式约束的非线性规划问题，此时条件(45)退化为非线性规划的 KKT 条件。

设 $\bar{x}$ 为问题(44)的可行解。若梯度集合

$$\{\nabla g_i(\bar{x})\}_{i\in I_g} \cup \{\nabla h_i(\bar{x})\}_{i=1}^s$$

线性无关，其中 $I_g = I_g(\bar{x}) := \{i \mid g_i(\bar{x}) = 0\}$，则称 $\bar{x}$ 满足线性独立约束规格（LICQ）。

若不存在非零向量 (η^h, η^g) 使得

$$0 = \sum_{i\in I_g} \nabla g_i(\bar{x})\eta_i^g + \sum_{i=1}^s \nabla h_i(\bar{x})\eta_i^h, \quad \eta^g \geq 0,$$

则称在 $\bar{x}$ 处满足正线性独立约束规格(PLICQ),也称为无非零异常约束规格(NNAMCQ)。

根据择一定理可知,PLICQ/NNAMCQ 等价于 Mangasarian-Fromovitz 约束规格(MFCQ):等式约束梯度 $\{\nabla h_i(\bar{x})\}_{i=1}^s$ 线性无关，且存在向量 $v \in \mathbb{R}^n$ 使得

$$\nabla g_i(\bar{x})^T v < 0, \quad \forall i \in I_g, \quad \nabla h_i(\bar{x})^T v = 0, \quad \forall i = 1, \ldots, s.$$

Part V

其他

29 小记

29.1 一种证明迭代点列线性收敛的框架

设不动点迭代：

$$x^{k+1} = \Phi(x^k),$$

其中 $\Phi : \operatorname{dom}\Phi \subseteq \mathbb{R}^n \to \mathbb{R}^n$ 是某个（单值）映射。

设 X^* 表示 Φ 的非空不动点集。**令 $\psi : \operatorname{dom}\Phi \to \mathbb{R}_+$ 是 X^* 的残差函数，即 ψ 连续且 $\psi(x) = 0$ 当且仅当 $x \in X^*$**。假设存在三个正常数 η_1, η_2 和 δ，满足

- $\psi(x) - \psi(\Phi(x)) \geq \eta_1 \|x - \Phi(x)\|^2, \quad \forall x \in \operatorname{dom}\Phi,$
- $\psi(\Phi(x)) \leq \eta_2 \|x - \Phi(x)\|^2, \quad \forall x \in \operatorname{dom}\Phi$ 且 $\|x - \Phi(x)\| \leq \delta.$

结合 $x^{k+1} = \Phi(x^k)$,, 则上面两个条件说明

- $\psi(x^k) - \psi(x^{k+1}) \geq \eta_1 \|x^k - x^{k+1}\|^2$, 从这个意义上说，$\psi$ 一个评价函数。
- $\psi(x^{k+1}) \leq \eta_2 \|x^k - x^{k+1}\|^2.$

定理 29.1 *设 $\Phi : \operatorname{dom}\Phi \subseteq \mathbb{R}^n \to \mathbb{R}^n$ 是连续函数，其不动点集 X^* 非空。令 $\{x^k\}$ 由迭代 (12.6.1) 定义。若存在 X^* 的连续残差函数 $\psi : \operatorname{dom}\Phi \to \mathbb{R}_+$ 满足 (12.6.2) 和 (12.6.3)，则 $\{\psi(x^k)\}$ 至少以 R-线性速率收敛到 0，且序列 $\{x^k\}$ 至少以 R-线性速率收敛到 X^* 中的某个元素。*

证明：由两个条件共同推出

$$\psi(x^{k+1}) \leq \frac{\eta_2}{\eta_1 + \eta_2}\psi(x^k),$$

于是得到 $\{\psi(x^k)\}$ 的 Q-线性收敛速率，且收敛到 0.

由第一个条件有

$$\eta_1 \|x^k - x^{k+1}\|^2 \leq \psi(x^k) \leq \left(\frac{\eta_2}{\eta_1 + \eta_2}\right)^k \psi(x^0),$$

从而得到

$$\|x^k - x^{k+1}\| \leq \sqrt{\frac{\psi(x^0)}{\eta_1}} \left(\sqrt{\frac{\eta_2}{\eta_1 + \eta_2}}\right)^k.$$

因此，

$$\|x^k - x^{k+m}\| \leq \sqrt{\frac{\psi(x^0)}{\eta_1}} \sum_{j=k}^{k+m-1} \left(\sqrt{\frac{\eta_2}{\eta_1 + \eta_2}}\right)^j.$$

故 $\{x^k\}$ 是 Cauchy 序列，从而收敛，记极限为 x^∞。由 ψ 的连续性且 $\lim \psi(x^k) = \Psi(x^\infty) = 0$，$x^\infty$ 属于 X^*；进一步，令 $m \to \infty$

$$\|x^k - x^\infty\| \leq \sqrt{\frac{\psi(x^0)}{\eta_1}} \frac{1}{1 - \sqrt{\frac{\eta_2}{\eta_1+\eta_2}}} \left(\sqrt{\frac{\eta_2}{\eta_1+\eta_2}}\right)^k,$$

这表明 $\{x^k\}$ 至少以 R-线性速率收敛到 x^∞。

注 29.1 我觉得上述想法来源可能是一个特殊情况，就是 $\psi(x^k) = \|x^k - x^*\|^2$ 的时候，此时第一个条件其实就是我们熟悉的

$$\|x^{k+1} - x^*\|^2 \leq \|x^k - x^*\|^2 - \eta_1 \|x^{k+1} - x^k\|^2$$

此时只要再结合第二个 $\|x^{k+1} - x^*\|^2 \leq \eta_2 \|x^k - x^{k+1}\|^2$ 就可以得到 $\{x^k\}$ 的 Q-线性收敛。

而如果把第二个条件换成 $\|x^k - x^*\|^2 \leq \eta_3 \|x^k - x^{k+1}\|^2$，且 $\eta_3 > \eta_1$，其实也可以得到 $\{x^k\}$ 的 Q-线性收敛。于是上述第二个条件可以换成

$$\psi(x^k) \leq \eta_3 \|x^k - x^{k+1}\|^2, \eta_3 > \eta_1.$$