


最优化理论与方法

Lin Wenjie

Nanjing Normal University

版本：1.0

更新：2025 年 10 月 24 日



目录

I	最优化理论基础	4
1	收敛性	5
2	光滑优化的最优性条件	6
3	一般的最优性条件	9
3.1	凸优化的最优性条件	9
3.2	非凸优化的最优性条件	10
3.3	KKT 条件	11
4	一般 NLP 中的 KKT 条件、锥与约束资格条件	15
4.1	问题形式与基本目标	15
4.2	切锥、线性化锥与极锥	15
4.3	Fréchet 正则法锥、Mordukhovich 法锥与 Clarke 法锥	16
4.4	局部极小点的最原始一阶必要条件	18
4.5	线性化锥极锥的显式表达	18
4.6	KKT 条件的由来	20
4.7	各类约束资格条件 (CQ)	21

4.8	CQ 之间的常见关系	22
4.9	KKT 定理	22
4.10	KKT 条件的几何意义与作用	23
4.11	总结	23
5	最优化基本算法框架	25
5.1	线搜索的搜索方向	26
5.1.1	下降方向	26
5.1.2	牛顿方向	26
5.1.3	拟牛顿方向	27
5.1.4	共轭梯度方向	27
5.2	信赖域子问题的近似模型	28
II	基础算法	29
6	线搜索方法: Line Search Methods	30
6.1	步长的选择	30
6.1.1	Wolfe Conditions	30
6.1.2	Goldstein 条件	32
6.2	线搜索方法的收敛性	33
6.3	线搜索方法的收敛率	34
6.3.1	最速下降法的收敛率	34
6.3.2	梯度法在凸函数上的收敛性	35
6.3.3	牛顿法的收敛率	36
6.3.4	拟牛顿法的收敛率	37
6.4	调整海瑟矩阵的牛顿法	37
7	次梯度法	39
7.1	带 Polyak 步长的投影次梯度法	39
7.1.1	无约束优化的次梯度法	39
7.1.2	带约束优化的次梯度法	39
7.2	用投影梯度法求解凸可行性问题	44
7.2.1	贪婪投影算法	45
7.2.2	交替投影法	46
7.2.3	线性可行性问题的求解	46
8	交替方向乘子法 (Alternating Direction Method of Multipliers / ADMM)	48
8.1	增广拉格朗日法 (The Augmented Lagrangian Method / ALM)	48

8.2	交替方向乘子法 (Alternating Direction Method of Multipliers / ADMM)	49
8.3	ADMM 的收敛性	51
9	信赖域方法	56
9.1	映射 H_k 的选择	58
9.2	子问题求解要求	58
9.3	正则化条件	59
9.4	信赖域算法的迭代复杂度	60
9.5	信赖域算法的收敛性	64
9.6	截断共轭梯度法	66
10	小记	67
10.1	一种证明迭代点列线性收敛的框架	67

Part I

最优化理论基础

1 收敛性

定义 1.1 (收敛性) 若由某算法生成的序列 x_k 在有限次迭代内达到问题的最优解 x^* , 或者 x_k 存在一个聚点且该聚点为最优解 x^* , 则称该算法是收敛的。

- 特别地, 若仅当初始点 x_0 充分接近 x^* 时, x_k 才收敛到最优解 x^* , 则称该算法为局部收敛的。
- 若对任意可行初始点 x_0 , x_k 都能收敛到最优解 x^* , 则称该算法为全局收敛的。

另一种评估算法性能的方式是收敛速度, 其定义如下。

定义 1.2 (收敛速度) 设序列 x_k 收敛到 x^* , 且

$$\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = \beta$$

- 若 $0 < \beta < 1$, 则称 x_k 是线性收敛的。
- 若 $\beta = 0$, 则称 x_k 是超线性收敛的。
- 若 $\beta = 1$, 则称 x_k 是次线性收敛的。

上述定义给出了不同的收敛速度, 其中超线性收敛表示序列 x_k 以最快的方式收敛到 x^* 。下面我们进一步刻画超线性收敛。

定义 1.3 (p 阶收敛) 设序列 x_k 收敛到 x^* , 若存在 $p \geq 1$, 使得

$$\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^p} = \beta, \quad 0 < \beta < \infty$$

则称 x_k 是 p 阶收敛的。特别地, 当 $p = 2$ 时, 称 x_k 是二次收敛的。

2 光滑优化的最优性条件

无约束最优化问题考虑下面这样的问题形式：

$$\min_x f(x),$$

其中 $x \in \mathbb{R}^n$, $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是一个光滑函数。这个问题的解是什么呢？一般来说，最优化问题需要求解如下的三种极小点。

定义 2.1 (极小点)

- 全局极小点: 若对所有的 x , 都有 $f(x^*) \leq f(x)$, 则点 x^* 是全局极小点。
- 局部极小点: 若存在 x^* 的一个邻域 $\mathcal{N}$, 使得对所有的 $x \in \mathcal{N}$, 都有 $f(x^*) \leq f(x)$, 则点 x^* 是局部极小点。
- 严格局部极小点: 若存在 x^* 的一个邻域 $\mathcal{N}$, 使得对所有的 $x \in \mathcal{N}$ 且 $x \neq x^*$, 都有 $f(x^*) < f(x)$, 则点 x^* 是严格局部极小点 (也称为强局部极小点)。

注 2.1 对于一个优化问题, 最好当然可以找到全局极小点, 实在不行也可以退而求其次找到局部极小点或严格局部极小点。

如何判断这个点是极小点呢? 如果完全根据定义, 那就需要比较其附近的所有点, 对于数值计算来说不现实。不过对于一个光滑函数我们有更高效的方法验证某个点是否是极小点, 主要用到的工具是光滑函数的泰勒展开。

定理 2.1 (泰勒定理) 设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是连续可微的, 且 $p \in \mathbb{R}^n$ 。则存在 $t \in (0, 1)$, 使得

$$f(x+p) = f(x) + \nabla f(x+tp)^T p.$$

此外, 若 f 是二次连续可微的, 则存在 $t \in (0, 1)$, 使得

$$\nabla f(x+p) = \nabla f(x) + \int_0^1 \nabla^2 f(x+tp) p dt,$$

且

$$f(x+p) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T \nabla^2 f(x+tp) p.$$

定理 2.2 (一阶必要条件) 若 x^* 是局部极小点, 且 f 在 x^* 的一个开邻域内连续可微, 则 $\nabla f(x^*) = 0$ 。

证明. 假设 $\nabla f(x^*) \neq 0$ 。令 $p = -\nabla f(x^*)$, 注意到 $p^T \nabla f(x^*) = -\|\nabla f(x^*)\|^2 < 0$ 。由于 ∇f 在 x^* 附近连续, 存在 $T > 0$, 使得对所有 $t \in [0, T]$, 有

$$p^T \nabla f(x^* + tp) < 0.$$

对任意 $\bar{t} \in (0, T]$, 由泰勒定理可知, 存在 $t \in (0, \bar{t})$, 使得

$$f(x^* + \bar{t}p) = f(x^*) + \bar{t}p^T \nabla f(x^* + tp).$$

因此, 对所有 $\bar{t} \in (0, T]$, 有 $f(x^* + \bar{t}p) < f(x^*)$. 故 x^* 不是局部极小点, 矛盾。

注 2.2

- 若 $\nabla f(x^*) = 0$, 则称 x^* 为稳定点。根据定理 2.2, 任何局部极小点都为稳定点。
- 我个人更习惯通过极限的保号性得到该结论:

证明. 如果 $\nabla f(x^*) \neq 0$, 令 $g(t) = f(x^* - t\nabla f(x^*))$, 则 $g'(0) = -\|\nabla f(x^*)\|^2 < 0$, 即

$$\lim_{t \rightarrow 0^+} \frac{g(t) - g(0)}{t} = g'(0) < 0$$

根据保号性, 存在 $\delta > 0$, 使得 $\forall t \in (0, \delta)$, 有

$$\frac{g(t) - g(0)}{t} < 0$$

于是 $g(t) < g(0)$, 即 $f(x^* - t\nabla f(x^*)) < f(x^*)$, $\forall t \in (0, \delta)$, 这与局部极小点的定义矛盾

定理 2.3 (二阶必要条件) 若 x^* 是 f 的局部极小点, 且 $\nabla^2 f$ 在 x^* 的一个开邻域内存在且连续, 则 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*)$ 是半正定的。

证明. 由定理 2.2 知 $\nabla f(x^*) = 0$ 。假设 $\nabla^2 f(x^*)$ 不是半正定的。此时可选取向量 p 使得 $p^T \nabla^2 f(x^*) p < 0$, 又因 $\nabla^2 f$ 在 x^* 附近连续, 故存在 $T > 0$, 使得对所有 $t \in [0, T]$, 有 $p^T \nabla^2 f(x^* + tp) p < 0$ 。

对 x^* 做泰勒展开, 对所有 $\bar{t} \in (0, T]$ 及某个 $t \in (0, \bar{t})$, 有

$$f(x^* + \bar{t}p) = f(x^*) + \bar{t}p^T \nabla f(x^*) + \frac{1}{2}\bar{t}^2 p^T \nabla^2 f(x^* + tp) p < f(x^*).$$

故 x^* 不是局部极小点, 矛盾。

定理 2.4 (二阶充分条件) 假设 $\nabla^2 f$ 在 x^* 的一个开邻域内连续, 且 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*)$ 是正定的。则 x^* 是 f 的严格局部极小点。

证明. 由于 Hessian 矩阵在 x^* 处连续且正定, 存在 $r > 0$, 使得对于开球 $\mathcal{D} = \{z \mid \|z - x^*\| < r\}$ 内的所有 x , $\nabla^2 f(x)$ 保持正定。取任意非零向量 p 满足 $\|p\| < r$, 则 $x^* + p \in \mathcal{D}$, 于是

$$\begin{aligned} f(x^* + p) &= f(x^*) + p^T \nabla f(x^*) + \frac{1}{2}p^T \nabla^2 f(z)p \\ &= f(x^*) + \frac{1}{2}p^T \nabla^2 f(z)p, \end{aligned}$$

其中 $z = x^* + tp$ 对某个 $t \in (0, 1)$ 成立。由于 $z \in \mathcal{D}$, 故 $p^T \nabla^2 f(z)p > 0$, 因此 $f(x^* + p) > f(x^*)$, 得证。

注 2.3 注意, 二阶充分条件不是必要的: 点 x^* 可能是严格局部极小点, 但却不满足充分条件。一个简单的例子是函数 $f(x) = x^4$, 其点 $x^* = 0$ 是严格局部极小点, 但在该点处 Hessian 矩阵为零 (因此不是正定的)。

定理 2.5 当 f 是凸函数时, 任何局部极小点 x^* 都是 f 的全局极小点。又若 f 可微, 则任何稳定点 x^* 都是 f 的全局极小点。

证明. 假设 x^* 是局部极小点但不是全局极小点, 则存在点 $z \in \mathbb{R}^n$ 使得 $f(z) < f(x^*)$ 。考虑连接 x^* 和 z 的线段, 即

$$x = \lambda z + (1 - \lambda)x^*, \quad \text{对某个 } \lambda \in (0, 1].$$

由 f 的凸性, 有

$$f(x) \leq \lambda f(z) + (1 - \lambda)f(x^*) < f(x^*).$$

x^* 的任意邻域 $\mathcal{N}$ 都包含线段的一部分, 因此总存在 $x \in \mathcal{N}$ 满足上式, 故 x^* 不是局部极小点, 矛盾。

又若 f 可微, 假设 x^* 不是全局极小点, 点 $z \in \mathbb{R}^n$ 使得 $f(z) < f(x^*)$ 。由凸性, 有

$$\begin{aligned} \nabla f(x^*)^T(z - x^*) &= \left. \frac{d}{d\lambda} f(x^* + \lambda(z - x^*)) \right|_{\lambda=0} \\ &= \lim_{\lambda \downarrow 0} \frac{f(x^* + \lambda(z - x^*)) - f(x^*)}{\lambda} \\ &\leq \lim_{\lambda \downarrow 0} \frac{\lambda f(z) + (1 - \lambda)f(x^*) - f(x^*)}{\lambda} \\ &= f(z) - f(x^*) < 0. \end{aligned}$$

因此, $\nabla f(x^*) \neq 0$, 故 x^* 不是稳定点, 矛盾。

注 2.4 本节的讨论概括起来就是:

- 对于一个一般的无约束最优化问题, 一个最好的情况是可以得到全局极小点;
- 如果无法全局极小点, 可以退而求其次去得到局部极小点或严格局部极小点;
- 对于一个光滑函数, 可以用局部极小点的一阶和二阶必要条件以及严格局部极小点的充分条件来判断极小点;
- 对于一个凸函数, 局部极小点与全局极小点是等价的;
- 对于一个光滑凸函数, 只要求得稳定点就可以得到全局极小点。

注 2.5 上述的讨论一般都基于其目标函数可微的情况, 对于非光滑的目标函数, 通常用次梯度 (梯度的推广) 来判断极小点, 这里暂不做讨论。

3 一般的最优性条件

上一节考虑了可微背景下的最优性条件，本节考虑不可微的最优性条件，设 $\mathbb{E}$ 是一个赋范空间。

3.1 凸优化的最优性条件

定理 3.1 (Fermat 最优性条件) 设 $f : \mathbb{E} \rightarrow (-\infty, \infty]$ 是适当凸函数，则

$$x^* \in \operatorname{argmin}\{f(x) : x \in \mathbb{E}\}$$

当且仅当 $0 \in \partial f(x^*)$ 。

证明.

$$\begin{aligned} x^* \in \operatorname{argmin}\{f(x) : x \in \mathbb{E}\} \\ \iff f(x) \geq f(x^*), \quad \forall x \in \operatorname{dom}(f), \\ \iff f(x) \geq f(x^*) + \langle 0, x - x^* \rangle, \quad \forall x \in \operatorname{dom}(f), \\ \iff 0 \in \partial f(x^*) \end{aligned}$$

考虑约束优化问题

$$\min\{f(x) : x \in C\},$$

其中 f 是广义实值凸函数，且 $C \subseteq \mathbb{E}$ 是凸集。

定理 3.2 (凸约束优化的充要最优性条件) 设 $f : \mathbb{E} \rightarrow (-\infty, \infty]$ 是适当凸函数， $C \subseteq \mathbb{E}$ 是凸集且满足 $\operatorname{ri}(\operatorname{dom}(f)) \cap \operatorname{ri}(C) \neq \emptyset$ 。则 $x^* \in C$ 是上述问题的最优解当且仅当

$$\text{存在 } g \in \partial f(x^*) \text{ 使得 } -g \in N_C(x^*).$$

证明.

$$\min\{f(x) : x \in C\},$$

可改写为

$$\min_{x \in \mathbb{E}} f(x) + \delta_C(x).$$

由于 $\operatorname{ri}(\operatorname{dom}(f)) \cap \operatorname{ri}(C) \neq \emptyset$ ，根据次微分的和法则，对任意 $x \in C$ ，有

$$\partial(f + \delta_C)(x) = \partial f(x) + \partial \delta_C(x) = \partial f(x) + N_C(x).$$

于是, 利用定理 3.1, $x^* \in C$ 是最优解当且仅当 $0 \in \partial f(x^*) + N_C(x^*)$, 即当且仅当

$$\text{存在 } g \in \partial f(x^*) \text{ 使得 } -g \in N_C(x^*).$$

注 3.1 进一步由法锥的定义得到: $x^* \in C$ 是最优解当且仅当

$$\text{存在 } g \in \partial f(x^*) \text{ 使得对任意 } x \in C, \langle g, x - x^* \rangle \geq 0.$$

这就是变分不等式。

3.2 非凸优化的最优性条件

定理 3.3 (复合问题的最优性条件) 设 $f: \mathbb{E} \rightarrow (-\infty, \infty]$ 是适当函数, $g: \mathbb{E} \rightarrow (-\infty, \infty]$ 是适当凸函数, 且满足 $\text{dom}(g) \subseteq \text{int}(\text{dom}(f))$ 。考虑问题

$$\min_{x \in \mathbb{E}} f(x) + g(x).$$

(a) (必要条件) 若 $x^* \in \text{dom}(g)$ 是问题 (P) 的局部最优解, 且 f 在 x^* 处可微, 则

$$-\nabla f(x^*) \in \partial g(x^*).$$

(b) (凸问题的充要条件) 假设 f 是凸函数。若 f 在 $x^* \in \text{dom}(g)$ 处可微, 则 x^* 是问题 (P) 的全局最优解当且仅当上述条件成立。

证明.

(a) 设 $y \in \text{dom}(g)$ 。由 $\text{dom}(g)$ 的凸性, 对任意 $\lambda \in (0, 1)$, 点 $x_\lambda = (1 - \lambda)x^* + \lambda y$ 属于 $\text{dom}(g)$; 再由 x^* 的局部最优性, 当 λ 足够小时, 有

$$f(x_\lambda) + g(x_\lambda) \geq f(x^*) + g(x^*).$$

即

$$f((1 - \lambda)x^* + \lambda y) + g((1 - \lambda)x^* + \lambda y) \geq f(x^*) + g(x^*).$$

利用 g 的凸性, 可得

$$f((1 - \lambda)x^* + \lambda y) + (1 - \lambda)g(x^*) + \lambda g(y) \geq f(x^*) + g(x^*),$$

整理得

$$\frac{f((1 - \lambda)x^* + \lambda y) - f(x^*)}{\lambda} \geq g(x^*) - g(y).$$

令 $\lambda \rightarrow 0^+$, 由 f 在 x^* 处可微, 于是 $f'(x^*; y - x^*) = \langle \nabla f(x^*), y - x^* \rangle$, 因此对任意 $y \in \text{dom}(g)$, 有

$$g(y) \geq g(x^*) + \langle -\nabla f(x^*), y - x^* \rangle,$$

于是 $-\nabla f(x^*) \in \partial g(x^*)$ 。

(b) 额外假设 f 是凸函数。若 x^* 是问题 (P) 的最优解，由 (a) 已证条件成立。反之，若条件成立，则对任意 $y \in \text{dom}(g)$ ，有

$$g(y) \geq g(x^*) + \langle -\nabla f(x^*), y - x^* \rangle.$$

由 f 的凸性，对任意 $y \in \text{dom}(g)$ ，有

$$f(y) \geq f(x^*) + \langle \nabla f(x^*), y - x^* \rangle.$$

将两式相加，得对任意 $y \in \text{dom}(g)$ ，有

$$f(y) + g(y) \geq f(x^*) + g(x^*),$$

即 x^* 是问题 (P) 的最优解。

注 3.2

- 当 f 可微， g 适当凸，我们称满足下面关系的 x^* 为稳定点：

$$-\nabla f(x^*) \in \partial g(x^*).$$

- 当 $g = \delta_C$ （其中 $C \subseteq \mathbb{E}$ 是非空凸集）时，问题 (P) 变为

$$\min\{f(x) : x \in C\}.$$

若 f 在 $x^* \in C$ 处可微，则 x^* 是问题 (P) 的平稳点当且仅当

$$-\nabla f(x^*) \in \partial \delta_C(x^*) = N_C(x^*),$$

根据法锥的定义，条件可改写为

$$\langle \nabla f(x^*), x - x^* \rangle \geq 0 \quad \forall x \in C.$$

也就是说，求这个问题的稳定点相当于求解一个变分不等式问题。

3.3 KKT 条件

引理 3.4 考虑如下约束的优化问题

$$\begin{aligned} \min & f(x) \\ \text{s.t.} & g_i(x) \leq 0, \quad i = 1, 2, \dots, m, \end{aligned}$$

其中 $f, g_1, g_2, \dots, g_m : \mathbb{E} \rightarrow \mathbb{R}$ 是实值函数。假设问题的最小值有限且等于 $\bar{f}$ 。定义函数

$$F(x) \equiv \max\{f(x) - \bar{f}, g_1(x), g_2(x), \dots, g_m(x)\}.$$

则原问题的最优解集与 F 的极小值点集相同。

证明. 设 X^* 是问题的最优解集。 F 满足以下两个性质：

(i) 对任意 $x \notin X^*$ ，有 $F(x) > 0$ ；

设 $x \notin X^*$ ，分两种情况：

- 若 x 不可行，即存在 i 使得 $g_i(x) > 0$ ，由 F 的定义知 $F(x) > 0$ ；
- 若 x 可行但非最优，则对所有 i 有 $g_i(x) \leq 0$ 且 $f(x) > \bar{f}$ ，因此 $F(x) > 0$ 。

(ii) 对任意 $x \in X^*$ ，有 $F(x) = 0$ 。

设 $x \in X^*$ ，则对所有 i 有 $g_i(x) \leq 0$ 且 $f(x) = \bar{f}$ ，故 $F(x) = 0$ 。

上面分析可以看出， F 的极小值点集就是 $\{x : F(x) = 0\} = X^*$ ，即原问题的最优解集与 F 的极小值点集相同。

定理 3.5 (Fritz-John 必要最优性条件) 考虑如下约束的优化问题

$$\begin{aligned} \min & f(x) \\ \text{s.t. } & g_i(x) \leq 0, \quad i = 1, 2, \dots, m, \end{aligned}$$

其中 $f, g_1, g_2, \dots, g_m : \mathbb{E} \rightarrow \mathbb{R}$ 是实值凸函数。设 x^* 是问题的最优解，则存在不全为零的 $\lambda_0, \lambda_1, \dots, \lambda_m \geq 0$ ，使得

$$\begin{aligned} 0 & \in \lambda_0 \partial f(x^*) + \sum_{i=1}^m \lambda_i \partial g_i(x^*) \\ \lambda_i g_i(x^*) & = 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

证明. 设 x^* 是问题的最优解，记问题的最优值为 $\bar{f} = f(x^*)$ 。由定理 3.4， x^* 是问题

$$\min_{x \in \mathbb{E}} \{F(x) \equiv \max\{g_0(x), g_1(x), \dots, g_m(x)\}\}$$

(其中 $g_0(x) = f(x) - \bar{f}$) 的最优解，显然 $F(x^*) = 0$ 。由于 F 是凸函数的最大值，故 F 是凸函数。利用定理 3.1，有

$$0 \in \partial F(x^*) = \text{conv} \left(\bigcup_{i \in I(x^*)} \partial g_i(x^*) \right),$$

其中 $I(x^*) = \{i \in \{0, 1, \dots, m\} : g_i(x^*) = 0\}$ 。结合上式可知，存在 $\lambda_i \geq 0$ ($i \in I(x^*)$) 且 $\sum_{i \in I(x^*)} \lambda_i = 1$ ，使得

$$0 \in \sum_{i \in I(x^*)} \lambda_i \partial g_i(x^*).$$

由于 $g_0(x^*) = f(x^*) - \bar{f} = 0$ ，故 $0 \in I(x^*)$ ，因此上式可改写为

$$0 \in \lambda_0 \partial f(x^*) + \sum_{i \in I(x^*) \setminus \{0\}} \lambda_i \partial g_i(x^*).$$

对任意 $i \in \{1, 2, \dots, m\} \setminus I(x^*)$ ，令 $\lambda_i = 0$ ，则两个条件都成立。最后，由于 $\sum_{i \in I(x^*)} \lambda_i = 1$ ，故 λ_i 不全为零。

如果要求 $\lambda_0 = 1$ ，则需要满足以下附加条件（称为 Slater 条件）：

存在 $\bar{x} \in \mathbb{E}$ 使得 $g_i(\bar{x}) < 0, i = 1, 2, \dots, m$.

KKT 条件的充分性不需要额外假设（除凸性外），且无需借助弗里茨-约翰条件的结论即可轻松推导。

定理 3.6 (KKT 条件) 考虑如下的优化问题

$$\min f(x)$$

$$\text{s.t. } g_i(x) \leq 0, i = 1, 2, \dots, m,$$

其中 $f, g_1, g_2, \dots, g_m : \mathbb{E} \rightarrow \mathbb{R}$ 是实值凸函数。

(a) 设 x^* 是问题的最优解，且 Slater 条件成立，则存在 $\lambda_1, \dots, \lambda_m \geq 0$ ，使得

$$\begin{aligned} 0 &\in \partial f(x^*) + \sum_{i=1}^m \lambda_i \partial g_i(x^*) \\ \lambda_i g_i(x^*) &= 0, i = 1, 2, \dots, m. \end{aligned}$$

(b) 若可行点 $x^* \in \mathbb{E}$ 对某组 $\lambda_1, \lambda_2, \dots, \lambda_m \geq 0$ 满足上述两个条件，则 x^* 是问题的最优解。

证明.

(a) 由定理 3.5，存在不全为零的 $\tilde{\lambda}_0, \tilde{\lambda}_1, \dots, \tilde{\lambda}_m \geq 0$ ，使得

$$0 \in \tilde{\lambda}_0 \partial f(x^*) + \sum_{i=1}^m \tilde{\lambda}_i \partial g_i(x^*)$$

且

$$\tilde{\lambda}_i g_i(x^*) = 0, i = 1, 2, \dots, m.$$

只要证明 $\tilde{\lambda}_0 \neq 0$ 即可。假设 $\tilde{\lambda}_0 = 0$ ，则由上式得

$$0 \in \sum_{i=1}^m \tilde{\lambda}_i \partial g_i(x^*),$$

即存在 $\xi_i \in \partial g_i(x^*) (i = 1, 2, \dots, m)$ ，使得

$$\sum_{i=1}^m \tilde{\lambda}_i \xi_i = 0.$$

设 $\bar{x}$ 是满足 Slater 条件的点，对函数 $g_i (i = 1, 2, \dots, m)$ ，由次梯度定义有

$$g_i(x^*) + \langle \xi_i, \bar{x} - x^* \rangle \leq g_i(\bar{x}), i = 1, 2, \dots, m.$$

将第 i 个不等式乘以 $\tilde{\lambda}_i \geq 0$ 并对 $i = 1, 2, \dots, m$ 求和, 得

$$\sum_{i=1}^m \tilde{\lambda}_i g_i(x^*) + \left\langle \sum_{i=1}^m \tilde{\lambda}_i \xi_i, \bar{x} - x^* \right\rangle \leq \sum_{i=1}^m \tilde{\lambda}_i g_i(\bar{x}).$$

但是左边两项都为 0, 故 $\sum_{i=1}^m \tilde{\lambda}_i g_i(\bar{x}) \geq 0$ 。但 Slater 条件中 $g_i(\bar{x}) < 0$ 且 $\tilde{\lambda}_i \geq 0$ (不全为零), 于是矛盾。因此 $\tilde{\lambda}_0 > 0$ 。

令 $\lambda_i = \frac{\tilde{\lambda}_i}{\tilde{\lambda}_0}$ ($i = 1, 2, \dots, m$), 则

$$\begin{aligned} 0 &\in \partial f(x^*) + \sum_{i=1}^m \lambda_i \partial g_i(x^*) \\ \lambda_i g_i(x^*) &= 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

(b) 假设可行点 x^* 对某组 $\lambda_1, \lambda_2, \dots, \lambda_m \geq 0$ 满足两个条件。设 $\bar{x}$ 是可行点, 即 $g_i(\bar{x}) \leq 0$ ($i = 1, 2, \dots, m$), 我们证明 $f(\bar{x}) \geq f(x^*)$ 。

定义函数

$$h(x) = f(x) + \sum_{i=1}^m \lambda_i g_i(x),$$

则 h 是凸函数。于是 KKT 条件告诉我们

$$0 \in \partial h(x^*),$$

结合定理 3.1, x^* 是 h 在 $\mathbb{E}$ 上的极小值点。

于是

$$f(x^*) = f(x^*) + \sum_{i=1}^m \lambda_i g_i(x^*) = h(x^*) \leq h(\bar{x}) = f(\bar{x}) + \sum_{i=1}^m \lambda_i g_i(\bar{x}).$$

由于 $\lambda_i \geq 0$ 且 $g_i(\bar{x}) \leq 0$, 故 $\sum_{i=1}^m \lambda_i g_i(\bar{x}) \leq 0$, 因此

$$f(x^*) \leq f(\bar{x}) + \sum_{i=1}^m \lambda_i g_i(\bar{x}) \leq f(\bar{x}),$$

即 x^* 是最优解。

注 3.3 我们将满足以下条件的 x^* 称为 KKT 点:

$$\begin{aligned} 0 &\in \partial f(x^*) + \sum_{i=1}^m \lambda_i \partial g_i(x^*) \\ \lambda_i g_i(x^*) &= 0, \quad i = 1, 2, \dots, m, \\ g_i(x^*) &\leq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

4 一般 NLP 中的 KKT 条件、锥与约束资格条件

4.1 问题形式与基本目标

考虑一般非线性规划问题

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p, \end{aligned} \quad (1)$$

其中 f, g_i, h_j 在所讨论点附近可微。记可行集为

$$\Omega := \{x \in \mathbb{R}^n : g_i(x) \leq 0, i = 1, \dots, m, h_j(x) = 0, j = 1, \dots, p\}. \quad (2)$$

对于给定可行点 $x^* \in \Omega$ ，记活动不等式指标集为

$$I(x^*) := \{i \in \{1, \dots, m\} : g_i(x^*) = 0\}. \quad (3)$$

本文的目标是解释：

1. 局部极小点为什么应当满足 KKT 条件；
2. KKT 条件中的乘子从何而来；
3. 切锥、线性化锥、极锥与法锥在这一理论中扮演什么角色；
4. 为什么需要各种约束资格条件（constraint qualifications, CQ）。

4.2 切锥、线性化锥与极锥

定义 4.1 (Bouligand 切锥) 设 $\Omega \subset \mathbb{R}^n$, $x \in \Omega$ 。定义 Ω 在 x 处的 Bouligand (或 contingent) 切锥为

$$T_\Omega(x) := \left\{ d \in \mathbb{R}^n : \exists x^k \in \Omega, x^k \rightarrow x, \exists t_k \downarrow 0, \frac{x^k - x}{t_k} \rightarrow d \right\}. \quad (4)$$

定义 4.1 中的切锥描述的是可行集在点 x 处的真实一阶可行方向。

定义 4.2 (线性化锥) 对问题 (1)，其在可行点 x^* 处的线性化锥定义为

$$L_\Omega(x^*) := \left\{ d \in \mathbb{R}^n : \nabla g_i(x^*)^\top d \leq 0, i \in I(x^*), \nabla h_j(x^*)^\top d = 0, j = 1, \dots, p \right\}. \quad (5)$$

定义 4.2 中的线性化锥表示把约束在 x^* 处作一阶线性化后得到的“近似可行方向锥”。

命题 4.1 对任意可行点 $x^* \in \Omega$, 都有

$$T_{\Omega}(x^*) \subseteq L_{\Omega}(x^*). \quad (6)$$

证明. 任取 $d \in T_{\Omega}(x^*)$ 。由定义 4.1, 存在 $x^k \in \Omega$ 与 $t_k \downarrow 0$ 使

$$\frac{x^k - x^*}{t_k} \rightarrow d.$$

由于 x^k 可行, 对任意 $i \in I(x^*)$,

$$g_i(x^k) \leq 0, \quad g_i(x^*) = 0.$$

由 g_i 的可微性,

$$g_i(x^k) = g_i(x^*) + \nabla g_i(x^*)^{\top} (x^k - x^*) + o(\|x^k - x^*\|).$$

除以 $t_k > 0$ 并令 $k \rightarrow \infty$, 得到

$$\nabla g_i(x^*)^{\top} d \leq 0.$$

同理, 由 $h_j(x^k) = h_j(x^*) = 0$ 及 h_j 的可微性可得

$$\nabla h_j(x^*)^{\top} d = 0.$$

因此 $d \in L_{\Omega}(x^*)$, 即 (6) 成立。

定义 4.3 (极锥) 对任意锥 $K \subseteq \mathbb{R}^n$, 其极锥定义为

$$K^{\circ} := \{v \in \mathbb{R}^n : \langle v, d \rangle \leq 0, \forall d \in K\}. \quad (7)$$

定义 4.3 表明: 锥 K 描述“可以走的方向”, 而其极锥 K° 描述“阻止这些方向的法向”。

4.3 Fréchet 正则法锥、Mordukhovich 法锥与 Clarke 法锥

定义 4.4 (Fréchet 正则法锥) 设 $\Omega \subseteq \mathbb{R}^n$, $x \in \Omega$ 。定义 Fréchet (regular) 法锥为

$$\hat{N}_{\Omega}(x) := \left\{ v \in \mathbb{R}^n : \limsup_{\substack{y \rightarrow x \\ y \in \Omega, y \neq x}} \frac{\langle v, y - x \rangle}{\|y - x\|} \leq 0 \right\}. \quad (8)$$

命题 4.2 对任意集合 $\Omega \subseteq \mathbb{R}^n$ 及任意 $x \in \Omega$, 有

$$\hat{N}_{\Omega}(x) = T_{\Omega}(x)^{\circ}. \quad (9)$$

证明. 先证 “ $\subseteq$ ”。任取 $v \in \widehat{N}_\Omega(x)$ 与 $d \in T_\Omega(x)$ 。由定义 4.1, 存在 $y^k \in \Omega$ 与 $t_k \downarrow 0$ 使

$$\frac{y^k - x}{t_k} \rightarrow d.$$

若 $d \neq 0$, 则

$$\left\langle v, \frac{y^k - x}{t_k} \right\rangle = \frac{\langle v, y^k - x \rangle}{\|y^k - x\|} \cdot \frac{\|y^k - x\|}{t_k}.$$

由 (8), 第一因子的上极限不超过 0; 第二因子收敛到 $\|d\|$ 。因此

$$\langle v, d \rangle \leq 0.$$

若 $d = 0$, 则结论显然成立。故 $v \in T_\Omega(x)^\circ$ 。

再证 “ $\supseteq$ ”。设 $v \in T_\Omega(x)^\circ$, 若 $v \notin \widehat{N}_\Omega(x)$, 则由 (8) 的否定形式, 存在 $\varepsilon > 0$ 与 $y^k \in \Omega$, $y^k \rightarrow x$ 使

$$\frac{\langle v, y^k - x \rangle}{\|y^k - x\|} \geq \varepsilon.$$

令

$$t_k := \|y^k - x\|, \quad d^k := \frac{y^k - x}{t_k}.$$

则 $\|d^k\| = 1$ 。取子列仍记为 d^k , 使 $d^k \rightarrow d$ 。由定义 4.1, 有 $d \in T_\Omega(x)$ 。于是

$$\langle v, d \rangle = \lim_{k \rightarrow \infty} \left\langle v, \frac{y^k - x}{t_k} \right\rangle \geq \varepsilon > 0,$$

这与 $v \in T_\Omega(x)^\circ$ 矛盾。故 $v \in \widehat{N}_\Omega(x)$ 。

定义 4.5 (Mordukhovich 法锥) 定义 Mordukhovich (limiting/basic) 法锥为

$$N_\Omega^M(x) := \left\{ v \in \mathbb{R}^n : \exists x^k \in \Omega, x^k \rightarrow x, \exists v^k \rightarrow v, v^k \in \widehat{N}_\Omega(x^k) \right\}. \quad (10)$$

定义 4.6 (Clarke 法锥) 定义 Clarke 法锥为

$$N_\Omega^C(x) := \overline{\text{co}} N_\Omega^M(x). \quad (11)$$

命题 4.3 总有

$$\widehat{N}_\Omega(x) \subseteq N_\Omega^M(x) \subseteq N_\Omega^C(x). \quad (12)$$

证明. 由定义 (10), 取常值序列 $x^k \equiv x$ 与 $v^k \equiv v$, 可得

$$\widehat{N}_\Omega(x) \subseteq N_\Omega^M(x).$$

再由定义 (11), $N_\Omega^C(x)$ 是 $N_\Omega^M(x)$ 的闭凸包, 故

$$N_\Omega^M(x) \subseteq N_\Omega^C(x).$$

4.4 局部极小点的最原始一阶必要条件

命题 4.4 若 x^* 是问题 (1) 的局部极小点, 则

$$-\nabla f(x^*) \in T_\Omega(x^*)^\circ = \widehat{N}_\Omega(x^*). \quad (13)$$

证明. 任取 $d \in T_\Omega(x^*)$ 。由定义 4.1, 存在 $x^k \in \Omega$ 与 $t_k \downarrow 0$ 使

$$\frac{x^k - x^*}{t_k} \rightarrow d.$$

由于 x^* 是局部极小点, 对充分大的 k 有

$$f(x^k) \geq f(x^*).$$

由 f 的可微性,

$$f(x^k) = f(x^*) + \nabla f(x^*)^\top (x^k - x^*) + o(\|x^k - x^*\|).$$

移项并除以 t_k , 令 $k \rightarrow \infty$, 得

$$\nabla f(x^*)^\top d \geq 0.$$

这等价于

$$-\nabla f(x^*)^\top d \leq 0, \quad \forall d \in T_\Omega(x^*),$$

即

$$-\nabla f(x^*) \in T_\Omega(x^*)^\circ.$$

再由命题 4.2, 得到 (13)。

命题 4.4 表明: 局部极小点处, 目标函数不能沿任何真实切方向下降, 因此其负梯度必须属于可行集的法锥。

4.5 线性化锥极锥的显式表达

令

$$K := \{d : \nabla g_i(x^*)^\top d \leq 0, i \in I(x^*)\}, \quad (14)$$

$$S := \{d : \nabla h_j(x^*)^\top d = 0, j = 1, \dots, p\}. \quad (15)$$

则由定义 4.2,

$$L_\Omega(x^*) = K \cap S. \quad (16)$$

命题 4.5 对任意闭凸锥 $C_1, C_2 \subseteq \mathbb{R}^n$, 有

$$(C_1 \cap C_2)^\circ = \overline{C_1^\circ + C_2^\circ}. \quad (17)$$

证明. 先证

$$\overline{C_1^\circ + C_2^\circ} \subseteq (C_1 \cap C_2)^\circ.$$

任取 $u = u_1 + u_2$, 其中 $u_1 \in C_1^\circ$, $u_2 \in C_2^\circ$ 。对任意 $x \in C_1 \cap C_2$, 有

$$\langle u_1, x \rangle \leq 0, \quad \langle u_2, x \rangle \leq 0,$$

故

$$\langle u, x \rangle = \langle u_1, x \rangle + \langle u_2, x \rangle \leq 0.$$

所以 $u \in (C_1 \cap C_2)^\circ$, 进而其闭包也包含于 $(C_1 \cap C_2)^\circ$ 。

再证反向包含。设

$$M := \overline{C_1^\circ + C_2^\circ}.$$

由上一步, $M \subseteq (C_1 \cap C_2)^\circ$ 。对两边取极锥, 包含关系反向, 得

$$((C_1 \cap C_2)^\circ)^\circ \subseteq M^\circ.$$

由双极定理 (闭凸锥满足 $K = (K^\circ)^\circ$), 可得

$$C_1 \cap C_2 \subseteq M^\circ.$$

另一方面, 因为闭包不影响极锥, 所以

$$M^\circ = (C_1^\circ + C_2^\circ)^\circ.$$

若 $x \in (C_1^\circ + C_2^\circ)^\circ$, 则对任意 $u_1 \in C_1^\circ$, $u_2 \in C_2^\circ$,

$$\langle x, u_1 + u_2 \rangle \leq 0.$$

令 $u_2 = 0$, 得 $\langle x, u_1 \rangle \leq 0$ 对任意 $u_1 \in C_1^\circ$ 成立, 因此

$$x \in (C_1^\circ)^\circ = C_1.$$

同理可得 $x \in C_2$ 。故

$$(C_1^\circ + C_2^\circ)^\circ \subseteq C_1 \cap C_2.$$

于是

$$M^\circ \subseteq C_1 \cap C_2.$$

结合前面的包含关系, 得到 $M^\circ = C_1 \cap C_2$ 。再取极锥并用双极定理, 即得

$$(C_1 \cap C_2)^\circ = M = \overline{C_1^\circ + C_2^\circ}.$$

命题 4.6 线性化锥 $L_\Omega(x^*)$ 的极锥可显式写成

$$L_\Omega(x^*)^\circ = \left\{ \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \mu_j \nabla h_j(x^*) : \lambda_i \geq 0, \mu_j \in \mathbb{R} \right\}. \quad (18)$$

证明. 由 (16) 与命题 4.5,

$$L_\Omega(x^*)^\circ = (K \cap S)^\circ = \overline{K^\circ + S^\circ}.$$

先计算 K° 。由 (14),

$$K = \bigcap_{i \in I(x^*)} \{d : \nabla g_i(x^*)^\top d \leq 0\}.$$

每个半空间锥的极锥为

$$\{d : \nabla g_i(x^*)^\top d \leq 0\}^\circ = \{\lambda_i \nabla g_i(x^*) : \lambda_i \geq 0\}.$$

因此

$$K^\circ = \text{cone}\{\nabla g_i(x^*) : i \in I(x^*)\} = \left\{ \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) : \lambda_i \geq 0 \right\}. \quad (19)$$

再计算 S° 。由 (15), S 是线性子空间, 因此

$$S^\circ = S^\perp = \text{span}\{\nabla h_j(x^*) : j = 1, \dots, p\} = \left\{ \sum_{j=1}^p \mu_j \nabla h_j(x^*) : \mu_j \in \mathbb{R} \right\}. \quad (20)$$

将 (19) 与 (20) 代入, 并注意此时和为闭集, 故闭包可省, 即得 (18)。

命题 4.6 正是 KKT 乘子式出现的根源: 活动不等式梯度生成非负锥, 等式梯度生成线性空间, 两者相加便是线性化锥的极锥。

4.6 KKT 条件的由来

KKT 条件的证明结构可概括为:

局部极小 $\implies -\nabla f(x^*) \in T_\Omega(x^*)^\circ \implies -\nabla f(x^*) \in L_\Omega(x^*)^\circ \implies$ 存在乘子, 满足 KKT.

因此真正的关键, 是找到足够的条件保证

$$T_\Omega(x^*)^\circ = L_\Omega(x^*)^\circ.$$

这正是各类约束资格条件的作用。

4.7 各类约束资格条件 (CQ)

定义 4.7 (LICQ) 称问题 (1) 在可行点 x^* 处满足 LICQ (linear independence constraint qualification), 如果向量组

$$\{\nabla g_i(x^*) : i \in I(x^*)\} \cup \{\nabla h_j(x^*) : j = 1, \dots, p\} \quad (21)$$

线性无关。

定义 4.8 (MFCQ) 称问题 (1) 在可行点 x^* 处满足 MFCQ (Mangasarian–Fromovitz constraint qualification), 如果

1. $\nabla h_j(x^*)$ ($j = 1, \dots, p$) 线性无关;
2. 存在某个方向 $d \in \mathbb{R}^n$ 使

$$\nabla h_j(x^*)^\top d = 0, \quad j = 1, \dots, p, \quad (22)$$

且

$$\nabla g_i(x^*)^\top d < 0, \quad i \in I(x^*). \quad (23)$$

定义 4.9 (CRCQ) 称问题 (1) 在可行点 x^* 处满足 CRCQ (constant rank constraint qualification), 如果存在 x^* 的一个邻域 $N(x^*)$, 使得对任意

$$I_1 \subseteq I(x^*), \quad I_2 \subseteq \{1, \dots, p\},$$

向量组

$$\{\nabla g_i(x) : i \in I_1\} \cup \{\nabla h_j(x) : j \in I_2\}$$

在整个邻域 $N(x^*)$ 内都保持相同秩。

定义 4.10 (CPLD) 称问题 (1) 在可行点 x^* 处满足 CPLD (constant positive linear dependence), 如果对任意

$$I_1 \subseteq I(x^*), \quad I_2 \subseteq \{1, \dots, p\},$$

一旦向量组

$$\{\nabla g_i(x^*) : i \in I_1\} \cup \{\nabla h_j(x^*) : j \in I_2\}$$

在点 x^* 处正线性相关, 则它们在某个邻域内保持线性相关。

定义 4.11 (ACQ) 称问题 (1) 在可行点 x^* 处满足 ACQ (Abadie constraint qualification), 如果

$$T_\Omega(x^*) = L_\Omega(x^*). \quad (24)$$

定义 4.12 (GCQ) 称问题 (1) 在可行点 x^* 处满足 GCQ (Guignard constraint qualification), 如果

$$T_\Omega(x^*)^\circ = L_\Omega(x^*)^\circ. \quad (25)$$

评论 4.1 各类 CQ 的本质作用都是保证：线性化信息足够忠实地反映可行集的局部几何。其中 ACQ 要求锥本身相等，GCQ 只要求极锥相等；对推出 KKT 而言，GCQ 已经足够。

4.8 CQ 之间的常见关系

在标准可微 NLP 框架下，常见的蕴含关系可写成

$$\text{LICQ} \implies \text{MFCQ}, \quad \text{LICQ} \implies \text{CRCQ}, \quad (26)$$

$$\text{MFCQ} \implies \text{CPLD}, \quad \text{CRCQ} \implies \text{CPLD}, \quad (27)$$

$$\text{CPLD} \implies \text{ACQ} \implies \text{GCQ}. \quad (28)$$

需要注意的是，MFCQ 与 CRCQ 一般互不包含。

4.9 KKT 定理

定理 4.7 (KKT 必要条件) 设 x^* 是问题 (1) 的局部极小点。若在 x^* 处满足 GCQ (见定义 4.12)，则存在乘子

$$\lambda \in \mathbb{R}^m, \quad \mu \in \mathbb{R}^p$$

使得

$$\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \mu_j \nabla h_j(x^*) = 0, \quad (29)$$

$$g_i(x^*) \leq 0, \quad h_j(x^*) = 0, \quad (30)$$

$$\lambda_i \geq 0, \quad (31)$$

$$\lambda_i g_i(x^*) = 0, \quad i = 1, \dots, m. \quad (32)$$

特别地，若在 x^* 处满足 ACQ、CPLD、MFCQ 或 LICQ，则上述 KKT 条件同样成立。

证明. 由命题 4.4,

$$-\nabla f(x^*) \in T_{\Omega}(x^*)^{\circ}.$$

由 GCQ 的定义 4.12,

$$T_{\Omega}(x^*)^{\circ} = L_{\Omega}(x^*)^{\circ}.$$

因此

$$-\nabla f(x^*) \in L_{\Omega}(x^*)^{\circ}.$$

再由命题 4.6, 存在 $\lambda_i \geq 0$ ($i \in I(x^*)$) 与 $\mu_j \in \mathbb{R}$, 使

$$-\nabla f(x^*) = \sum_{i \in I(x^*)} \lambda_i \nabla g_i(x^*) + \sum_{j=1}^p \mu_j \nabla h_j(x^*).$$

对 $i \notin I(x^*)$ 定义 $\lambda_i := 0$, 即可得到 (29)。由构造, $\lambda_i \geq 0$, 且当 $i \notin I(x^*)$ 时 $g_i(x^*) < 0$ 且 $\lambda_i = 0$; 当 $i \in I(x^*)$ 时 $g_i(x^*) = 0$ 。故

$$\lambda_i g_i(x^*) = 0, \quad i = 1, \dots, m.$$

结合原始可行性 (30), 定理得证。

最后, 由 (28) 以及 (26)–(27) 可知, ACQ、CPLD、MFCQ、LICQ 都蕴含 GCQ, 因此结论同样成立。

4.10 KKT 条件的几何意义与作用

评论 4.2 (几何意义) 由定理 4.7 可见, KKT 条件本质上是

$$-\nabla f(x^*) \in N_{\Omega}(x^*),$$

也就是: 在局部极小点处, 目标函数的下降趋势已经被活动约束的法向完全抵消。

评论 4.3 (理论作用) KKT 条件是一阶必要条件; 在此基础上, 可以进一步讨论二阶必要条件与二阶充分条件。

评论 4.4 (算法作用) SQP、内点法、增广拉格朗日法等经典 NLP 算法, 本质上都在求解或逼近 KKT 系统 (29)–(32)。

评论 4.5 (灵敏度与对偶解释) KKT 乘子还具有对偶变量与边际价值的解释: 某个活动约束的乘子越大, 通常表明该约束对最优值的影响越显著。

4.11 总结

综上, 一般 NLP 中 KKT 条件的由来可以概括为

$$\text{局部极小} \implies -\nabla f(x^*) \in T_{\Omega}(x^*)^{\circ} \implies -\nabla f(x^*) \in L_{\Omega}(x^*)^{\circ} \implies \text{存在乘子, 满足 KKT.} \quad (33)$$

其中:

- 切锥 $T_{\Omega}(x^*)$ 描述真实可行方向 (定义 4.1);
- 线性化锥 $L_{\Omega}(x^*)$ 描述一阶近似可行方向 (定义 4.2);
- Fréchet 正则法锥满足 $\hat{N}_{\Omega}(x^*) = T_{\Omega}(x^*)^{\circ}$ (命题 4.2);

- 线性化锥的极锥具有显式梯度生成形式（命题 4.6）；
- 各类 CQ 的作用，是保证从真实几何到线性化几何的过渡合法（见定义 4.7–4.12 及定理 4.7）。

因此，KKT 条件并不是凭空写出的代数方程，而是局部最优性的几何性质、锥的对偶结构以及约束资格条件共同作用的结果。

5 最优化基本算法框架

最优化算法是一种数值算法，从初始点 x_0 开始，按一定的规则 (算法) 得到点列 $\{x^k\}$ ，从而得到解点 x^* 的近似点。

最优化算法根据 x^k 处 (甚至 $x^0, x^1, \dots, x^{k-1}$ 处) 的信息 (如函数值、导数信息等) 得到下一个迭代点 x^{k+1} 。一般来说有两种类型的策略：**线搜索 (Line Search)** 与 **信赖域 (Trust Region)**。

- **线搜索:**

在线搜索策略中，算法选择一个方向 p_k ，并从当前迭代点 x_k 沿该方向搜索，以找到函数值更小的新迭代点。沿 p_k 移动的距离 (步长 α_k) 可通过近似求解以下问题来确定：

$$\alpha_k = \operatorname{argmin}_{\alpha > 0} f(x_k + \alpha p_k).$$

然后令 $x_{k+1} = x_k + \alpha_k p_k$ 。若精确求解 α_k 固然很好，但精确极小化可能成本高昂且通常得不偿失。

- **信赖域:**

在信赖域策略中，每一次迭代需要构造一个模型函数 m_k ，该函数是在当前点 x_k 附近对目标函数 f 的相似。由于当 x 远离 x_k 时，模型 m_k 可能无法很好地近似 f ，因此我们将对 m_k 极小点的搜索限制在 x_k 周围的某个区域 (即信赖域) 内。信赖域策略通过近似求解以下子问题来找到候选步长 p_k ：

$$p_k = \operatorname{argmin}_p m_k(x_k + p), \quad \text{其中 } x_k + p \text{ 位于信赖域内.}$$

若 p_k 未使 f 产生足够的下降，则判定信赖域过大，会缩小并重新求解该子问题。通常，信赖域是一个由 $\|p\| \leq \Delta$ 定义的球，其中 $\Delta > 0$ 称为信赖域半径。

f 的近似模型 m_k 通常定义为如下形式的二次函数：

$$m_k(x_k + p) = f_k + p^T \nabla f_k + \frac{1}{2} p^T B_k p,$$

其中 f_k 和 ∇f_k 选取为在点 x_k 处的函数值和梯度值，使得 m_k 和 f 在当前迭代点 x_k 处一阶一致，矩阵 B_k 是 $\nabla^2 f_k$ 或其近似矩阵。

- **区别:**

线搜索和信赖域方法的区别在于**选择移动到下一个迭代点的方向和距离的顺序**。线搜索先固定方向 p_k ，然后确定合适的距离，即步长 α_k 。在信赖域中，首先选择最大距离——信赖域半径 Δ_k ，然后在该距离约束下寻找能实现最佳改进的方向和步长，若该效果不理想，我们就减小距离度量 Δ_k 并再次尝试。

对此有两个主要问题：线搜索方法中搜索方向 p_k 的选择，以及信赖域方法中 B_k 的选择。

5.1 线搜索的搜索方向

5.1.1 下降方向

最速下降方向为 $-\nabla f_k$ ，它是线搜索方法中搜索方向的直观选择，是从 x_k 出发使 f 下降最快的方向。事实上，令 $h(\alpha) = f(x_k + \alpha p)$ ，为了让其在 x_k 处有最快的下降方向，则需要 $\frac{d}{d\alpha}h(0) = \nabla f_k^\top p$ 最小，即

$$\min_p \nabla f_k^\top p, \quad \text{s.t. } \|p\| = 1.$$

由于 $\nabla f_k^\top p = \|p\| \|\nabla f_k\| \cos \theta = \|\nabla f_k\| \cos \theta$ （其中 θ 是 p 与 ∇f_k 的夹角），易知当 $\cos \theta = -1$ 时取得极小值，此时

$$p = -\nabla f_k / \|\nabla f_k\|.$$

除此之外，任何下降方向——与 $-\nabla f_k$ 的夹角严格小于 $\pi/2$ 的方向，也可以作为线搜索方向。这是因为只要步长足够小，都能保证使 f 减小。事实上，此时 $\frac{d}{d\alpha}h(0) = \nabla f_k^\top p < 0$ ，则根据可微函数的性质对足够小的 $\epsilon > 0$ ，有 $f(x_k + \epsilon p_k) < f(x_k)$ 。

5.1.2 牛顿方向

另一种线搜索方向是**牛顿方向**。该方向由 $f(x_k + p)$ 的二阶泰勒级数近似推导而来，即

$$f(x_k + p) \approx f_k + p^\top \nabla f_k + \frac{1}{2} p^\top \nabla^2 f_k p \stackrel{\text{def}}{=} m_k(p).$$

假设 $\nabla^2 f_k$ 是正定的，通过寻找使 $m_k(p)$ 极小的向量 p 可得到牛顿方向，即：

$$p_k^N = -(\nabla^2 f_k)^{-1} \nabla f_k.$$

注 5.1 牛顿方向实际上是利用对目标函数的二阶近似得到的搜索方向，而下降方向是通过对目标函数的一阶近似得到的。从这个角度上来看，如果忽略求使用牛顿方向涉及的矩阵运算带来的计算成本，牛顿方向比下降方向更有优势。

当 $\nabla^2 f_k$ 正定时，有

$$\nabla f_k^\top p_k^N = -p_k^{NT} \nabla^2 f_k p_k^N \leq -\sigma_k \|p_k^N\|^2$$

其中 $\sigma_k > 0$ 为 $\nabla^2 f_k$ 的最小特征值，故牛顿方向也是下降方向。但是与一般的下降方向不同的是，选取牛顿方向是步长一般可以直接取 1，不必再进行线搜索（这是因为求解牛顿方向时已经蕴含了对步长的求解）。

5.1.3 拟牛顿方向

如果 $\nabla^2 f_k$ 或者 $\nabla^2 f_k^{-1}$ 不易求解怎么办？通常可以使用 $\nabla^2 f_k$ 的近似矩阵 B_k 代替 $\nabla^2 f_k$ ，且在每一步后更新 B_k 。更新利用了如下近似：

$$\nabla^2 f_k(x_{k+1} - x_k) \approx \nabla f_{k+1} - \nabla f_k,$$

即选择的 Hessian 近似 B_{k+1} ，要求它满足以下割线方程：

$$B_{k+1}s_k = y_k,$$

其中

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f_{k+1} - \nabla f_k.$$

另外通常会对 B_{k+1} 施加额外条件，例如：

- 对称性（由精确 Hessian 的对称性启发）；
- 要求连续近似 B_k 和 B_{k+1} 之间的差具有低秩。

以下是两种更新公式：

- 秩一公式: $B_{k+1} = B_k + \frac{(y_k - B_k s_k)(y_k - B_k s_k)^T}{(y_k - B_k s_k)^T s_k}$
- BFGS 公式: $B_{k+1} = B_k - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k} + \frac{y_k y_k^T}{y_k^T s_k}$

注 5.2 注意，秩一公式中矩阵 B_k 和 B_{k+1} 之间的差是秩一矩阵，BFGS 公式中是秩二矩阵。这两种更新都满足割线方程，且都保持对称性。可以证明，当初始近似 B_0 正定且 $s_k^T y_k > 0$ 时，BFGS 更新会生成正定近似。

由于搜索方向定义为 $p_k = -B_k^{-1} \nabla f_k$ ，于是更节约的办法是直接对 $H_K = B_k^{-1}$ 进行更新：

$$H_{k+1} = (I - \rho_k s_k y_k^T) H_k (I - \rho_k y_k s_k^T) + \rho_k s_k s_k^T, \quad \rho_k = \frac{1}{y_k^T s_k}.$$

此时，搜索方向可通过 $p_k = -H_k \nabla f_k$ 计算。

5.1.4 共轭梯度方向

非线性共轭梯度方向形式为

$$p_k = -\nabla f(x_k) + \beta_k p_{k-1},$$

其中 $\beta_k \in \mathbb{R}^n$ 使得 p_k 和 p_{k-1} 是共轭的。

注 5.3 共轭梯度方法最初用于求解线性方程组 $Ax = b$ （其中系数矩阵 A 对称正定）。求解该线性系统的问题等价于极小化凸二次函数

$$\min_x \phi(x) = \frac{1}{2} x^T A x - b^T x,$$

如果将其推广到扩展到更一般的无约束极小化问题就是非线性共轭梯度法。一般来说，非线性共轭梯度方向比最速下降方向有效得多，且计算几乎同样简单。这些方法虽未达到牛顿或拟牛顿方法的快速收敛速度，但优势在于避免存储矩阵。

5.2 信赖域子问题的近似模型

信赖域子问题一般取：

$$\min_p m_k(x_k + p) = f_k + p^T \nabla f_k + \frac{1}{2} p^T B_k p, \quad \text{s.t. } \|p\| \leq \Delta_k.$$

若令 $B_k = 0$ ，并使用欧几里得范数，则信赖域子问题变为

$$\min_p f_k + p^T \nabla f_k \quad \text{s.t. } \|p\|_2 \leq \Delta_k,$$

上述问题的解可写成：

$$p_k = -\frac{\Delta_k \nabla f_k}{\|\nabla f_k\|}.$$

注 5.4 这是一个简单的最速下降步，步长由信赖域半径确定；此时信赖域和线搜索方法本质上是相同的。

如果选择 B_k 为精确 Hessian $\nabla^2 f_k$ 。由于信赖域限制 $\|p\|_2 \leq \Delta_k$ ，即使 $\nabla^2 f_k$ 不正定，子问题也保证有解。

若二次模型函数 m_k 中的矩阵 B_k 由拟牛顿近似定义，则得到信赖域拟牛顿法。

Part II

基础算法

6 线搜索方法：Line Search Methods

线搜索方法的每次迭代都会计算一个搜索方向 p_k ，然后决定沿该方向移动多远 (即步长 α_k)。迭代公式为

$$x_{k+1} = x_k + \alpha_k p_k$$

其中 α_k 称为步长。 p_k 和 α_k 的有效选择是线搜索方法的关键。

6.1 步长的选择

在选择步长时, 当然希望 α_k 可以显著降低 f 的值, 但是同时又不能花费过多时间。比如可以选择 $\phi(\cdot)$ 的全局极小点:

$$\phi(\alpha) = f(x_k + \alpha p_k), \quad \alpha > 0$$

但一般来说, 确定这个值的计算成本很高。更实用的策略是执行**非精确线搜索准则**, 以较小的成本获得使 f 足够降低的步长。

6.1.1 Wolfe Conditions

一个显然的目的是选择 α_k 使得 f 有充分的减少:

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f_k^T p_k,$$

其中 $c_1 \in (0, 1)$ 。这个不等式就是**充分下降条件**, 有时被称为 Armijo 条件。不等式右侧是一个线性函数, 可记为 $l(\alpha)$, 斜率为 $c_1 \nabla f_k^T p_k$ 为负。**Wolfe Conditions** 表明, 只有当 $\phi(\alpha) \leq l(\alpha)$ 时, α 才被接受。在实际应用中, c_1 通常选得很小, 例如 $c_1 = 10^{-4}$ 。

通常充分下降条件本身不一定确保算法取得合理进展, 因为对于所有足够小的 α , 该条件都能满足。为了排除过小的步长, 通常会要求步长 α_k 满足**曲率条件**:


$$\nabla f(x_k + \alpha_k p_k)^T p_k \geq c_2 \nabla f_k^T p_k,$$

其中 $c_2 \in (c_1, 1)$ 。注意, 左侧就是导数 $\phi'(\alpha_k)$, 这个条件确保了 ϕ 在 α_k 处的斜率大于初始斜率 $\phi'(0)$ 的 c_2 倍。当搜索方向 p_k 由牛顿法或拟牛顿法选取时, c_2 一般为 0.9; 当 p_k 由非线性共轭梯度法得到时, c_2 一般为 0.1。

充分下降条件和曲率条件都被统称为 **Wolfe 条件**:

$$\begin{aligned} f(x_k + \alpha p_k) &\leq f(x_k) + c_1 \alpha \nabla f_k^T p_k, \\ \nabla f(x_k + \alpha_k p_k)^T p_k &\geq c_2 \nabla f_k^T p_k, \end{aligned}$$

其中, $0 < c_1 < c_2 < 1$.



如果按照 Wolfe 条件, 步长可能较大, 从而远离附近的局部极小点, 如上图。可以修改曲率条件, 迫使 α_k 至少位于 ϕ 的局部极小值点或驻点的一个邻域内, 则得到强 Wolfe 条件:

$$\begin{aligned} f(x_k + \alpha_k p_k) &\leq f(x_k) + c_1 \alpha_k \nabla f_k^T p_k, \\ |\nabla f(x_k + \alpha_k p_k)^T p_k| &\leq c_2 |\nabla f_k^T p_k|, \end{aligned}$$

其中 $0 < c_1 < c_2 < 1$ 。区别在于强 Wolfe 条件不允许 $\phi'(\alpha_k)$ 超过 0 太多。

下面一个定理说明了对于一个连续可微函数一定存在步长区间满足 Wolfe 条件。

定理 6.1 假设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是连续可微的。设 p_k 是在 x_k 处的下降方向, 且假设 $f(x_k + \alpha p_k)$ 在 $\alpha > 0$ 时下方有界。那么若 $0 < c_1 < c_2 < 1$, 存在满足 Wolfe 条件和强 Wolfe 条件的步长区间。

证明. 注意到 $\phi(\alpha) = f(x_k + \alpha p_k)$ 对所有 $\alpha > 0$ 下方有界。由于 $c_1 \nabla f_k^T p_k < 0$, 则直线 $l(\alpha) = f(x_k) + \alpha c_1 \nabla f_k^T p_k$ 下方无界, 因此至少与 ϕ 的图像相交一次。设 $\alpha' > 0$ 是 α 的最小相交值, 即

$$f(x_k + \alpha' p_k) = f(x_k) + \alpha' c_1 \nabla f_k^T p_k$$

考虑函数 $g(\alpha) = f(x_k + \alpha p_k) - f(x_k) - \alpha c_1 \nabla f_k^T p_k$, 因为 $g(0) = g(\alpha') = 0$ 且 $g'(0) = (1 - c_1) \nabla f_k^T p_k < 0$, 则根据连续可微函数的性质, 充分下降条件对所有小于 α' 的步长成立。

由中值定理, 存在 $\alpha'' \in (0, \alpha')$ 使得

$$f(x_k + \alpha' p_k) - f(x_k) = \alpha' \nabla f(x_k + \alpha'' p_k)^T p_k$$

结合上述两式，可得

$$\nabla f(x_k + \alpha'' p_k)^T p_k = c_1 \nabla f_k^T p_k > c_2 \nabla f_k^T p_k$$

因为 $c_1 < c_2$ 且 $\nabla f_k^T p_k < 0$ 。因此， α'' 满足 Wolfe 条件。又由 f 的连续可微，存在以 α'' 的领域，在该领域内 Wolfe 条件成立。


此外，由于 $\nabla f(x_k + \alpha'' p_k)^T p_k = c_1 \nabla f_k^T p_k$ 为负，显然强 Wolfe 条件在同一领域内也成立。

6.1.2 Goldstein 条件

另一种 Goldstein 条件也可以确保步长 α 实现充分下降且不会过短。Goldstein 条件为：

$$f(x_k) + (1 - c)\alpha_k \nabla f_k^T p_k \leq f(x_k + \alpha_k p_k) \leq f(x_k) + c\alpha_k \nabla f_k^T p_k$$

其中 $0 < c < 1/2$ 。其中第二个不等式是充分下降条件，而第一个不等式用于从下方控制步。



注 6.1 Goldstein 条件相较于 Wolfe 条件有一个缺点是，其第一个不等式可能会排除 ϕ 的所有极小值点。不过，Goldstein 条件和 Wolfe 条件的收敛理论十分相似。Goldstein 条件常用于牛顿型方法，但不太适用于保持正定 Hessian 近似的拟牛顿方法。

6.2 线搜索方法的收敛性

假设 p_k 为下降方向, 即 $\nabla f_k^\top p_k < 0$, 因此 p_k 和最速下降方向 $-f_k$ 的夹角的余弦值为

$$\cos \theta_k = \frac{-\nabla f_k^\top p_k}{\|\nabla f_k\| \|p_k\|}.$$

定理 6.2 考虑迭代 $x_{k+1} = x_k + \alpha_k p_k$, 其中 p_k 是下降方向且 α_k 满足 Wolfe 条件。假设 f 在 $\mathbb{R}^n$ 上下有界, 且 f 在包含水平集 $\mathcal{L} \triangleq \{x : f(x) \leq f(x_0)\}$ 的开集 $\mathcal{N}$ 上连续可微, 其中 x_0 是迭代的起始点, 假设梯度 ∇f 在 $\mathcal{N}$ 上是 Lipschitz 连续的, 即存在常数 $L > 0$, 使得

$$\|\nabla f(x) - \nabla f(\tilde{x})\| \leq L\|x - \tilde{x}\|, \quad \forall x, \tilde{x} \in \mathcal{N}.$$

则

$$\sum_{k \geq 0} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty.$$

证明. 由 Wolfe 条件第二个不等式与 Lipschitz 条件可得

$$\begin{aligned} (\nabla f_{k+1} - \nabla f_k)^\top p_k &\geq (c_2 - 1) \nabla f_k^\top p_k, \\ (\nabla f_{k+1} - \nabla f_k)^\top p_k &\leq \alpha_k L \|p_k\|^2. \end{aligned}$$

于是可得

$$\alpha_k \geq \frac{c_2 - 1}{L} \frac{\nabla f_k^\top p_k}{\|p_k\|^2}.$$

将此不等式代入 Wolfe 条件第二个不等式可得

$$f_{k+1} \leq f_k - c_1 \frac{1 - c_2}{L} \frac{(\nabla f_k^\top p_k)^2}{\|p_k\|^2}.$$

即

$$c \cos^2 \theta_k \|\nabla f_k\|^2 \leq f_k - f_{k+1},$$

其中 $c = c_1(1 - c_2)/L$ 。求和可得 $\forall N \in \mathbb{N}^+$

$$\sum_{k=0}^N \cos^2 \theta_k \|\nabla f_k\|^2 \leq \frac{1}{c} (f_0 - f_{k+1}).$$

由于 f 下有界, 所以有 $f_0 - f_{k+1}$ 小于某个正常数。取极限可得

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty.$$

注 6.2

- 我们称 $\sum_{k=0}^{\infty} \cos^2 \theta_k \|\nabla f_k\|^2 < \infty$ 为 Zoutendijk 条件.
- 由 Zoutendijk 条件可以得到: $\cos^2 \theta_k \|\nabla f_k\|^2 \rightarrow 0$. 因此如果 $\exists \delta > 0, \forall k, \cos \theta_k \geq \delta > 0$, 则 $\|\nabla f_k\| \rightarrow 0$. 也就是说, 只要让搜索方向与负梯度的方向夹角始终小于 $\pi/2$, 就可以得到迭代点梯度的收敛性.
- 对于牛顿法或者拟牛顿法, $p_k = -B_k^{-1} f_k$, 其中 B_k 为对称正定矩阵, 则

$$\cos \theta_k = \frac{\nabla f_k^\top B_k \nabla f_k}{\|\nabla f_k\| \|B_k^{-1} f_k\|} \geq \frac{\|B_k\|^{-1} \|\nabla f_k\|^2}{\|B_k^{-1}\| \|\nabla f_k\|^2} = \frac{\|B_k\|^{-1}}{\|B_k^{-1}\|},$$

因此只要 $\|B_k\| \|B_k^{-1}\| \leq \delta^{-1}$ 即可.

6.3 线搜索方法的收敛率

6.3.1 最速下降法的收敛率

我们先考虑最基础的算法最速下降法的收敛率, 先考虑最简单问题

$$f(x) = \frac{1}{2} x^T Q x - b^T x,$$

其中 Q 是对称正定矩阵. 梯度为 $\nabla f(x) = Qx - b$, 问题的全局极小点 x^* 就是线性方程组 $Qx = b$ 的唯一解. 通过对 $f(x_k - \alpha \nabla f_k)$ 求极小可得最速下降法的步长为:

$$\alpha_k = \frac{\nabla f_k^T \nabla f_k}{\nabla f_k^T Q \nabla f_k},$$

于是最速下降迭代式为

$$x_{k+1} = x_k - \left(\frac{\nabla f_k^T \nabla f_k}{\nabla f_k^T Q \nabla f_k} \right) \nabla f_k,$$

其中 $\nabla f_k = Qx_k - b$.

设 $\|x\|_Q^2 = x^T Q x$. 利用关系 $Qx^* = b$, 可以得到

$$\begin{aligned} \frac{1}{2} \|x - x^*\|_Q^2 &= \frac{1}{2} x^\top Q x - x^{*\top} Q x + \frac{1}{2} x^{*\top} Q x^* \\ &= \frac{1}{2} x^\top Q x - b^\top x - \frac{1}{2} x^{*\top} Q x^* + x^{*\top} Q x^* \\ &= \frac{1}{2} x^\top Q x - b^\top x - \left(\frac{1}{2} x^{*\top} Q x^* - b^\top x^* \right) \\ &= f(x) - f(x^*), \end{aligned}$$

因此该范数衡量了当前目标函数值与最优值之间的距离. 由于 $\nabla f_k = Q(x_k - x^*)$, 可推

导出等式

$$\begin{aligned}
\frac{1}{2}\|x_{k+1} - x^*\|_Q^2 &= f(x^{k+1}) - f(x^*) \\
&= \frac{1}{2}(x^k - \alpha_k \nabla f(x^k))^\top Q (x^k - \alpha_k \nabla f(x^k)) - b^\top (x^k - \alpha_k \nabla f(x^k)) - f(x^*) \\
&= \frac{1}{2}x^{k\top} Q x^k - b^\top x^k - f(x^*) + \frac{\alpha_k^2}{2} \nabla f(x^k)^\top Q \nabla f(x^k) - \alpha_k \nabla f(x^k)^\top (Q x^k - b) \\
&= \frac{1}{2}\|x_k - x^*\|_Q^2 + \frac{\alpha_k^2}{2} \nabla f(x^k)^\top Q \nabla f(x^k) - \alpha_k \nabla f(x^k)^\top \nabla f(x^k)
\end{aligned}$$

其中由于

$$\begin{aligned}
&\alpha_k^2 \nabla f(x^k)^\top Q \nabla f(x^k) - 2\alpha_k \nabla f(x^k)^\top \nabla f(x^k) \\
&= \frac{(\nabla f_k^\top \nabla f_k)^2}{(\nabla f_k^\top Q \nabla f_k)^2} \nabla f_k^\top Q \nabla f_k - 2 \frac{(\nabla f_k^\top \nabla f_k)^2}{\nabla f_k^\top Q \nabla f_k} \\
&= - \frac{(\nabla f_k^\top \nabla f_k)^2}{\nabla f_k^\top Q \nabla f_k} \\
&= - \frac{(\nabla f_k^\top \nabla f_k)^2}{(\nabla f_k^\top Q \nabla f_k)(\nabla f_k^\top Q^{-1} \nabla f_k)} \nabla f_k^\top Q^{-1} \nabla f_k \\
&= - \frac{(\nabla f_k^\top \nabla f_k)^2}{(\nabla f_k^\top Q \nabla f_k)(\nabla f_k^\top Q^{-1} \nabla f_k)} (x_k - x^*)^\top Q^\top Q^{-1} Q (x_k - x^*) \\
&= - \frac{(\nabla f_k^\top \nabla f_k)^2}{(\nabla f_k^\top Q \nabla f_k)(\nabla f_k^\top Q^{-1} \nabla f_k)} \|x_k - x^*\|_Q^2
\end{aligned}$$

于是：

$$\|x_{k+1} - x^*\|_Q^2 = \left\{ 1 - \frac{(\nabla f_k^\top \nabla f_k)^2}{(\nabla f_k^\top Q \nabla f_k)(\nabla f_k^\top Q^{-1} \nabla f_k)} \right\} \|x_k - x^*\|_Q^2$$

这个表达式描述了每次迭代中 f 的精确下降量，上述讨论可以进一步得到下面这个定理：

定理 6.3

$$\|x_{k+1} - x^*\|_Q^2 \leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \right)^2 \|x_k - x^*\|_Q^2$$

其中 $0 < \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ 是 Q 的特征值。

6.3.2 梯度法在凸函数上的收敛性

定理 6.4 (梯度法在凸函数上的收敛性) 设函数 $f(x)$ 为凸的梯度 L -利普希茨连续函数， $f^* = f(x^*) = \inf_x f(x)$ 存在且可达。如果步长 α_k 取为常数 α 且满足 $0 < \alpha < \frac{1}{L}$ ，那么由迭代得到的点列 $\{x^k\}$ 的函数值收敛到最优值，且在函数值的意义下收敛速度为 $O\left(\frac{1}{k}\right)$ 。

证明. 因为函数 f 是利普希茨可微函数, 对任意的 x 有

$$f(x - \alpha \nabla f(x)) \leq f(x) - \alpha \left(1 - \frac{L\alpha}{2}\right) \|\nabla f(x)\|^2$$

现在记 $\tilde{x} = x - \alpha \nabla f(x)$ 并限制 $0 < \alpha < \frac{1}{L}$ 有

$$\begin{aligned} f(\tilde{x}) &\leq f(x) - \frac{\alpha}{2} \|\nabla f(x)\|^2 \\ &\leq f^* + \nabla f(x)^T (x - x^*) - \frac{\alpha}{2} \|\nabla f(x)\|^2 \\ &= f^* + \frac{1}{2\alpha} (\|x - x^*\|^2 - \|x - x^* - \alpha \nabla f(x)\|^2) \\ &= f^* + \frac{1}{2\alpha} (\|x - x^*\|^2 - \|\tilde{x} - x^*\|^2), \end{aligned}$$

其中第一个不等式是由于前述式子, 第二个不等式为 f 的凸性。在上式中取 $x = x^{i-1}$, $\tilde{x} = x^i$ 并将不等式对 $i = 1, 2, \dots, k$ 求和得到

$$\begin{aligned} \sum_{i=1}^k (f(x^i) - f^*) &\leq \frac{1}{2\alpha} \sum_{i=1}^k (\|x^{i-1} - x^*\|^2 - \|x^i - x^*\|^2) \\ &= \frac{1}{2\alpha} (\|x^0 - x^*\|^2 - \|x^k - x^*\|^2) \\ &\leq \frac{1}{2\alpha} \|x^0 - x^*\|^2. \end{aligned}$$

根据前述式子得知 $f(x^i)$ 是非增的, 所以

$$f(x^k) - f^* \leq \frac{1}{k} \sum_{i=1}^k (f(x^i) - f^*) \leq \frac{1}{2k\alpha} \|x^0 - x^*\|^2.$$

注 6.3 如果只要求 $0 < \alpha < \frac{2}{L}$, 则只能得到迭代点收敛到稳定点, 而得不到收敛率

6.3.3 牛顿法的收敛率

考虑步长为 1 的牛顿法 $x_{k+1} = x_k + p_k^N = x_k - \nabla^2 f_k^{-1} \nabla f_k$

定理 6.5 假设 f 二阶可微, 且 Hessian 矩阵 $\nabla^2 f(x)$ 在解 x^* 的邻域内 Lipschitz 连续, 其中 x^* 满足 $\nabla f(x^*) = 0$, $\nabla^2 f(x^*)$ 正定。考虑迭代 $x_{k+1} = x_k + p_k^N = x_k - \nabla^2 f_k^{-1} \nabla f_k$ 。则

- (i) 若初始点 x_0 足够接近 x^* , 则迭代序列收敛到 x^* ;
- (ii) $\{x_k\}$ 的收敛速度是二次的;
- (iii) 梯度范数序列 $\{\|\nabla f_k\|\}$ 二次收敛到零。

证明. 由 $\nabla f_* = 0$

$$x_k + p_k^N - x^* = x_k - x^* - \nabla^2 f_k^{-1} \nabla f_k = \nabla^2 f_k^{-1} [\nabla^2 f_k (x_k - x^*) - (\nabla f_k - \nabla f_*)]$$

由于

$$\nabla f_k - \nabla f_* = \int_0^1 \nabla^2 f(x_k + t(x^* - x_k))(x_k - x^*) dt$$

我们有

$$\begin{aligned} \|\nabla^2 f(x_k)(x_k - x^*) - (\nabla f_k - \nabla f(x^*))\| &= \left\| \int_0^1 [\nabla^2 f(x_k) - \nabla^2 f(x_k + t(x^* - x_k))](x_k - x^*) dt \right\| \\ &\leq \int_0^1 \|\nabla^2 f(x_k) - \nabla^2 f(x_k + t(x^* - x_k))\| \|x_k - x^*\| dt \\ &\leq \|x_k - x^*\|^2 \int_0^1 L t dt = \frac{1}{2} L \|x_k - x^*\|^2, \end{aligned}$$

其中 L 是 $\nabla^2 f(x)$ 在 x 接近 x^* 时的 Lipschitz 常数（上面这个不等式很像 **L-smooth** 里面的下降引理，证明都差不多）。

由于 $\nabla^2 f(x^*)$ 非奇异，存在半径 $r > 0$ ，使得对所有满足 $\|x_k - x^*\| \leq r$ 的 x_k ，有 $\|\nabla^2 f_k^{-1}\| \leq 2\|\nabla^2 f(x^*)^{-1}\|$ 。将其代入上面的式子，我们得到

$$\|x_k + p_k^N - x^*\| \leq L \|\nabla^2 f(x^*)^{-1}\| \|x_k - x^*\|^2 = \tilde{L} \|x_k - x^*\|^2,$$

其中 $\tilde{L} = L \|\nabla^2 f(x^*)^{-1}\|$ 。选择 x_0 使得 $\|x_0 - x^*\| \leq \min(r, 1/(2\tilde{L}))$ ，我们可以用数学归纳法推出该序列收敛到 x^* ，且收敛速度是二次的。

通过利用关系 $x_{k+1} - x_k = p_k^N$ 和 $\nabla f_k + \nabla^2 f_k p_k^N = 0$ ，我们得到

$$\begin{aligned} \|\nabla f(x_{k+1})\| &= \|\nabla f(x_{k+1}) - \nabla f_k - \nabla^2 f(x_k) p_k^N\| \\ &= \left\| \int_0^1 \nabla^2 f(x_k + t p_k^N)(x_{k+1} - x_k) dt - \nabla^2 f(x_k) p_k^N \right\| \\ &\leq \int_0^1 \|\nabla^2 f(x_k + t p_k^N) - \nabla^2 f(x_k)\| \|p_k^N\| dt \\ &\leq \frac{1}{2} L \|p_k^N\|^2 \\ &\leq \frac{1}{2} L \|\nabla^2 f(x_k)^{-1}\|^2 \|\nabla f_k\|^2 \\ &\leq 2L \|\nabla^2 f(x^*)^{-1}\|^2 \|\nabla f_k\|^2, \end{aligned}$$

这证明了梯度范数二次收敛到零。

注 6.4 上述定理的条件其实是比较强的

6.3.4 拟牛顿法的收敛率

6.4 调整海瑟矩阵的牛顿法

牛顿法的迭代方向由以下方程聚决定：

$$\nabla^2 f(x_k) p_k^N = -\nabla f(x_k)$$

但是这带来几个问题

- Hessian 矩阵 $\nabla^2 f(x)$ 可能不是正定的, 因此牛顿方向 p_k^N 可能不是下降方向
- 求解上述方程有时不是一件容易的事情

为了克服上述困难, 考虑修改 Hessian 矩阵, 修改后的 Hessian 矩阵是通过将正定对角矩阵或满矩阵添加到真实的 Hessian 矩阵 $\nabla^2 f(x_k)$ 中得到的:

Algorithm 1 带修正的线搜索牛顿法

Require: 初始点 x_0

- 1: **while** $k = 0, 1, 2, \dots$ **do**
 - 2: 对矩阵 $B_k = \nabla^2 f(x_k) + E_k$ 进行分解, 其中若 $\nabla^2 f(x_k)$ 是充分正定的, 则 $E_k = 0$; 否则, 选择 E_k 以确保 B_k 是充分正定的;
 - 3: 求解 $B_k p_k = -\nabla f(x_k)$;
 - 4: 令 $x_{k+1} \leftarrow x_k + \alpha_k p_k$, 其中 α_k 满足 Wolfe、Goldstein 或 Armijo 回溯条件;
 - 5: **end while**
-

注 6.5 通常不需要得到显示的 E_k , 而是动态的修改。为了得到全局收敛结果, 需要选择 E_k 使得 B_k 满足有界修改分解性质, 即 $\{\nabla^2 f(x_k)\}$ 有界时

$$\kappa(B_k) = \|B_k\| \|B_k^{-1}\| \leq C, \quad \text{对某个 } C > 0 \text{ 和所有 } k = 0, 1, 2, \dots,$$

它确保了修正后的矩阵 B_k 不会过于“病态”

定理 6.6 设 f 在开集 D 上二阶连续可微, 假设算法 1 的起始点 x_0 满足水平集 $\mathcal{L} = \{x \in D : f(x) \leq f(x_0)\}$ 是紧集。且有界修改分解性质成立, 则有

$$\lim_{k \rightarrow \infty} \nabla f(x_k) = 0.$$

7 次梯度法

7.1 带 Polyak 步长的投影次梯度法

7.1.1 无约束优化的次梯度法

考虑无约束优化问题

$$\min_{x \in \mathbb{E}} f(x)$$

其中 f 是适当闭凸函数。

- 如果 f 可微：我们知道 $-\nabla f(x^k)$ 是 f 在 x^k 处的下降方向，则可以考虑最速下降法：

$$\begin{aligned} x^{k+1} &= x^k - t_k \nabla f(x^k) \\ t_k &\in \operatorname{argmin}_{t \geq 0} f(x^k - t \nabla f(x^k)). \end{aligned}$$

- 如果 f 不可微，则对非光滑情形的一个自然推广是用次梯度代替梯度 (假设次梯度存在), 即次梯度法：

$$x^{k+1} = x^k - t_k g^k, \quad g^k \in \partial f(x^k),$$

其中从 $\partial f(x^k)$ 中选取的次梯度是任意的。

注 7.1 梯度法与次梯度法的一个关键区别在于：负次梯度方向不一定是下降方向。次梯度法的步长 t_k 无法被选成保证函数值下降的形式。

注 7.2 Wolfe 给出过一个经典反例：将梯度法应用于非光滑凸函数，且步长由精确线搜索选取。该迭代方法生成的每一个迭代点处，函数都是可微的。(算法每一步选取的搜索方向均为下降方向，且函数值序列严格单调递减) 然而，尽管表面上算法似乎“避开”了函数的非光滑区域，但事实并非如此。梯度法生成的迭代序列最终会收敛到一个非最优点。

7.1.2 带约束优化的次梯度法

如果考虑带约束的优化问题

$$\begin{aligned} \min_{x \in \mathbb{E}} f(x) \\ \text{s.t. } x \in C \end{aligned}$$

假设 7.1

- $f: \mathbb{E} \rightarrow (-\infty, \infty]$ 是适当闭凸函数

- $C \subseteq \text{int}(\text{dom}(f))$ 是非空闭凸集
- 上述问题的最优解集非空, 记为 X^* , 问题的最优值记为 f_{opt}
- 由于 f 是凸函数且 $C \subseteq \text{int}(\text{dom}(f))$, 则 f 在 C 上是次可微的。
- 此外, 由于 f 是闭函数, 集合 $X^* = C \cap \text{Lev}(f, f_{\text{opt}})$ 是闭的。
- 以下我们使用 $f'(x)$ 表示 f 在 x 处的某个次梯度, 即 $\partial f(x)$ 中的一个元素

Algorithm 2 投影次梯度法 (Projected Subgradient Method)

Require: 初始点 $x^0 \in C$

- 1: **while** $k = 0, 1, 2, \dots$ **do**
 - 2: 选择步长 $t_k > 0$ 和次梯度 $f'(x^k) \in \partial f(x^k)$;
 - 3: 令 $x^{k+1} = P_C(x^k - t_k f'(x^k))$.
 - 4: **end while**
-

注 7.3 对于可微情形的投影梯度法, 本节的结论也全部成立

设投影次梯度法生成的序列为 $\{x^k\}_{k \geq 0}$, 方法生成的函数值序列为 $\{f(x^k)\}_{k \geq 0}$ 。此时的函数值序列不一定是单调的, 因此我们关注已达最优函数值序列, 即

$$f_{\text{best}}^k \equiv \min_{n=0,1,\dots,k} f(x^n).$$

显然, 序列 $\{f_{\text{best}}^k\}_{k \geq 0}$ 是非增的。

投影次梯度法的分析依赖以下简单的技术性引理。

引理 7.1 (投影次梯度法的基本不等式) 在本节的假设下。令 $\{x^k\}_{k \geq 0}$ 为投影次梯度法生成的序列, 则对任意 $x^* \in X^*$ 及 $k \geq 0$, 有

$$\|x^{k+1} - x^*\|^2 \leq \|x^k - x^*\|^2 - 2t_k(f(x^k) - f_{\text{opt}}) + t_k^2 \|f'(x^k)\|^2.$$

证明.

$$\begin{aligned} \|x^{k+1} - x^*\|^2 &= \|P_C(x^k - t_k f'(x^k)) - P_C(x^*)\|^2 \\ &\stackrel{(*)}{\leq} \|x^k - t_k f'(x^k) - x^*\|^2 \\ &= \|x^k - x^*\|^2 - 2t_k \langle f'(x^k), x^k - x^* \rangle + t_k^2 \|f'(x^k)\|^2 \\ &\stackrel{(**)}{\leq} \|x^k - x^*\|^2 - 2t_k(f(x^k) - f_{\text{opt}}) + t_k^2 \|f'(x^k)\|^2, \end{aligned}$$

其中不等式 (*) 由正交投影算子的非扩张性得到, (**) 由次梯度不等式得到。

注 7.4 为了使得上式的右端充分小, 步长 t_k 的一种选择方式是:

$$t_k = \frac{f(x^k) - f_{\text{opt}}}{\|f'(x^k)\|^2}.$$

当 $f'(x^k) = 0$ 时, 上述公式无定义, 而此时 x^k 是问题的最优解, 这时我们人为定义 $t_k = 1$ 。因此完整的公式为:

$$t_k = \begin{cases} \frac{f(x^k) - f_{\text{opt}}}{\|f'(x^k)\|^2}, & f'(x^k) \neq 0, \\ 1, & f'(x^k) = 0. \end{cases}$$

该步长称为 Polyak 步长。

假设 7.2 存在常数 $L_f > 0$, 使得对所有 $g \in \partial f(x)$ 及 $x \in C$, 均有 $\|g\| \leq L_f$ 。

注 7.5 上述假设意味着 f 在 C 上是 Lipschitz 连续的, Lipschitz 常数为 L_f , 即

$$|f(x) - f(y)| \leq L_f \|x - y\| \quad \text{对所有 } x, y \in C.$$

定理 7.2 (采用 Polyak 步长的投影次梯度法的性质) 假设 7.1 和假设 7.2 成立。令 $\{x^k\}_{k \geq 0}$ 为采用 Polyak 步长的投影次梯度法生成的序列, 则

- (a) $\forall k \geq 0$ 和 $x^* \in X^*$, $\|x^{k+1} - x^*\|^2 \leq \|x^k - x^*\|^2$;
- (b) $\lim_{k \rightarrow \infty} f(x^k) = f_{\text{opt}}$;
- (c) $\forall k \geq 0$, $f_{\text{best}}^k - f_{\text{opt}} \leq \frac{L_f d_{X^*}(x^0)}{\sqrt{k+1}}$.

证明.

(a) 设 n 为非负整数, $x^* \in X^*$ 。由定理 7.1, 有

$$\|x^{n+1} - x^*\|^2 \leq \|x^n - x^*\|^2 - 2t_n(f(x^n) - f_{\text{opt}}) + t_n^2 \|f'(x^n)\|^2.$$

若 $f'(x^n) \neq 0$, 将 $t_n = \frac{f(x^n) - f_{\text{opt}}}{\|f'(x^n)\|^2}$ 代入上式, 可得

$$\|x^{n+1} - x^*\|^2 \leq \|x^n - x^*\|^2 - \frac{(f(x^n) - f_{\text{opt}})^2}{\|f'(x^n)\|^2}.$$

利用界 $\|f'(x^n)\| \leq L_f$, 得到

$$\|x^{n+1} - x^*\|^2 \leq \|x^n - x^*\|^2 - \frac{(f(x^n) - f_{\text{opt}})^2}{L_f^2}.$$

当 $f'(x^n) = 0$ 时, 上述不等式同样成立 (因为此时 $f(x^n) = f_{\text{opt}}$ 且 $x^{n+1} = x^n$)。由上式可直接得到

$$\|x^{n+1} - x^*\|^2 \leq \|x^n - x^*\|^2,$$

将 $n = k$ 代入即证明了 (a)。

(b) 对 $n = 0, 1, \dots, k$ 求和, 得

$$\frac{1}{L_f^2} \sum_{n=0}^k (f(x^n) - f_{\text{opt}})^2 \leq \|x^0 - x^*\|^2 - \|x^{k+1} - x^*\|^2,$$

因此

$$\sum_{n=0}^k (f(x^n) - f_{\text{opt}})^2 \leq L_f^2 \|x^0 - x^*\|^2.$$

由于上述不等式对任意 $x^* \in X^*$ 成立, 故有

$$\sum_{n=0}^k (f(x^n) - f_{\text{opt}})^2 \leq L_f^2 d_{X^*}^2(x^0),$$

这意味着 $\lim_{k \rightarrow \infty} f(x^k) = f_{\text{opt}}$.

(c) 对任意 $n = 0, 1, \dots, k$, 均有 $f(x^n) \geq f_{\text{best}}^k$, 因此

$$\sum_{n=0}^k (f(x^n) - f_{\text{opt}})^2 \geq (k+1)(f_{\text{best}}^k - f_{\text{opt}})^2,$$

结合之前的结论, 可得

$$(k+1)(f_{\text{best}}^k - f_{\text{opt}})^2 \leq L_f^2 d_{X^*}^2(x^0),$$

因此

$$f_{\text{best}}^k - f_{\text{opt}} \leq \frac{L_f d_{X^*}(x^0)}{\sqrt{k+1}}.$$

注 7.6 在上面的证明中, 常数 L_f 可以替换为 $\max_{n=0,1,\dots,k} \|f'(x^n)\|$, 可以进一步的压缩右端项

注 7.7 在复杂度分析中, 我们关注的问题是: 要获得一个 ε -最优解, 需要多少次迭代? 即需要多少次迭代才能满足

$$f_{\text{best}}^k - f_{\text{opt}} \leq \varepsilon.$$

由定理 7.2(c), 满足上式的一个充分条件是

$$\frac{L_f d_{X^*}(x^0)}{\sqrt{k+1}} \leq \varepsilon,$$

即

$$k \geq \frac{L_f^2 d_{X^*}^2(x^0)}{\varepsilon^2} - 1.$$

因此, 要获得一个 ε -最优解, 需要的迭代次数为 $O(1/\varepsilon^2)$ 阶. 于是有下面的定理

定理 7.3 (采用 Polyak 步长的投影次梯度法的复杂度) 假设 7.1 和假设 7.2 成立。设 $\{x^k\}_{k \geq 0}$ 为采用 Polyak 步长的投影次梯度法生成的序列。则对任意满足

$$k \geq \frac{L_f^2 d_{X^*}^2(x^0)}{\varepsilon^2} - 1$$

的非负整数 k , 有

$$f_{\text{best}}^k - f_{\text{opt}} \leq \varepsilon.$$

定义 7.1 (Fejér 单调性) 若序列 $\{x^k\}_{k \geq 0} \subseteq \mathbb{E}$ 对集合 $S \subseteq \mathbb{E}$ 满足:

$$\|x^{k+1} - y\| \leq \|x^k - y\| \quad \text{对所有 } k \geq 0 \text{ 和 } y \in S,$$

则称该序列关于集合 S 是 Fejér 单调的。

注 7.8 由于关于集合 S 的 Fejér 单调性意味着对所有 $k \geq 0$ 和任意 $y \in S$, 均有 $\|x^k - y\| \leq \|x^0 - y\|$, 因此 Fejér 单调序列总是有界的。现在我们证明: 若一个序列关于包含其所有极限点的集合是 Fejér 单调的, 则该序列收敛。

定理 7.4 (Fejér 单调性下的收敛性) 设 $\{x^k\}_{k \geq 0} \subseteq \mathbb{E}$ 为一序列, S 为满足 $D \subseteq S$ 的集合, 其中 D 是 $\{x^k\}_{k \geq 0}$ 的所有极限点构成的集合。若 $\{x^k\}_{k \geq 0}$ 关于 S 是 Fejér 单调的, 则该序列收敛于 D 中的某一点。

证明. 由于 $\{x^k\}_{k \geq 0}$ 是 Fejér 单调的, 因此它是有界的, 从而存在极限点。设 $\tilde{x}$ 为序列 $\{x^k\}_{k \geq 0}$ 的一个极限点, 即存在子序列 $\{x^{k_j}\}_{j \geq 0}$ 使得 $x^{k_j} \rightarrow \tilde{x}$ 。由于 $\tilde{x} \in D \subseteq S$, 由关于 S 的 Fejér 单调性可知, 对任意 $k \geq 0$, 有

$$\|x^{k+1} - \tilde{x}\| \leq \|x^k - \tilde{x}\|.$$

因此, $\{\|x^k - \tilde{x}\|\}_{k \geq 0}$ 是一个非增且有下界 (下界为 0) 的序列, 从而收敛。由于当 $j \rightarrow \infty$ 时 $\|x^{k_j} - \tilde{x}\| \rightarrow 0$, 故整个序列 $\{\|x^k - \tilde{x}\|\}_{k \geq 0}$ 收敛于 0, 因此当 $k \rightarrow \infty$ 时 $x^k \rightarrow \tilde{x}$ 。

定理 7.5 (采用 Polyak 步长的投影次梯度法生成序列的收敛性) 假设 7.1 和假设 7.2 成立。设 $\{x^k\}_{k \geq 0}$ 为采用 Polyak 步长的投影次梯度法生成的序列, 则 $\{x^k\}_{k \geq 0}$ 收敛于 X^* 中的某一点。

证明. 由定理 7.2(a), 该序列关于 X^* 是 Fejér 单调的。因此, 根据定理 7.4, 要证明序列收敛于 X^* 中的某一点, 只需证明序列的任何极限点必然属于 X^* (即问题的最优解)。设 $\tilde{x}$ 为序列的一个极限点, 则存在子序列 $\{x^{k_j}\}_{j \geq 0}$ 收敛于 $\tilde{x}$ 。由 C 的闭性可知 $\tilde{x} \in C$ 。由定理 7.2(b), 有

$$f(x^{k_j}) \rightarrow f_{\text{opt}}, \quad j \rightarrow \infty.$$

由于 $\tilde{x} \in C \subseteq \text{int}(\text{dom}(f))$, 由 f 的闭性, 结合上式可得 $f(\tilde{x}) = f_{\text{opt}}$, 即 $\tilde{x} \in X^*$ 。

7.2 用投影梯度法求解凸可行性问题

设 $S_1, S_2, \dots, S_m \subseteq \mathbb{E}$ 为非空闭凸集, 且 $S \equiv \bigcap_{i=1}^m S_i \neq \emptyset$.

凸可行性问题就是寻找交集 $\bigcap_{i=1}^m S_i$ 中一点 x 。该问题可以转化为如下优化问题:

$$\min_x \left\{ f(x) \equiv \max_{i=1,2,\dots,m} d_{S_i}(x) \right\}.$$

注 7.9 由于交集非空, 因此最优值 $f_{\text{opt}} = 0$, 最优解集为 S 。此外, 函数 f 是 Lipschitz 连续的, Lipschitz 常数为 1。

证明. 设 $i \in \{1, 2, \dots, m\}$, 对任意 $x, y \in \mathbb{E}$, 有

$$\begin{aligned} d_{S_i}(x) &= \|x - P_{S_i}(x)\| \\ &\leq \|x - P_{S_i}(y)\| \quad (\text{由 } d_{S_i}(x) = \arg \min_{v \in S_i} \|x - v\|) \\ &\leq \|x - y\| + \|y - P_{S_i}(y)\| \quad (\text{三角不等式}) \\ &= \|x - y\| + d_{S_i}(y). \end{aligned}$$

因此

$$d_{S_i}(x) - d_{S_i}(y) \leq \|x - y\|.$$

交换 x 和 y 的角色, 可得

$$d_{S_i}(y) - d_{S_i}(x) \leq \|x - y\|,$$

综上得到

$$|d_{S_i}(x) - d_{S_i}(y)| \leq \|x - y\|.$$

对任意 $x, y \in \mathbb{E}$, 有

$$|f(x) - f(y)| = \left| \max_{i=1,2,\dots,m} d_{S_i}(x) - \max_{i=1,2,\dots,m} d_{S_i}(y) \right| = \left| \|v_x\|_\infty - \|v_y\|_\infty \right|,$$

其中 $v_x = (d_{S_i}(x))_{i=1}^m \in \mathbb{R}^m$, $v_y = (d_{S_i}(y))_{i=1}^m \in \mathbb{R}^m$ 。利用范数的三角不等式得

$$\begin{aligned} |f(x) - f(y)| &\leq \left| \|v_x\|_\infty - \|v_y\|_\infty \right| \\ &\leq \|v_x - v_y\|_\infty \\ &= \max_{i=1,2,\dots,m} |d_{S_i}(x) - d_{S_i}(y)| \\ &\leq \|x - y\|. \end{aligned}$$

7.2.1 贪婪投影算法

我们将 Polyak 步长规则下的投影次梯度法求解凸可行性问题

- 第 k 次迭代的次梯度可通过以下步骤计算：
 - (i) 计算 $i_k \in \arg\max_{i=1,2,\dots,m} d_{S_i}(\mathbf{x}^k)$;
 - (ii) 任取 $\mathbf{g}^k \in \partial d_{S_{i_k}}(\mathbf{x}^k)$ 。
- 次梯度可以选择为 $\mathbf{g}^k = \frac{\mathbf{x}^k - P_{S_{i_k}}(\mathbf{x}^k)}{d_{S_{i_k}}(\mathbf{x}^k)}$
- 此时更新步骤为 (利用 $f_{\text{opt}} = 0$ 和 $\|\mathbf{g}^k\| = 1$)

$$\begin{aligned}\mathbf{x}^{k+1} &= \mathbf{x}^k - \frac{d_{S_{i_k}}(\mathbf{x}^k) - f_{\text{opt}}}{\|\mathbf{g}^k\|^2} \cdot \frac{\mathbf{x}^k - P_{S_{i_k}}(\mathbf{x}^k)}{d_{S_{i_k}}(\mathbf{x}^k)} \\ &= \mathbf{x}^k - d_{S_{i_k}}(\mathbf{x}^k) \frac{\mathbf{x}^k - P_{S_{i_k}}(\mathbf{x}^k)}{d_{S_{i_k}}(\mathbf{x}^k)} \\ &= P_{S_{i_k}}(\mathbf{x}^k),\end{aligned}$$

上述算法称为贪婪投影算法，它在每次迭代中将当前迭代点 $\mathbf{x}^k$ 投影到 $S_1, S_2, \dots, S_m$ 中距离最远的集合上。算法总结如下：

Algorithm 3 贪婪投影算法 (Greedy Projection Algorithm)

Require: m 个非空闭凸集 $S_1, S_2, \dots, S_m$, 初始点 $\mathbf{x}^0 \in C$

1: **while** $k = 0, 1, 2, \dots$ **do**
2:

$$\mathbf{x}^{k+1} = P_{S_{i_k}}(\mathbf{x}^k),$$

其中 $i_k \in \arg\max_{i=1,2,\dots,m} d_{S_i}(\mathbf{x}^k)$ 。

3: **end while**

我们可以调用定理 7.2 和定理 7.5，得到该算法的收敛性结果。

定理 7.6 (贪婪投影算法的收敛性) 设 $S_1, S_2, \dots, S_m \subseteq \mathbb{E}$ 为闭凸集，满足 $S \equiv \bigcap_{i=1}^m S_i \neq \emptyset$ 。令 $\{\mathbf{x}^k\}_{k \geq 0}$ 为贪婪投影算法生成的序列。

(a) 对任意 $k \geq 0$ ，有

$$\min_{n=0,1,\dots,k} \left\{ \max_{i=1,2,\dots,m} d(\mathbf{x}^n, S_i) \right\} \leq \frac{d_S(\mathbf{x}^0)}{\sqrt{k+1}}.$$

(b) 存在 $\mathbf{x}^* \in S$ ，使得 $\lim_{k \rightarrow +\infty} \mathbf{x}^k = \mathbf{x}^*$ 。

证明. 定义 $f(\mathbf{x}) \equiv \max_{i=1,2,\dots,m} d(\mathbf{x}, S_i)$ ，并取 $C = \mathbb{E}$ 。此时问题 $\min\{f(\mathbf{x}) : \mathbf{x} \in C\}$ 的最优解集为 $X^* = S$ 。

此时假设 7.1(f 是真、闭且凸的, $C = \mathbb{E}$ 显然是非空闭凸集, 且包含在 $\text{int}(\text{dom}(f)) = \mathbb{E}$ 中; $X^* = S$ 非空) 和假设 7.2(取 $L_f = 1$) 满足, 因此, 由于贪婪投影算法等价于采用 Polyak 步长规则的投影次梯度法, 由定理 7.2 和定理 7.5 可得结论。

7.2.2 交替投影法

当 $m = 2$ 时, 该算法退化为交替投影法, 描述如下:

Algorithm 4 交替投影法 (Alternating Projection Method)

Require: 两个非空闭凸集 S_1, S_2 , 初始点 $x^0 \in C$

1: **while** $k = 0, 1, 2, \dots$ **do**

2:

$$\mathbf{x}^{k+1} = P_{S_2}(P_{S_1}(\mathbf{x}^k)).$$

。

3: **end while**

如果 $S_1 \cap S_2 \neq \emptyset$, 由定理 7.6, 交替投影法生成的序列收敛于 $S_1 \cap S_2$ 中的一点。

推论 7.7 (交替投影法的收敛性) 设 S_1, S_2 为闭凸集, 满足 $S \equiv S_1 \cap S_2 \neq \emptyset$ 。令 $\{\mathbf{x}^k\}_{k \geq 0}$ 为以 $\mathbf{x}^0 \in S_2$ 为初始点的交替投影法生成的序列, 则

(a) 对任意 $k \geq 0$,

$$\min_{n=0,1,\dots,k} d(\mathbf{x}^n, S_1) \leq \frac{d_S(\mathbf{x}^0)}{\sqrt{k+1}};$$

(b) 存在 $\mathbf{x}^* \in S$, 使得 $\lim_{k \rightarrow +\infty} \mathbf{x}^k = \mathbf{x}^*$ 。

7.2.3 线性可行性问题的求解

例 7.1 (线性可行性问题的求解) 考虑如下线性等式与不等式系统:

$$\mathbf{Ax} = \mathbf{b}, \mathbf{x} \geq 0,$$

其中 $\mathbf{A} \in \mathbb{R}^{m \times n}$ 为满行秩矩阵, $\mathbf{b} \in \mathbb{R}^m$ 。这是线性规划问题可行集的标准形式之一。求解该问题的一种方法是使用交替投影法。定义

$$S_1 = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{Ax} = \mathbf{b}\}, \quad S_2 = \mathbb{R}_+^n.$$

S_1 和 S_2 上的投影有如下的解析表达式:

$$P_{S_1}(\mathbf{x}) = \mathbf{x} - \mathbf{A}^T(\mathbf{AA}^T)^{-1}(\mathbf{Ax} - \mathbf{b}), \quad P_{S_2}(\mathbf{x}) = [\mathbf{x}]_+.$$

求解上述问题的交替投影法形式如下:

Algorithm 5 求解线性可行性问题的交替投影法

- 初始化：任选 $\mathbf{x}^0 \in \mathbb{R}_+^n$ 。
- 迭代步骤 ($k \geq 0$):

$$\mathbf{x}^{k+1} = [\mathbf{x}^k - \mathbf{A}^T(\mathbf{A}\mathbf{A}^T)^{-1}(\mathbf{A}\mathbf{x}^k - \mathbf{b})]_+.$$

注 7.10 上述方案的迭代步骤需要计算 $(\mathbf{A}\mathbf{A}^T)^{-1}(\mathbf{A}\mathbf{x}^k - \mathbf{b})$ ，这涉及矩阵 $\mathbf{A}\mathbf{A}^T$ 的计算以及线性系统 $(\mathbf{A}\mathbf{A}^T)\mathbf{z} = \mathbf{A}\mathbf{x}^k - \mathbf{b}$ 的求解。当这些计算成本过高，此时可以采用另一种投影算法，避免求解线性系统：

记 $\mathbf{A}$ 的第 i 行为 $\mathbf{a}_i^T$ ，并定义

$$T_i = \{\mathbf{x} \in \mathbb{R}^n : \mathbf{a}_i^T \mathbf{x} = b_i\}, \quad i = 1, 2, \dots, m, \quad T_{m+1} = \mathbb{R}_+^n,$$

则求解上述问题等价于寻找交集 $\bigcap_{i=1}^{m+1} T_i$ 中的一点。因为

$$P_{T_i}(\mathbf{x}) = \mathbf{x} - \frac{\mathbf{a}_i^T \mathbf{x} - b_i}{\|\mathbf{a}_i\|_2^2} \mathbf{a}_i, \quad i = 1, 2, \dots, m.$$

所以

$$d_{T_i}(\mathbf{x}) = \|\mathbf{x} - P_{T_i}(\mathbf{x})\| = \frac{|\mathbf{a}_i^T \mathbf{x} - b_i|}{\|\mathbf{a}_i\|_2}.$$

我们现在可以调用贪婪投影法，其形式如下：

Algorithm 6 求解线性可行性问题的贪婪投影法

- 初始化：任选 $\mathbf{x}^0 \in \mathbb{E}$ 。
- 迭代步骤 ($k = 0, 1, \dots$):
 1. 计算 $i_k \in \arg\max_{i=1,2,\dots,m} \frac{|\mathbf{a}_i^T \mathbf{x}^k - b_i|}{\|\mathbf{a}_i\|_2}$ 。
 2. 若 $\frac{|\mathbf{a}_{i_k}^T \mathbf{x}^k - b_{i_k}|}{\|\mathbf{a}_{i_k}\|_2} > \|\mathbf{x}^k - [\mathbf{x}^k]_+\|_2$ ，则

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \frac{\mathbf{a}_{i_k}^T \mathbf{x}^k - b_{i_k}}{\|\mathbf{a}_{i_k}\|_2^2} \mathbf{a}_{i_k};$$

否则，

$$\mathbf{x}^{k+1} = [\mathbf{x}^k]_+.$$

此时贪婪投影法比交替投影法计算上更简单。

8 交替方向乘子法 (Alternating Direction Method of Multipliers / ADMM)

8.1 增广拉格朗日法 (The Augmented Lagrangian Method / ALM)

考虑问题

$$H_{\text{opt}} = \min\{H(x, z) \equiv h_1(x) + h_2(z) : Ax + Bz = c\}, \quad (34)$$

其中 $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{m \times p}$, $c \in \mathbb{R}^m$ 。设 h_1 和 h_2 是适当闭凸函数。构造拉格朗日函数:

$$L(x, z; y) = h_1(x) + h_2(z) + \langle y, Ax + Bz - c \rangle.$$

因此对偶目标函数为

$$\begin{aligned} q(y) &= \min_{x \in \mathbb{R}^n, z \in \mathbb{R}^p} \{h_1(x) + h_2(z) + \langle y, Ax + Bz - c \rangle\} \\ &= -h_1^*(-A^T y) - h_2^*(-B^T y) - \langle c, y \rangle, \end{aligned}$$

对应的对偶问题为

$$q_{\text{opt}} = \max_{y \in \mathbb{R}^m} \{-h_1^*(-A^T y) - h_2^*(-B^T y) - \langle c, y \rangle\}, \quad (35)$$

或等价的极小化形式

$$\min_{y \in \mathbb{R}^m} \{h_1^*(-A^T y) + h_2^*(-B^T y) + \langle c, y \rangle\}.$$

将邻近点方法应用于上述对偶问题, 其更新步骤为 ($\rho > 0$ 为给定常数)

$$y^{k+1} = \arg \min_{y \in \mathbb{R}^m} \left\{ h_1^*(-A^T y) + h_2^*(-B^T y) + \langle c, y \rangle + \frac{1}{2\rho} \|y - y^k\|^2 \right\}.$$

由最优性条件可知, 上述成立当且仅当

$$0 \in -A\partial h_1^*(-A^T y^{k+1}) - B\partial h_2^*(-B^T y^{k+1}) + c + \frac{1}{\rho}(y^{k+1} - y^k).$$

利用共轭次梯度定理, 可知 y^{k+1} 满足上式当且仅当

$$y^{k+1} = y^k + \rho(Ax^{k+1} + Bz^{k+1} - c),$$

其中 x^{k+1} 和 z^{k+1} 满足

$$x^{k+1} \in \arg \min_{x \in \mathbb{R}^n} \{\langle A^T y^{k+1}, x \rangle + h_1(x)\},$$

$$z^{k+1} \in \arg \min_{z \in \mathbb{R}^p} \{ \langle B^T y^{k+1}, z \rangle + h_2(z) \}.$$

将 y^{k+1} 的更新式代入上述条件, 可得 y^{k+1} 满足原条件当且仅当

$$y^{k+1} = y^k + \rho(Ax^{k+1} + Bz^{k+1} - c),$$

$$x^{k+1} \in \arg \min_{x \in \mathbb{R}^n} \{ \langle A^T(y^k + \rho(Ax^{k+1} + Bz^{k+1} - c)), x \rangle + h_1(x) \},$$

$$z^{k+1} \in \arg \min_{z \in \mathbb{R}^p} \{ \langle B^T(y^k + \rho(Ax^{k+1} + Bz^{k+1} - c)), z \rangle + h_2(z) \}.$$

利用 h_1 和 h_2 的适当凸性, 结合最优性条件, 上述条件等价于

$$y^{k+1} = y^k + \rho(Ax^{k+1} + Bz^{k+1} - c),$$

$$0 \in A^T(y^k + \rho(Ax^{k+1} + Bz^{k+1} - c)) + \partial h_1(x^{k+1}),$$

$$0 \in B^T(y^k + \rho(Ax^{k+1} + Bz^{k+1} - c)) + \partial h_2(z^{k+1}).$$

上述两条件成立当且仅当 (x^{k+1}, z^{k+1}) 是函数

$$\tilde{H}(x, z) \equiv h_1(x) + h_2(z) + \frac{\rho}{2} \left\| Ax + Bz - c + \frac{1}{\rho} y^k \right\|^2$$

的极小点, 即全局极小点。因此, 我们给出了对偶邻近点方法的原始形式, 即增广拉格朗日方法。上述论证说明, 对对偶问题做邻近方法得到了增广拉格朗日方法。

Algorithm 7 增广拉格朗日方法 (ALM)

• 初始化: 任选 $y^0 \in \mathbb{R}^m$, $\rho > 0$ 。

• 迭代步骤 ($k = 0, 1, \dots$):

1. 计算

$$(x^{k+1}, z^{k+1}) = \arg \min_{x, z} \left\{ h_1(x) + h_2(z) + \frac{\rho}{2} \left\| Ax + Bz - c + \frac{1}{\rho} y^k \right\|^2 \right\}.$$

2. 更新对偶变量

$$y^{k+1} = y^k + \rho(Ax^{k+1} + Bz^{k+1} - c).$$

8.2 交替方向乘子法 (Alternating Direction Method of Multipliers / ADMM)

增广拉格朗日方法通常不是一种可直接实现的方法, 因为子问题的求解难度与原问题相当, 主要的困难在于变量 x 和 z 之间的耦合项, 形式为 $\rho(x^T A^T Bz)$ 。交替方向乘子法 (ADMM) 为解决这一问题, 先对 x 极小化目标函数, 再对 z 极小化。

Algorithm 8 交替方向乘子法 (ADMM)

• 初始化: $x^0 \in \mathbb{R}^n, z^0 \in \mathbb{R}^p, y^0 \in \mathbb{R}^m, \rho > 0$.

• 迭代步骤 ($k = 0, 1, \dots$):

1. 对 x 进行更新:

$$x^{k+1} \in \arg \min_x \left\{ h_1(x) + \frac{\rho}{2} \left\| Ax + Bz^k - c + \frac{1}{\rho} y^k \right\|^2 \right\};$$

2. 对 z 进行更新:

$$z^{k+1} \in \arg \min_z \left\{ h_2(z) + \frac{\rho}{2} \left\| Ax^{k+1} + Bz - c + \frac{1}{\rho} y^k \right\|^2 \right\};$$

3. 更新对偶变量:

$$y^{k+1} = y^k + \rho (Ax^{k+1} + Bz^{k+1} - c).$$

接下来我们分析一种比 ADMM 更一般的方法, 在该方法中, 我们在前两个步骤的目标函数中加入邻近项。假设给定两个半正定矩阵 $G \in \mathbb{S}_+^n, Q \in \mathbb{S}_+^p$, 并定义 $\|x\|_G^2 = x^T G x$, $\|x\|_Q^2 = x^T Q x$ 。

Algorithm 9 带邻近项的交替方向乘子法 (AD-PM)

• 初始化: $x^0 \in \mathbb{R}^n, z^0 \in \mathbb{R}^p, y^0 \in \mathbb{R}^m, \rho > 0$.

• 迭代步骤 ($k = 0, 1, \dots$):

1. 对 x 进行更新:

$$x^{k+1} \in \arg \min_{x \in \mathbb{R}^n} \left\{ h_1(x) + \frac{\rho}{2} \left\| Ax + Bz^k - c + \frac{1}{\rho} y^k \right\|^2 + \frac{1}{2} \|x - x^k\|_G^2 \right\};$$

2. 对 z 进行更新:

$$z^{k+1} \in \arg \min_{z \in \mathbb{R}^p} \left\{ h_2(z) + \frac{\rho}{2} \left\| Ax^{k+1} + Bz - c + \frac{1}{\rho} y^k \right\|^2 + \frac{1}{2} \|z - z^k\|_Q^2 \right\};$$

3. 更新对偶变量:

$$y^{k+1} = y^k + \rho (Ax^{k+1} + Bz^{k+1} - c).$$

引入 AD-PM 的一个重要动机是, 通过选择合适的 G 和 Q , 可以极大简化 ADMM 步骤中的极小化问题。选择 $G = \alpha I - \rho A^T A$ (其中 $\alpha \geq \rho \lambda_{\max}(A^T A)$), $Q = \beta I - \rho B^T B$

(其中 $\beta \geq \rho \lambda_{\max}(B^T B)$), 此时 $G, Q \in \mathbb{S}_+^n$, x 步需要极小化的函数可简化为:

$$\begin{aligned}
& h_1(x) + \frac{\rho}{2} \left\| Ax + Bz^k - c + \frac{1}{\rho} y^k \right\|^2 + \frac{1}{2} \|x - x^k\|_G^2 \\
&= h_1(x) + \frac{\rho}{2} \left\| A(x - x^k) + Ax^k + Bz^k - c + \frac{1}{\rho} y^k \right\|^2 + \frac{1}{2} \|x - x^k\|_G^2 \\
&= h_1(x) + \frac{\rho}{2} \|A(x - x^k)\|^2 + \left\langle \rho Ax, Ax^k + Bz^k - c + \frac{1}{\rho} y^k \right\rangle \\
&\quad + \frac{\alpha}{2} \|x - x^k\|^2 - \frac{\rho}{2} \|A(x - x^k)\|^2 + \text{常数} \\
&= h_1(x) + \rho \left\langle Ax, Ax^k + Bz^k - c + \frac{1}{\rho} y^k \right\rangle + \frac{\alpha}{2} \|x - x^k\|^2 + \text{常数}.
\end{aligned}$$

因此, AD-PMM 的步骤 1 等价于:

$$x^{k+1} = \arg \min_{x \in \mathbb{R}^n} \left\{ h_1(x) + \rho \left\langle Ax, Ax^k + Bz^k - c + \frac{1}{\rho} y^k \right\rangle + \frac{\alpha}{2} \|x - x^k\|^2 \right\}.$$

同理, 步骤 2 等价于:

$$z^{k+1} = \arg \min_{z \in \mathbb{R}^p} \left\{ h_2(z) + \rho \left\langle Bz, Ax^{k+1} + Bz^k - c + \frac{1}{\rho} y^k \right\rangle + \frac{\beta}{2} \|z - z^k\|^2 \right\}.$$

上述更新公式中的目标函数, 是通过 ADMM 步骤 1 和 2 中的二次项进行线性化, 并添加邻近项得到的, 因此该方法被称为交替方向线性化邻近乘子法 (AD-LPMM)。我们也可以用邻近算子来表示这些更新公式

Algorithm 10 交替方向线性化邻近乘子法 (AD-LPMM)

- 初始化: $x^0 \in \mathbb{R}^n, z^0 \in \mathbb{R}^p, y^0 \in \mathbb{R}^m, \rho > 0, \alpha \geq \rho \lambda_{\max}(A^T A), \beta \geq \rho \lambda_{\max}(B^T B)$.
- 迭代步骤 ($k = 0, 1, \dots$):
 1. 对 x 进行更新:

$$x^{k+1} = \text{prox}_{\frac{1}{\alpha} h_1} \left[x^k - \frac{\rho}{\alpha} A^T \left(Ax^k + Bz^k - c + \frac{1}{\rho} y^k \right) \right];$$

2. 对 z 进行更新:

$$z^{k+1} = \text{prox}_{\frac{1}{\beta} h_2} \left[z^k - \frac{\rho}{\beta} B^T \left(Ax^{k+1} + Bz^k - c + \frac{1}{\rho} y^k \right) \right];$$

3. 更新对偶变量:

$$y^{k+1} = y^k + \rho (Ax^{k+1} + Bz^{k+1} - c).$$

8.3 ADMM 的收敛性

在本节对 AD-PMM 方法进行收敛速率分析。注意, ADMM 和 AD-LPMM 都是 AD-PMM 的特例。

假设 8.1 • (A) $h_1 : \mathbb{R}^n \rightarrow (-\infty, \infty]$ 和 $h_2 : \mathbb{R}^p \rightarrow (-\infty, \infty]$ 是适当闭凸函数。

- (B) $A \in \mathbb{R}^{m \times n}$, $B \in \mathbb{R}^{m \times p}$, $c \in \mathbb{R}^m$, $\rho > 0$ 。
- (C) $G \in \mathbb{S}_+^n$, $Q \in \mathbb{S}_+^p$ 。
- (D) 对任意 $a \in \mathbb{R}^n$, $b \in \mathbb{R}^p$, 问题

$$\min_{x \in \mathbb{R}^n} \left\{ h_1(x) + \frac{\rho}{2} \|Ax\|^2 + \frac{1}{2} \|x\|_G^2 + \langle a, x \rangle \right\}$$

与

$$\min_{z \in \mathbb{R}^p} \left\{ h_2(z) + \frac{\rho}{2} \|Bz\|^2 + \frac{1}{2} \|z\|_Q^2 + \langle b, z \rangle \right\}$$

的最优解集非空。

- (E) 存在 $\hat{x} \in \text{ri}(\text{dom}(h_1))$ 和 $\hat{z} \in \text{ri}(\text{dom}(h_2))$, 使得 $A\hat{x} + B\hat{z} = c$ 。
- (F) 问题(34)的最优解集非空, 记为 X^* , 对应的最优值为 H_{opt} 。

定理 8.1 上述假设成立时, 令 H_{opt} 和 q_{opt} 分别为原始问题(34)和对偶问题(35)的最优值, 则 $H_{\text{opt}} = q_{\text{opt}}$, 且对偶问题(35)存在最优解。

定理 8.2 (AD-PMM 的 $O(1/k)$ 收敛速率) 上述假设成立时, 设 $\{x^k, z^k\}_{k \geq 0}$ 为 AD-PMM 求解问题(34)生成的序列, (x^*, z^*) 为问题(34)的最优解, y^* 为对偶问题(35)的最优解。设 $\gamma > 0$ 为任意满足 $\gamma \geq 2\|y^*\|$ 的常数, 则对所有 $n \geq 0$, 有

$$H(x^{(n)}, z^{(n)}) - H_{\text{opt}} \leq \frac{\|x^* - x^0\|_G^2 + \|z^* - z^0\|_C^2 + \frac{1}{\rho}(\gamma + \|y^0\|)^2}{2(n+1)},$$

$$\|Ax^{(n)} + Bz^{(n)} - c\| \leq \frac{\|x^* - x^0\|_G^2 + \|z^* - z^0\|_C^2 + \frac{1}{\rho}(\gamma + \|y^0\|)^2}{\gamma(n+1)},$$

其中 $C = \rho B^T B + Q$, 且

$$x^{(n)} = \frac{1}{n+1} \sum_{k=0}^n x^{k+1}, \quad z^{(n)} = \frac{1}{n+1} \sum_{k=0}^n z^{k+1}.$$

证明.

- 由费马最优性条件及 AD-PMM 的更新步骤, 可得 x^{k+1} 和 z^{k+1} 满足

$$-\rho A^T \left(Ax^{k+1} + Bz^k - c + \frac{1}{\rho} y^k \right) - G(x^{k+1} - x^k) \in \partial h_1(x^{k+1}),$$

$$-\rho B^T \left(Ax^{k+1} + Bz^k - c + \frac{1}{\rho} y^k \right) - Q(z^{k+1} - z^k) \in \partial h_2(z^{k+1}).$$

我们使用如下记号:

$$\tilde{x}^k = x^{k+1}, \quad \tilde{z}^k = z^{k+1}, \quad \tilde{y}^k = y^k + \rho(Ax^{k+1} + Bz^k - c).$$

利用上述两式、次梯度不等式及上述记号, 对任意 $x \in \text{dom}(h_1)$ 和 $z \in \text{dom}(h_2)$, 有

$$h_1(x) - h_1(\tilde{x}^k) + \left\langle \rho A^T \left(A\tilde{x}^k + B\tilde{z}^k - c + \frac{1}{\rho}y^k \right) + G(\tilde{x}^k - x^k), x - \tilde{x}^k \right\rangle \geq 0,$$

$$h_2(z) - h_2(\tilde{z}^k) + \left\langle \rho B^T \left(A\tilde{x}^k + B\tilde{z}^k - c + \frac{1}{\rho}y^k \right) + Q(\tilde{z}^k - z^k), z - \tilde{z}^k \right\rangle \geq 0.$$

利用 $\tilde{y}^k$ 的定义, 上述两个不等式可改写为

$$h_1(x) - h_1(\tilde{x}^k) + \langle A^T \tilde{y}^k + G(\tilde{x}^k - x^k), x - \tilde{x}^k \rangle \geq 0,$$

$$h_2(z) - h_2(\tilde{z}^k) + \langle B^T \tilde{y}^k + (\rho B^T B + Q)(\tilde{z}^k - z^k), z - \tilde{z}^k \rangle \geq 0.$$

将上述两个不等式相加, 并利用恒等式

$$y^{k+1} - y^k = \rho(A\tilde{x}^k + B\tilde{z}^k - c),$$

可得对任意 $x \in \text{dom}(h_1)$, $z \in \text{dom}(h_2)$ 和 $y \in \mathbb{R}^m$, 有

$$H(x, z) - H(\tilde{x}^k, \tilde{z}^k) + \left\langle \begin{pmatrix} x - \tilde{x}^k \\ z - \tilde{z}^k \\ y - \tilde{y}^k \end{pmatrix}, \begin{pmatrix} A^T \tilde{y}^k \\ B^T \tilde{y}^k \\ -A\tilde{x}^k - B\tilde{z}^k + c \end{pmatrix} - \begin{pmatrix} G(x^k - \tilde{x}^k) \\ C(z^k - \tilde{z}^k) \\ \frac{1}{\rho}(y^k - y^{k+1}) \end{pmatrix} \right\rangle \geq 0,$$

其中 $C = \rho B^T B + Q$ 。

- 我们将使用对任意半正定矩阵 P 成立的恒等式:

$$(a - b)^T P (c - d) = \frac{1}{2} (\|a - d\|_P^2 - \|a - c\|_P^2 + \|b - c\|_P^2 - \|b - d\|_P^2).$$

利用上述恒等式, 可得

$$(x - \tilde{x}^k)^T G(x^k - \tilde{x}^k) = \frac{1}{2} (\|x - \tilde{x}^k\|_G^2 - \|x - x^k\|_G^2 + \|\tilde{x}^k - x^k\|_G^2) \geq \frac{1}{2} \|x - \tilde{x}^k\|_G^2 - \frac{1}{2} \|x - x^k\|_G^2,$$

以及

$$(z - \tilde{z}^k)^T C(z^k - \tilde{z}^k) = \frac{1}{2} \|z - \tilde{z}^k\|_C^2 - \frac{1}{2} \|z - z^k\|_C^2 + \frac{1}{2} \|z^k - \tilde{z}^k\|_C^2,$$

还有

$$\begin{aligned} 2(y - \tilde{y}^k)^T (y^k - y^{k+1}) &= \|y - y^{k+1}\|^2 - \|y - y^k\|^2 + \|\tilde{y}^k - y^k\|^2 - \|\tilde{y}^k - y^{k+1}\|^2 \\ &= \|y - y^{k+1}\|^2 - \|y - y^k\|^2 + \rho^2 \|A\tilde{x}^k + B\tilde{z}^k - c\|^2 - \rho^2 \|B(z^k - \tilde{z}^k)\|^2. \end{aligned}$$

因此

$$\frac{1}{\rho} (y - \tilde{y}^k)^T (y^k - y^{k+1}) \geq \frac{1}{2\rho} (\|y - y^{k+1}\|^2 - \|y - y^k\|^2) - \frac{\rho}{2} \|B(z^k - \tilde{z}^k)\|^2.$$

记

$$H = \begin{pmatrix} G & 0 & 0 \\ 0 & C & 0 \\ 0 & 0 & \frac{1}{\rho}I \end{pmatrix},$$

以及

$$w = \begin{pmatrix} x \\ z \\ y \end{pmatrix}, \quad w^k = \begin{pmatrix} x^k \\ z^k \\ y^k \end{pmatrix}, \quad \tilde{w}^k = \begin{pmatrix} \tilde{x}^k \\ \tilde{z}^k \\ \tilde{y}^k \end{pmatrix},$$

结合上述不等式可得

$$\left\langle \begin{pmatrix} x - \tilde{x}^k \\ z - \tilde{z}^k \\ y - \tilde{y}^k \end{pmatrix}, \begin{pmatrix} G(x^k - \tilde{x}^k) \\ C(z^k - \tilde{z}^k) \\ \frac{1}{\rho}(y^k - y^{k+1}) \end{pmatrix} \right\rangle \geq \frac{1}{2}\|w - w^{k+1}\|_H^2 - \frac{1}{2}\|w - w^k\|_H^2.$$

- 将上述不等式与之前的不等式结合，对任意 $x \in \text{dom}(h_1)$, $z \in \text{dom}(h_2)$ 和 $y \in \mathbb{R}^m$ ，有

$$H(x, z) - H(\tilde{x}^k, \tilde{z}^k) + \langle w - \tilde{w}^k, F\tilde{w}^k + \tilde{c} \rangle \geq \frac{1}{2}\|w - w^{k+1}\|_H^2 - \frac{1}{2}\|w - w^k\|_H^2,$$

其中

$$F = \begin{pmatrix} 0 & 0 & A^T \\ 0 & 0 & B^T \\ -A & -B & 0 \end{pmatrix}, \quad \tilde{c} = \begin{pmatrix} 0 \\ 0 \\ c \end{pmatrix}.$$

注意到

$$\langle w - \tilde{w}^k, F\tilde{w}^k + \tilde{c} \rangle = \langle w - \tilde{w}^k, Fw + \tilde{c} \rangle,$$

因此上式可改写为

$$H(x, z) - H(\tilde{x}^k, \tilde{z}^k) + \langle w - \tilde{w}^k, Fw + \tilde{c} \rangle \geq \frac{1}{2}\|w - w^{k+1}\|_H^2 - \frac{1}{2}\|w - w^k\|_H^2.$$

对 $k = 0, 1, \dots, n$ 求和，可得

$$(n+1)H(x, z) - \sum_{k=0}^n H(\tilde{x}^k, \tilde{z}^k) + \left\langle (n+1)w - \sum_{k=0}^n \tilde{w}^k, Fw + \tilde{c} \right\rangle \geq -\frac{1}{2}\|w - w^0\|_H^2.$$

定义

$$w^{(n)} = \frac{1}{n+1} \sum_{k=0}^n \tilde{w}^k, \quad x^{(n)} = \frac{1}{n+1} \sum_{k=0}^n x^{k+1}, \quad z^{(n)} = \frac{1}{n+1} \sum_{k=0}^n z^{k+1},$$

利用 H 的凸性，可得

$$H(x, z) - H(x^{(n)}, z^{(n)}) + \langle w - w^{(n)}, Fw + \tilde{c} \rangle + \frac{1}{2(n+1)}\|w - w^0\|_H^2 \geq 0.$$

对任意 $x \in \text{dom}(h_1)$ 和 $z \in \text{dom}(h_2)$, 上式可改写为

$$H(x^{(n)}, z^{(n)}) - H(x, z) + \langle w^{(n)} - w, Fw^{(n)} + \tilde{c} \rangle \leq \frac{1}{2(n+1)} \|w - w^0\|_H^2.$$

设 (x^*, z^*) 为问题(34)的最优解, 则 $H(x^*, z^*) = H_{\text{opt}}$ 且 $Ax^* + Bz^* = c$ 。将 $x = x^*$, $z = z^*$ 代入上式, 整理可得

$$H(x^{(n)}, z^{(n)}) - H_{\text{opt}} + \langle y, Ax^{(n)} + Bz^{(n)} - c \rangle \leq \frac{\|x^* - x^0\|_G^2 + \|z^* - z^0\|_C^2 + \frac{1}{\rho} \|y - y^0\|^2}{2(n+1)}.$$

由于上式对任意 $y \in \mathbb{R}^m$ 成立, 两边在 $y \in B[0, \gamma]$ 上取最大值, 可得

$$H(x^{(n)}, z^{(n)}) - H_{\text{opt}} + \gamma \|Ax^{(n)} + Bz^{(n)} - c\| \leq \frac{\|x^* - x^0\|_G^2 + \|z^* - z^0\|_C^2 + \frac{1}{\rho} (\gamma + \|y^0\|)^2}{2(n+1)}.$$

结合强对偶性, 定理得证。

9 信赖域方法

信赖域方法其基本思想与牛顿法一致：在点 x 附近，我们用二次模型来逼近函数 f ：

$$f(x+s) \approx m_x(s) = f(x) + \langle \nabla f(x), s \rangle + \frac{1}{2} \langle H_x(s), s \rangle.$$

这里， H_x 可以是任意自伴线性映射，通常选择 H_x 为 f 的 Hessian。在迭代点 x_k 处，定义

$$m_k(s) = f(x_k) + \langle \nabla f(x_k), s \rangle + \frac{1}{2} \langle H_k(s), s \rangle$$

其中 H_k 是一个自伴线性映射，考虑信赖域子问题：

$$\min_s m_k(s) \quad \text{s.t.} \quad \|s\| \leq \Delta_k,$$

其中 Δ_k 是第 k 次迭代的信赖域半径。如果 s_k 是信赖域子问题的解，则下一步迭代点为 $x_k^+ = x_k + s_k$ 。

Algorithm 11 信赖域方法 (TR)

参数: 最大信赖域半径 $\bar{\Delta} > 0$, 接受阈值 $\rho' \in (0, 1/4)$

输入: 初始点 x_0 , 初始半径 $\Delta_0 \in (0, \bar{\Delta}]$

初始化: $k = 0$

for $k = 0, 1, 2, \dots$

- 选取映射 H_k , 构造二次模型

$$m_k(s) = f(x_k) + \langle \nabla f(x_k), s \rangle + \frac{1}{2} \langle H_k(s), s \rangle$$

- 近似求解信赖域子问题, 得到试探步 s_k

$$\min_s m_k(s) \quad \text{s.t.} \quad \|s\| \leq \Delta_k,$$

- 计算试探迭代点 $x_k^+ = x_k + s_k$
- 计算实际下降与模型下降的比值

$$\rho_k = \frac{f(x_k) - f(x_k^+)}{m_k(0) - m_k(s_k)}$$

- 更新迭代点

$$x_{k+1} = \begin{cases} x_k^+ & \rho_k > \rho' (\text{成功步}) \\ x_k & \rho_k \leq \rho' (\text{失败步}) \end{cases}$$

- 更新信赖域半径

$$\Delta_{k+1} = \begin{cases} \frac{1}{4}\Delta_k & \rho_k < \frac{1}{4} \\ \min(2\Delta_k, \bar{\Delta}) & \rho_k > \frac{3}{4} \text{ 且 } \|s_k\| = \Delta_k \\ \Delta_k & \text{其他} \end{cases}$$

注 9.1

- 更现实的目标是找到 x_k , 满足

$$\|\nabla f(x)\| \leq \varepsilon_g \quad \text{且} \quad \nabla^2 f(x) \succeq -\varepsilon_H I (\lambda_{\min}(\nabla^2 f(x)) > \varepsilon_H) \quad (36)$$

- 如果只关心一阶最优性条件, ε_H 也可以取为无穷大 (也就是说忽略第二个条件)。
- 本章的主要目标之一是证明: 在合适的假设条件下, 无论算法如何初始化, 算法都能在有限次迭代内找到满足上述条件的点。
- 需要先考虑的问题是
 - 如何选取映射 H_k
 - 信赖域子问题如何求解以及求解精度
 - f 的正则性条件

9.1 映射 H_k 的选择

模型 m_{x_k} 由映射 H_k 决定。映射越简单，信赖域子问题就越容易求解。选择 H_k 时，我们需要在模型精度、计算效率和实现便利性之间取得平衡。

考虑到我们的目标是 $\|\nabla f(x)\| \leq \varepsilon_g$, $\nabla^2 f(x) \succeq -\varepsilon_H I$ ，我们引入以下要求：

- 当迭代点的梯度较大时，条件会非常宽松。本质上，这类迭代的核心目标是降低梯度范数，仅用一阶精度的模型即可实现：

假设 9.1 (条件 A1) 对所有满足 $\|\nabla f(x_k)\| > \varepsilon_g$ 的迭代 k ，我们要求：

1. H_k 是线性的，即

$$\forall s, \alpha \geq 0, \quad H_k(\alpha s) = \alpha H_k(s);$$

2. H_k 是一致有界的，即存在与 k 无关的常数 $c_0 \geq 0$ ，使得

$$\forall s, \quad |\langle s, H_k(s) \rangle| \leq c_0 \|s\|^2.$$

注 9.2

- 一个选择是 $H_k = L \cdot \text{Id}$ (其中 $L > 0$)。这种形式简单、计算成本低，且信赖域子问题有闭式解。但该模型完全不包含二阶信息，可能会减慢收敛速度。
- 也可以通过有限差分近似 Hessian 来构造径向线性的 H_k
- 也可以直接使用 f 的 Hessian 作为 H_k 。
- 当迭代点的梯度较小，且我们希望近似满足二阶必要最优性条件 (即 $\varepsilon_H < \infty$) 时，模型需要至少具有近似二阶精度。

假设 9.2 (A2) 对所有满足 $\|\nabla f(x_k)\| \leq \varepsilon_g$ 的迭代 k ，我们要求

1. H_k 是线性自伴映射。
2. 存在与 k 无关的常数 $c_1 \geq 0$ ，使得

$$\|\nabla^2 f(x_k) - H_k\| \leq \frac{c_1 \Delta_k}{3},$$

其中 $\|\cdot\|$ 表示自伴映射的算子范数，即其特征值的最大绝对值。

注 9.3

- 下文的收敛结果保证， H_k 最终几乎是半正定的。这一结论只有在 H_k 与 $\nabla^2 f(x_k)$ 的算子范数距离足够小时才有意义。
- 当 $H_k = \nabla^2(f \circ R_{x_k})(0) = \nabla^2 f(x_k)$ 。此时 A2 成立，且常数 $c_1 = 0$ 。

9.2 子问题求解要求

近似求解信赖域子问题是每次迭代中最关键的一步。这里先给出子问题求解的最低要求。

- 针对一阶条件:

假设 9.3 (A3) 存在常数 $c_2 > 0$, 使得对所有满足 $\|\nabla f(x_k)\| > \varepsilon_g$ 的迭代 k , 步长 s_k 满足

$$m_k(0) - m_k(s_k) \geq c_2 \min \left(\Delta_k, \frac{\|\nabla f(x_k)\|}{c_0} \right) \|\nabla f(x_k)\|,$$

其中 c_0 是 A1 中的常数。

A3 可以通过以下方式得到

引理 9.1 设 $g_k = \nabla f(x_k)$ 。柯西点是切向量 $s_k^C = -t\nabla f(x_k)$ ($t \geq 0$), 且在约束 $\|s_k^C\| \leq \Delta_k$ 下使 $m_k(s_k^C)$ 最小。在 A1 下, 最优的 t 可显式地表达为:

$$t = \begin{cases} \min \left(\frac{\|g_k\|^2}{\langle g_k, H_k(g_k) \rangle_{x_k}}, \frac{\Delta_k}{\|g_k\|} \right) & \text{若 } \langle H_k(g_k) \rangle_{x_k} > 0, \\ [6pt] \frac{\Delta_k}{\|g_k\|} & \text{其他.} \end{cases}$$

此外, 取 $s_k = s_k^C$ 时, 则 A3 成立, 且 $c_2 = \frac{1}{2}$ 。

- 当梯度较小且 $\varepsilon_H < \infty$ 时, 需要关注二阶最优性条件:

假设 9.4 (A4) 存在常数 $c_3 > 0$, 使得对所有满足 $\|\nabla f(x_k)\| \leq \varepsilon_g$ 且 $\lambda_{\min}(H_k) < -\varepsilon_H$ 的迭代 k , 步长 s_k 满足

$$m_k(0) - m_k(s_k) \geq c_3 \Delta_k^2 \varepsilon_H.$$

(注意: 由 A2, H_k 的特征值均为实数)

A4 可以通过以下方式得到

引理 9.2 在 A2 下, 若 $\lambda_{\min}(H_k) < -\varepsilon_H$, 则存在切向量 $u \in T_{x_k} \mathcal{M}$, 满足

$$\|u\| = 1, \quad \langle \nabla f(x_k), u \rangle \leq 0, \quad \langle u, H_k(u) \rangle < -\varepsilon_H.$$

在 RTR 中取 $s_k = \Delta_k u$ (称为特征步) 时, A 6.4 成立, 且 $c_3 = \frac{1}{2}$ 。

推论 9.3 若每次迭代中 H_k 都是线性自伴映射, 则在每次迭代中取 s_k 为信赖域子问题的全局极小值点, 可同时满足 A3 和 A4, 且 $c_2 = c_3 = \frac{1}{2}$ 。类似地, 若 s_k 能达到最优模型下降的至少 $\alpha \in (0, 1)$ 倍, 则条件成立, 且 $c_2 = c_3 = \frac{\alpha}{2}$ 。

9.3 正则化条件

假设 9.5 (A5) 存在常数 $f_{\text{low}} \in \mathbb{R}$, 使得对 $\forall k \in \mathbb{N}^+$, 均有 $f(x_k) \geq f_{\text{low}}$ 。

此外, 我们仍需要拉回函数在给定缩回 R 下满足一阶 Lipschitz 型条件。集合 S_g 的定义稍后给出。

假设 9.6 (A6) 给定集集 S_g , 存在常数 $L_g > 0$, 使得对所有 $(x, s) \in S_g$, 有

$$f(x + s) \leq f(x) + \langle \nabla f(x), s \rangle + \frac{L_g}{2} \|s\|^2.$$

除上述条件外, 我们还引入二阶 Lipschitz 型条件。若 $\nabla^2 f$ 以常数 L_H Lipschitz 连续, 则该条件成立。

假设 9.7 (A7) 给定集合 S_H , 存在常数 $L_H > 0$, 使得对所有 $(x, s) \in S_H$, 有

$$f(x + s) \leq f(x) + \langle \nabla f(x), s \rangle + \frac{1}{2} \langle s, \nabla^2 f(x)[s] \rangle + \frac{L_H}{6} \|s\|^3.$$

注 9.4 注意, 由于 $\bar{\Delta}$ 是算法中考虑的最大信赖域半径, 因此 S_g 和 S_H 无需包含范数大于 $\bar{\Delta}$ 的切向量。这对处理非全局定义或性质不佳的缩回尤为有用。

9.4 信赖域算法的迭代复杂度

定理 9.4 (信赖域算法的迭代复杂度) 设 $S = \{(x_0, s_0), (x_1, s_1), \dots\}$ 为信赖域算法在假设 9.1, 假设 9.1, 假设 9.2, 假设 9.3, 假设 9.4, 假设 9.5 下生成的迭代点与迭代方向。进一步假设在集合

$$S_g = \{(x_k, s_k) \in S : \|\nabla f(x_k)\| > \varepsilon_g\},$$

$$S_H = \{(x_k, s_k) \in S : \|\nabla f(x_k)\| \leq \varepsilon_g \text{ 且 } \lambda_{\min}(H_k) < -\varepsilon_H\}$$

上, 假设 9.6, 假设 9.6 以常数 L_g 和 L_H 成立。定义

$$\lambda_g = \frac{1}{4} \min \left(\frac{1}{c_0}, \frac{c_2}{L_g + c_0} \right), \quad \lambda_H = \frac{3}{4} \frac{c_3}{L_H + c_1}.$$

我们分两种情况讨论 (取决于是否以二阶最优性条件为目标):

1. 若 $\varepsilon_g \leq \frac{\Delta_0}{\lambda_g}$ 且 $\varepsilon_H = \infty$, 则存在迭代次数 t , 使得 $\|\nabla f(x_t)\| \leq \varepsilon_g$, 且

$$t \leq \frac{3}{2} \frac{f(x_0) - f_{\text{low}}}{\rho' c_2 \lambda_g} \frac{1}{\varepsilon_g^2} + \frac{1}{2} \log_2 \left(\frac{\Delta_0}{\lambda_g \varepsilon_g} \right) = O \left(\frac{1}{\varepsilon_g^2} \right).$$

(此情形下, 假设 A6.2、A6.4 和 A6.7 无关。)

2. 若 $\varepsilon_g \leq \frac{\Delta_0}{\lambda_g}$ 、 $\varepsilon_g \leq \frac{c_2}{c_3} \frac{\lambda_H}{\lambda_g^2}$ 且 $\varepsilon_H < \frac{c_2}{c_3} \frac{1}{\lambda_g}$, 则存在 $t' \geq t$, 使得 $\|\nabla f(x_{t'})\| \leq \varepsilon_g$ 且 $\lambda_{\min}(H_{t'}) \geq -\varepsilon_H$, 且

$$t' \leq \frac{3}{2} \frac{f(x_0) - f_{\text{low}}}{\rho' c_3 \lambda^2} \frac{1}{\varepsilon^2 \varepsilon_H} + \frac{1}{2} \log_2 \left(\frac{\Delta_0}{\lambda \varepsilon} \right) = O \left(\frac{1}{\varepsilon^2 \varepsilon_H} \right),$$

其中 $(\lambda, \varepsilon) = (\lambda_g, \varepsilon_g)$ 当 $\lambda_g \varepsilon_g \leq \lambda_H \varepsilon_H$, 否则 $(\lambda, \varepsilon) = (\lambda_H, \varepsilon_H)$ 。

由于算法是下降方法, 故 $f(x_{t'}) \leq f(x_t) \leq f(x_0)$ 。

为证明上述定理，我们通过三个引理逐步推导。第一个引理给出信赖域半径的下界。

引理 9.5 (信赖域半径的下界) 在定理 9.4 的假设下，设 $x_0, \dots, x_n$ 为信赖域算法生成的迭代序列。若所有迭代均不满足终止条件，则对 $k = 0, \dots, n$ ，有

$$\Delta_k \geq \min(\Delta_0, \lambda_g \varepsilon_g, \lambda_H \varepsilon_H).$$

证明. 由 ρ_k 的定义，结合 $m_k(0) = f(x_k)$ ，有

$$1 - \rho_k = 1 - \frac{f(x_k) - f(x_k + s_k)}{m_k(0) - m_k(s_k)} = \frac{f(x_k + s_k) - m_k(s_k)}{m_k(0) - m_k(s_k)}.$$

• 如果 $\|\nabla f(x_k)\| > \varepsilon_g$ ：

• 由假设 9.1 和假设 9.6，有：

$$\begin{aligned} f(x_k + s_k) - m_k(s_k) &= f(x_k + s_k) - f(x_k) - \langle \nabla f(x_k), s_k \rangle - \frac{1}{2} \langle H_k(s_k), s_k \rangle \\ &\leq \frac{L_g + c_0}{2} \|s_k\|^2. \end{aligned}$$

• 由假设 9.3，有：

$$m_k(0) - m_k(s_k) \geq c_2 \min\left(\Delta_k, \frac{\varepsilon_g}{c_0}\right) \varepsilon_g.$$

• 结合 $\|s_k\|_{x_k} \leq \Delta_k$ ，可得

$$1 - \rho_k \leq \frac{1}{2} \frac{L_g + c_0}{c_2 \varepsilon_g} \frac{\Delta_k^2}{\min\left(\Delta_k, \frac{\varepsilon_g}{c_0}\right)}.$$

• 若 $\Delta_k \leq \frac{\varepsilon_g}{c_0}$ ，则上式中的最后一项为 Δ_k 。若进一步有 $\Delta_k \leq \frac{c_2 \varepsilon_g}{L_g + c_0}$ ，则 $1 - \rho_k \leq \frac{1}{2}$ 。结合 λ_g 的定义，可得：若 $\Delta_k \leq 4\lambda_g \varepsilon_g$ ，则 $\rho_k \geq \frac{1}{2}$ ，且算法的更新规则得到 $\Delta_{k+1} \geq \Delta_k$ 。

• 如果 $\|\nabla f(x_k)\| \leq \varepsilon_g$ 且 $\lambda_{\min}(H_k) < -\varepsilon_H$

• 由假设 9.2 和假设 9.7 及 $\|s_k\|_{x_k} \leq \Delta_k$ ，分子：

$$\begin{aligned} f(x_k + s_k) - m_k(s_k) &= f(x_k + s_k) - f(x_k) - \langle \nabla f(x_k), s_k \rangle_{x_k} - \frac{1}{2} \langle \text{Hess}(f \circ R_{x_k}(0))[s_k], s_k \rangle_{x_k} \\ &\quad + \frac{1}{2} \langle (\text{Hess}(f \circ R_{x_k}(0)) - H_k)[s_k], s_k \rangle_{x_k} \\ &\leq \frac{L_H + c_1}{6} \Delta_k^3, \end{aligned}$$

• 由假设 9.4，有：

$$m_k(0) - m_k(s_k) \geq c_3 \Delta_k^2 \varepsilon_H.$$

• 综合可得:

$$1 - \rho_k \leq \frac{L_H + c_1}{6c_3\varepsilon_H} \Delta_k.$$

• 结合 λ_H 的定义, 若 $\Delta_k \leq 4\lambda_H\varepsilon_H$, 则 $\rho_k \geq \frac{1}{2}$, 因此 $\Delta_{k+1} \geq \Delta_k$ 。

- 综上, 若 $\Delta_k \leq 4\min(\lambda_g\varepsilon_g, \lambda_H\varepsilon_H)$, 则 $\Delta_{k+1} \geq \Delta_k$ 。
- 根据上述性质, 由数学归纳法可以得到引理结论。

第二个引理给出终止前成功迭代次数的上界。

引理 9.6 (终止前成功迭代次数的上界) 在定理 9.4 的假设下, 设 $x_0, \dots, x_n$ 为信赖域生成的迭代序列。若所有迭代均不满足终止条件, 定义其中成功迭代步的集合为

$$S_n = \{k \in \{0, \dots, n\} : \rho_k > \rho'\},$$

并令 U_n 表示失败迭代的集合 (S_n 和 U_n 构成 $\{0, \dots, n\}$ 的一个划分)。在定理 9.4 的第一种情形下, 成功迭代次数满足

$$|S_n| \leq \frac{f(x_0) - f_{\text{low}}}{\rho'c_2} \frac{1}{\lambda_g\varepsilon_g^2}.$$

同理, 在第二种情形下, 有

$$|S_n| \leq \frac{f(x_0) - f_{\text{low}}}{\rho'c_3} \frac{1}{\min(\lambda_g\varepsilon_g, \lambda_H\varepsilon_H)^2\varepsilon_H}.$$

证明.

- 若 $k \in U_n$, 则 $f(x_k) = f(x_{k+1})$ 。
- 若 $k \in S_n$, 则由 ρ_k 的定义结合假设 9.3 和假设 9.4 可得:

$$\begin{aligned} f(x_k) - f(x_{k+1}) &= \rho_k(m_k(0) - m_k(s_k)) \\ &\geq \rho' \min \left(c_2 \min \left(\Delta_k, \frac{\varepsilon_g}{c_0} \right) \varepsilon_g, c_3 \Delta_k^2 \varepsilon_H \right). \end{aligned}$$

由定理 9.5 及 $\lambda_g\varepsilon_g \leq \Delta_0$ (定理 9.4 的条件), 可知 $\Delta_k \geq \min(\lambda_g\varepsilon_g, \lambda_H\varepsilon_H)$ 。此外, 利用 $\lambda_g \leq 1/c_0$ 可得

$$\min \left(\Delta_k, \frac{\varepsilon_g}{c_0} \right) \geq \min(\Delta_k, \lambda_g\varepsilon_g) \geq \min(\lambda_g\varepsilon_g, \lambda_H\varepsilon_H).$$

因此,

$$f(x_k) - f(x_{k+1}) \geq \rho' \min(c_2\lambda_g\varepsilon_g^2, c_2\lambda_H\varepsilon_g\varepsilon_H, c_3\lambda_g^2\varepsilon_g^2\varepsilon_H, c_3\lambda_H^2\varepsilon_H^3).$$

- 在第一种情形下, $\varepsilon_H = \infty$, 上式简化为:

$$f(x_k) - f(x_{k+1}) \geq \rho' c_2 \lambda_g \varepsilon_g^2.$$

对迭代求和并结合假设 9.5(f 有下界), 得:

$$\begin{aligned} f(x_0) - f_{\text{low}} &\geq f(x_0) - f(x_{n+1}) \\ &= \sum_{k \in S_n} f(x_k) - f(x_{k+1}) + \sum_{k \in U_n} f(x_k) - f(x_{k+1}) \\ &= \sum_{k \in S_n} f(x_k) - f(x_{k+1}) \geq |S_n| \rho' c_2 \lambda_g \varepsilon_g^2. \end{aligned}$$

整理即得 $|S_n|$ 的上界。

- 同理, 在第二种情形下, 由上述不等式出发, 结合条件可得

$$f(x_0) - f_{\text{low}} \geq |S_n| \rho' c_3 \min(\lambda_g \varepsilon_g, \lambda_H \varepsilon_H)^2 \varepsilon_H.$$

整理即得 $|S_n|$ 的上界。

第三个引理给出了终止前成功迭代次数的下界, 它与终止前总迭代次数成一定比例。这反映了一个事实: 我们不可能出现任意长的连续失败迭代序列。

引理 9.7 (终止前成功迭代次数的下界) 在定理 9.4 的假设下, 设 $x_0, \dots, x_n$ 为信赖域算法生成的迭代序列。若所有迭代均不满足终止条件, 则采用定理 9.6 中的记号 S_n 和 U_n , 有

$$|S_n| \geq \frac{2}{3}(n+1) - \frac{1}{3} \max \left(0, \log_2 \left(\frac{\Delta_0}{\lambda_g \varepsilon_g} \right), \log_2 \left(\frac{\Delta_0}{\lambda_H \varepsilon_H} \right) \right).$$

证明.

- 对所有 $k \in S_n$, 有 $\Delta_{k+1} \leq 2\Delta_k$; 对所有 $k \in U_n$, 有 $\Delta_{k+1} \leq 2^{-2}\Delta_k$ 。因此,

$$\Delta_n = \Delta_0 \prod_{k=1}^n \Delta_k / \Delta_{k-1} \leq 2^{|S_n| - 2|U_n|} \Delta_0.$$

- 另一方面, 由定理 9.5, 有

$$\Delta_n \geq \min(\Delta_0, \lambda_g \varepsilon_g, \lambda_H \varepsilon_H).$$

- 结合两式, 除以 Δ_0 并取以 2 为底的对数, 可得:

$$|S_n| - 2|U_n| \geq \min \left(0, \log_2 \left(\frac{\lambda_g \varepsilon_g}{\Delta_0} \right), \log_2 \left(\frac{\lambda_H \varepsilon_H}{\Delta_0} \right) \right).$$

利用 $|S_n| + |U_n| = n + 1$ 即可得出结论。

有了这些引理，主定理的证明就很容易了。

定理 9.4 的证明. 对每种情形，定理 9.7 和定理 9.6 分别给出了 $|S_n|$ 的上界和下界，结合两者即可得到 n 的上界。例如，在第一种情形下，若 n 使得所有迭代 $x_0, \dots, x_n$ 的梯度均不小于 ε_g ，则

$$n \leq \frac{3}{2} \frac{f(x_0) - f_{\text{low}}}{\rho' c_2} \frac{1}{\lambda_g \varepsilon_g^2} + \frac{1}{2} \log_2 \left(\frac{\Delta_0}{\lambda_g \varepsilon_g} \right) - 1.$$

因此，由逆否命题可知，当迭代次数超过上式右侧的值后，必然会找到一个梯度足够小的迭代点。同理，第二种情形的论证过程类似。

9.5 信赖域算法的收敛性

基于定理 9.4，还可以证明算法的所有聚点都是临界点。

推论 9.8 设 $S = \{(x_0, s_0), (x_1, s_1), \dots\}$ 为信赖域算法在假设 9.1 假设 9.3 假设 9.5 且取 $\varepsilon_g = 0$ 时生成的迭代与迭代方向。进一步假设 9.6 在 S 上成立。则

$$\liminf_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0,$$

即对任意 $\varepsilon > 0$ 和 K ，存在 $k \geq K$ 使得 $\|\nabla f(x_k)\| \leq \varepsilon$ 。

证明. 任取 $\varepsilon > 0$ 和 $K \in \{0, 1, 2, \dots\}$ 。由假设可知， $S_K = \{(x_K, s_K), (x_{K+1}, s_{K+1}), \dots\}$ 是信赖域算法在假设 9.1 假设 9.3 假设 9.5 且取 $\varepsilon_g = 0, \varepsilon_H = \infty$ 且假设 9.6 在 S_K 上成立时生成的序列。因此，定理 9.4 保证存在 $k \geq K$ 使得 $\|\nabla f(x_k)\| \leq \varepsilon$ 。

假设 9.8 (A8) 给定子集 S ，存在常数 $L_{gn} > 0$ ，使得对所有 $(x, s) \in S$ ，有

$$\| \|\nabla f(x + s)\| - \|\nabla f(x)\| \| \leq L_{gn} \|s\|.$$

注 9.5 上述假设比一般的

$$\|\nabla f(x + s) - \nabla f(x)\| \leq L_{gn} \|s\|$$

更弱，但是依然可以证明相应结论。

命题 9.9 设 $S = \{(x_0, s_0), (x_1, s_1), \dots\}$ 为信赖域算法在假设 9.1 假设 9.3 假设 9.5 且取 $\varepsilon_g = 0$ 时生成的迭代与迭代方向。进一步假设 9.6 和假设 9.8 在 S 上成立。则

$$\lim_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0.$$

特别地， $x_0, x_1, \dots$ 的所有聚点 (若存在) 都是临界点。

证明.

- 若迭代 k 是失败的 ($\rho_k \leq \rho'$), 则 $x_{k+1} = x_k$.
- 若迭代 k 是成功的, 则由假设 9.8 可得

$$\|\nabla f(x_{k+1})\| \geq \|\nabla f(x_k)\| - L_{gn}\|s_k\|.$$

- 固定任意满足 $\nabla f(x_m) \neq 0$ 的索引 m 。对所有 $\ell \geq m$, 有

$$\|\nabla f(x_{\ell+1})\| \geq \|\nabla f(x_m)\| - L_{gn} \sum_{\substack{m \leq k \leq \ell \\ \rho_k > \rho'}} \|s_k\|.$$

- 选取满足 $\|\nabla f(x_{\ell+1})\| \leq \frac{1}{2}\|\nabla f(x_m)\|$ 的最小 $\ell \geq m$, 由定理 9.8 可知这样的 ℓ 存在。于是

$$\|\nabla f(x_m)\| \leq 2L_{gn} \sum_{\substack{m \leq k \leq \ell \\ \rho_k > \rho'}} \|s_k\| \leq 2L_{gn} \sum_{\substack{m \leq k \leq \ell \\ \rho_k > \rho'}} \Delta_k.$$

- 根据 ℓ 的选取, 对 $k = m, \dots, \ell$, 有 $\|\nabla f(x_k)\| > \frac{1}{2}\|\nabla f(x_m)\|$ 。又对所有满足 $\rho_k > \rho'$ 的 k , 有 $x_{k+1} = x_k + s_k$ 。因此, 由假设 9.3 和 ρ_k 的定义可得

$$\begin{aligned} f(x_m) - f(x_{\ell+1}) &= \sum_{\substack{m \leq k \leq \ell \\ \rho_k > \rho'}} f(x_k) - f(x_{k+1}) \\ &\geq \sum_{\substack{m \leq k \leq \ell \\ \rho_k > \rho'}} \frac{\rho' c_2}{2} \min\left(\Delta_k, \frac{\|\nabla f(x_m)\|}{2c_0}\right) \|\nabla f(x_m)\|. \end{aligned}$$

- 考虑两种情形:

- 若求和范围内存在某个 k 使得 $\frac{\|\nabla f(x_m)\|_{x_m}}{2c_0} \leq \Delta_k$, 则用对应项给出下界:

$$f(x_m) - f(x_{\ell+1}) \geq \frac{\rho' c_2}{4c_0} \|\nabla f(x_m)\|^2.$$

- 若对求和范围内所有 k 都有 $\frac{\|\nabla f(x_m)\|_{x_m}}{2c_0} > \Delta_k$, 则结合上式可得:

$$\begin{aligned} f(x_m) - f(x_{\ell+1}) &\geq \frac{\rho' c_2}{2} \|\nabla f(x_m)\| \sum_{\substack{m \leq k \leq \ell \\ \rho_k > \rho'}} \Delta_k \\ &\geq \frac{\rho' c_2}{4L_{gn}} \|\nabla f(x_m)\|^2. \end{aligned}$$

- 序列 $\{f(x_k)\}$ 由假设 9.5 知有下界且单调不增, 故收敛于某个 f_∞ 。结合上述结果与 $f(x_m) - f_\infty \geq f(x_m) - f(x_{\ell+1})$, 对所有 m 可得

$$f(x_m) - f_\infty \geq \frac{\rho' c_2}{4 \max(L_{gn}, c_0)} \|\nabla f(x_m)\|^2.$$

令 $m \rightarrow \infty$, 利用 $f(x_m) - f_\infty \rightarrow 0$ 即可证得结论。

9.6 截断共轭梯度法

10 小记

10.1 一种证明迭代点列线性收敛的框架

设不动点迭代:

$$x^{k+1} = \Phi(x^k),$$

其中 $\Phi : \text{dom } \Phi \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^n$ 是某个 (单值) 映射。

设 X^* 表示 Φ 的非空不动点集。令 $\psi : \text{dom } \Phi \rightarrow \mathbb{R}_+$ 是 X^* 的残差函数, 即 ψ 连续且 $\psi(x) = 0$ 当且仅当 $x \in X^*$ 。假设存在三个正常数 η_1, η_2 和 δ , 满足

- $\psi(x) - \psi(\Phi(x)) \geq \eta_1 \|x - \Phi(x)\|^2, \quad \forall x \in \text{dom } \Phi,$
- $\psi(\Phi(x)) \leq \eta_2 \|x - \Phi(x)\|^2, \quad \forall x \in \text{dom } \Phi \text{ 且 } \|x - \Phi(x)\| \leq \delta.$

结合 $x^{k+1} = \Phi(x^k)$, 则上面两个条件说明

- $\psi(x^k) - \psi(x^{k+1}) \geq \eta_1 \|x^k - x^{k+1}\|^2$, 从这个意义上说, ψ 一个评价函数。
- $\psi(x^{k+1}) \leq \eta_2 \|x^k - x^{k+1}\|^2$.

定理 10.1 设 $\Phi : \text{dom } \Phi \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^n$ 是连续函数, 其不动点集 X^* 非空。令 $\{x^k\}$ 由迭代 (12.6.1) 定义。若存在 X^* 的连续残差函数 $\psi : \text{dom } \Phi \rightarrow \mathbb{R}_+$ 满足 (12.6.2) 和 (12.6.3), 则 $\{\psi(x^k)\}$ 至少以 R-线性速率收敛到 0, 且序列 $\{x^k\}$ 至少以 R-线性速率收敛到 X^* 中的某个元素。

证明: 由两个条件共同推出

$$\psi(x^{k+1}) \leq \frac{\eta_2}{\eta_1 + \eta_2} \psi(x^k),$$

于是得到 $\{\psi(x^k)\}$ 的 Q-线性收敛速率, 且收敛到 0。

由第一个条件有

$$\eta_1 \|x^k - x^{k+1}\|^2 \leq \psi(x^k) \leq \left(\frac{\eta_2}{\eta_1 + \eta_2} \right)^k \psi(x^0),$$

从而得到

$$\|x^k - x^{k+1}\| \leq \sqrt{\frac{\psi(x^0)}{\eta_1}} \left(\sqrt{\frac{\eta_2}{\eta_1 + \eta_2}} \right)^k.$$

因此,

$$\|x^k - x^{k+m}\| \leq \sqrt{\frac{\psi(x^0)}{\eta_1}} \sum_{j=k}^{k+m-1} \left(\sqrt{\frac{\eta_2}{\eta_1 + \eta_2}} \right)^j.$$

故 $\{x^k\}$ 是 Cauchy 序列, 从而收敛, 记极限为 x^∞ 。由 ψ 的连续性且 $\lim \psi(x^k) = \Psi(x^\infty) = 0$, x^∞ 属于 X^* ; 进一步, 令 $m \rightarrow \infty$

$$\|x^k - x^\infty\| \leq \sqrt{\frac{\psi(x^0)}{\eta_1}} \frac{1}{1 - \sqrt{\frac{\eta_2}{\eta_1 + \eta_2}}} \left(\sqrt{\frac{\eta_2}{\eta_1 + \eta_2}} \right)^k,$$

这表明 $\{x^k\}$ 至少以 $\mathbf{R}$ -线性速率收敛到 x^∞ 。

注 10.1 我觉得上述想法来源可能是一个特殊情况, 就是 $\psi(x^k) = \|x^k - x^*\|^2$ 的时候, 此时第一个条件其实就是我们熟悉的

$$\|x^{k+1} - x^*\|^2 \leq \|x^k - x^*\|^2 - \eta_1 \|x^{k+1} - x^k\|^2$$

此时只要再结合第二个 $\|x^{k+1} - x^*\|^2 \leq \eta_2 \|x^k - x^{k+1}\|^2$ 就可以得到 $\{x^k\}$ 的 $\mathbf{Q}$ -线性收敛。

而如果把第二个条件换成 $\|x^k - x^*\|^2 \leq \eta_3 \|x^k - x^{k+1}\|^2$, 且 $\eta_3 > \eta_1$, 其实也可以得到 $\{x^k\}$ 的 $\mathbf{Q}$ -线性收敛。于是上述第二个条件可以换成

$$\psi(x^k) \leq \eta_3 \|x^k - x^{k+1}\|^2, \eta_3 > \eta_1.$$